Nexo

Arquitetura do banco de dados

Diagrama de relacionamentos, todas as tabelas com campos, tipos, chaves e restrições, os índices, a coleção vetorial, o arquivo de contas, as decisões de arquitetura e os caminhos para trocar de banco e escalar.

Versão 1.5.0
Outubro de 2026

Copyright (©) 2026 Erik Pimenta

Sumário

01 Visão geral 4

1.1 Três lugares, três papéis 4
1.2 Criação automática 4
1.3 Convenções 5
1.4 Tabelas por área 5

02 Diagrama de relacionamentos 6

2.1 Relacionamentos 6
2.2 Diagrama 6

03 Acervo 8

3.1 nx_document 8
3.2 Ciclo do status 8

04 Conversas e mensagens 9

4.1 nx_conversation 9
4.2 nx_conversation_document 9
4.3 nx_message 9
4.4 nx_message_source 10
4.5 nx_feedback 10

05 Banco vetorial 12

5.1 Coleção 12
5.2 O que entra no embedding 12
5.3 Filtros e exclusão 12
5.4 Trocar o modelo de embeddings 13

06 Contas e arquivos 14

6.1 data/usuarios.json 14
6.2 data/uploads 14
6.3 data/.segredo 15

07 Consultas e índices 16

7.1 Consultas principais 16
7.2 Lista de índices 17

08 Decisões de arquitetura 18

8.1 Relacional e vetorial separados 18
8.2 Fontes gravadas com cópia do texto 18
8.3 Contas em arquivo 18
8.4 IDs gerados pela aplicação 18
8.5 Escopo por ausência 18

Copyright (©) 2026 Erik Pimenta

09 Fluxos de dados 19

9.1 Envio de um PDF 19
9.2 Uma pergunta 19
9.3 Exclusões 19

10 Outros bancos e escala 20

10.1 Outro banco relacional 20
10.2 Migrando dados do SQLite 20
10.3 Crescimento 20
10.4 Backup 20
10.5 DDL de referência 21

Copyright (©) 2026 Erik Pimenta

01

Visão geral

O Nexo guarda informações em três lugares, cada um com um papel. Este documento descreve a estrutura que os dados devem seguir, para quem administra o banco, migra para outro servidor ou integra o Nexo com outros sistemas.

1.1 Três lugares, três papéis

Camada	Onde fica (padrão)	O que guarda
Banco relacional	`data/nexo.db` (SQLite) ou o banco de `NEXO_DATABASE_URL`	Documentos, conversas, mensagens, fontes citadas e avaliações
Banco vetorial	`data/chroma/` (ChromaDB) ou Qdrant (`data/qdrant/` ou servidor)	Trechos dos PDFs com os embeddings e os metadados de origem
Arquivos	`data/uploads/<id>.pdf`	PDFs originais, gravados com o id interno
Contas	`data/usuarios.json`	Usuários, perfis e hashes de senha
Segredo	`data/.segredo`	Chave das sessões quando `NEXO_SECRET` está vazio

A pasta `data` (ou a de `NEXO_DATA_DIR`) concentra tudo o que é local. Copiar essa pasta com o servidor parado é um backup completo.

1.2 Criação automática

As tabelas são criadas pelo SQLAlchemy na primeira conexão (`Base.metadata.create_all`), sem passo de migração. No SQLite, cada conexão liga `PRAGMA foreign_keys=ON`, para que as regras `ON DELETE` funcionem, e `PRAGMA journal_mode=WAL`, para que leituras não esperem as gravações da fila de indexação. Os arquivos `docs/schema-postgresql.sql` e `docs/schema-sqlite.sql` trazem o DDL equivalente para quem prefere criar o banco manualmente.

Copyright (©) 2026 Erik Pimenta

1.3 Convenções

Convenção	Regra
Prefixo	Todas as tabelas começam com `nx_`, para conviver com outras aplicações no mesmo banco
Chaves de texto	`id` de documentos, conversas e mensagens é um UUID4 em hexadecimal, `varchar(32)`, gerado pela aplicação
Chaves numéricas	Fontes e avaliações usam `integer` autoincremento (`SERIAL` no PostgreSQL)
Datas	`timestamp` sem fuso, sempre em UTC; a interface converte para o horário local
Usuários	Colunas `owner` e `uploaded_by` guardam o `username` do arquivo de contas (não há tabela de usuários)
Estados	Textos em maiúsculas (`PENDING`, `PROCESSING`, `READY`, `FAILED`)

1.4 Tabelas por área

Área	Tabelas
Acervo	`nx_document`
Conversas	`nx_conversation`, `nx_conversation_document`
Mensagens	`nx_message`, `nx_message_source`
Qualidade	`nx_feedback`

Copyright (©) 2026 Erik Pimenta

02

Diagrama de relacionamentos

As seis tabelas formam dois ramos que se encontram nas fontes citadas: o acervo de documentos e as conversas com suas mensagens.

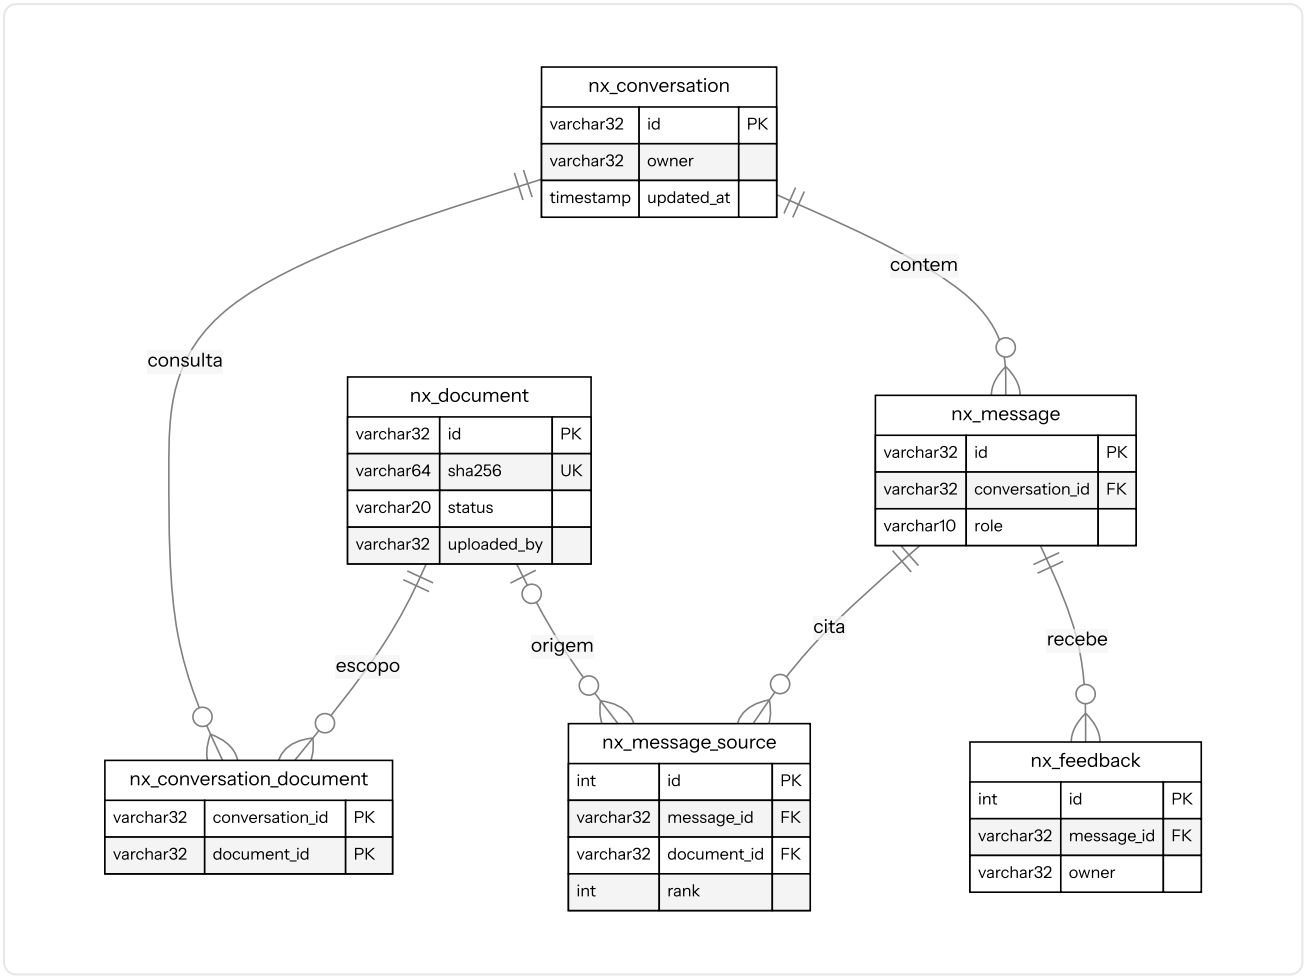
2.1 Relacionamentos

Pai	Filho	Relação	Ao excluir o pai
`nx_conversation`	`nx_conversation_document`	1 para N	CASCADE: o escopo some com a conversa
`nx_document`	`nx_conversation_document`	1 para N	CASCADE: o documento sai do escopo de todas as conversas
`nx_conversation`	`nx_message`	1 para N	CASCADE: as mensagens somem com a conversa
`nx_message`	`nx_message_source`	1 para N	CASCADE
`nx_document`	`nx_message_source`	0..1 para N	SET NULL: o título e o trecho continuam no histórico
`nx_message`	`nx_feedback`	1 para N (uma por usuário)	CASCADE

2.2 Diagrama

O diagrama mostra as chaves e as colunas usadas nas consultas principais; todas as colunas estão nos capítulos 3 e 4.

Copyright (©) 2026 Erik Pimenta



Copyright (©) 2026 Erik Pimenta

03

Acervo

O acervo é a lista de PDFs enviados. Cada linha acompanha o arquivo em `data/uploads` e os trechos no banco vetorial.

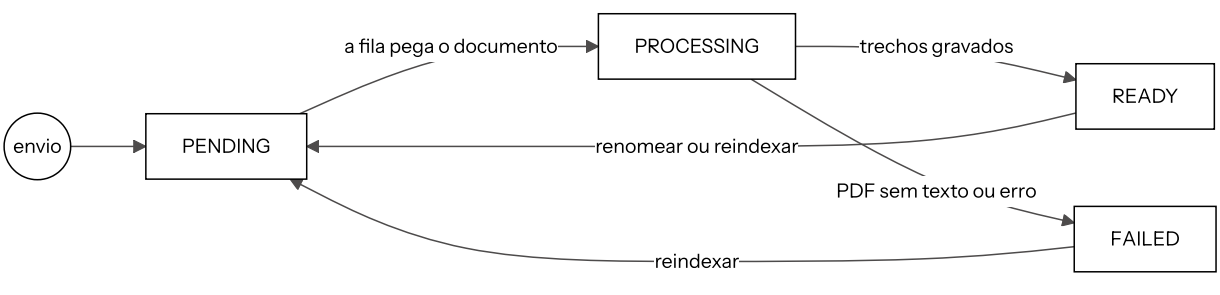
3.1 nx_document

Um registro por PDF enviado.

Coluna	Tipo	Nulo	Padrão	Regra
`id`	varchar(32)	não	UUID4 hex	PK. O PDF fica em `data/uploads/<id>.pdf`
`title`	varchar(200)	não	—	Título dos metadados do PDF ou o nome do arquivo; entra no texto do embedding
`filename`	varchar(255)	não	—	Nome original, saneado
`sha256`	varchar(64)	não	—	Único. Impede o envio do mesmo arquivo duas vezes
`size_bytes`	integer	não	—	Tamanho do arquivo, limitado por `NEXO_MAX_UPLOAD_MB`
`pages`	integer	não	0	Total de páginas do PDF
`chunks`	integer	não	0	Trechos gravados no banco vetorial
`status`	varchar(20)	não	`PENDING`	`PENDING`, `PROCESSING`, `READY` ou `FAILED` (indexado)
`error`	text	sim	—	Motivo da falha, quando houver
`uploaded_by`	varchar(32)	não	—	Usuário que enviou (indexado)
`created_at`	timestamp	não	agora (UTC)	Envio
`indexed_at`	timestamp	sim	—	Fim da indexação

3.2 Ciclo do status

Ao iniciar, o servidor recoloca na fila os documentos que ficaram em `PENDING` ou `PROCESSING` (queda no meio da indexação), então nenhum envio se perde.



Copyright (©) 2026 Erik Pimenta

04

Conversas e mensagens

Cada conversa pertence a um único usuário e guarda as perguntas, as respostas e os trechos que embasaram cada resposta.

4.1 nx_conversation

Uma conversa pertence a um único usuário (`owner`). Ninguém mais consegue abri-la.

Coluna	Tipo	Nulo	Padrão	Regra
`id`	varchar(32)	não	UUID4 hex	PK
`owner`	varchar(32)	não	—	Usuário dono (indexado)
`title`	varchar(160)	não	"Nova conversa"	Recebe a primeira pergunta; pode ser renomeado
`created_at`	timestamp	não	agora (UTC)	Criação
`updated_at`	timestamp	não	agora (UTC)	Atualizado a cada pergunta ou mudança; indexado para ordenar a lista

4.2 nx_conversation_document

Escopo da conversa. Sem linhas, a conversa consulta todos os documentos prontos. Com linhas, a busca vetorial é filtrada pelos documentos listados.

Coluna	Tipo	Nulo	Regra
`conversation_id`	varchar(32)	não	PK e FK para `nx_conversation`, ON DELETE CASCADE
`document_id`	varchar(32)	não	PK e FK para `nx_document`, ON DELETE CASCADE

4.3 nx_message

Perguntas (`role = user`) e respostas (`role = assistant`).

Copyright (©) 2026 Erik Pimenta

Coluna	Tipo	Nulo	Regra
`id`	varchar(32)	não	PK
`conversation_id`	varchar(32)	não	FK para `nx_conversation`, ON DELETE CASCADE (indexado)
`role`	varchar(10)	não	`user` ou `assistant`
`content`	text	não	Texto da pergunta ou da resposta, com as citações `[n]`
`answered`	boolean	sim	`false` quando nada relevante foi encontrado e o Nexo respondeu que não achou a informação
`grounded`	boolean	sim	Resultado da verificação de fidelidade (`NEXO_VERIFY_ANSWERS=true`); nulo se desligada
`model`	varchar(120)	sim	Modelo que respondeu (por exemplo `llama3.1` ou `extrativo`)
`latency_ms`	integer	sim	Tempo gasto na resposta
`created_at`	timestamp	não	Índice composto com `conversation_id`

4.4 nx_message_source

Os trechos efetivamente enviados ao modelo, na ordem das citações `[1]`, `[2]` …

Coluna	Tipo	Nulo	Regra
`id`	integer	não	PK autoincremento
`message_id`	varchar(32)	não	FK para `nx_message`, ON DELETE CASCADE (indexado)
`document_id`	varchar(32)	sim	FK para `nx_document`, ON DELETE SET NULL (indexado)
`document_title`	varchar(200)	não	Cópia do título; mantém o histórico legível depois de exclusões
`chunk_id`	varchar(80)	não	Id do trecho no banco vetorial
`page`	integer	não	Página do PDF, a partir de 1
`rank`	integer	não	Número da citação `[n]` na resposta
`similarity`	float	sim	Similaridade de cosseno da busca vetorial
`rerank_score`	float	sim	Nota do reranker; nula com `NEXO_RERANKER=none`
`excerpt`	text	não	Texto do trecho (até 1.200 caracteres)

4.5 nx_feedback

Avaliação de cada resposta. Um usuário tem no máximo uma avaliação por resposta.

Copyright (©) 2026 Erik Pimenta

Coluna	Tipo	Nulo	Regra
`id`	integer	não	PK autoincremento
`message_id`	varchar(32)	não	FK para `nx_message`, ON DELETE CASCADE
`owner`	varchar(32)	não	Usuário que avaliou; único junto com `message_id` (`uk_feedback_message_owner`)
`rating`	integer	não	1 (útil) ou -1 (não ajudou). Enviar 0 pela API remove a avaliação
`comment`	text	sim	Comentário opcional (via API)
`created_at`	timestamp	não	Data da avaliação

Copyright (©) 2026 Erik Pimenta

05

Banco vetorial

Os trechos dos PDFs ficam numa coleção do ChromaDB (padrão) ou do Qdrant, com os embeddings e os metadados que ligam cada trecho ao documento de origem.

5.1 Coleção

Coleção padrão: `nexo_trechos` (`NEXO_COLLECTION`), com distância de cosseno.

Campo	Conteúdo
`id`	UUID v5 calculado de `nexo:<id do documento>:<posição do trecho>`; reindexar gera os mesmos ids
`embedding`	Vetor do modelo configurado em `NEXO_EMBED_MODEL`
`document`	Texto do trecho (até `NEXO_CHUNK_SIZE` tokens, com `NEXO_CHUNK_OVERLAP` de sobreposição)
`metadata.source_id`	`nx_document.id` do PDF de origem
`metadata.title`	Título do documento
`metadata.filename`	Nome do arquivo
`metadata.page`	Página do PDF, começando em 1
`metadata.chunk_index`	Posição do trecho dentro do documento

5.2 O que entra no embedding

Só o título do documento entra no texto usado para gerar o embedding, junto com o conteúdo do trecho. Isso ajuda perguntas como "no manual da bomba, ...". `source_id` , `filename` , `page` e `chunk_index` ficam fora do embedding e servem só para filtrar e citar.

5.3 Filtros e exclusão

Operação	Como é feita
Escopo da conversa	Filtro de metadados `source_id` igual ao documento (um) ou dentro da lista (vários)
Excluir documento	Apaga todos os vetores com `source_id` do documento antes de apagar a linha e o PDF
Reindexar	Apaga os vetores do documento e grava os novos; nunca há duplicação

Copyright (©) 2026 Erik Pimenta

5.4 Trocar o modelo de embeddings

Vetores de modelos diferentes não são comparáveis. Depois de mudar `NEXO_EMBED_PROVIDER` ou `NEXO_EMBED_MODEL`, use uma coleção nova (`NEXO_COLLECTION`) ou reindexe todos os documentos pela tela Documentos.

Copyright (©) 2026 Erik Pimenta

06

Contas e arquivos

As contas ficam num arquivo JSON, fora do banco relacional, para que o login funcione mesmo antes de qualquer banco externo ser configurado.

6.1 data/usuarios.json

```
{
  "versao": 1,
  "usuarios": [
    {
      "username": "admin",
      "name": "Administrador",
      "role": "admin",
      "password_hash": "$2b$12$...",
      "created_at": "2026-01-01T12:00:00+00:00",
      "last_login_at": null
    }
  ]
}
```

Campo	Regra
`username`	3 a 32 caracteres minúsculos: letras, números, ponto, hífen e sublinhado. Referenciado por `owner` e `uploaded_by`
`name`	Nome exibido na interface
`role`	`admin` (exclui qualquer documento e vê o total de contas) ou `user`
`password_hash`	Hash bcrypt; a senha nunca é guardada
`created_at` / `last_login_at`	ISO 8601 em UTC

- O arquivo é regravado de forma atômica: a versão nova vai para um arquivo temporário na mesma pasta e substitui o antigo de uma vez.
- Uma trava em memória impede duas gravações ao mesmo tempo dentro do processo.
- Se o arquivo não existir, o Nexo cria o login pré-definido `admin` / `Nexo@2026`.
- Para redefinir uma senha esquecida: `python scripts/redefinir_senha.py nome-do-usuario`.

6.2 data/uploads

Cada PDF é gravado como `<id>.pdf`, com o `id` de `nx_document`. O nome original fica só na coluna `filename`, o que evita conflitos e nomes perigosos no disco.

Copyright (©) 2026 Erik Pimenta

6.3 data/.segredo

Chave aleatória criada quando `NEXO_SECRET` está vazio. Apagar o arquivo invalida todas as sessões abertas.

Copyright (©) 2026 Erik Pimenta

07

Consultas e índices

Cada índice existe por causa de uma consulta da aplicação.

7.1 Consultas principais

Tela ou rotina	Consulta	Índice usado
Lista de conversas	`nx_conversation` por `owner`, ordenada por `updated_at` desc	`ix_nx_conversation_owner`, `ix_nx_conversation_updated_at`
Abrir conversa	`nx_message` por `conversation_id`, ordenada por `created_at`	`ix_nx_message_conversation_created`
Fontes de uma resposta	`nx_message_source` por `message_id`, ordenada por `rank`	`ix_nx_message_source_message_id`
Excluir documento	`nx_message_source` por `document_id` (SET NULL)	`ix_nx_message_source_document_id`
Envio de PDF	`nx_document` por `sha256`	restrição única de `sha256`
Retomar a fila	`nx_document` com `status` em `PENDING` ou `PROCESSING`	`ix_nx_document_status`
Sistema e conta	contagem de `nx_document` por `status` e soma de `chunks`	`ix_nx_document_status`
Documentos de um usuário	`nx_document` por `uploaded_by`	`ix_nx_document_uploaded_by`

Copyright (©) 2026 Erik Pimenta

7.2 Lista de índices

Índice	Tabela	Colunas
ix_nx_document_status	nx_document	status
ix_nx_document_uploaded_by	nx_document	uploaded_by
ix_nx_conversation_owner	nx_conversation	owner
ix_nx_conversation_updated_at	nx_conversation	updated_at
ix_nx_message_conversation_id	nx_message	conversation_id
ix_nx_message_conversation_created	nx_message	conversation_id, created_at
ix_nx_message_source_message_id	nx_message_source	message_id
ix_nx_message_source_document_id	nx_message_source	document_id
uk_feedback_message_owner	nx_feedback	message_id, owner (único)
único de sha256	nx_document	sha256

Copyright (©) 2026 Erik Pimenta

08

Decisões de arquitetura

8.1 Relacional e vetorial separados

O banco relacional guarda o que precisa de integridade e histórico (documentos, conversas, citações); o vetorial guarda só o que serve à busca. A ligação entre os dois é o `source_id` nos metadados e o `chunk_id` nas fontes. Assim, dá para trocar ChromaDB por Qdrant sem mexer nas tabelas.

8.2 Fontes gravadas com cópia do texto

`nx_message_source` guarda o título e o trecho, não só a referência. Uma resposta antiga continua auditável mesmo depois que o documento é excluído ou reindexado com outro tamanho de trecho.

8.3 Contas em arquivo

Sem tabela de usuários, o primeiro acesso funciona antes de qualquer banco externo e a redefinição de senha é um script de uma linha. O preço é que `owner` e `uploaded_by` não têm chave estrangeira: a aplicação confere o usuário a cada pedido.

8.4 IDs gerados pela aplicação

UUIDs em hexadecimal permitem gravar o PDF em disco antes do commit e evitam colisões ao juntar bancos. As tabelas de alto volume e sem exposição externa (`nx_message_source` , `nx_feedback`) usam autoincremento, que ocupa menos espaço.

8.5 Escopo por ausência

Uma conversa sem linhas em `nx_conversation_document` consulta tudo o que está pronto. Documentos novos entram automaticamente nas conversas abertas, sem atualizar escopos.

Copyright (©) 2026 Erik Pimenta

09

Fluxos de dados

9.1 Envio de um PDF

1. A API confere o cabeçalho `%PDF`, o tamanho e o SHA-256 (duplicado devolve `409 DUPLICATE`).
2. Grava `data/uploads/<id>.pdf` e a linha em `nx_document` com `PENDING`.
3. A fila muda para `PROCESSING`, extrai o texto por página, divide em trechos e grava os vetores.
4. Termina em `READY` com `pages`, `chunks` e `indexed_at`, ou em `FAILED` com `error`.

9.2 Uma pergunta

1. Grava a pergunta em `nx_message` (`role = user`).
2. Reescreve a pergunta com as últimas `NEXO_HISTORY_TURNS` trocas, busca no banco vetorial com o filtro de escopo, aplica os cortes e o reranking.
3. Grava a resposta (`role = assistant`) com `answered`, `grounded`, `model` e `latency_ms`, e uma linha em `nx_message_source` por trecho citado.
4. Atualiza `nx_conversation.updated_at` e, na primeira pergunta, o título.

9.3 Exclusões

O que é excluído	Efeito em cascata
Documento	Vetores apagados, PDF removido, linha apagada, escopos apagados (CASCADE), fontes com `document_id` nulo (SET NULL)
Conversa	Escopo, mensagens, fontes e avaliações apagados (CASCADE)
Avaliação (rating 0)	Só a linha de `nx_feedback`

Copyright (©) 2026 Erik Pimenta

10

Outros bancos e escala

10.1 Outro banco relacional

Defina `NEXO_DATABASE_URL` no `.env` e instale o driver:

Banco	Driver	Exemplo de URL
PostgreSQL	`pip install "psycopg[binary]"`	`postgresql+psycopg://nexo:senha@localhost:5432/nexo`
MySQL / MariaDB	`pip install pymysql`	`mysql+pymysql://nexo:senha@localhost:3306/nexo`
SQL Server	`pip install pyodbc`	`mssql+pyodbc://nexo:senha@servidor/nexo?driver=ODBC+Driver+18+for+SQL+Server`

O `docker-compose.yml` tem um serviço PostgreSQL de exemplo (`docker compose --profile postgres up -d`). Troque a senha do arquivo antes de usar.

10.2 Migrando dados do SQLite

1. Pare o servidor e faça uma cópia de `data/nexo.db` .
2. Crie o banco novo com `docs/schema-postgresql.sql` (ou deixe o Nexo criar ao iniciar com a URL nova).
3. Copie as tabelas na ordem das chaves: `nx_document` , `nx_conversation` , `nx_conversation_document` , `nx_message` , `nx_message_source` , `nx_feedback` .
4. No PostgreSQL, ajuste as sequências de `nx_message_source.id` e `nx_feedback.id` para o maior id copiado.
5. Defina `NEXO_DATABASE_URL` e suba o servidor. O banco vetorial e os PDFs não mudam.

10.3 Crescimento

Tabela ou coleção	Cresce com	O que fazer quando ficar grande
Coleção vetorial	Páginas indexadas	Passar para Qdrant em servidor (`NEXO_QDRANT_URL`)
`nx_message` e `nx_message_source`	Perguntas feitas	PostgreSQL; apagar conversas antigas apaga as fontes em cascata
`nx_document`	PDFs enviados	Cresce pouco; o peso está em `data/uploads`

10.4 Backup

Pare o servidor e copie a pasta `data` inteira: banco SQLite, vetores locais, PDFs, usuários e segredo. Com bancos externos (PostgreSQL, Qdrant, ChromaDB em servidor), faça também o backup deles pelas ferramentas próprias, no mesmo momento, para que as referências entre eles continuem batendo.

Copyright (©) 2026 Erik Pimenta

10.5 DDL de referência

O DDL completo está em `docs/schema-postgresql.sql` e `docs/schema-sqlite.sql`. Trecho do PostgreSQL:

```
CREATE TABLE nx_document (
    id VARCHAR(32) NOT NULL,
    title VARCHAR(200) NOT NULL,
    filename VARCHAR(255) NOT NULL,
    sha256 VARCHAR(64) NOT NULL,
    size_bytes INTEGER NOT NULL,
    pages INTEGER NOT NULL,
    chunks INTEGER NOT NULL,
    status VARCHAR(20) NOT NULL,
    error TEXT,
    uploaded_by VARCHAR(32) NOT NULL,
    created_at TIMESTAMP WITHOUT TIME ZONE NOT NULL,
    indexed_at TIMESTAMP WITHOUT TIME ZONE,
    PRIMARY KEY (id),
    UNIQUE (sha256)
);

CREATE TABLE nx_message_source (
    id SERIAL NOT NULL,
    message_id VARCHAR(32) NOT NULL,
    document_id VARCHAR(32),
    document_title VARCHAR(200) NOT NULL,
    chunk_id VARCHAR(80) NOT NULL,
    page INTEGER NOT NULL,
    rank INTEGER NOT NULL,
    similarity FLOAT,
    rerank_score FLOAT,
    excerpt TEXT NOT NULL,
    PRIMARY KEY (id),
    FOREIGN KEY(message_id) REFERENCES nx_message (id) ON DELETE CASCADE,
    FOREIGN KEY(document_id) REFERENCES nx_document (id) ON DELETE SET NULL
);
```

Copyright (©) 2026 Erik Pimenta