Nexo

Manual técnico

Agentes de IA com bases de conhecimento próprias, chats com vários agentes e atendimento pelo WhatsApp, com respostas baseadas somente nos documentos enviados. Instalação, configuração, cada tela, integrações, arquitetura, banco de dados, API e manutenção, passo a passo.

Versão 2.3.0
Novembro de 2026

Copyright (©) 2026 Erik Pimenta

Sumário

01	**Visão geral**	**5**
1.1	Para que serve	5
1.2	O que há de novo na 2.3.0	6
1.3	O que o projeto entrega	7
1.4	Funcionalidades	8
1.5	Identidade visual	9
02	**Instalação**	**10**
2.1	Pré-requisitos	10
2.2	Caminho rápido	10
2.3	Passo a passo manual	11
2.4	Primeiro acesso	11
2.5	Atualizando a partir da 1.5	11
2.6	Atualizando a partir da 2.0	11
2.7	Atualizando a partir da 2.1	12
2.8	Atualizando a partir da 2.2	12
2.9	Com Docker	12
03	**Configuração**	**14**
3.1	Modos prontos	14
3.2	Todas as variáveis	15
3.3	Calibrando a precisão	17
3.4	Serviços externos com Docker	17
3.5	Acesso pela rede	18
3.6	Ajustes pela tela	18
04	**Usando o Nexo**	**19**
4.1	Entrada	20
4.2	Tutorial de primeiro acesso	21
4.3	Conversas	22
4.4	Chats com agentes	25

Copyright (©) 2026 Erik Pimenta

4.5	Agentes	26
4.6	Bases de conhecimento	28
4.7	WhatsApp	34
4.8	Busca nos trechos	37
4.9	Documentos	38
4.10	Painel de qualidade	40
4.11	Integrações	43
4.12	Sistema e conta	45
4.13	Paleta de comandos e atalhos	50
4.14	Tema e celular	52
05	**Integrações**	**54**
5.1	Autenticação por chave de API	54
5.2	Pergunta direta: /api/ask	55
5.3	Alimentando uma base pela API	56
5.4	Busca pela API	57
5.5	Webhooks	57
5.6	Boas práticas	59
5.7	Exportação de conversas	60
5.8	Respostas em streaming	60
06	**WhatsApp**	**62**
6.1	Escolhendo o provedor	62
6.2	Conectando com a Evolution API (QR code)	62
6.3	Conectando com a API oficial da Meta	63
6.4	Testando com o simulador	63
6.5	Como o atendimento funciona	64
6.6	Segurança	65
6.7	Solução de problemas	65
07	**Arquitetura**	**66**
7.1	Módulos do código	66
7.2	Indexação de um item	68
7.3	Respondendo uma pergunta	69

Copyright (©) 2026 Erik Pimenta

7.4	Como o agente responde	70
7.5	Como as alucinações são reduzidas	70
7.6	Segurança	71
08	**Banco de dados**	**72**
8.1	Onde cada dado fica	72
8.2	Diagrama de relacionamentos	73
8.3	Tabelas	73
8.4	Coleção vetorial	74
8.5	Arquivo de usuários	74
8.6	Migração automática	75
8.7	Outro banco relacional	75
09	**API**	**76**
9.1	Autenticação	76
9.2	Rotas	76
9.3	Exemplo com curl	79
9.4	Erros	79
10	**Qualidade e manutenção**	**82**
10.1	Testes automatizados	82
10.2	Medindo a recuperação	82
10.3	Integração contínua	83
10.4	Commit automático diário	83
10.5	Backup	83
10.6	Linha de comando	83
10.7	Registros e acompanhamento	84
10.8	Atualizando dependências	84
10.9	Solução de problemas	84

Copyright (©) 2026 Erik Pimenta

01

Visão geral

O Nexo é uma aplicação web em que você cria agentes de IA, cada um com a própria base de conhecimento, e conversa com eles ou deixa que atendam clientes pelo WhatsApp. As respostas usam só o que está nos documentos, textos e arquivos da base. Cada resposta mostra os trechos usados, com documento e página. Quando a informação não está na base, o Nexo diz isso em vez de inventar.

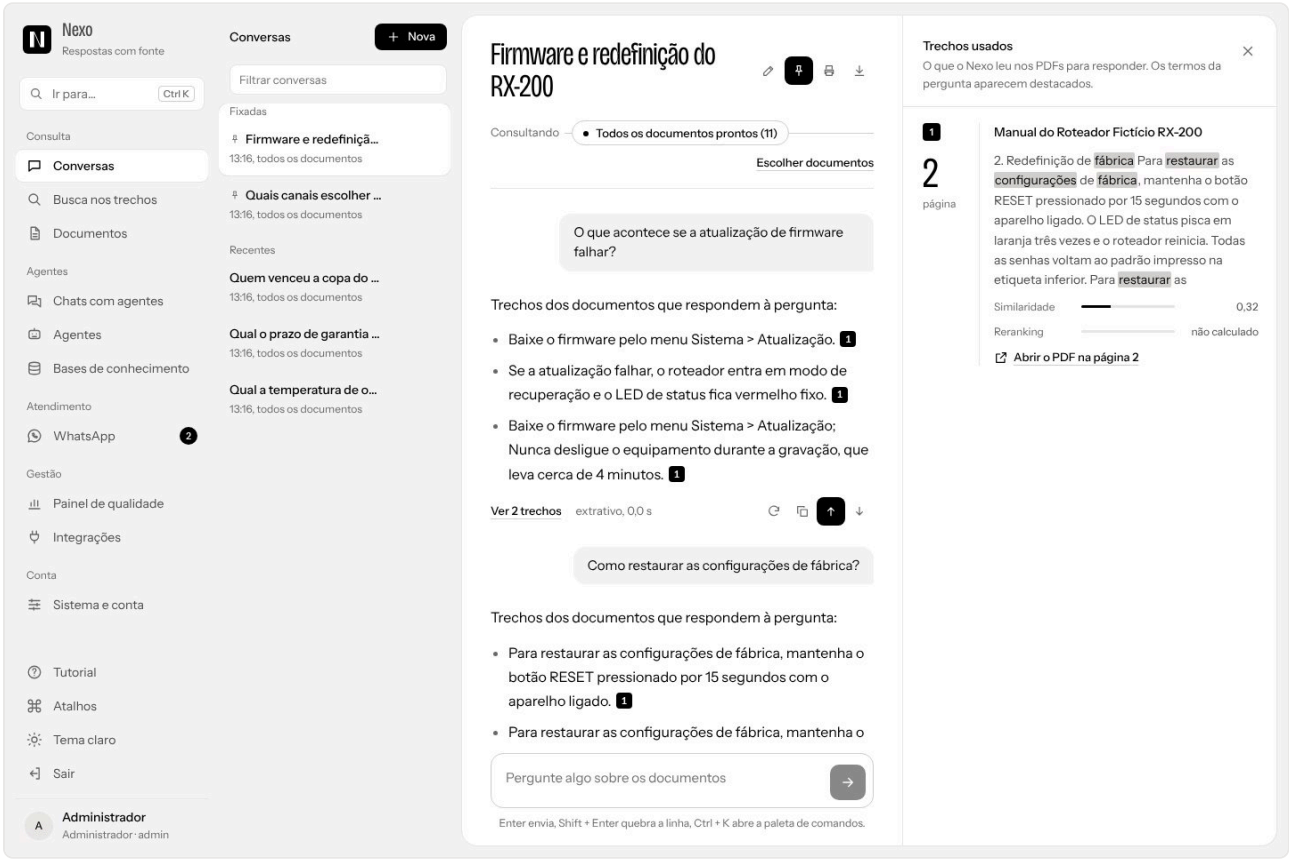


Figura 1.1 Conversa com citações numeradas e o painel de trechos usados, com os termos da pergunta destacados, o link para o PDF na página e o botão Refazer no rodapé de cada resposta.

1.1 Para que serve

- Consultar manuais de equipamentos, normas, procedimentos internos e livros técnicos sem folhear centenas de páginas.

Copyright (©) 2026 Erik Pimenta

- Criar agentes especializados, como Suporte técnico, Comercial ou RH, cada um respondendo só com a base dele.
- Atender clientes pelo WhatsApp com um agente que responde com fonte e passa a conversa para uma pessoa quando não sabe.
- Dar a uma equipe um ponto único de consulta, em que cada resposta pode ser conferida no documento original.
- Estudar um livro complexo fazendo perguntas e indo direto à página que trata do assunto.

1.2 O que há de novo na 2.3.0

A versão 2.3.0 cuida de quem opera o Nexo: ajustes pela tela, diagnóstico, manutenção, backup, registro de atividades e uma linha de comando, além de recursos de uso diário pedidos por quem conversa e atende. A identidade "caixa única" continua igual, e tudo o que funcionava na 2.2 continua funcionando; o banco é migrado sozinho na primeira execução.

Ajustes pela tela Sistema e conta › Ajustes

Modelo, temperatura, cortes, trechos, cadastro, limites e retenção mudam na hora, sem editar o .env nem reiniciar.

Diagnóstico tela e linha de comando

Confere banco, disco, segurança, modelos, banco vetorial, arquivos, índice e integrações, com o que fazer em cada aviso.

Manutenção e backup Sistema e conta › Manutenção

Reindexar falhas, desatualizados ou tudo, limpar órfãos, apagar conversas antigas, compactar o banco e baixar um backup .zip.

Registro de atividades auditoria

Quem entrou, criou, alterou ou excluiu bases, agentes, documentos, contas, chaves e conexões, com filtro e CSV.

Base de teste um clique ou um comando

Arquivos de exemplo em seis formatos e um agente pronto, para experimentar o Nexo sem os seus documentos.

Importar de um link páginas e arquivos publicados

Traz uma página ou arquivo da internet para a base e atualiza quando ele mudar, com bloqueio da rede interna.

Trechos indexados Documentos e Bases

Mostra exatamente como cada arquivo foi dividido, com busca por palavra e o link para a página do PDF.

Conversas fixadas e rascunhos Conversas

Fixe as conversas mais usadas no topo; o que você digitou fica guardado mesmo trocando de conversa.

Comentário no "não ajudou" avaliação

Quem avalia diz o que faltou; o comentário vai para o painel, o CSV e o webhook feedback.negative.

Perguntas sugeridas e duplicar Agentes

Atalhos de pergunta no começo de cada chat e cópia de um agente para criar variações rápido.

Respostas prontas WhatsApp

Textos da equipe com {nome} e {telefone}, inseridos pelo botão ou digitando / na caixa de resposta.

Painel por agente Painel de qualidade

Perguntas, taxa de resposta, tempo e avaliações de cada agente, com filtro do painel e do CSV.

Chaves com permissão consulta, alimentação ou completa

Cada chave pode só perguntar, só alimentar bases ou tudo, e pode vencer sozinha em 30, 90 ou 365 dias.

Limite e CORS proteção da API

Limite de perguntas por minuto por conta (HTTP 429) e liberação de sites que chamam a API pelo navegador.

Copyright (©) 2026 Erik Pimenta

Operação logs, métricas e Docker

Logs em texto ou JSON com o id do pedido, métricas no formato do Prometheus, Dockerfile e serviço no compose.

Atalhos e avisos uso diário

Atalhos Alt + N, B, D e W, a tecla ? com a lista de atalhos, aviso de servidor fora do ar e contador do WhatsApp no menu.

Na 2.2.0, as respostas passaram a aparecer enquanto são escritas, com Parar e Refazer; vieram as contas pela tela, as sessões encerradas na troca de senha, os formatos EPUB, PPTX, XLSX e ODT, as ações em lote, a busca no conteúdo das conversas, o CSV do painel e os webhooks com nova tentativa.

Na 2.1.0, o Nexo virou uma plataforma de agentes: agentes com instruções próprias, bases de conhecimento, textos digitados direto na base, chats com vários agentes em abas ou lado a lado, atendimento pelo WhatsApp (Evolution API, API oficial ou simulador), a aba Integrar de cada base, o tutorial de primeiro acesso e a migração automática dos bancos da 2.0.

1.3 O que o projeto entrega

O Nexo é entregue como estrutura pronta: interfaces, arquitetura, banco de dados e documentação. Quem instala decide quais arquivos enviar, quais modelos usar, qual número de WhatsApp conectar e onde hospedar. Nenhum documento real ou dado pessoal vem no repositório; o único PDF incluído é um manual fictício para testes.

Camada	Tecnologia	Papel
Interface	React 19, TypeScript, Vite	Telas de entrada, tutorial, conversas, chats com agentes, agentes, bases, WhatsApp, busca, documentos, painel, integrações e sistema
API	Python 3.11+, FastAPI, Uvicorn	Rotas REST, respostas em streaming (SSE), autenticação por sessão ou chave de API, envio de arquivos, fila de indexação e webhook do WhatsApp
Pipeline de dados	LlamaIndex, pypdf	Leitura dos arquivos, divisão em trechos, busca e montagem das respostas
Banco vetorial	ChromaDB (padrão) ou Qdrant	Embeddings dos trechos e metadados de origem
Embeddings	HuggingFace, OpenAI ou Ollama	Transformam texto em vetores para a busca semântica
Reranking	Cross-encoder HuggingFace ou Cohere Rerank	Reordenam os candidatos antes de chegarem ao modelo
Modelo de linguagem	Ollama (local) ou OpenAI	Redige a resposta a partir dos trechos, seguindo as instruções do agente
Banco relacional	SQLAlchemy com SQLite (padrão), PostgreSQL, MySQL ou SQL Server	Bases, documentos, agentes, conversas, mensagens, fontes, avaliações, chaves, webhooks e WhatsApp
Contas	Arquivo JSON com bcrypt, sessões JWT com versão	Login pré-definido, cadastro próprio, gestão pelo administrador, encerramento de sessões e tutorial visto

Copyright (©) 2026 Erik Pimenta

Camada	Tecnologia	Papel
Integrações	Chaves nxk_ com permissão e validade, webhooks com HMAC-SHA256	Perguntas, buscas e envios vindos de outros sistemas e avisos de eventos, com nova tentativa automática
Operação	Ajustes em data/ajustes.json, auditoria, logs JSON, Prometheus, CLI e Docker	Configurar sem reiniciar, diagnosticar, manter, fazer backup e acompanhar o servidor
WhatsApp	Evolution API v2, WhatsApp Cloud API da Meta ou simulador	Receber mensagens de clientes e responder pelo agente ou por uma pessoa

1.4 Funcionalidades

- Bases de conhecimento com PDF, DOCX, ODT, EPUB, PPTX, XLSX, TXT, MD, CSV, JSON e HTML, enviados por arrastar e soltar, vários de uma vez, com limite de tamanho e bloqueio de duplicados por SHA-256 dentro de cada base.
- Textos digitados direto na base, editáveis a qualquer hora; ao salvar, o texto é reindexado.
- Mover um item de uma base para outra sem reindexar; excluir apaga o arquivo e todos os vetores dele. Na tela Documentos, as três ações também valem para vários itens selecionados.
- Agentes com instruções próprias, saudação, resposta quando não souber, cor e opção de citar as fontes no WhatsApp.
- Chats com vários agentes ao mesmo tempo, em abas ou lado a lado, cada um consultando só a própria base.
- Respostas escritas ao vivo, com o botão Parar, e Refazer em cada resposta.
- Caixa de entrada do WhatsApp com filtros, resposta automática do agente, passagem para atendente, sugestão de resposta e simulador.
- Indexação em segundo plano com os estados Na fila, Indexando, Pronto e Falhou. A tela se atualiza sozinha.
- Conversas salvas por usuário, com título automático, renomeação, exclusão, filtro pelo título e pelo conteúdo e exportação em Markdown ou JSON.
- Citações [n] clicáveis que abrem o trecho usado, com os termos da pergunta destacados, e o PDF na página certa.
- Resposta padrão quando nada relevante é encontrado, que cada agente pode trocar pela própria frase.
- Busca direta nos trechos, de todo o acervo ou de uma base, sem o modelo de linguagem.
- Avaliação de cada resposta e painel de qualidade com as perguntas que ficaram sem resposta e exportação em CSV.
- Integrações por chave de API, pergunta direta em `/api/ask` (também para um agente) e webhooks assinados, com eventos do WhatsApp e nova tentativa automática.
- Contas com troca de senha que encerra as outras sessões, Sair dos outros dispositivos, nome editável e, para administradores, criação de contas e redefinição de senha.
- Tutorial no primeiro acesso, paleta de comandos `Ctrl + K`, tema claro, escuro ou automático e layout para celular.
- Ajustes do pipeline pela tela, diagnóstico, manutenção, backup e registro de atividades para administradores, também pela linha de comando `python -m nexo`.
- Importação de páginas e arquivos por link, visualização dos trechos indexados e uma base de teste pronta.

Copyright (©) 2026 Erik Pimenta

- Conversas fixadas, rascunho guardado, impressão da conversa e comentário na avaliação "não ajudou".
- Perguntas sugeridas e duplicação de agentes, respostas prontas no WhatsApp e painel de qualidade por agente.
- Chaves de API com permissão e validade, limite de perguntas por minuto, CORS e métricas para o Prometheus.

1.5 Identidade visual

A 2.3.0 mantém a identidade "caixa única", a mesma do painel Bento (Data-Driven-Admin-Panel), adotada na 1.5.0. As telas novas (as abas de Sistema e conta, os trechos indexados, as respostas prontas e os atalhos) usam os mesmos materiais: tampa preta para os resumos, paredes finas, pontos de cor para a situação.

Elemento	Como ficou
Mesa	Fundo, menu lateral e cabeçalhos no mesmo tom #F5F4F4, sem bordas
Caixa	Conversas, listas e painéis dividem paredes finas de 1 px dentro de caixas brancas de cantos arredondados
Tampa	Os resumos (acervo, base escolhida, caixa de entrada do WhatsApp, números do painel) e a lateral da tela de entrada ficam no bloco preto
Tipografia	Títulos e números em Bricolage Grotesque fina e condensada, textos em Instrument Sans, código em IBM Plex Mono
Agentes	Cada agente tem uma cor de destaque, usada só no selo com a inicial; o resto da tela continua em preto e branco
Status	Um ponto de cor e o texto neutro: verde para Pronto, azul para Indexando, cinza para Na fila, vermelho para Falhou
Temas	Claro, escuro ou automático; o escuro usa os mesmos materiais em tons escuros
Paleta	#FFFFFF, #4D4B4B, #000000, #333232 e #BAB7B6; a logo é sempre em preto e branco

Copyright (©) 2026 Erik Pimenta

02

Instalação

Este capítulo leva do download à primeira pergunta respondida. O caminho mais curto é o script de inicialização; os passos manuais vêm logo depois.

2.1 Pré-requisitos

Item	Versão	Para quê
Python	3.11 ou mais recente	Servidor, indexação e respostas
Node.js	20.19 ou mais recente	Compilar a interface (uma vez)
Ollama	Atual	Modelo de linguagem local e gratuito (modo padrão)
Espaço em disco	Cerca de 3 GB	Dependências do Python, modelos de embeddings e reranking
Memória	8 GB ou mais	Rodar o llama3.1 local com folga
WhatsApp (opcional)	Evolution API v2 ou conta Meta	Atender clientes pelo WhatsApp (capítulo 6)

Sem Ollama ou sem GPU? Use a OpenAI como modelo de linguagem (seção 3.1) ou o modo de teste sem modelos para validar a instalação. Os modelos de embeddings e reranking padrão rodam bem em CPU.

2.2 Caminho rápido

1. Baixe o repositório (botão **Code › Download ZIP** no GitHub ou `git clone`) e extraia em uma pasta.
2. Instale o Ollama em ollama.com e, num terminal, rode `ollama pull llama3.1`.
3. No Windows, dê dois cliques em `iniciar.cmd`. No Linux ou macOS, rode `./iniciar.sh`.
4. Espere a instalação terminar. Na primeira vez ela leva alguns minutos.
5. Abra `http://127.0.0.1:8000` no navegador e entre com `admin` / `Nexo@2026`. O tutorial aparece na primeira entrada.
6. Em **Bases de conhecimento**, envie um arquivo; em **Agentes**, crie um agente com essa base; em **Chats com agentes**, faça a primeira pergunta.

O script cria o ambiente virtual `.venv`, instala `requirements.txt`, copia `.env.example` para `.env`, compila a interface em `frontend/dist` e sobe o servidor. Nas próximas vezes ele só sobe o servidor; quando a versão muda, recompila a interface.

Copyright (©) 2026 Erik Pimenta

2.3 Passo a passo manual

```
python -m venv .venv
.venv\Scripts\activate          # Windows
source .venv/bin/activate        # Linux / macOS
pip install -r requirements.txt
copy .env.example .env           # Windows; no Linux/macOS use cp
cd frontend
npm install
npm run build
cd ..
python -m nexo
```

Para desenvolver a interface com recarga automática, rode `python -m nexo` em um terminal e `npm run dev` dentro de `frontend` em outro. A interface abre em `http://localhost:5173` e repassa as chamadas `/api` para a porta 8000.

2.4 Primeiro acesso

O login pré-definido é criado quando não há nenhum administrador, como na primeira execução. O aviso some da tela de entrada (seção 4.1) assim que a senha do admin é trocada. Troque-a em Sistema e conta no primeiro acesso. Para experimentar antes de enviar os seus arquivos, use **Criar base de teste** em Bases de conhecimento ou `python -m nexo base-de-teste` (seção 4.6).

Usuário	Senha	Perfil	Pode
`admin`	`Nexo@2026`	Administrador	Tudo: excluir conteúdo de outras pessoas, ver o painel de todos, criar e gerenciar contas, redefinir senhas, webhooks e conexões do WhatsApp
contas novas	definida no cadastro ou pelo administrador	Usuário	Criar bases e agentes, enviar arquivos, conversar, atender no WhatsApp, buscar, ver o próprio painel e criar as próprias chaves

2.5 Atualizando a partir da 1.5

1. Pare o servidor e faça uma cópia da pasta `data` (seção 10.5).
2. Substitua os arquivos do projeto pelos da 2.3.0, mantendo `data` e o seu `.env`.
3. Rode `pip install -r requirements.txt` e, em `frontend`, `npm install` e `npm run build`.
4. Se quiser, acrescente `NEXO_WEBHOOK_TIMEOUT=5` ao `.env`. Sem a linha, vale o padrão de 5 segundos.
5. Suba o servidor. As tabelas `nx_api_key` e `nx_webhook` da 2.0 e as tabelas da 2.1 são criadas sozinhas na primeira conexão; as tabelas existentes são migradas pela migração automática e os documentos vão para a base "Acervo geral".

2.6 Atualizando a partir da 2.0

1. Pare o servidor e faça uma cópia da pasta `data` (seção 10.5).
2. Substitua os arquivos do projeto pelos da 2.3.0, mantendo `data` e o seu `.env`.

Copyright (©) 2026 Erik Pimenta

3. Rode `pip install -r requirements.txt` e, em `frontend`, `npm install` e `npm run build` (o script de inicialização faz isso sozinho).
4. Se for usar o WhatsApp, acrescente `NEXO_PUBLIC_URL` ao `.env` (seção 3.2).
5. Suba o servidor. A migração automática cria as tabelas novas, acrescenta as colunas novas e coloca os documentos antigos na base "Acervo geral". Conversas antigas continuam consultando todos os documentos.

2.7 Atualizando a partir da 2.1

A 2.2 não mudou nenhuma tabela. Siga os passos da seção seguinte: a migração da 2.3 acrescenta as colunas e tabelas novas nos dois casos.

1. Pare o servidor. A cópia da pasta `data` (seção 10.5) continua recomendada antes de qualquer atualização.
2. Traga os arquivos novos com `git pull` (ou substitua pelos da versão nova), mantendo `data` e o seu `.env`.
3. Rode `pip install -r requirements.txt`.
4. Em `frontend`, rode `npm ci && npm run build`.
5. Suba o servidor. Nada mais precisa ser feito.

As sessões abertas antes da atualização continuam válidas. O arquivo `data/usuarios.json` ganha os campos `session_version` e `password_changed_at` automaticamente; não é preciso editá-lo. O `.env` também não muda.

2.8 Atualizando a partir da 2.2 Novo

1. Baixe um backup em Sistema e conta › Manutenção ou rode `python -m nexo backup` (seção 10.5).
2. Pare o servidor e traga os arquivos novos com `git pull`, mantendo `data` e o seu `.env`.
3. Rode o script de inicialização (ou `pip install -r requirements.txt` e, em `frontend`, `npm ci && npm run build`).
4. Suba o servidor. A migração automática cria as tabelas `nx_audit` e `nx_quick_reply` e acrescenta as colunas `pinned`, `suggestions`, `index_signature`, `source_url`, `scope` e `expires_at`. Os documentos prontos recebem a assinatura da configuração atual, então nada precisa ser reindexado.
5. Rode `python -m nexo diagnostico` ou abra Sistema e conta › Diagnóstico para conferir a instalação.

O `.env` antigo continua valendo. As variáveis novas (`NEXO_RATE_LIMIT`, `NEXO_RETENTION_DAYS`, `NEXO_LOG_FORMAT`, `NEXO_CORS_ORIGINS` e as de links) têm padrões seguros; o limite de 60 perguntas por minuto por conta passa a valer sem configurar nada. Chaves de API antigas ficam com permissão completa e sem validade.

2.9 Com Docker Novo

O `Dockerfile` compila a interface e monta uma imagem só com o Python e o Nexo, rodando como usuário sem privilégios, com a pasta de dados em `/dados` e checagem de saúde em `/api/health/ready`. O serviço `nexo` do `docker-compose.yml` fica no perfil `app`:

```
cp .env.example .env
docker compose --profile app --profile ollama up -d --build
docker compose exec ollama ollama pull llama3.1
```

Copyright (©) 2026 Erik Pimenta

A interface abre em `http://localhost:8000`. No compose, `NEXO_HOST`, `NEXO_DATA_DIR` e `NEXO_OLLAMA_URL` já apontam para o contêiner; o resto vem do `.env`. Os dados ficam no volume `nexo-dados`, e os modelos baixados do HuggingFace também, em `/dados/modelos`.

Copyright (©) 2026 Erik Pimenta

03

Configuração

A configuração base fica no arquivo .env na raiz do projeto: altere, salve e reinicie o servidor. Os parâmetros do dia a dia (modelo, busca, cortes, trechos, cadastro e limites) também mudam pela tela Sistema e conta › Ajustes, sem reiniciar (seção 3.6). As conexões do WhatsApp são feitas pela tela.

3.1 Modos prontos

Modo	Linhas no .env	Quando usar
Local e gratuito (padrão)	`NEXO_LLM_PROVIDER=ollama` `NEXO_LLM_MODEL=llama3.1` `NEXO_EMBED_PROVIDER=huggingface` `NEXO_RERANKER=huggingface`	Documentos sigilosos que não podem sair da máquina
OpenAI	`NEXO_LLM_PROVIDER=openai` `NEXO_LLM_MODEL=gpt-4o-mini` `OPENAI_API_KEY=sua-chave`	Respostas mais elaboradas sem precisar de GPU
Embeddings da OpenAI	`NEXO_EMBED_PROVIDER=openai` `NEXO_EMBED_MODEL=text-embedding-3-small` `NEXO_EMBED_QUERY_PREFIX=` `NEXO_EMBED_TEXT_PREFIX=`	Acervos grandes, sem baixar modelos locais
Reranking Cohere	`NEXO_RERANKER=cohere` `COHERE_API_KEY=sua-chave`	Melhor ordenação em vários idiomas sem custo de CPU
Qdrant	`NEXO_VECTOR_STORE=qdrant` `NEXO_QDRANT_URL=http://localhost:6333`	Acervos com muitos milhares de trechos ou servidor dedicado
Teste sem modelos	`NEXO_EMBED_PROVIDER=hash` `NEXO_LLM_PROVIDER=extrativo` `NEXO_RERANKER=none` `NEXO_MIN_SIMILARITY=0.1`	Validar a instalação e rodar os testes automatizados

Trocou o modelo de embeddings? Vetores de modelos diferentes não são comparáveis. Depois de mudar `NEXO_EMBED_PROVIDER` ou `NEXO_EMBED_MODEL`, os documentos aparecem como **índice desatualizado**: use **Reindexar desatualizados** em Sistema e conta › Manutenção ou `python -m nexo reindexar --desatualizados`.

Copyright (©) 2026 Erik Pimenta

3.2 Todas as variáveis

Variável	Padrão	Descrição
Servidor e contas		
`NEXO_HOST` / `NEXO_PORT`	127.0.0.1 / 8000	Endereço do servidor. Use 0.0.0.0 para aceitar acessos da rede
`NEXO_DATA_DIR`	data	Pasta do banco SQLite, arquivos enviados, vetores locais e usuários
`NEXO_SECRET`	gerado	Chave das sessões. Vazia: o Nexo cria data/.segredo
`NEXO_TOKEN_HOURS`	8	Duração da sessão em horas (1 a 168)
`NEXO_ALLOW_REGISTRATION`	true	Permite criar contas na tela de entrada. Desligado, só o administrador cria contas
`NEXO_MAX_UPLOAD_MB`	100	Tamanho máximo de cada arquivo (1 a 2048)
`NEXO_DATABASE_URL`	vazio	URL SQLAlchemy de outro banco relacional. Vazio: data/nexo.db
`NEXO_WEBHOOK_TIMEOUT`	5	Tempo máximo de cada tentativa de entrega de webhook, em segundos (até 120)
Operação Novo		
`NEXO_RATE_LIMIT`	60	Perguntas e buscas por minuto por conta. Acima disso, HTTP 429 com Retry-After. 0 desliga
`NEXO_RETENTION_DAYS`	0	Apaga conversas não fixadas sem atividade há mais dias que isso. 0 guarda para sempre
`NEXO_LOG_LEVEL` / `_FORMAT`	INFO / texto	Nível dos registros e formato: texto ou json (uma linha JSON por evento)
`NEXO_CORS_ORIGINS`	vazio	Sites liberados a chamar a API pelo navegador, separados por vírgula
`NEXO_ALLOW_PRIVATE_URLS`	false	Permite importar links da rede interna (localhost, 10.x, 192.168.x)
`NEXO_LINK_TIMEOUT`	20	Tempo máximo para baixar um link, em segundos
WhatsApp		
`NEXO_PUBLIC_URL`	vazio	Endereço público do Nexo (https://...) usado para montar a URL do webhook do WhatsApp
`NEXO_WHATSAPP_HISTORY`	6	Mensagens anteriores do contato usadas pelo agente para entender a pergunta

Copyright (©) 2026 Erik Pimenta

Variável	Padrão	Descrição
`NEXO_WHATSAPP_TIMEOUT`	15	Tempo máximo de cada chamada ao provedor do WhatsApp, em segundos
Modelo de linguagem		
`NEXO_LLM_PROVIDER`	ollama	ollama, openai ou extrativo
`NEXO_LLM_MODEL`	llama3.1	Nome do modelo no provedor escolhido
`NEXO_LLM_TEMPERATURE`	0.1	Criatividade do modelo (0 a 1). Mantenha baixa
`NEXO_LLM_TIMEOUT`	120	Tempo máximo de resposta do modelo, em segundos
`NEXO_OLLAMA_URL`	http://localhost:11434	Endereço do Ollama
`OPENAI_API_KEY`	vazio	Chave da OpenAI (também aceita NEXO_OPENAI_API_KEY)
`NEXO_OPENAI_BASE_URL`	vazio	Endpoint compatível com a OpenAI (Azure, LM Studio, vLLM)
Embeddings e banco vetorial		
`NEXO_EMBED_PROVIDER`	huggingface	huggingface, openai, ollama ou hash
`NEXO_EMBED_MODEL`	intfloat/multilingual-e5-small	Modelo de embeddings
`NEXO_EMBED_QUERY_PREFIX` / `_TEXT_PREFIX`	"query: " / "passage: "	Prefixos exigidos pela família E5. Deixe vazio em outros modelos
`NEXO_VECTOR_STORE`	chroma	chroma ou qdrant
`NEXO_COLLECTION`	nexo_trechos	Nome da coleção vetorial
`NEXO_CHROMA_HOST` / `_PORT`	vazio / 8001	Servidor ChromaDB. Vazio: arquivos em data/chroma
`NEXO_QDRANT_URL` / `_API_KEY`	vazio	Servidor Qdrant. Vazio: arquivos em data/qdrant
Reranking e recuperação		
`NEXO_RERANKER`	huggingface	huggingface, cohere ou none
`NEXO_RERANK_MODEL`	cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	Cross-encoder multilíngue do HuggingFace
`NEXO_COHERE_MODEL` / `COHERE_API_KEY`	rerank-v3.5 / vazio	Reranking da Cohere

Copyright (©) 2026 Erik Pimenta

Variável	Padrão	Descrição
`NEXO_CHUNK_SIZE` / `_OVERLAP`	512 / 64	Tamanho dos trechos e sobreposição, em tokens
`NEXO_TOP_K`	12	Candidatos trazidos pela busca vetorial
`NEXO_TOP_N`	4	Trechos enviados ao modelo depois do reranking
`NEXO_MIN_SIMILARITY`	0.15	Corte 1: similaridade de cosseno mínima para um trecho ser considerado
`NEXO_MIN_RERANK_SCORE`	0.1	Corte 2: nota mínima do reranker (0 a 1)
`NEXO_HISTORY_TURNS`	3	Trocas anteriores usadas para reescrever a pergunta (0 a 10)
`NEXO_VERIFY_ANSWERS`	false	Liga a verificação de fidelidade, uma segunda chamada ao modelo

3.3 Calibrando a precisão

- **Respostas dizendo que não encontrou, mas a informação existe:** baixe `NEXO_MIN_SIMILARITY` (por exemplo 0.1) e `NEXO_MIN_RERANK_SCORE` (0.05), ou aumente `NEXO_TOP_K`.
- **Respostas misturando assuntos:** suba `NEXO_MIN_RERANK_SCORE` (0.3) e reduza `NEXO_TOP_N` para 3. Separar os assuntos em bases e agentes diferentes também ajuda.
- **Tabelas e listas longas cortadas:** aumente `NEXO_CHUNK_SIZE` para 768 ou 1024 e reindexe.

Antes de mexer: use a aba Testar da base (seção 4.6) ou a Busca nos trechos para ver as notas reais dos trechos, e o Painel de qualidade para acompanhar a taxa de resposta depois do ajuste. Para medir em vez de adivinhar, use `scripts/avaliar.py` (seção 10.2).

3.4 Serviços externos com Docker

O `docker-compose.yml` traz serviços opcionais, cada um em um perfil:

```
docker compose --profile app up -d        # o próprio Nexo em http://localhost:8000 (seção 2.9)
docker compose --profile chroma up -d     # ChromaDB em http://localhost:8001
docker compose --profile qdrant up -d     # Qdrant em http://localhost:6333
docker compose --profile ollama up -d     # Ollama em http://localhost:11434
docker compose --profile postgres up -d   # PostgreSQL em localhost:5432
```

Depois aponte o `.env` para eles, por exemplo `NEXO_CHROMA_HOST=localhost` ou `NEXO_DATABASE_URL=postgresql+psycopg://nexo:troque-esta-senha@localhost:5432/nexo` (instale `pip install "psycopg[binary]"`). Troque a senha do PostgreSQL no arquivo antes de usar. A Evolution API, usada para conectar o próprio número de WhatsApp, tem imagem Docker oficial; siga a documentação do projeto para subi-la.

Copyright (©) 2026 Erik Pimenta

3.5 Acesso pela rede

Para outras máquinas acessarem, use `NEXO_HOST=0.0.0.0`, libere a porta no firewall e defina `NEXO_SECRET` com um valor longo e aleatório. Em produção, coloque o Nexo atrás de um proxy com HTTPS (Nginx, Caddy ou IIS) e desligue o cadastro aberto se o acesso deve ser restrito; o administrador continua criando contas pela tela.

Com integrações e WhatsApp, o HTTPS deixa de ser opcional: chaves de API viajam em cada pedido, e a API oficial da Meta só entrega webhooks em endereços HTTPS públicos. Defina `NEXO_PUBLIC_URL` com esse endereço. Para webhooks de saída, o servidor do Nexo precisa conseguir abrir conexões até as URLs cadastradas.

Respostas em streaming chegam por Server-Sent Events. No Nginx, desligue o buffer da rota de streaming (`proxy_buffering off`) para que o texto apareça enquanto é escrito. Para checagens de saúde do balanceador, use `GET /api/health/ready`, que devolve 503 quando o banco não responde. Atrás de um proxy, o Nexo registra o IP do cabeçalho `X-Forwarded-For` no registro de atividades.

3.6 Ajustes pela tela Novo

Em **Sistema e conta › Ajustes**, o administrador muda parte da configuração com o servidor no ar. O valor vale na próxima pergunta e fica guardado em `data/ajustes.json`, que tem prioridade sobre o `.env`. Cada campo mostra o padrão do `.env` quando foi alterado e o link **restaurar**; **Restaurar padrões** desfaz todos.

Grupo	Itens	Observação
Modelo	modelo de linguagem, temperatura, tempo limite, verificação de fidelidade	Trocar o modelo recarrega o LLM na próxima pergunta, no mesmo provedor
Busca	candidatos, trechos enviados ao modelo, similaridade mínima, nota mínima do reranker, turnos de histórico	Trechos enviados não pode passar dos candidatos
Indexação	tamanho do trecho, sobreposição, tamanho máximo do arquivo	Mudar o trecho marca os documentos como desatualizados; a tela oferece reindexar
Acesso	cadastro aberto, duração da sessão, limite de perguntas por minuto	Valem para as próximas entradas
Manutenção e WhatsApp	dias de retenção das conversas, histórico lido pelo agente no WhatsApp	A retenção roda ao subir e a cada 6 horas

Provedores, modelo de embeddings, banco vetorial, banco relacional, segredos e CORS continuam só no `.env`, porque exigem reiniciar ou reindexar tudo; a mesma aba mostra esses valores em **Definidos no .env**. Toda alteração entra no registro de atividades com o valor novo.

Copyright (©) 2026 Erik Pimenta

04

Usando o Nexo

As telas seguem o caminho natural de uso: entrar, montar as bases, criar os agentes, conversar, atender no WhatsApp, conferir a qualidade e integrar. O menu lateral agrupa as telas em Consulta, Agentes, Atendimento, Gestão e Conta.

Grupo	Telas	Para quê
Consulta	Conversas, Busca nos trechos, Documentos	Perguntar a todo o acervo, procurar trechos e ver todos os arquivos
Agentes	Chats com agentes, Agentes, Bases de conhecimento	Conversar com vários agentes, criá-los e cuidar dos dados de cada um
Atendimento	WhatsApp	Caixa de entrada com os clientes e as conexões dos números
Gestão	Painel de qualidade, Integrações	Acompanhar as respostas e ligar outros sistemas
Conta	Sistema e conta	Pipeline, acervo, perfil, senha, sessões e tutorial; para administradores, também ajustes, diagnóstico, manutenção, atividades e contas

No topo do menu, o botão **Ir para...** (`Ctrl + K`) abre a paleta de comandos. No rodapé ficam o tutorial, os **Atalhos** (ou a tecla `?`), o botão de tema, **Sair** e o usuário conectado. O item WhatsApp mostra quantos clientes aguardam atendente, e o título da aba do navegador também. Se o servidor sair do ar, uma faixa no topo avisa e some sozinha quando ele volta.

Copyright (©) 2026 Erik Pimenta

4.1 Entrada

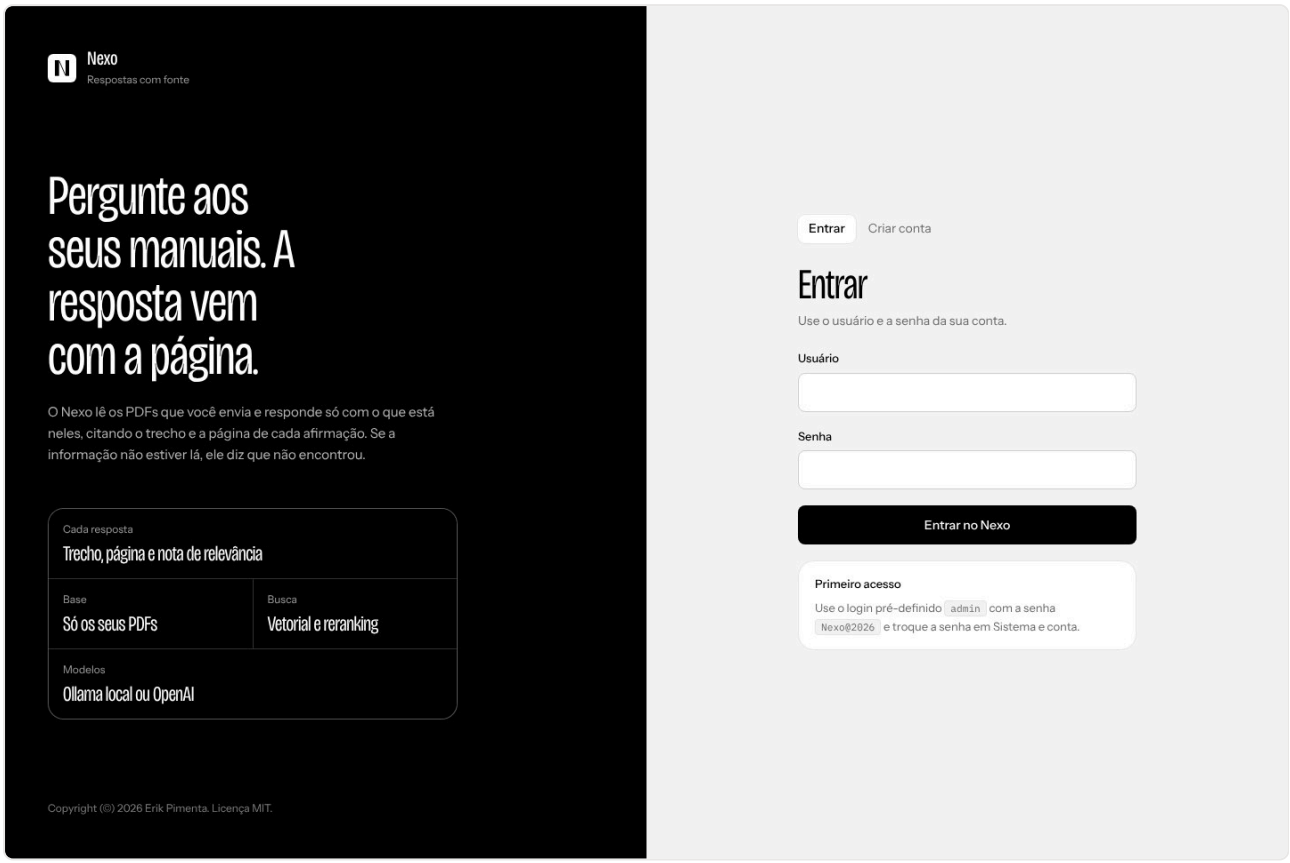


Figura 4.1 Entrada, com as abas Entrar e Criar conta e o aviso do login pré-definido enquanto a senha do admin não for trocada.

- **Entrar** pede usuário e senha. Cinco erros seguidos bloqueiam o usuário por 5 minutos; o administrador pode liberar antes redefinindo a senha.
- **Criar conta** aparece quando `NEXO_ALLOW_REGISTRATION=true`. O nome de usuário tem de 3 a 32 caracteres minúsculos; a senha, de 8 a 72 caracteres, com letras e números, sem conter o nome de usuário. Com o cadastro fechado, as contas são criadas pelo administrador em Sistema e conta.
- A sessão dura `NEXO_TOKEN_HOURS` horas e fica só na aba aberta.
- Uma sessão encerrada por troca de senha, por **Sair dos outros dispositivos** ou por redefinição feita pelo administrador volta para a entrada com o aviso de sessão encerrada.

Copyright (©) 2026 Erik Pimenta

4.2 Tutorial de primeiro acesso

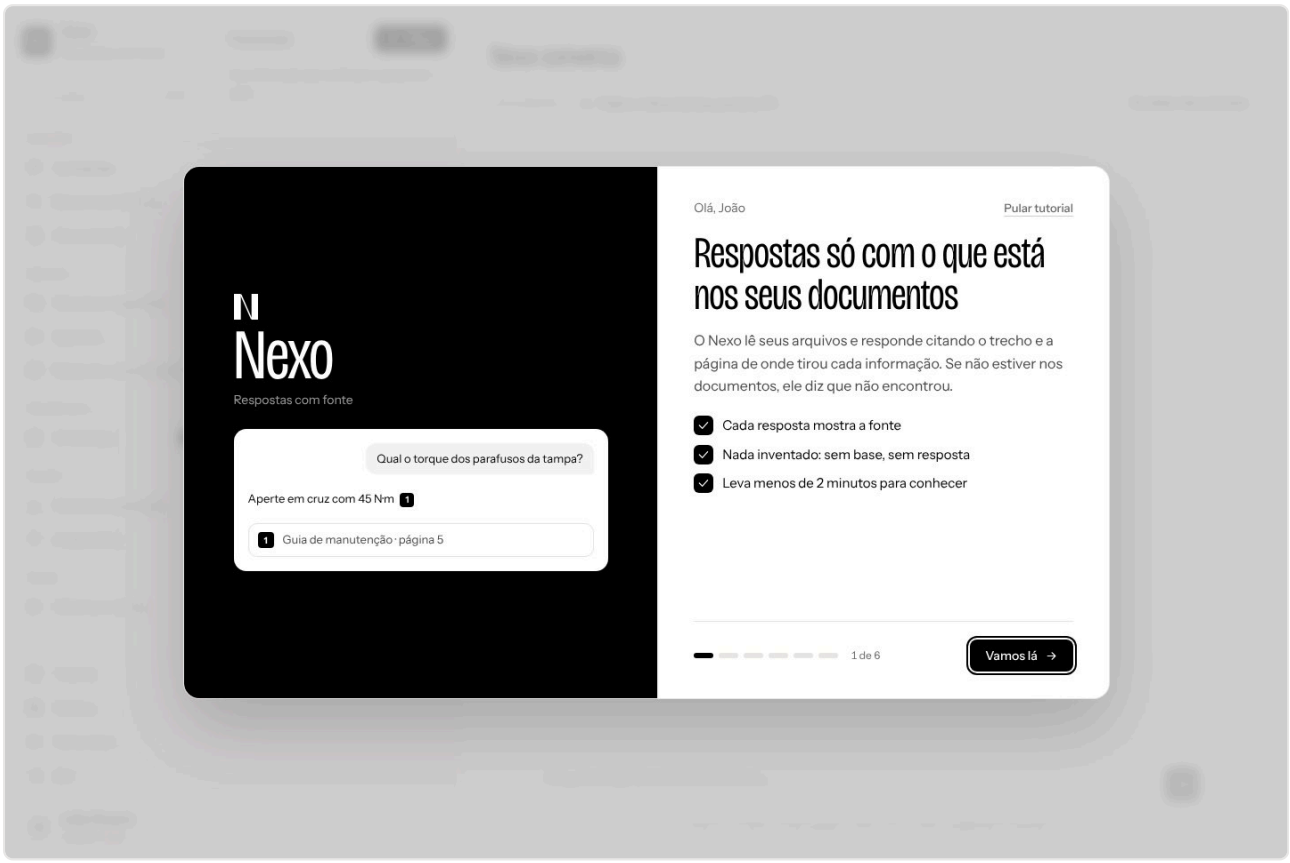


Figura 4.2 Tutorial de primeiro acesso: cada passo mostra uma ilustração da tela, o que fazer e o atalho para começar.

Na primeira vez que uma conta entra, o Nexo abre um tutorial curto por cima da tela. Ele explica, em poucos passos, o caminho completo: o que o Nexo faz, como montar uma base de conhecimento, como criar um agente, como conversar com vários agentes ao mesmo tempo e como ligar o WhatsApp. O último passo traz atalhos para criar a primeira base, o primeiro agente e conectar o WhatsApp.

- Avance com **Próximo** ou com a seta para a direita; volte com **Voltar** ou a seta para a esquerda. Os pontos no rodapé mostram em que passo você está e levam direto a qualquer um.
- **Pular** fecha o tutorial. Fechando ou concluindo, o Nexo marca o tutorial como visto na sua conta (campo `tutorial_done_at`), então ele não volta a aparecer, nem em outro computador.
- Para rever, use **Ver tutorial** na paleta de comandos ou em Sistema e conta.

Copyright (©) 2026 Erik Pimenta

4.3 Conversas

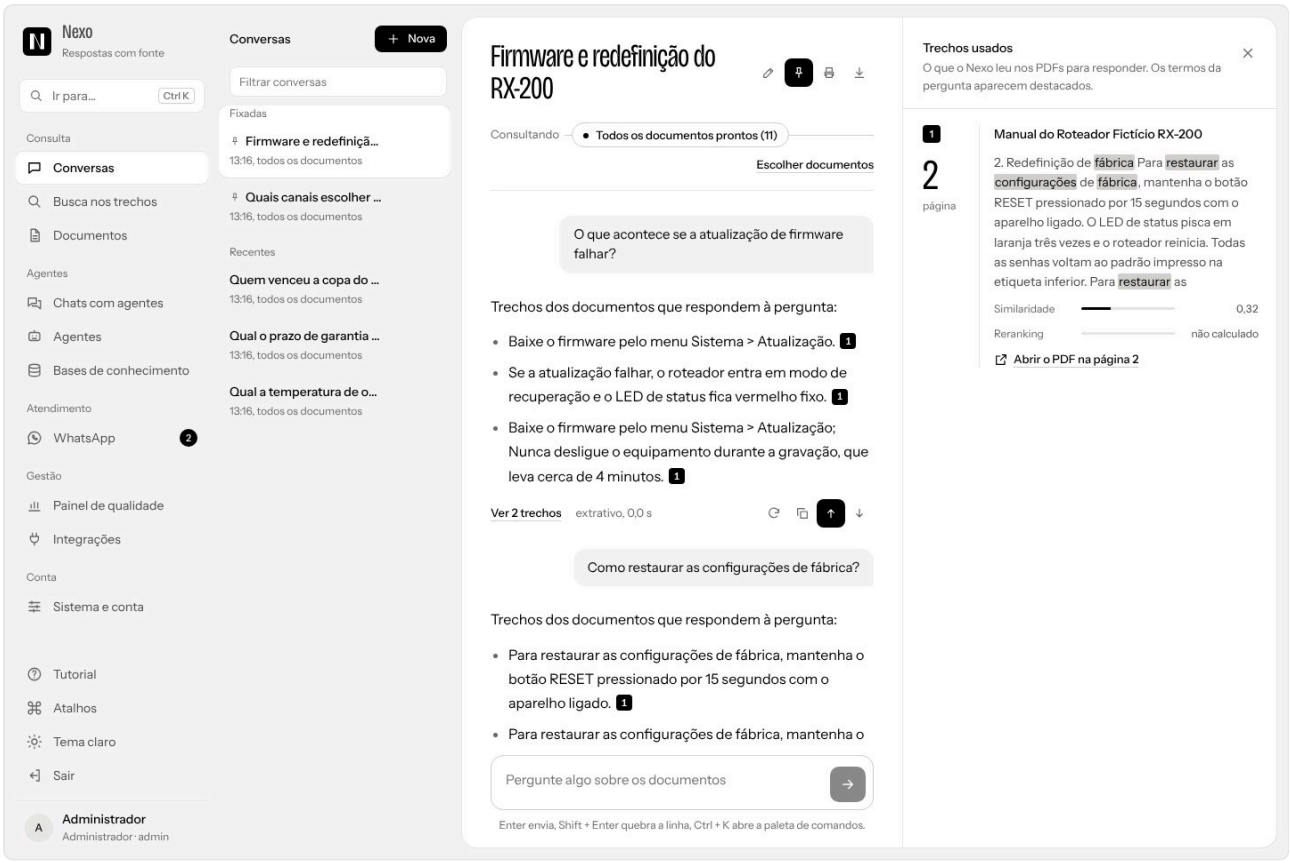


Figura 4.3 Duas perguntas na mesma conversa, com os trechos da primeira resposta abertos, os termos da pergunta destacados e Refazer no rodapé de cada resposta.

- **Nova** abre uma conversa vazia que consulta todo o acervo, de todas as bases. O campo **Filtrar conversas** encontra conversas pelo título e pelo conteúdo das perguntas e respostas. As conversas com agentes ficam na tela Chats com agentes.
- O título vem da primeira pergunta. No topo da conversa, o ícone de renomear edita o título e o ícone de exportar abre o menu Markdown / JSON (seção 5.7).
- `Enter` envia, `Shift + Enter` quebra a linha.
- A resposta aparece enquanto é escrita: primeiro a etapa de busca nos documentos, depois o texto chegando aos poucos. **Parar** cancela a resposta; nada é gravado e a pergunta volta para a caixa de texto.
- Os números [n] no texto indicam de qual trecho veio cada informação. Clique para destacá-lo no painel Trechos usados.
- Abaixo de cada resposta ficam **Ver N trechos**, **Refazer**, o ícone de copiar a resposta com as fontes e a avaliação útil / não ajudou.
- **Refazer** responde de novo a mesma pergunta, com o histórico anterior a ela, e troca a resposta no lugar: as fontes são renovadas e a avaliação anterior é apagada.
- Cada trecho mostra a página (ou a parte, em arquivos que não são PDF), a similaridade, a nota do reranker e o link para abrir o arquivo.
- Perguntas seguintes podem usar "isso" ou "e depois?": o Nexo reescreve a pergunta com o histórico antes de buscar.

Copyright (©) 2026 Erik Pimenta

- **Fixar** Novo: o alfinete no topo da conversa (ou na lista) leva a conversa ao grupo **Fixadas**, no alto da lista. Conversas fixadas não são apagadas pela retenção automática.
- **Rascunho** Novo: o que você digitou e não enviou fica guardado por conversa, mesmo trocando de conversa ou recarregando a página.
- **Imprimir** Novo: o ícone de impressora gera uma versão limpa da conversa, com as fontes, para imprimir ou salvar em PDF.
- A tecla `/` volta o cursor para a caixa de pergunta de qualquer ponto da conversa.

Avaliando e dizendo o que faltou Novo

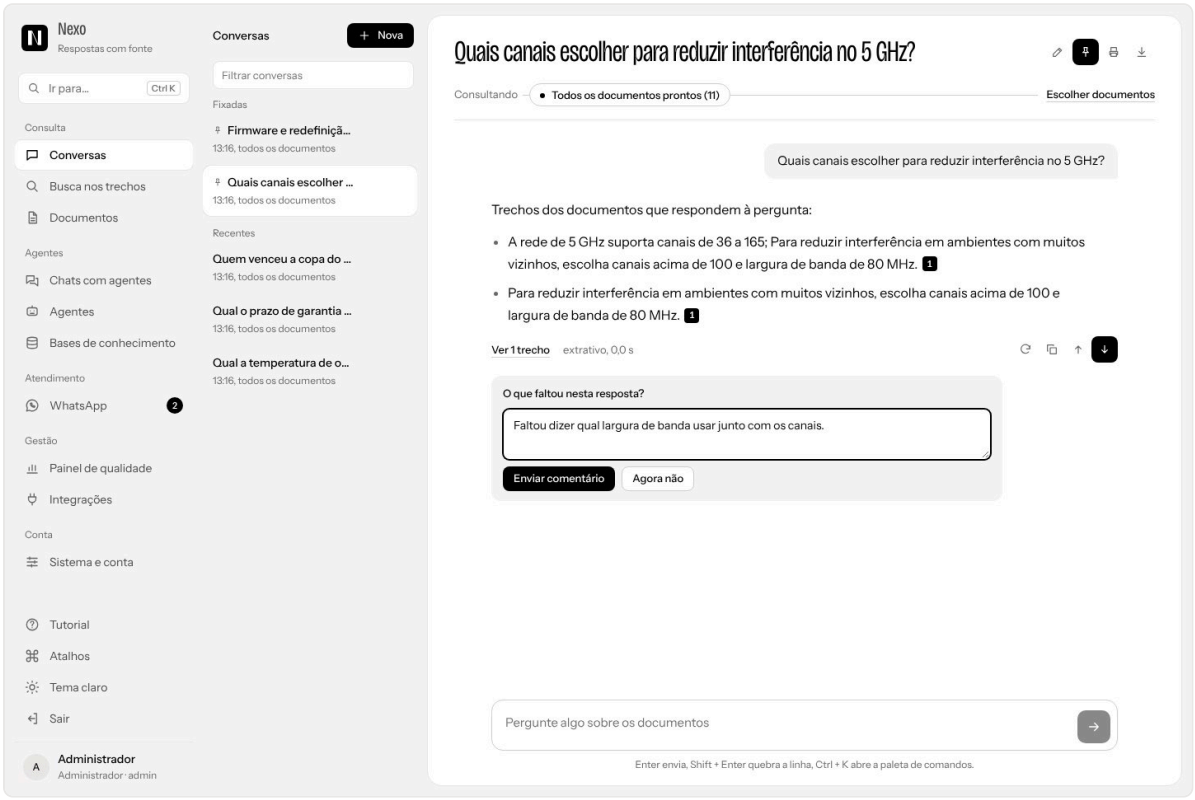


Figura 4.4 Depois de "não ajudou", o campo O que faltou nesta resposta? envia o comentário ao painel de qualidade.

Ao marcar **não ajudou**, abre o campo **O que faltou nesta resposta?**. O comentário é opcional e pode ser trocado depois; ele aparece no painel de qualidade junto da resposta, entra na coluna `comentario` do CSV e vai no campo `comment` do webhook `feedback.negative`.

Escolhendo os documentos consultados

A linha **Consultando** mostra o escopo atual. Clique em **Escolher documentos** e marque os documentos que a conversa deve usar. Sem nenhum marcado, todos os documentos prontos são consultados, inclusive os que forem enviados depois.

Copyright (©) 2026 Erik Pimenta

Quando a resposta não está nos documentos

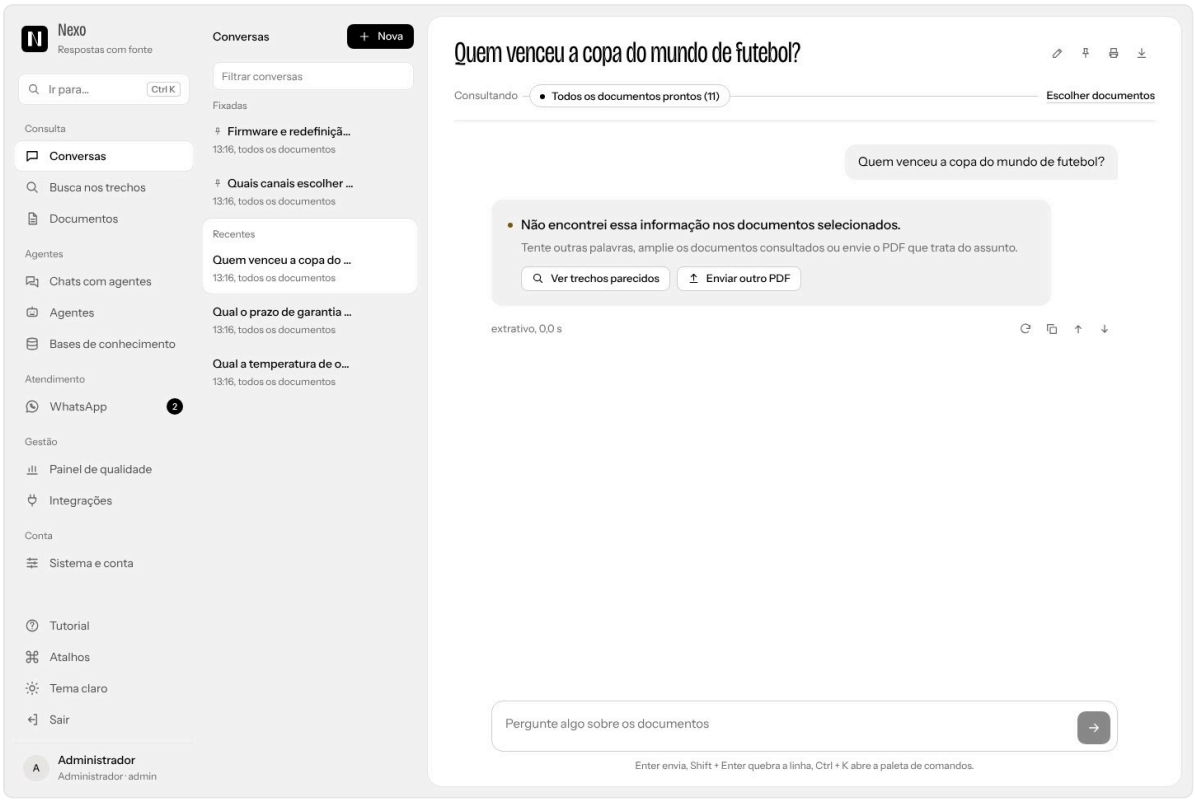


Figura 4.5 Pergunta fora do conteúdo dos documentos: o Nexo responde que não encontrou e sugere como reformular.

Se nenhum trecho passar pelos cortes de relevância, o modelo nem é chamado e a resposta aparece num quadro marcado, com três saídas: **Ver trechos parecidos**, **Consultar todos os documentos** (quando há escopo) e **Enviar outro arquivo**. A pergunta entra nas lacunas do painel de qualidade e, se houver webhook inscrito, dispara `question.unanswered`.

Copyright (©) 2026 Erik Pimenta

4.4 Chats com agentes

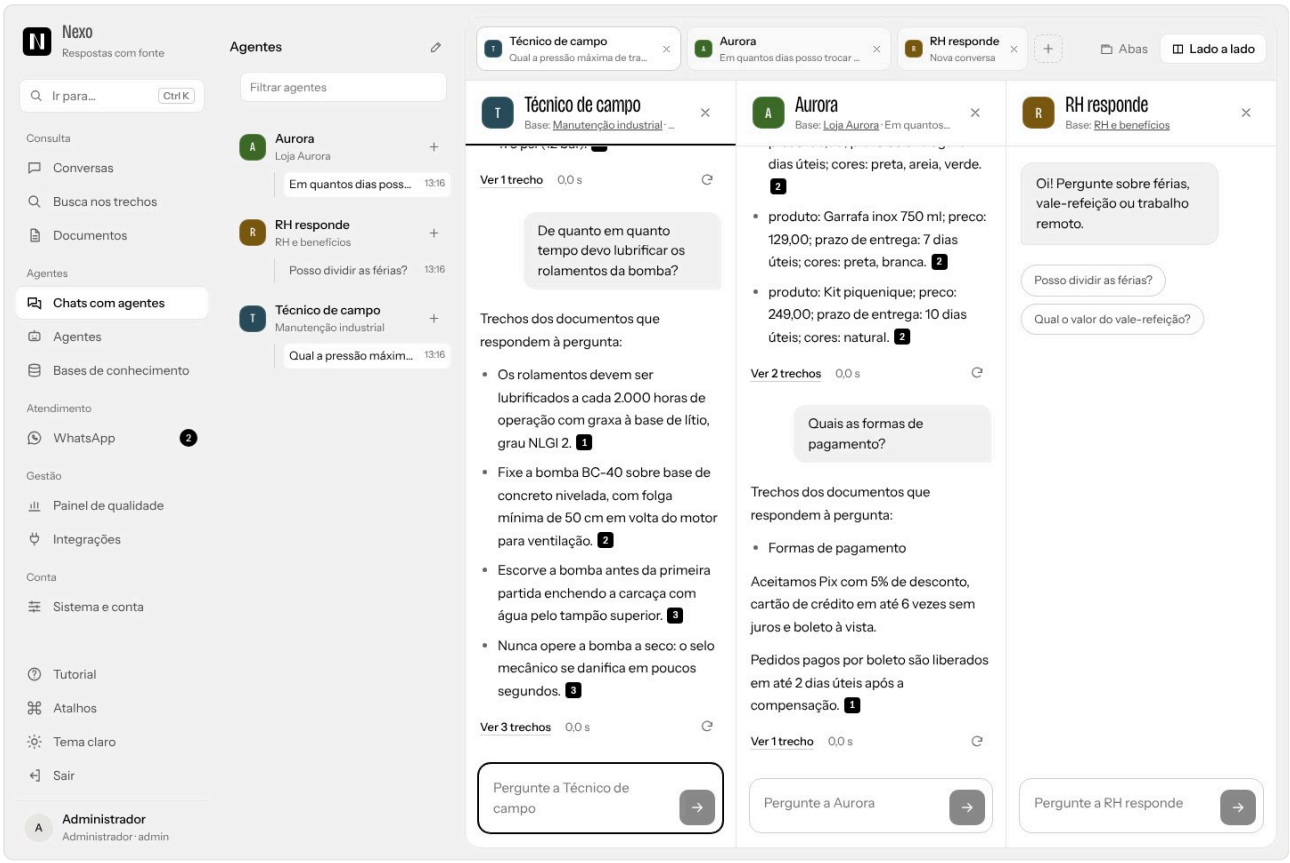


Figura 4.6 Chats com agentes lado a lado: cada coluna conversa com um agente diferente, que responde só com a própria base.

É aqui que você conversa com os agentes. A tela tem a lista de agentes e das conversas recentes à esquerda e, à direita, as conversas abertas em abas.

1. Clique num agente da lista (ou em **Conversar** na tela Agentes). Uma conversa nova abre numa aba, com a saudação do agente.
2. Escreva a pergunta e tecle `Enter`. O agente responde com base só na base de conhecimento dele, com as citações [n], e o texto aparece enquanto é escrito. **Parar** cancela sem gravar.
3. Abra outros agentes: cada um ganha uma aba. Clique numa aba para trazê-la à frente; o × fecha a aba sem apagar a conversa.
4. Clique em **Lado a lado** para ver até três conversas abertas ao mesmo tempo, uma por coluna. Clique em **Em abas** para voltar.
5. Em cada resposta, **Ver trechos** abre os trechos usados logo abaixo dela, com documento e página, e **Refazer** pede ao agente uma nova resposta para a mesma pergunta.

As abas abertas ficam guardadas no navegador. Conversas antigas de cada agente aparecem abaixo dele na lista e reabrem numa aba. Um agente cuja base ainda não tem conteúdo pronto avisa isso no lugar da caixa de pergunta.

Perguntas sugeridas Novo: numa conversa nova, as perguntas cadastradas no agente aparecem como botões abaixo da saudação. Um clique envia a pergunta.

Copyright (©) 2026 Erik Pimenta

4.5 Agentes

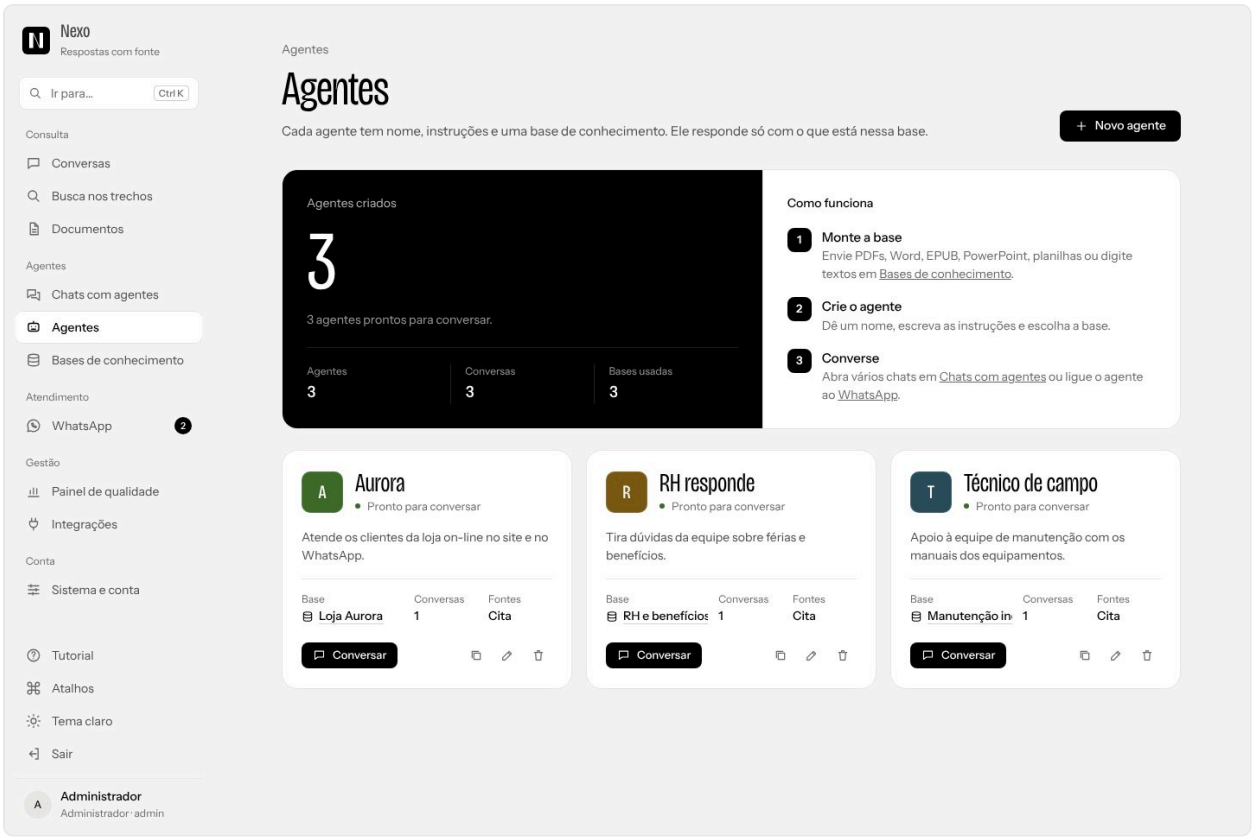


Figura 4.7 Agentes: cada cartão mostra a cor, a base de conhecimento, as conversas e se o agente está pronto para responder.

Um agente é um assistente com nome, personalidade e uma base de conhecimento própria. Ele segue as regras estritas do Nexo (responder só com a base e citar as fontes) e, dentro delas, as instruções que você escrever.

Campo	Para quê
Nome e descrição	Como o agente aparece nas listas, nos chats e no WhatsApp
Base de conhecimento	A única fonte das respostas. Escolha uma base existente; várias pessoas podem usar o mesmo agente
Instruções	Tom e regras, por exemplo "Responda de forma curta e cordial; trate o cliente por você". Não podem liberar o agente para inventar
Saudação	Mensagem de boas-vindas. Aparece ao abrir um chat e responde a cumprimentos como "oi" e "bom dia"
Quando não souber	Frase usada no lugar da resposta padrão, por exemplo "Vou chamar alguém da equipe"
Cor	Destaque do selo com a inicial do agente
Citar fontes no WhatsApp	Acrescenta "Fontes:" com documento e página no fim das respostas enviadas aos clientes
Perguntas sugeridas **Novo**	Até 6 perguntas, uma por linha, mostradas como atalhos no começo de cada chat

Copyright (©) 2026 Erik Pimenta

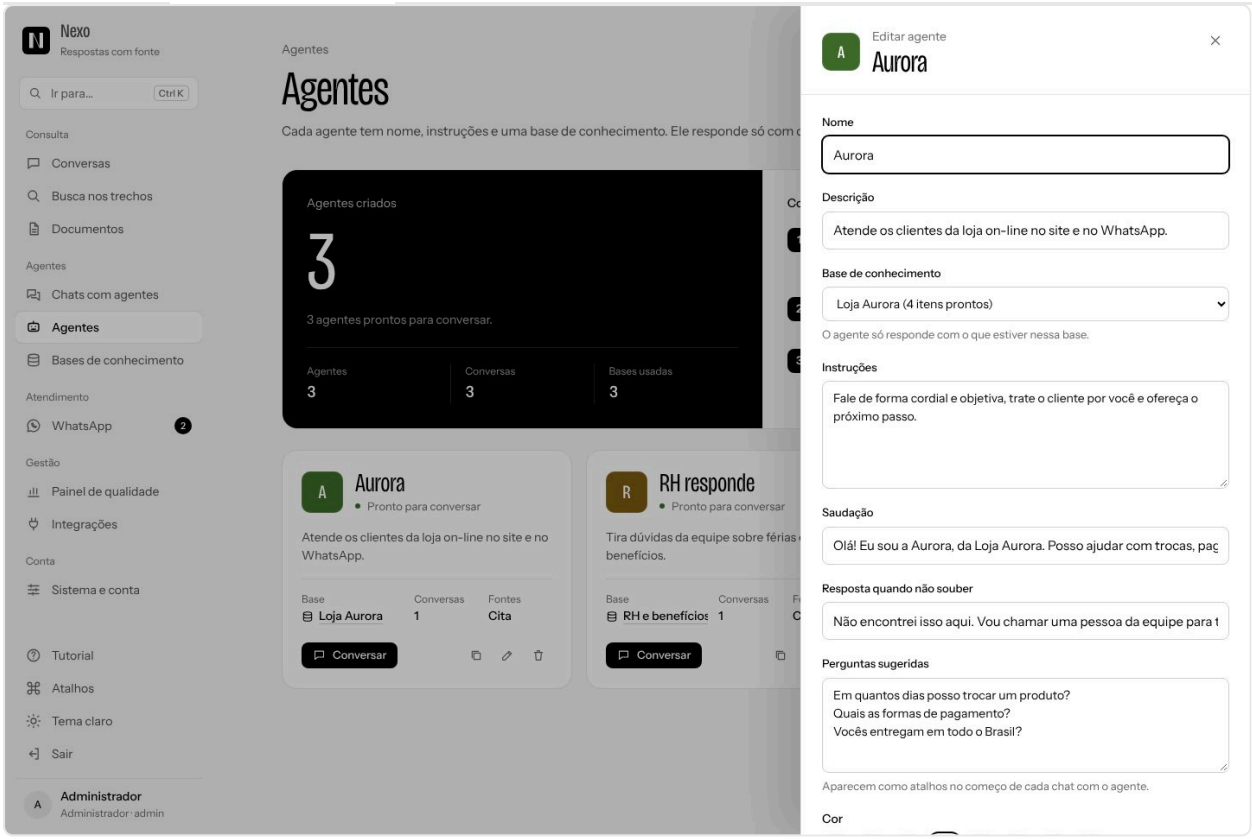


Figura 4.8 Painel de criação do agente: nome, base de conhecimento, instruções, saudação, frase para quando não souber e cor.

1. Abra **Agentes** e clique em **Criar agente**.
2. Dê um nome, escolha a base (ou crie uma em Bases de conhecimento antes) e escreva as instruções, a saudação e a frase para quando não souber.
3. Salve. O cartão mostra **Pronto** quando a base tem conteúdo indexado. Use **Conversar** para testar e **Editar** para ajustar.

Duplicar Novo cria uma cópia do agente com o nome "(cópia)", a mesma base e as mesmas instruções, pronta para editar: útil para testar outro tom sem mexer no agente que está no ar.

Excluir um agente apaga as conversas feitas com ele e desliga a resposta automática dos números de WhatsApp que ele atendia. Só quem criou o agente ou um administrador pode editá-lo ou excluí-lo.

Copyright (©) 2026 Erik Pimenta

4.6 Bases de conhecimento

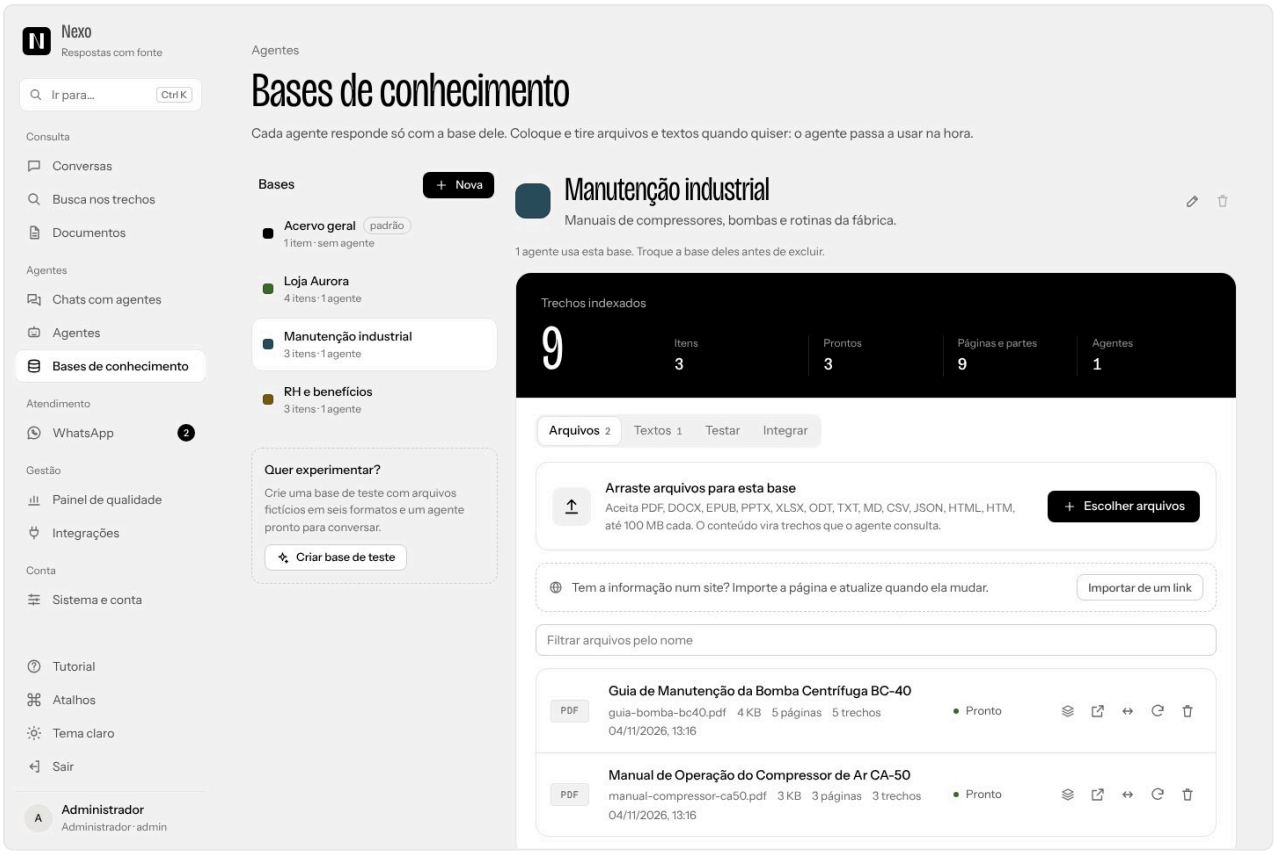


Figura 4.9 Base de conhecimento aberta: o resumo na tampa preta, as abas Arquivos, Textos, Testar e Integrar e a lista de arquivos.

A base de conhecimento é o "RAG" de cada agente: o conjunto de documentos, dados e arquivos de onde ele tira as respostas. A tela mostra todas as bases à esquerda e, à direita, a base escolhida, com o resumo na tampa preta (itens, prontos, trechos, páginas e agentes que usam a base) e quatro abas.

Aba	O que dá para fazer
Arquivos	Arrastar ou escolher arquivos PDF, DOCX, ODT, EPUB, PPTX, XLSX, TXT, MD, CSV, JSON e HTML; importar de um link; filtrar; abrir, ver os trechos, renomear, reindexar, mover para outra base e excluir
Textos	Escrever ou colar uma informação direto na base, com título; editar e excluir a qualquer hora
Testar	Fazer uma busca só nesta base e ver os trechos que um agente receberia, com as notas
Integrar	Exemplos prontos (curl, Python e JavaScript) para enviar arquivos, criar textos e perguntar ao agente desta base por outros sistemas, com os ids já preenchidos

Como cada formato é lido

Formato	Como vira texto	Citação
PDF	Texto de cada página com pypdf (PDF digitalizado precisa de OCR antes)	página N
DOCX	Parágrafos e tabelas do documento do Word	parte N

Copyright (©) 2026 Erik Pimenta

Formato	Como vira texto	Citação
ODT	Parágrafos e tabelas do documento do LibreOffice / OpenDocument	parte N
EPUB	O livro capítulo a capítulo, na ordem de leitura	parte N
PPTX	O texto de cada slide, um slide por parte	parte N
XLSX	As linhas de cada aba, como no CSV, com o nome da aba antes	parte N
TXT e MD	O texto como está, dividido em partes por parágrafos	parte N
CSV	Cada linha vira "coluna: valor", com o cabeçalho repetido a cada bloco de linhas	parte N
JSON	Cada valor vira "caminho: valor", para que chaves e valores entrem na busca	parte N
HTML	O texto visível da página, sem scripts e estilos	parte N
Texto da aba Textos	O texto digitado	parte N

Arquivos compactados. DOCX, ODT, EPUB, PPTX e XLSX são pacotes zip por dentro. O envio é recusado se algum item do pacote passar de 50 MB descompactado, o que protege o servidor de arquivos feitos para estourar a memória.

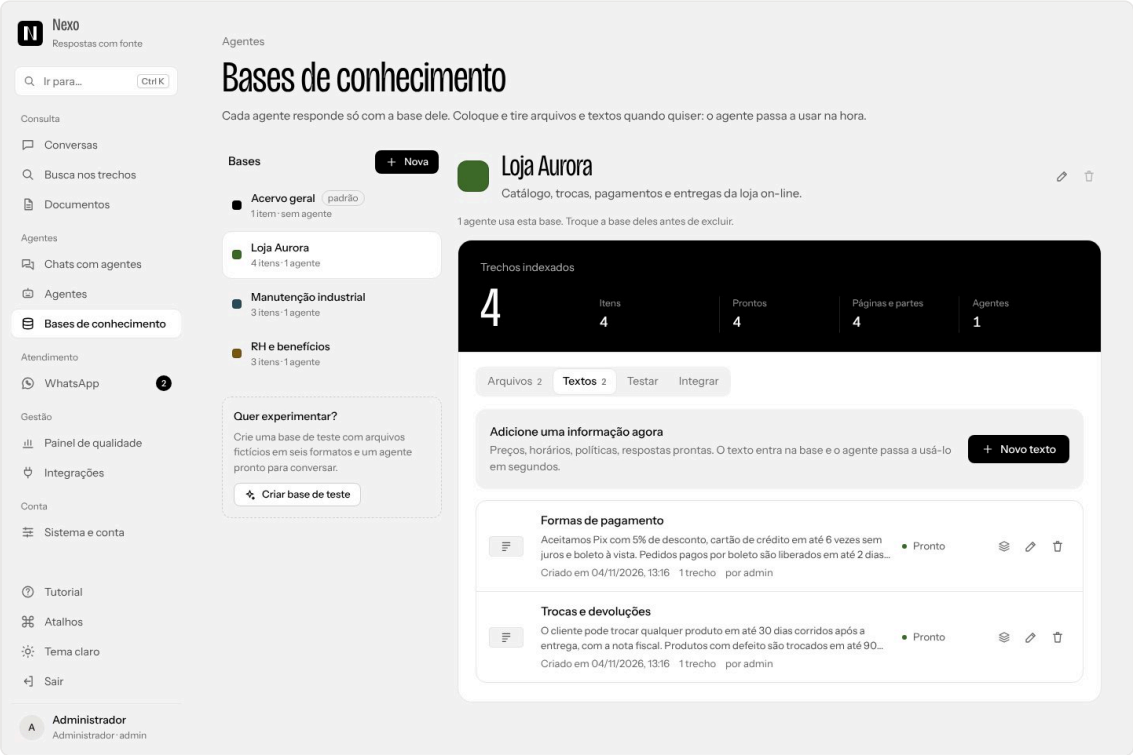


Figura 4.10 Aba Textos: informações escritas direto na base, editáveis a qualquer hora.

- **Acrescentar informação a qualquer hora:** envie arquivos ou crie textos; cada item entra na fila e, ao ficar Pronto, já é usado pelos agentes da base.

Copyright (©) 2026 Erik Pimenta

- **Retirar informação:** exclua o item. Os vetores dele saem do banco vetorial na hora e os agentes param de usá-lo.
- **Mover entre bases:** o ícone de mover troca a base de um item sem reindexar, porque a busca filtra pelos documentos de cada base.
- **Acervo geral:** a base padrão existe sempre, recebe os documentos antigos e os envios feitos pela tela Documentos sem base escolhida. Pode ser renomeada, mas não excluída.
- Uma base usada por algum agente não pode ser excluída; troque a base do agente antes.

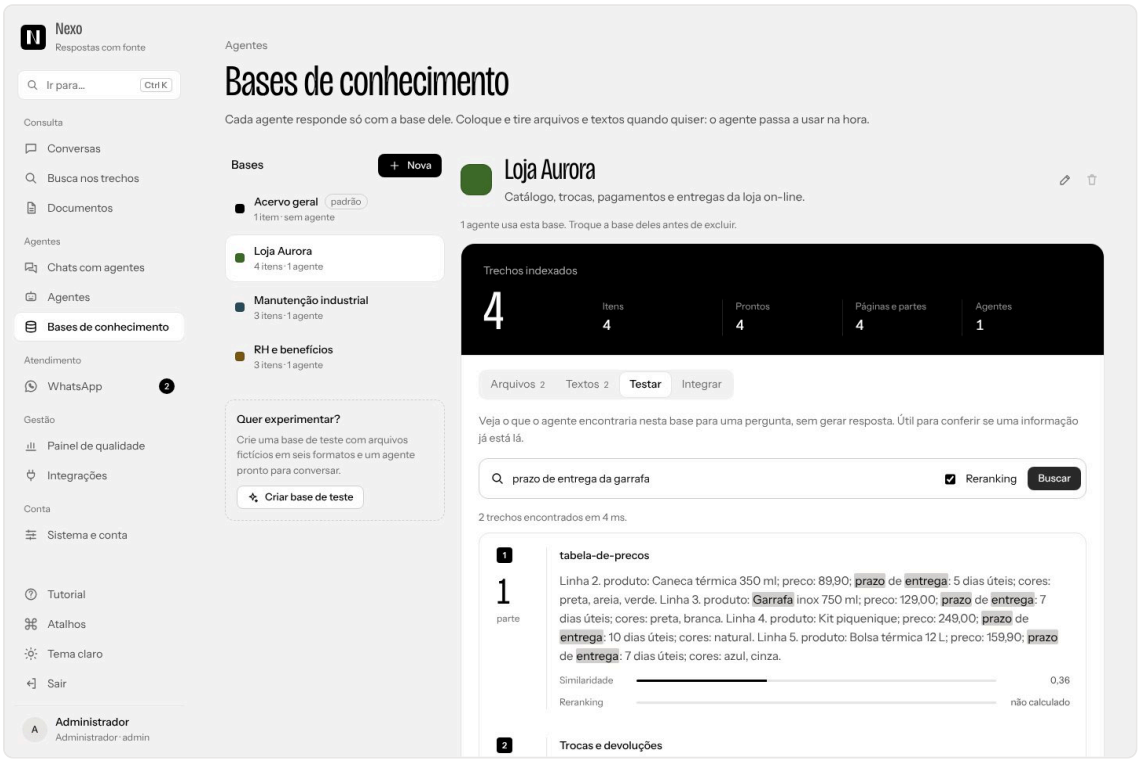


Figura 4.11 Aba Testar: busca só na base, com os trechos e as notas que o agente receberia.

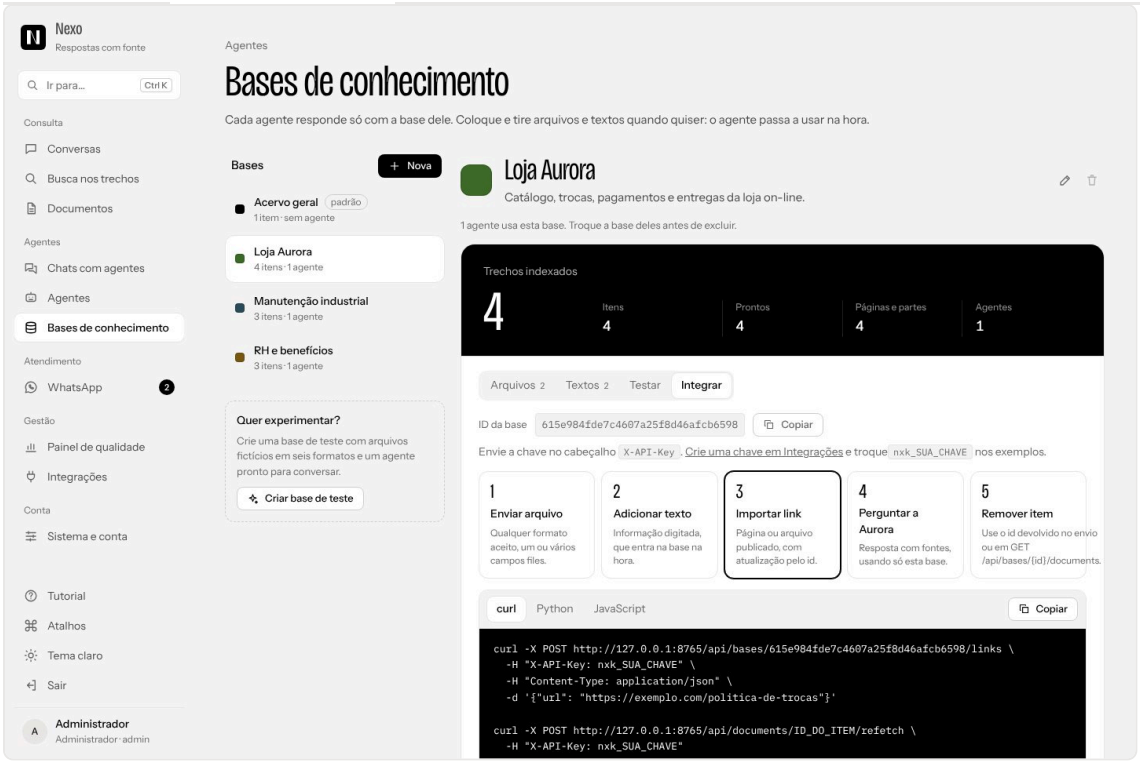


Figura 4.12 Aba Integrar: exemplos prontos com o id da base e do agente para levar dados e perguntas de outros sistemas.

Importar de um link Novo

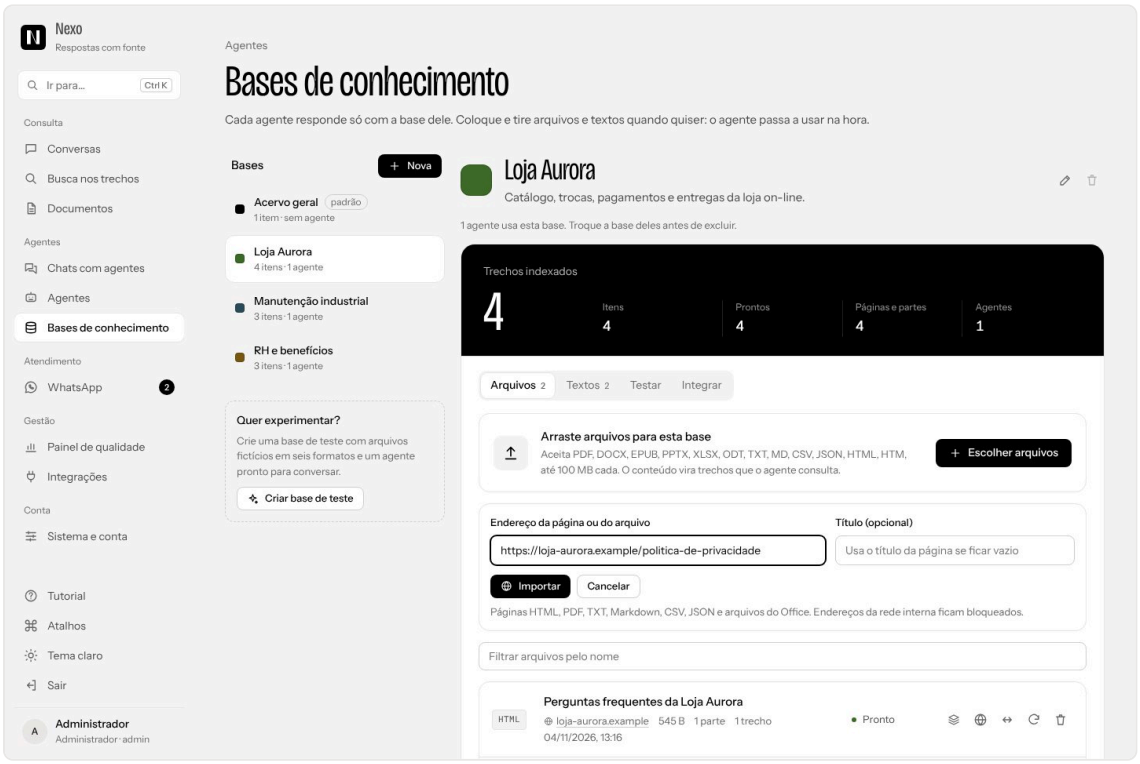


Figura 4.13 Importar de um link: o endereço da página ou do arquivo e um título opcional.

1. Na aba Arquivos, clique em **Importar de um link**.
2. Cole o endereço de uma página (HTML) ou de um arquivo publicado (PDF, DOCX, planilha, texto...) e, se quiser, um título.

Copyright (©) 2026 Erik Pimenta

3. Clique em **Importar**. O Nexo baixa o conteúdo, guarda o link de origem e indexa como qualquer outro item.
4. Quando a página mudar, use o ícone **Atualizar do link** do item: o Nexo baixa de novo e só reindexa se o conteúdo for diferente.

Por segurança, endereços da rede interna (localhost, 10.x, 172.16-31.x, 192.168.x e afins) são bloqueados, inclusive quando um site redireciona para eles. Para importar de uma intranet, ligue `NEXO_ALLOW_PRIVATE_URLS`.

Ver os trechos indexados Novo

O ícone de camadas em cada item abre a gaveta **Trechos indexados**: o texto exato de cada trecho, na ordem, com a página ou parte e o número de caracteres, uma busca por palavra que destaca os termos e o link para abrir o arquivo naquela página. É o jeito mais rápido de entender por que um assunto não é encontrado.

Base de teste Novo

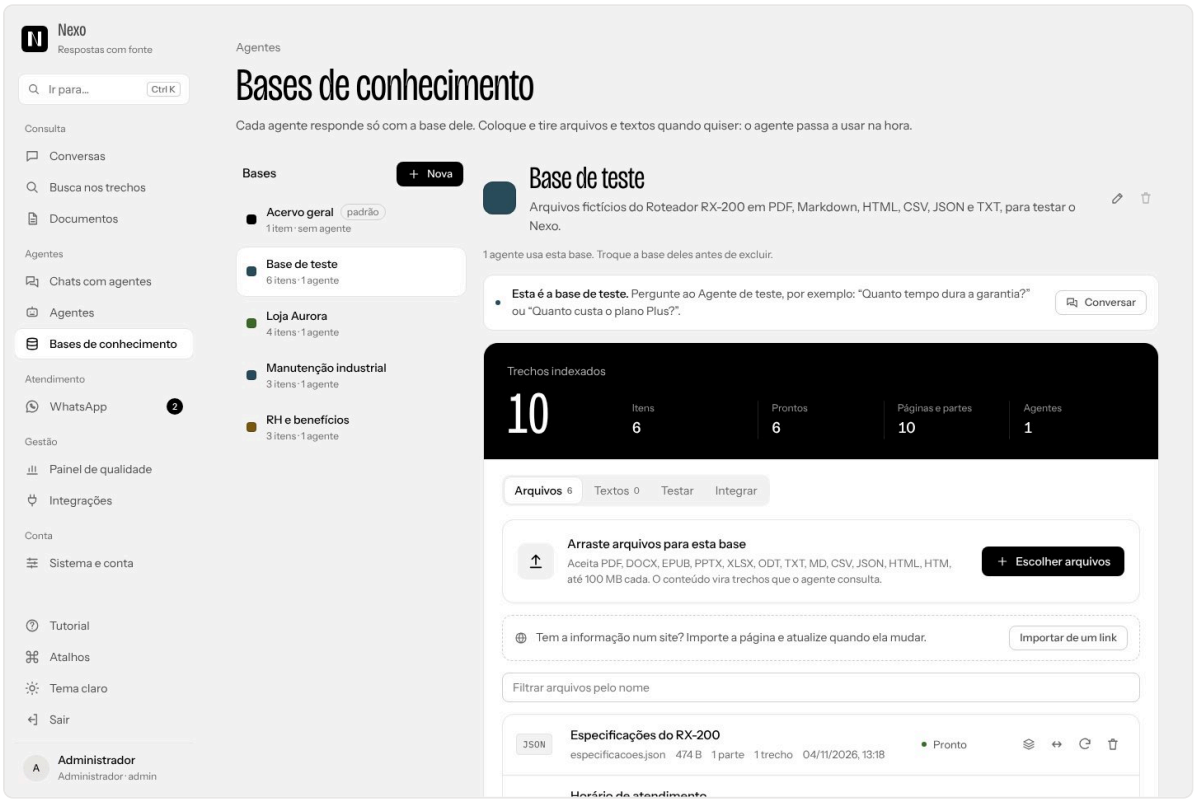


Figura 4.14 Base de teste criada com um clique: seis arquivos de exemplo e o Agente de teste.

Para experimentar o Nexo sem os seus documentos, clique em **Criar base de teste** no quadro "Quer experimentar?" da lista de bases, ou rode `python -m nexo base-de-teste`. O Nexo cria a **Base de teste** com os arquivos de `exemplos/base-de-teste` e o **Agente de teste**, já com perguntas sugeridas.

Arquivo	Formato	Conteúdo
manual-roteador-rx200.pdf	PDF	Manual do Roteador RX-200: instalação, reset, firmware e especificações
garantia.md	Markdown	Prazo, cobertura e como acionar a garantia
perguntas-frequentes.html	HTML	Senha do Wi-Fi, aparelhos conectados, operadoras e rede de visitantes

Copyright (©) 2026 Erik Pimenta

Arquivo	Formato	Conteúdo
planos-de-suporte.csv	CSV	Planos Básico, Plus e Empresarial com preço, atendimento e visita técnica
horario-de-atendimento.txt	TXT	Canais e horários do suporte
especificacoes.json	JSON	Ficha técnica do aparelho

Pergunte, por exemplo, "Quanto tempo dura a garantia?" ou "O suporte atende aos sábados?". O arquivo `exemplos/base-de-teste/perguntas-de-teste.jsonl` traz perguntas com a resposta esperada para o `scripts/avaliar.py`. Rodar de novo não duplica nada; para remover, exclua o agente e a base.

Copyright (©) 2026 Erik Pimenta

4.7 WhatsApp

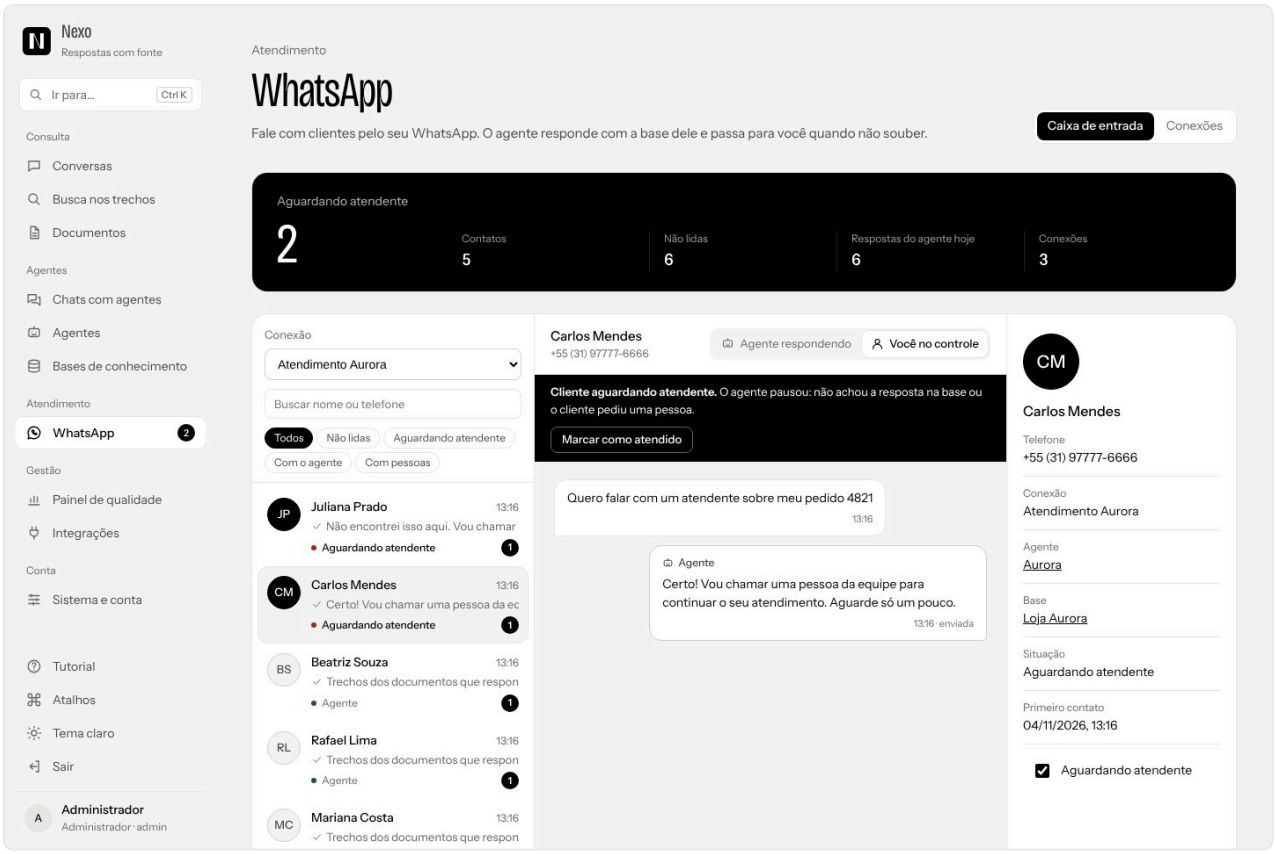


Figura 4.15 Caixa de entrada do WhatsApp: contatos com filtros, a conversa com o cliente, o agente respondendo e a sugestão de resposta.

A caixa de entrada reúne as conversas com os clientes de todos os números conectados. Em cima, a tampa preta resume contatos, não lidas, aguardando atendente e respostas do agente hoje.

- **Contatos:** busca por nome ou número e filtros Todos, Não lidas, Aguardando atendente, Com o agente e Com a equipe. A lista se atualiza sozinha a cada poucos segundos.
- **Conversa:** mensagens do cliente à esquerda, do agente e da equipe à direita, com o autor, o horário e a situação da entrega (enviada, entregue, lida ou falhou). Mensagens digitadas no próprio celular do número (Evolution) aparecem como **Pelo celular**.
- **Assumir:** escrever e enviar uma mensagem pela tela coloca a equipe no controle daquele contato e pausa o agente nele.
- **Devolver ao agente:** religa a resposta automática naquele contato e tira a marca de aguardando atendente.
- **Sugerir resposta:** o agente redige uma resposta para a última mensagem do cliente, com as fontes, e coloca no campo de texto sem enviar. Revise e envie.
- **Aguardando atendente:** quando o agente não encontra a resposta na base, ou quando o cliente pede "atendente" ou "humano", o contato ganha essa marca, o agente pausa nele e sai o evento `whatsapp.handoff`.

Copyright (©) 2026 Erik Pimenta

Respostas prontas Novo

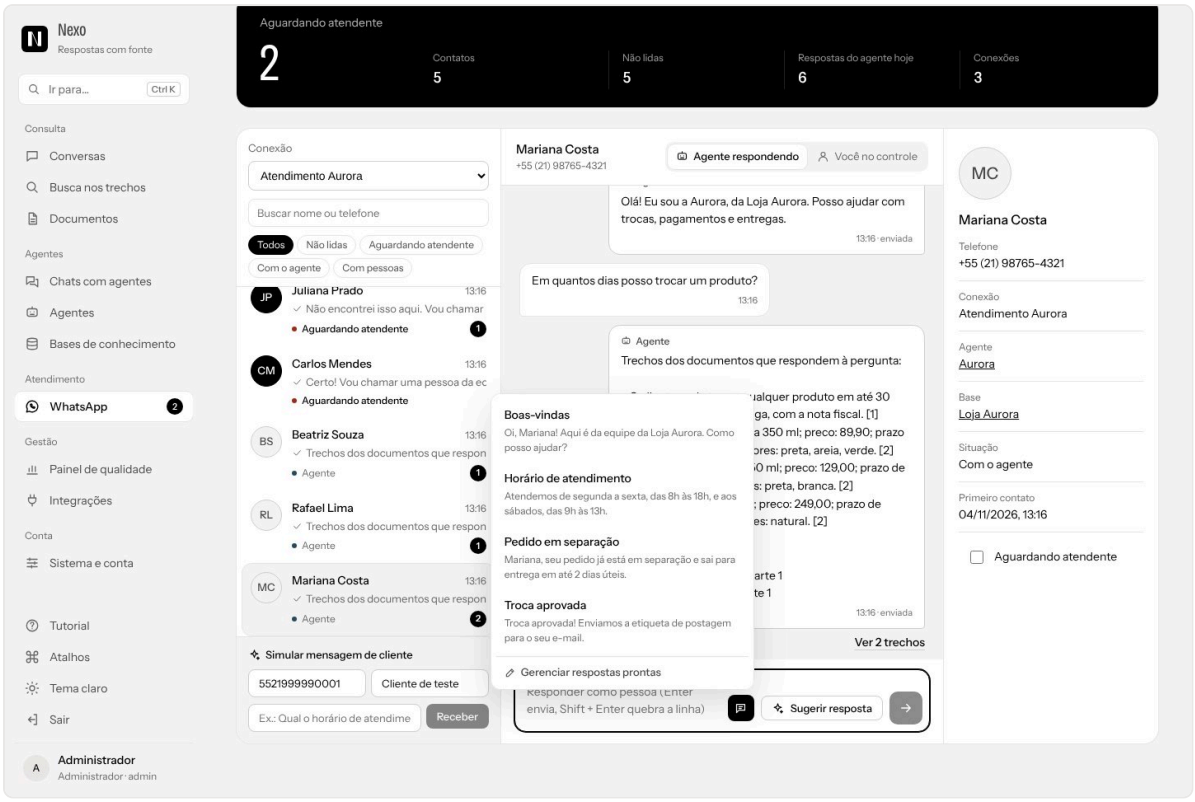


Figura 4.16 Menu de respostas prontas aberto na caixa de resposta do WhatsApp.

Textos que a equipe repete todo dia (boas-vindas, horário, prazo de entrega) ficam a um clique. Clique no ícone de raio ao lado da caixa de resposta, ou digite `/` no começo da caixa, e escolha a resposta; ela entra no campo para revisar antes de enviar. `{nome}` e `{telefone}` são trocados pelos dados do contato. **Gerenciar respostas prontas** cria, edita e exclui; quem criou ou um administrador pode alterar cada uma.

Copyright (©) 2026 Erik Pimenta

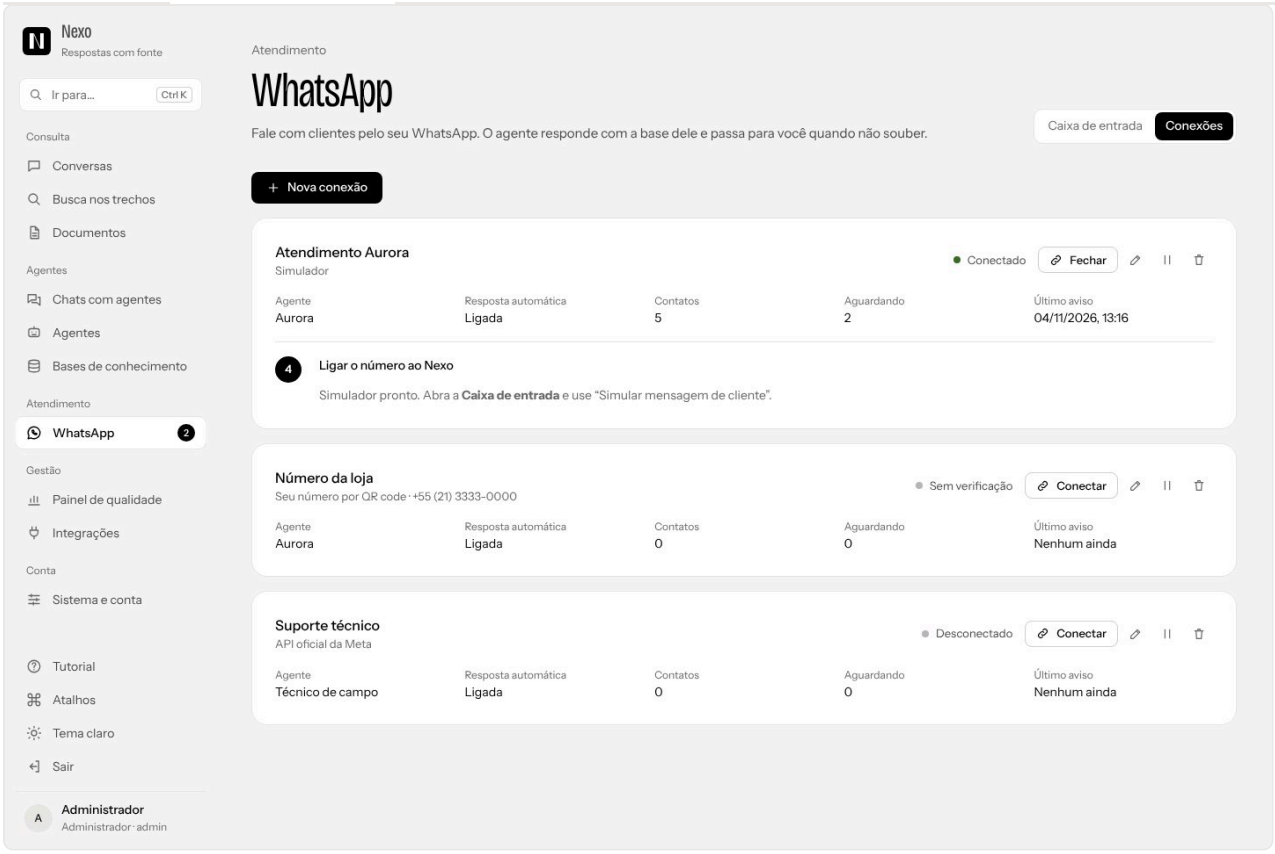


Figura 4.17 Aba Conexões: provedor, agente que atende, resposta automática, URL do webhook e o QR code da Evolution API.

A aba **Conexões** lista os números conectados e, para administradores, permite criar, editar, pausar e excluir conexões. O passo a passo de cada provedor está no capítulo 6. Com o provedor Simulador, a própria tela tem o quadro **Simular mensagem de cliente** para testar o agente sem um número real.

Copyright (©) 2026 Erik Pimenta

4.8 Busca nos trechos

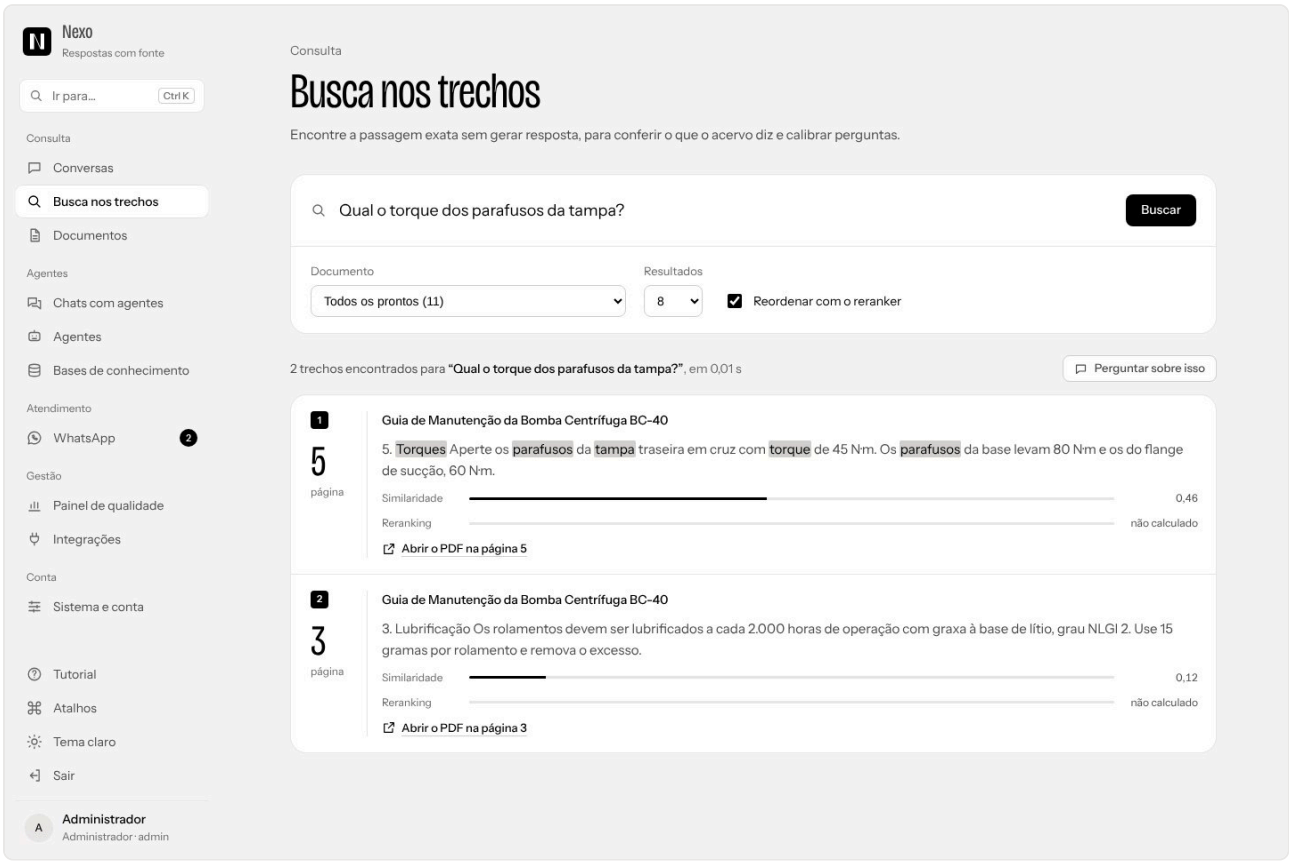


Figura 4.18 Busca nos trechos: resultados em ordem de relevância, com documento, página, similaridade, nota do reranker e o trecho.

A busca mostra o que o acervo tem sobre um assunto sem chamar o modelo de linguagem. É rápida, não gasta tokens e serve para conferir se um assunto está nos documentos antes de perguntar, ou para calibrar os cortes de relevância. Para buscar dentro de uma base só, use a aba Testar da base.

1. Abra **Busca nos trechos** no menu lateral.
2. Escreva o que procura (até 500 caracteres) e, se quiser, limite a busca a alguns documentos em **Documento**.
3. Deixe **Reordenar com o reranker** ligado para a ordem mais precisa, ou desligue para ver a ordem da busca vetorial pura.
4. Escolha em **Resultados** quantos quer ver (1 a 20; o padrão é 8) e clique em **Buscar** ou tecle `Enter`.
5. Clique num resultado para abrir o arquivo no trecho, ou em **Perguntar sobre isso** para levar o assunto a uma conversa.

Copyright (©) 2026 Erik Pimenta

4.9 Documentos

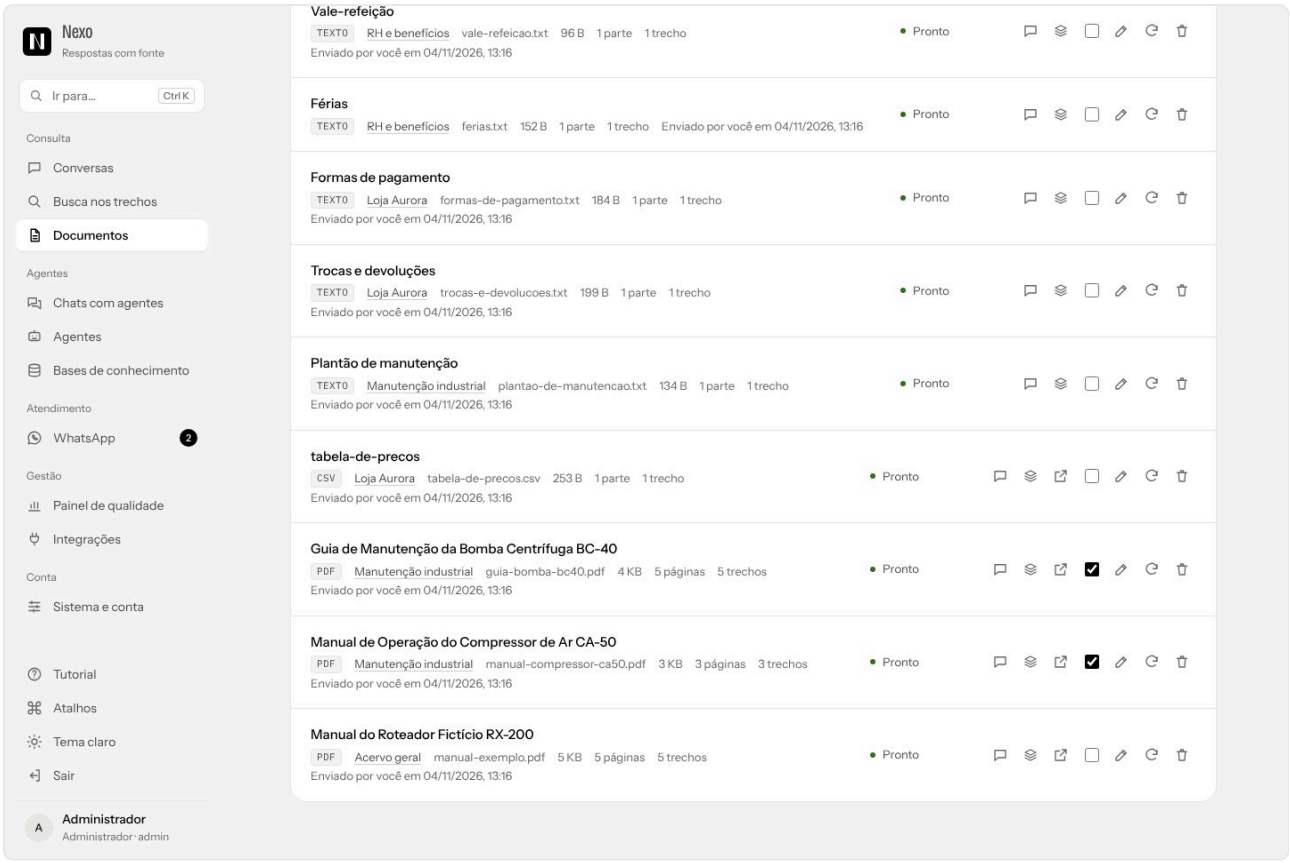


Figura 4.19 Documentos: a lista de todas as bases, com dois itens selecionados para uma ação em lote e os ícones de cada item.

A tela Documentos mostra todos os itens de todas as bases numa lista só, com o filtro **Base** para ver uma base de cada vez. Escolha em **Enviar para** a base onde os arquivos enviados aqui vão entrar; sem escolha, vão para a base "Acervo geral". Cada item entra como Na fila, passa a Indexando e termina em Pronto; se aparecer Falhou, o motivo fica abaixo do título. Os ícones à direita abrem o arquivo, perguntam a este documento, renomeiam (reindexa), reindexam e excluem. A barra acima da lista filtra por título, situação e ordem.

Copyright (©) 2026 Erik Pimenta

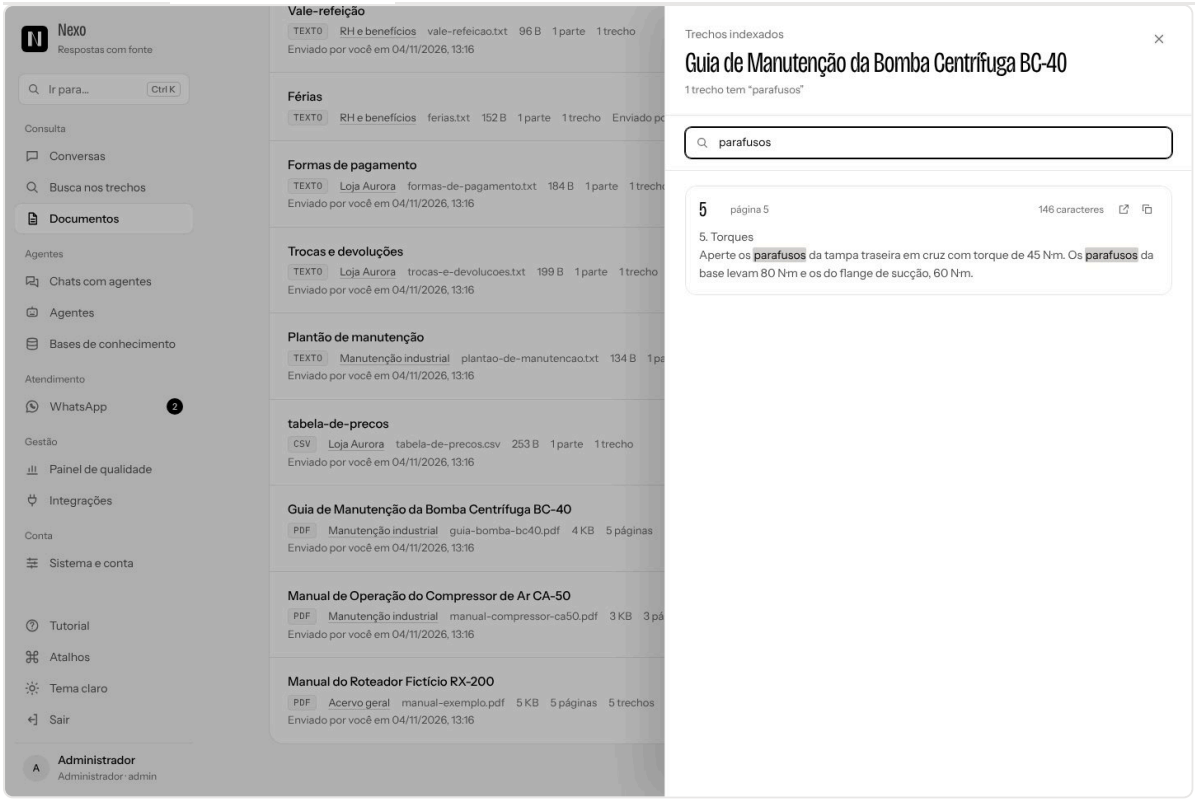


Figura 4.20 Gaveta Trechos indexados aberta por cima da lista, com a busca por palavra.

- **Ver trechos** Novo: o ícone de camadas abre a gaveta com os trechos do item (seção 4.6).
- **Índice desatualizado** Novo: um item indexado com outro modelo de embeddings ou outro tamanho de trecho ganha essa marca. A situação **Desatualizados** do filtro lista todos, e o administrador vê o aviso com o botão para reindexar só eles.
- Itens importados de um link mostram o endereço de origem abaixo do título.

Ações em lote

1. Marque a caixa de seleção dos itens desejados, ou a caixa do cabeçalho para marcar todos os itens filtrados.
2. Na barra que aparece, escolha **Reindexar**, **Mover para** (com a base de destino) ou **Excluir**. A exclusão pede confirmação.
3. O Nexo aplica a ação só aos itens que você pode alterar (os que você enviou, os das suas bases ou todos, para administradores) e avisa quantos foram pulados.

Copyright (©) 2026 Erik Pimenta

4.10 Painel de qualidade

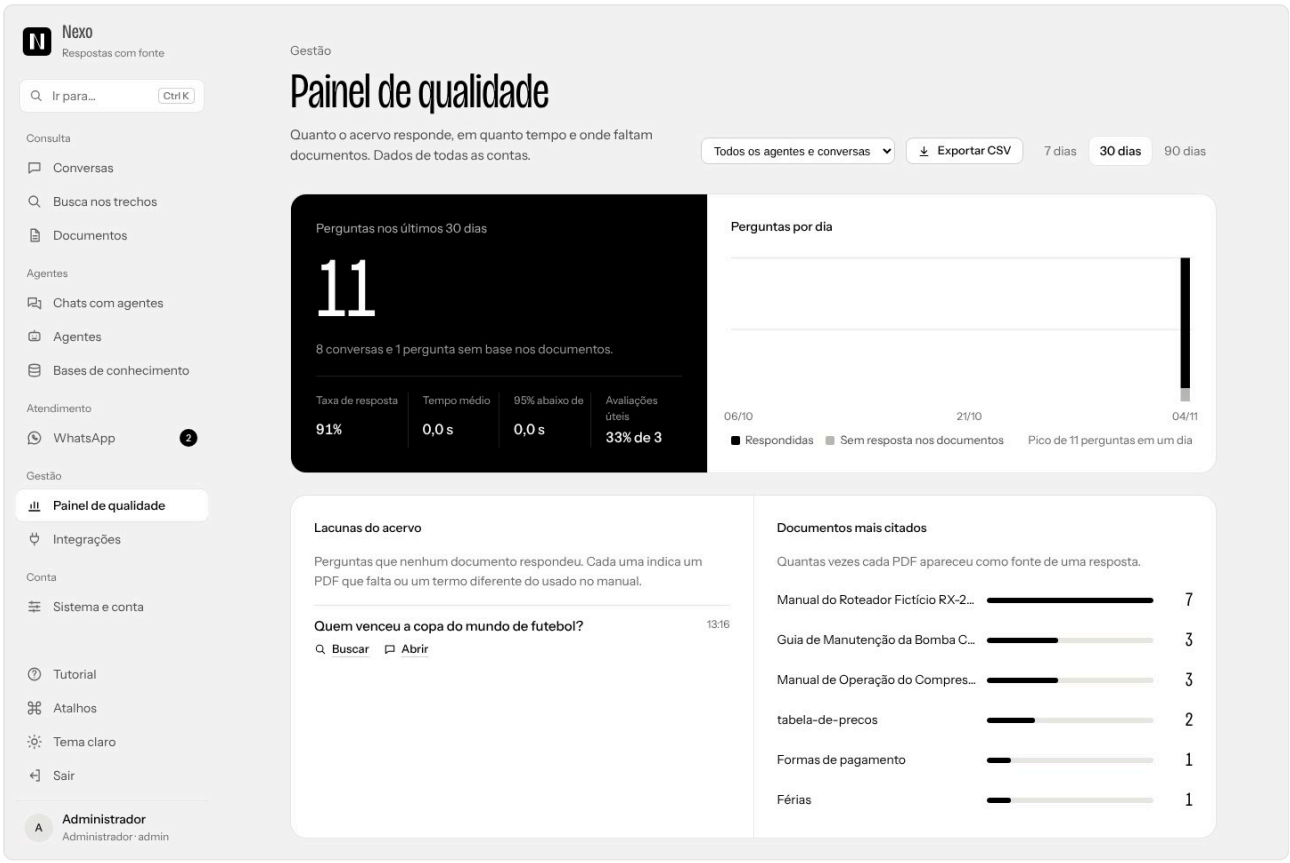


Figura 4.21 Painel de qualidade com os números do período na tampa preta, o botão Exportar CSV, as perguntas por dia e as lacunas do acervo.

O painel responde a duas perguntas: o Nexo está respondendo bem? E o que falta no acervo? O administrador vê os números de todas as conversas, inclusive as com agentes; os demais usuários veem só os das próprias conversas. Escolha o período em 7, 30 ou 90 dias.

Indicador	Como ler
Na tampa preta	
Perguntas	Total de perguntas feitas no período
Taxa de resposta	Respondidas ÷ perguntas. Caindo, o acervo não cobre o que as pessoas procuram ou os cortes estão altos
Tempo médio e p95	Tempo de resposta típico e o dos 5% mais lentos
Avaliações	Respostas marcadas como úteis e como "não ajudou"
Abaixo da tampa	
Perguntas por dia	Perguntas e perguntas sem resposta de cada dia
Documentos mais citados	Os seis documentos que mais embasaram respostas

Copyright (©) 2026 Erik Pimenta

Indicador	Como ler
Lacunas do acervo	As 10 perguntas sem resposta mais recentes, com Buscar e Abrir
Respostas avaliadas como "não ajudou"	As 10 respostas mais recentes marcadas como "não ajudou", com a pergunta e o comentário de quem avaliou
Por agente Novo	Perguntas, respondidas, taxa de resposta, tempo médio e "não ajudou" de cada agente e das conversas gerais

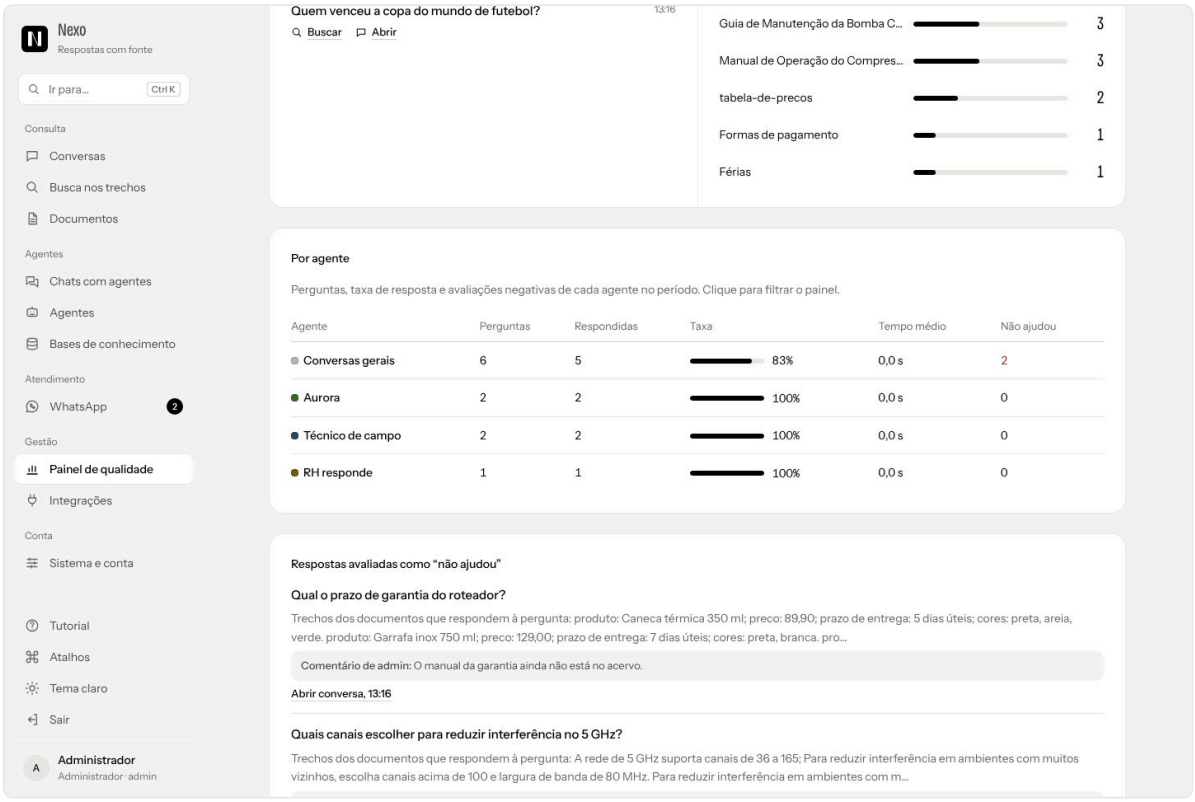


Figura 4.22 Tabela Por agente e as respostas avaliadas como "não ajudou" com o comentário.

O filtro **Agente** Novo, ao lado do período, restringe o painel inteiro e o CSV a um agente ou às conversas gerais. Clicar numa linha da tabela Por agente aplica o mesmo filtro.

Exportar CSV

O botão **Exportar CSV** baixa as perguntas do período escolhido, uma por linha, pela rota `GET /api/metrics/export?days=N`. O escopo é o mesmo do painel: tudo para o administrador, só as próprias conversas para os demais.

Coluna	Conteúdo
data	Quando a pergunta foi respondida
conversa	Título da conversa
pergunta	Texto da pergunta
respondida	Se a resposta veio dos documentos ou foi a resposta padrão

Copyright (©) 2026 Erik Pimenta

Coluna	Conteúdo
avaliação	Útil, não ajudou ou vazio
latência	Tempo de resposta, em milissegundos
fontes	Documentos e páginas citados
comentario Novo	O que faltou, escrito por quem marcou "não ajudou" (última coluna, para não mudar as anteriores)

Rotina sugerida. Uma vez por semana, leia as lacunas e os contatos que ficaram aguardando atendente no WhatsApp. Se o assunto é legítimo e não está na base, crie um texto ou envie o arquivo que falta na base do agente.

Copyright (©) 2026 Erik Pimenta

4.11 Integrações

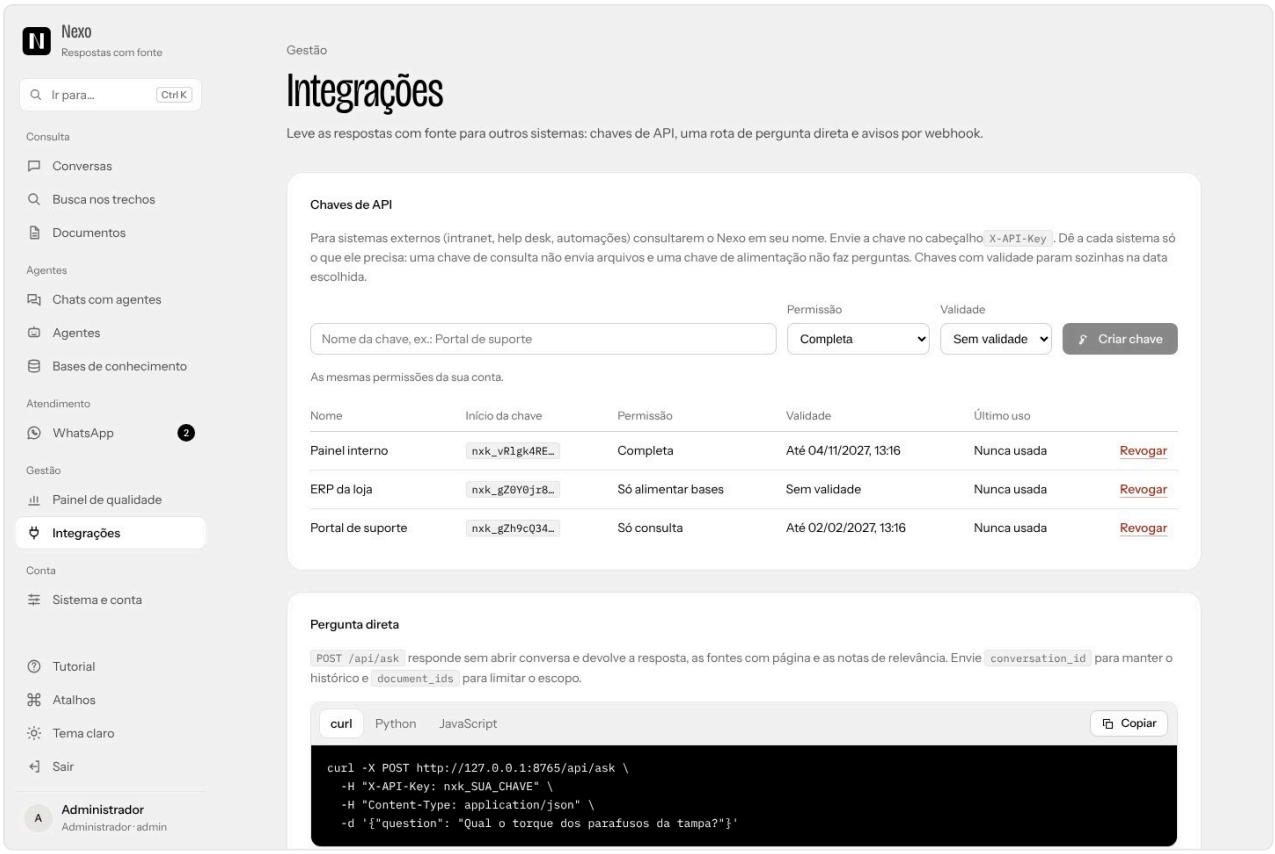


Figura 4.23 Integrações: chaves de API do usuário, a pergunta direta com exemplos em curl, Python e JavaScript e, para administradores, os webhooks.

Criar uma chave de API

1. Abra **Integrações** e, em **Chaves de API**, escreva um nome que diga onde a chave será usada.
2. Escolha a **Permissão** Novo: **Completa** (tudo o que a conta pode), **Só consulta** (perguntar e buscar) ou **Só alimentar bases** (enviar arquivos, textos e links). Escolha também a **Validade**: sem validade, 30, 90 ou 365 dias.
3. Clique em **Criar chave** e copie a chave exibida. Ela começa com `nxk_` e aparece uma única vez.
4. Guarde a chave no cofre de segredos do sistema que vai usá-la e teste com um dos exemplos de **Pergunta direta**.

Cadastrar um webhook (administrador)

1. Na seção **Webhooks**, informe a URL `http` ou `https` que vai receber os avisos.
2. Em **Avisar quando**, marque ao menos um evento, inclusive Mensagem recebida no WhatsApp e Cliente aguardando atendente, e clique em **Adicionar webhook**.
3. Copie o segredo de assinatura exibido (ele aparece uma única vez) e clique em **Testar**.

Cada webhook mostra o resultado da última entrega. Falhas passageiras são repetidas sozinhas, até três tentativas por evento (seção 5.5).

Copyright (©) 2026 Erik Pimenta

A tabela de chaves mostra a permissão, a validade e se a chave venceu. Para administradores, o quadro **Monitoramento** Novo traz a rota de métricas do Prometheus e o link da documentação interativa da API.

Copyright (©) 2026 Erik Pimenta

4.12 Sistema e conta

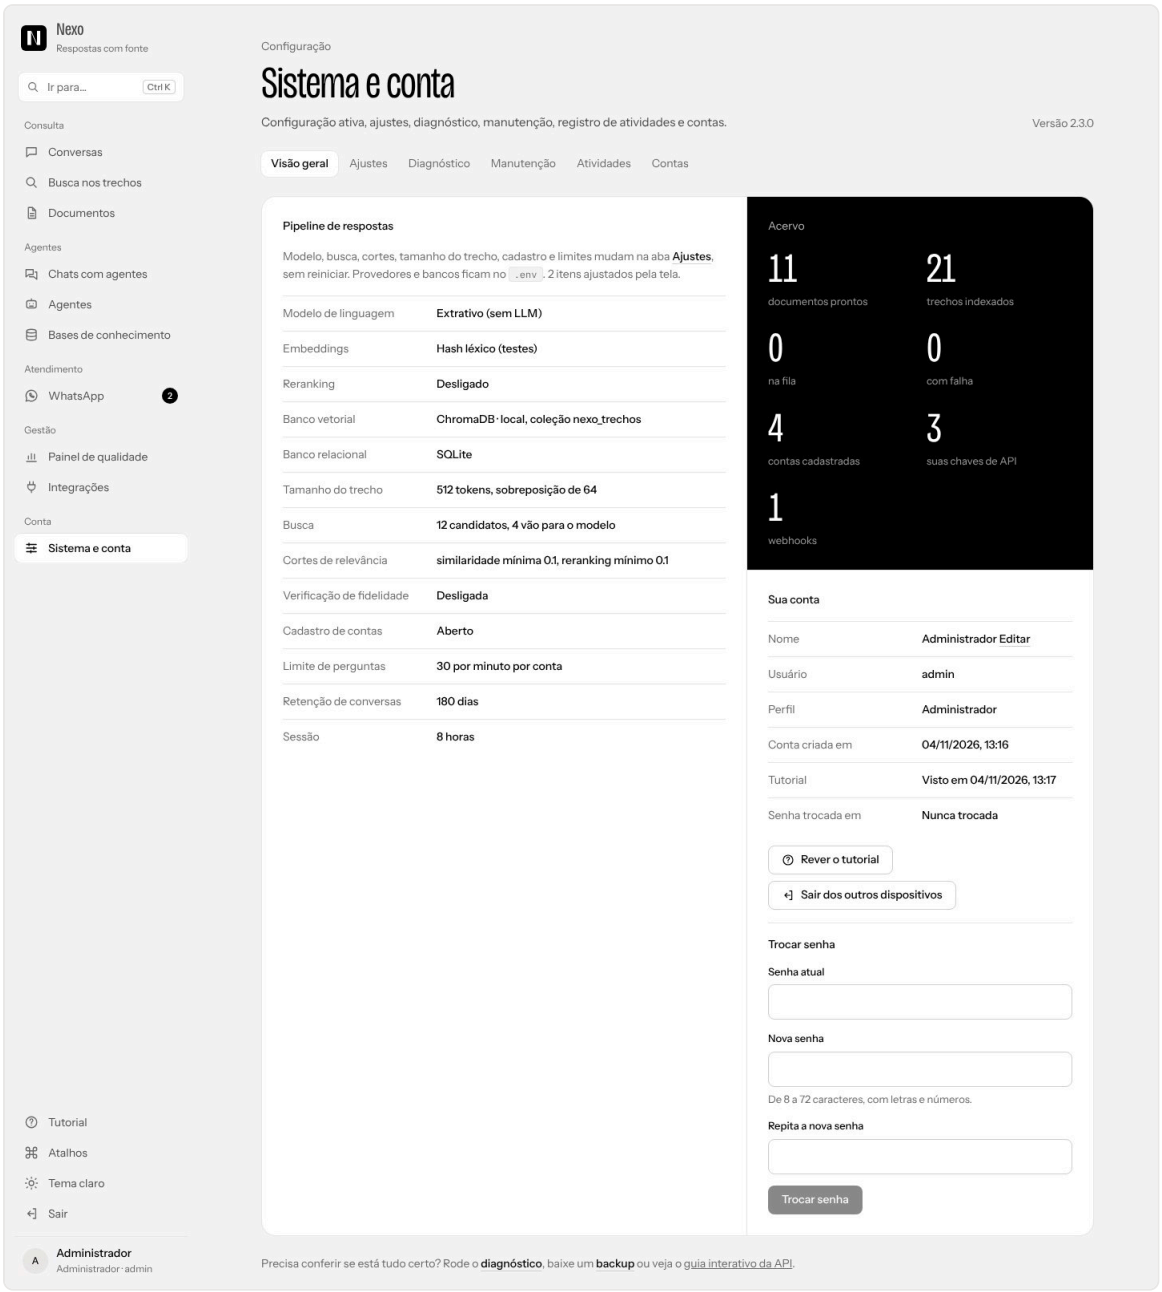


Figura 4.24 Sistema e conta, aba Visão geral: o pipeline de respostas com os provedores em uso, o acervo na tampa preta e a conta com a troca de senha e Sair dos outros dispositivos.

A tela tem abas **Novo**. **Visão geral** fica para todos; **Ajustes**, **Diagnóstico**, **Manutenção**, **Atividades** e **Contas** aparecem só para administradores. O endereço guarda a aba (`/sistema?aba=ajustes`), e a paleta de comandos leva direto a cada uma. Na Visão geral, o pipeline de respostas aparece na ordem em que a pergunta passa por ele, com os parâmetros de busca, e a tampa preta resume o acervo.

Sua conta

- **Nome**: cada pessoa troca o próprio nome de exibição (`PATCH /api/auth/me`). O nome de usuário não muda.

- **Trocar senha:** pede a senha atual e a nova, que precisa ser diferente da atual. Ao trocar, todas as outras sessões da conta são encerradas; esta aba continua conectada com uma sessão nova.
- **Sair dos outros dispositivos**: encerra as sessões abertas em outros navegadores e computadores sem trocar a senha. Útil depois de usar um computador compartilhado.
- **Senha trocada em** mostra a data da última troca ou redefinição da senha.
- **Ver tutorial** abre de novo o tutorial de primeiro acesso.

Contas (administrador)

- **Nova conta**: nome, usuário, senha e perfil. Funciona mesmo com o cadastro aberto desligado.
- **Redefinir senha**: define uma senha nova para a conta, encerra todas as sessões dela e libera o bloqueio por senhas erradas.
- Promover, rebaixar e excluir contas. Ninguém rebaixa nem exclui a própria conta, e o último administrador não pode ser rebaixado.

Ajustes Novo

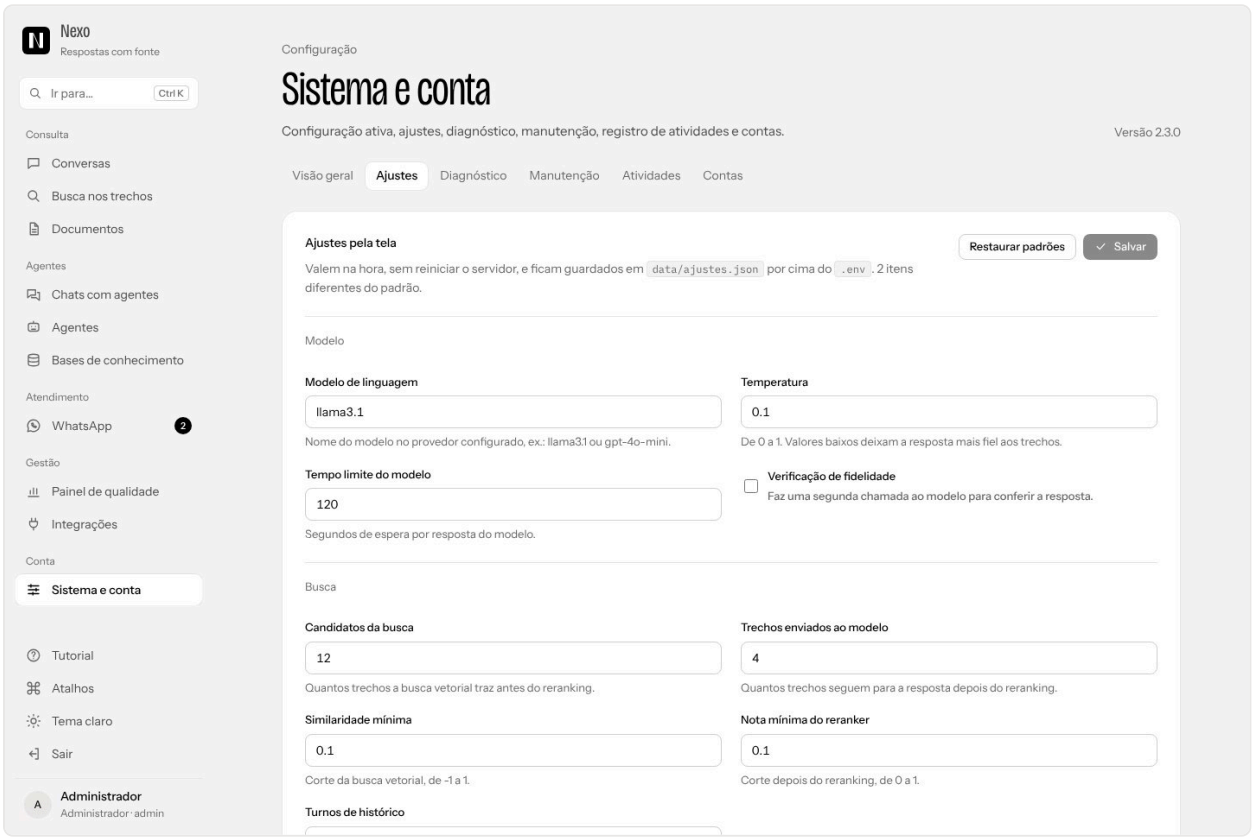


Figura 4.25 Aba Ajustes: modelo, busca, indexação, acesso e manutenção, com Salvar e Restaurar padrões.

Muda os parâmetros do pipeline e do acesso com o servidor no ar. Os campos e as regras estão na seção 3.6. **Salvar** só fica ativo quando algo mudou; um erro de validação aparece no próprio campo.

Copyright (©) 2026 Erik Pimenta

Diagnóstico Novo

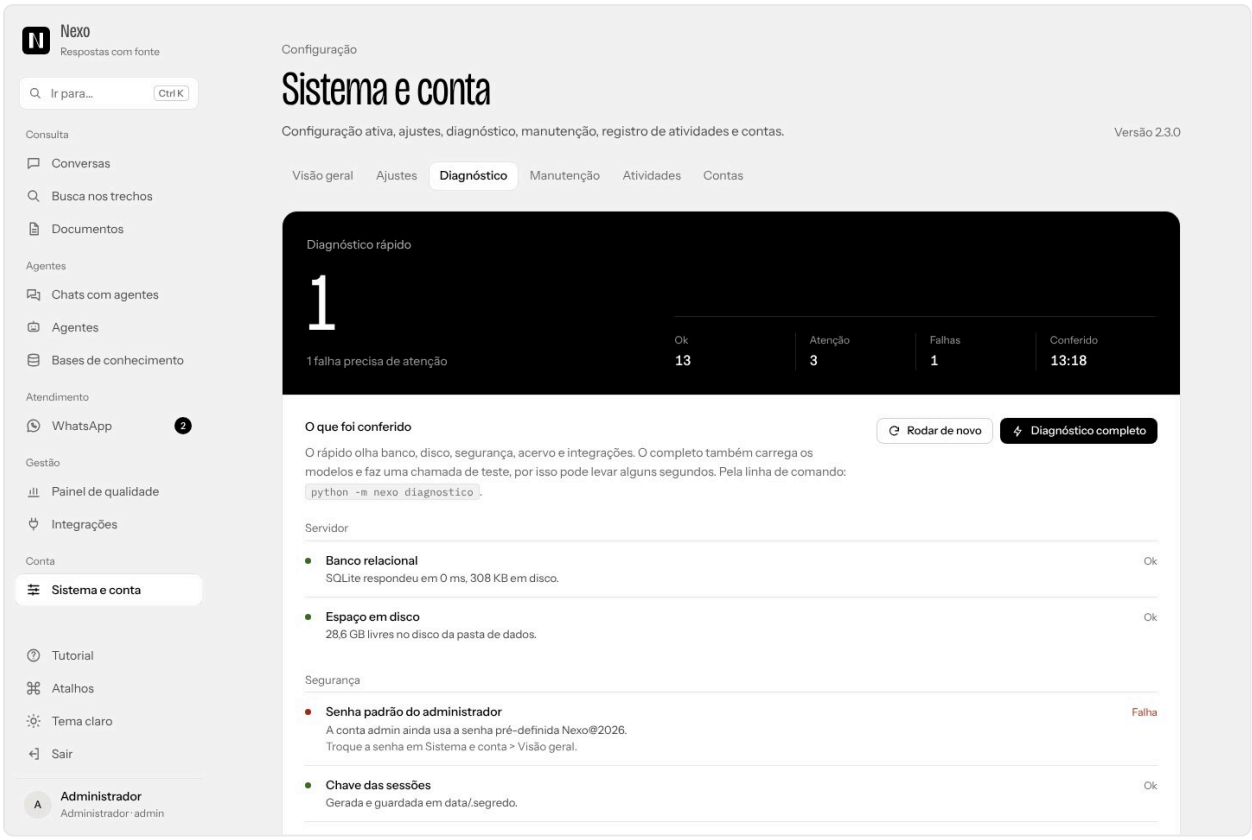


Figura 4.26 Aba Diagnóstico: o resumo na tampa preta e cada verificação com o que fazer.

O **diagnóstico rápido** roda ao abrir a aba e confere, em grupos: o servidor (banco relacional, espaço em disco), a segurança (senha padrão do administrador, segredo das sessões, cadastro aberto, CORS), os modelos (provedor e pacotes instalados), o acervo (documentos com falha, presos na fila, desatualizados, arquivos ausentes e trechos no banco vetorial), as integrações (webhooks falhando, conexões do WhatsApp) e a manutenção (backup e retenção). Cada aviso traz a orientação do que fazer. O **diagnóstico completo** também carrega o modelo de embeddings e faz uma chamada de teste ao modelo de linguagem, por isso leva mais tempo.

Copyright (©) 2026 Erik Pimenta

Manutenção Novo

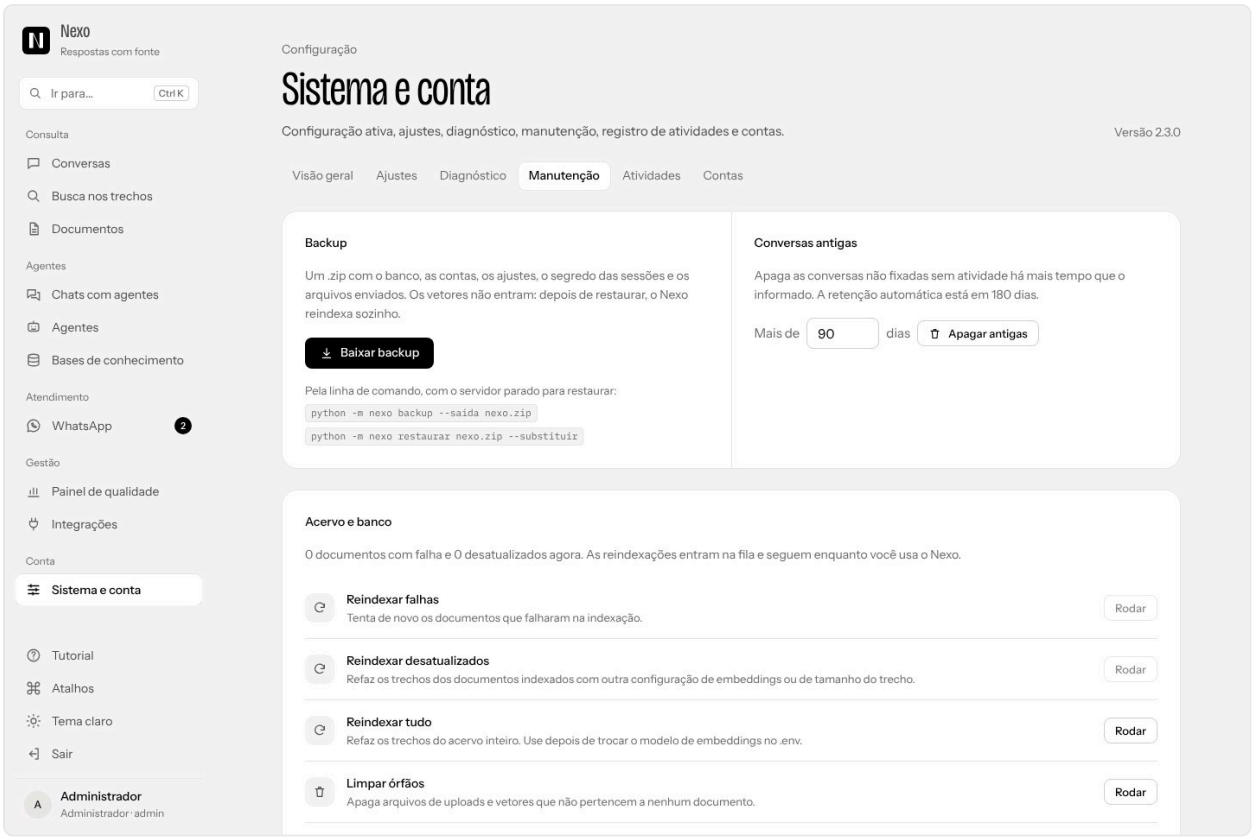


Figura 4.27 Aba Manutenção: backup, conversas antigas e as ações sobre o acervo e o banco.

Ação	O que faz
Baixar backup	Um .zip com o banco SQLite, as contas, os ajustes, o segredo das sessões e os arquivos enviados (seção 10.5)
Apagar conversas antigas	Apaga as conversas não fixadas sem atividade há mais dias que o informado
Reindexar falhas	Coloca de novo na fila os itens que falharam
Reindexar desatualizados	Reindexa só os itens indexados com outra configuração de embeddings ou de trecho
Reindexar tudo	Reindexa o acervo inteiro, por exemplo depois de trocar o modelo de embeddings
Limpar órfãos	Apaga arquivos em `data/uploads` e vetores que não pertencem a nenhum item
Compactar o banco	VACUUM e checkpoint do SQLite, com o tamanho antes e depois

As reindexações entram na fila e seguem enquanto você usa o Nexo. Cada ação mostra o resultado na tela e entra no registro de atividades.

Copyright (©) 2026 Erik Pimenta

Atividades Novo

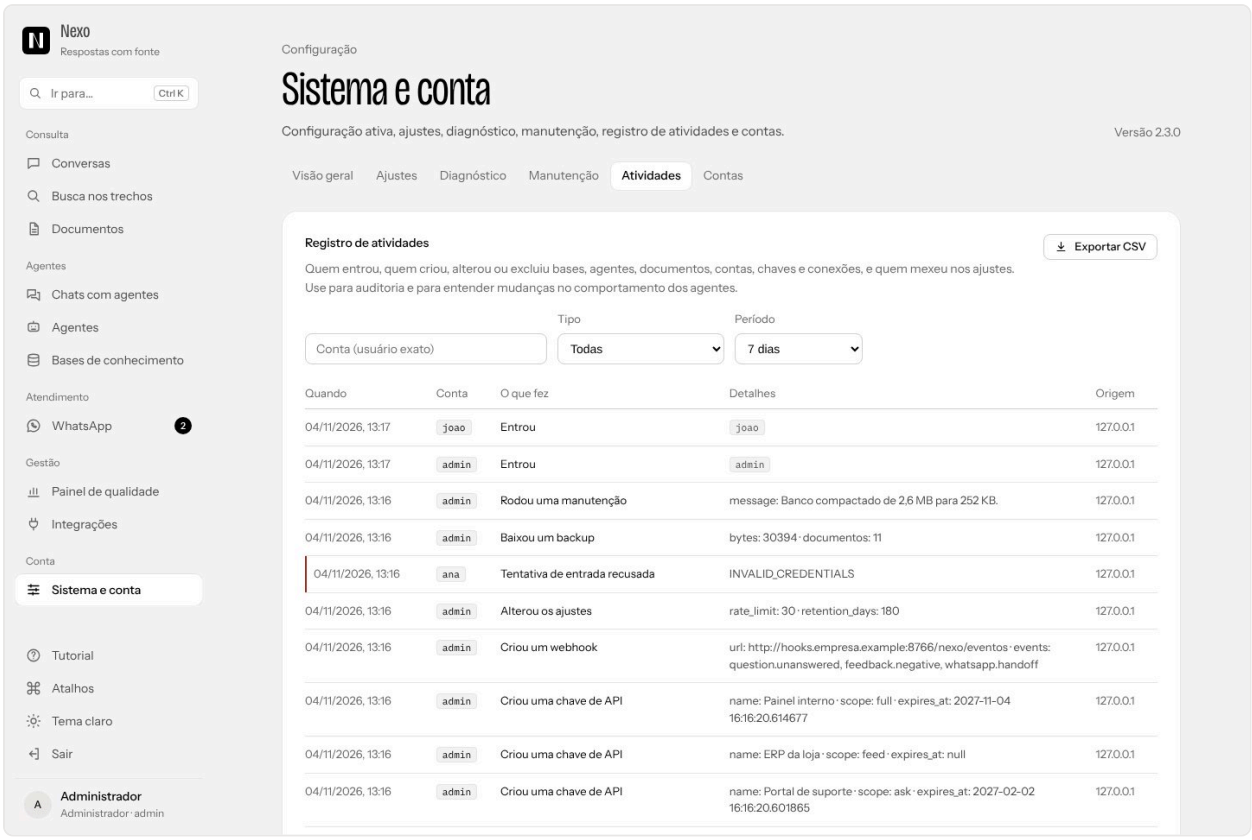


Figura 4.28 Aba Atividades: quem fez o quê, quando, com os detalhes e o IP de origem.

O registro de atividades guarda entradas e tentativas falhas, cadastros, trocas e redefinições de senha, e a criação, alteração e exclusão de bases, textos, documentos, agentes, chaves, webhooks, conexões do WhatsApp, respostas prontas, contas e ajustes, além das manutenções e backups. Filtre por conta, tipo e período (1, 7, 30 ou 90 dias) e use **Exportar CSV** para guardar ou auditar fora do Nexo. Senhas, chaves e segredos nunca entram nos detalhes.

Copyright (©) 2026 Erik Pimenta

4.13 Paleta de comandos e atalhos

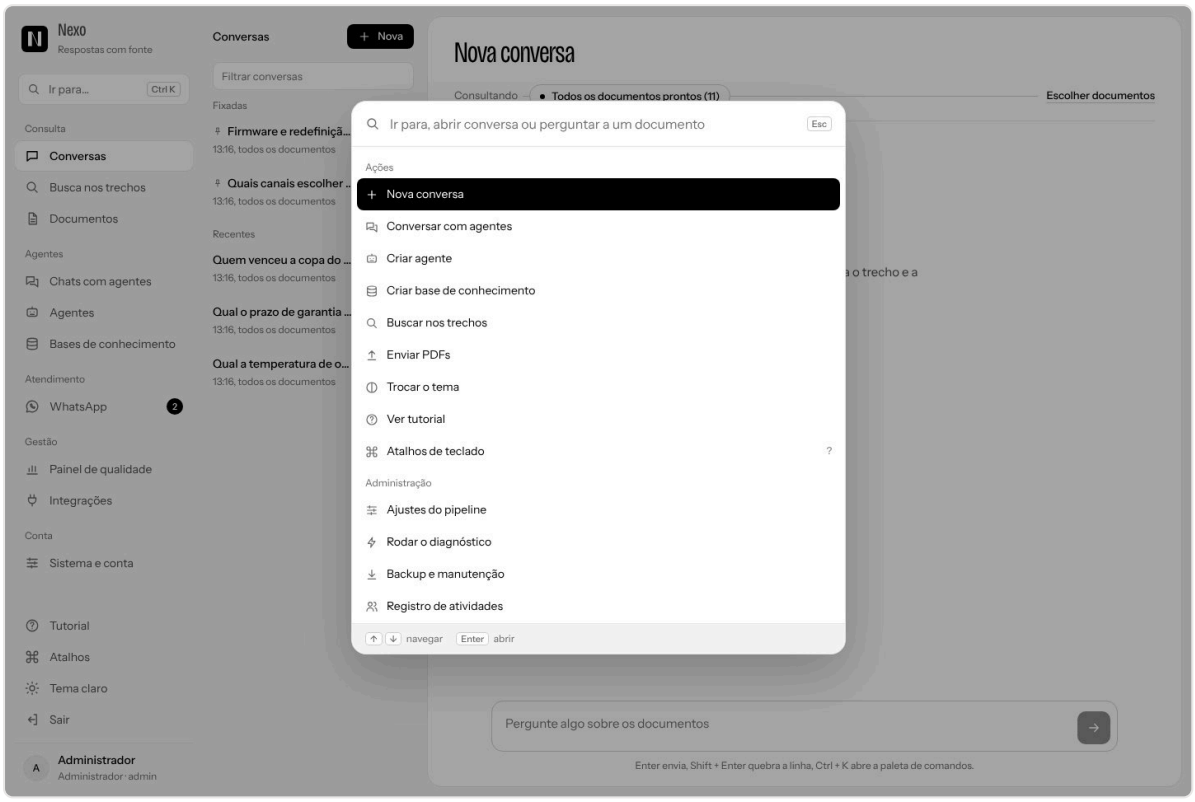


Figura 4.29 Paleta de comandos aberta com Ctrl + K.

Clique em **Ir para...** ou tecle `Ctrl + K` em qualquer tela, escreva parte do nome do que procura e tecle `Enter`. A paleta leva a qualquer tela, abre conversas e executa ações como nova conversa, criar agente, criar base, abrir o WhatsApp, trocar o tema e ver o tutorial.

Copyright (©) 2026 Erik Pimenta

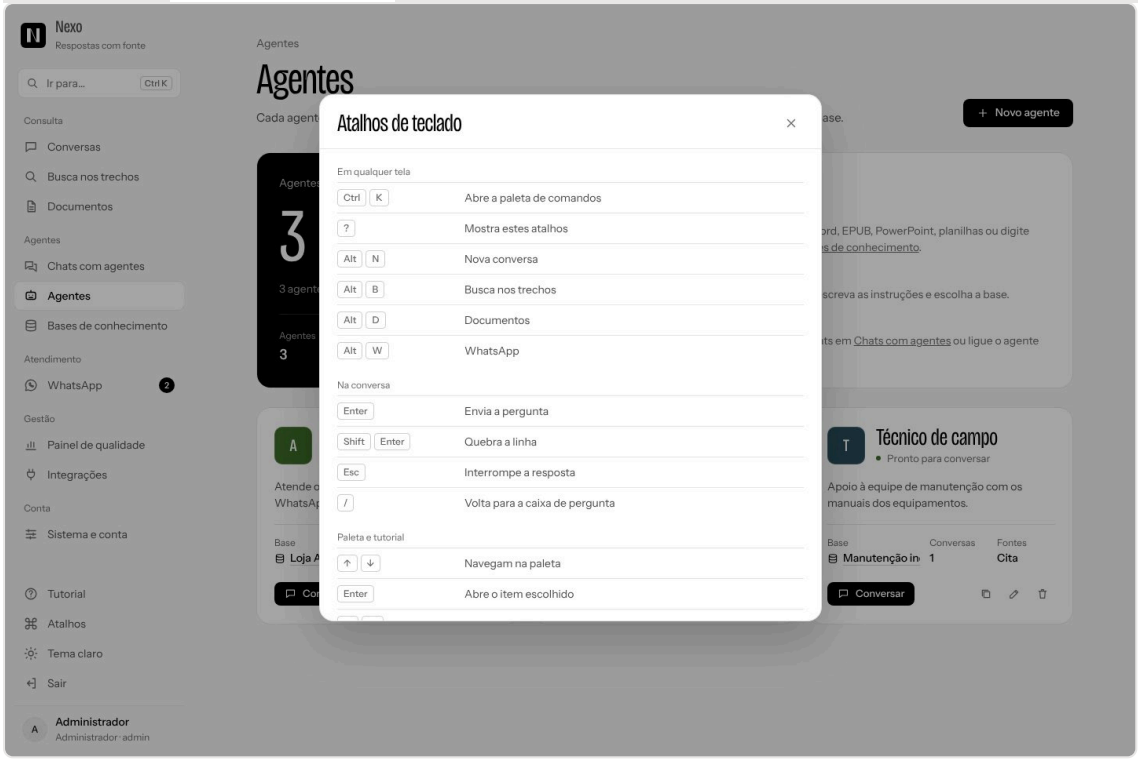


Figura 4.30 Lista de atalhos, aberta com a tecla ? ou pelo botão Atalhos do menu.

Atalho	O que faz
`Ctrl + K`	Abre a paleta de comandos
`?` **Novo**	Mostra a lista de atalhos
`Alt + N` / `Alt + B` **Novo**	Nova conversa / Busca nos trechos
`Alt + D` / `Alt + W` **Novo**	Documentos / WhatsApp
`/` **Novo**	Na conversa, volta para a caixa de pergunta; no WhatsApp, no começo da caixa, abre as respostas prontas
Setas e `Enter`	Escolhem e executam um comando da paleta; no tutorial, as setas avançam e voltam
`Esc`	Fecha a paleta ou o tutorial e interrompe a resposta que está sendo escrita
`Enter`	Envia a pergunta, a mensagem do WhatsApp e a busca
`Shift + Enter`	Quebra a linha

Copyright (©) 2026 Erik Pimenta

4.14 Tema e celular

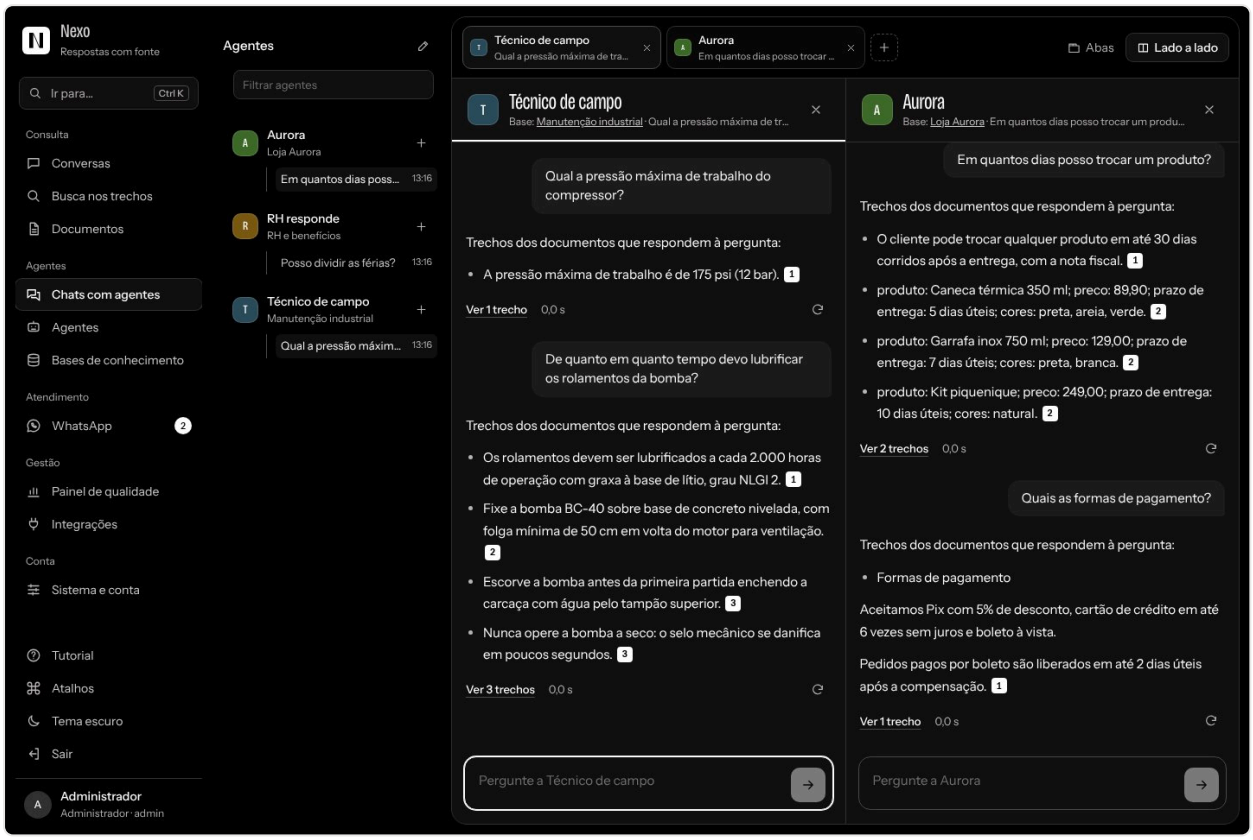


Figura 4.31 Tema escuro: os mesmos materiais da caixa única em tons escuros.

Copyright (©) 2026 Erik Pimenta

O botão de tema no rodapé do menu alterna **Tema claro**, **Tema escuro** e **Tema automático**. No celular, o menu recolhe para o botão no topo, as listas abrem por botões e as colunas viram uma só. Na tela Chats com agentes, o modo lado a lado vira abas; na caixa do WhatsApp, a lista de contatos e a conversa se alternam.

As respostas ao vivo e os botões Parar e Refazer funcionam igual no celular.

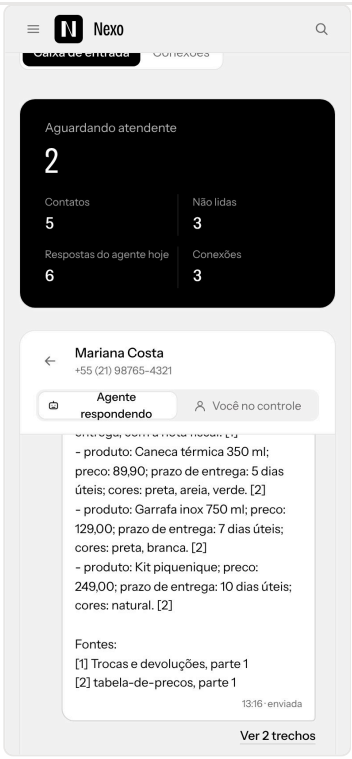


Figura 4.32 Conversa no celular, com o menu recolhido.

Copyright (©) 2026 Erik Pimenta

05

Integrações

Outros sistemas podem perguntar ao Nexo e aos agentes, alimentar as bases, buscar nos trechos e receber avisos. Este capítulo mostra como autenticar com uma chave de API, como usar a pergunta direta, como receber respostas em streaming e como receber e conferir webhooks.

5.1 Autenticação por chave de API

Toda rota que aceita a sessão da interface também aceita uma chave de API. Envie a chave num destes cabeçalhos:

```
X-API-Key: nxk_Q2x5...                  # recomendado
Authorization: Bearer nxk_Q2x5...       # alternativa, para clientes que só enviam Bearer
```

- A chave age em nome de quem a criou, limitada pela permissão escolhida ao criá-la.
- Formato: `nxk_` seguido de 43 caracteres. O prefixo (12 primeiros caracteres) identifica a chave nas telas sem expô-la.
- O Nexo guarda só o hash SHA-256 da chave. Se ela se perder, revogue e crie outra.
- Chave inválida ou revogada recebe 401 `INVALID_API_KEY`; chave vencida, 401 `API_KEY_EXPIRED`. Encerrar as sessões da conta não afeta as chaves de API.

Permissão e validade Novo

Permissão	`scope`	O que a chave pode fazer
Completa	`full`	Tudo o que a conta pode fazer, inclusive as rotas de administrador se a conta for administradora
Só consulta	`ask`	Perguntar (`/api/ask` , conversas e streaming), buscar nos trechos e ler bases, agentes e formatos
Só alimentar bases	`feed`	Listar bases, enviar arquivos, criar e editar textos, importar e atualizar links

Fora do que a permissão libera, a resposta é 403 `KEY_SCOPE`. Uma chave restrita nunca age como administrador nem cria outras chaves. Na criação, `expires_days` (1 a 3650) define a validade; sem ele, a chave não vence.

Copyright (©) 2026 Erik Pimenta

Limite de perguntas Novo

Cada conta pode fazer até `NEXO_RATE_LIMIT` perguntas e buscas por minuto (60 por padrão), somando a interface e as chaves. Acima disso, a resposta é 429 `RATE_LIMITED` com o cabeçalho `Retry-After` dizendo quantos segundos esperar. O administrador muda o limite em Ajustes; 0 desliga.

Chamadas pelo navegador (CORS) Novo

Um site em outro endereço só consegue chamar a API pelo navegador se estiver em `NEXO_CORS_ORIGINS`, por exemplo `https://portal.empresa.com.br,https://intranet.empresa.com.br`. Integrações de servidor para servidor não precisam disso.

5.2 Pergunta direta: /api/ask

Uma chamada, uma resposta com fontes. Sem `conversation_id`, nada é gravado. Com ele, o Nexo usa o histórico e grava a troca. Com `bot_id`, a pergunta vai para um agente: valem a base, as instruções, a saudação e a frase de quando não souber dele.

Campo do corpo	Tipo	Regra
`question`	texto	Obrigatório, 1 a 4000 caracteres
`bot_id`	id ou null	Opcional. Responde como o agente, só com a base dele
`document_ids`	lista de ids	Opcional. Vazio consulta todos os documentos prontos (ou a base do agente)
`conversation_id`	id ou null	Opcional. Conversa do próprio usuário cujo histórico será usado e onde a troca será gravada

curl

```
curl -X POST http://127.0.0.1:8000/api/ask \
  -H "X-API-Key: $NEXO_CHAVE" \
  -H "Content-Type: application/json" \
  -d '{"question": "Qual a temperatura de operação?", "bot_id": "ID_DO_AGENTE"}'
```

Resposta

```
{
  "answer": "A faixa de operação vai de 5 °C a 40 °C [1].",
  "answered": true,
  "grounded": null,
  "model": "llama3.1",
  "latency_ms": 2140,
  "conversation_id": null,
  "sources": [
    { "rank": 1, "document_id": "3f2a…", "document_title": "Manual de exemplo",
      "page": 5, "similarity": 0.71, "rerank_score": 0.93, "kind": "pdf",
      "excerpt": "Temperatura de operação: 5 °C a 40 °C…" }
  ]
}
```

Copyright (©) 2026 Erik Pimenta

Python

```
import os
import requests

resp = requests.post(
    "http://127.0.0.1:8000/api/ask",
    headers={"X-API-Key": os.environ["NEXO_CHAVE"]},
    json={"question": "Como restaurar as configurações de fábrica?"},
    timeout=180,
)
resp.raise_for_status()
dados = resp.json()
print(dados["answer"])
for f in dados["sources"]:
    print(f"[{f['rank']}] {f['document_title']}, página {f['page']}")
```

JavaScript (Node.js 18+ ou navegador)

```
const resp = await fetch("http://127.0.0.1:8000/api/ask", {
  method: "POST",
  headers: { "X-API-Key": process.env.NEXO_CHAVE, "Content-Type": "application/json" },
  body: JSON.stringify({ question: "Como restaurar as configurações de fábrica?" }),
});
if (!resp.ok) throw new Error((await resp.json()).message);
const dados = await resp.json();
console.log(dados.answer);
```

5.3 Alimentando uma base pela API

Qualquer sistema pode acrescentar ou retirar informação de uma base. Os mesmos exemplos aparecem prontos, com os ids preenchidos, na aba Integrar da base. Os formatos aceitos são os da seção 4.6.

```
curl -X POST http://127.0.0.1:8000/api/bases/ID_DA_BASE/documents \
  -H "X-API-Key: $NEXO_CHAVE" \
  -F "files=@tabela-de-precos.xlsx" -F "files=@politica-de-trocas.docx"

curl -X POST http://127.0.0.1:8000/api/bases/ID_DA_BASE/texts \
  -H "X-API-Key: $NEXO_CHAVE" -H "Content-Type: application/json" \
  -d '{"title": "Horário de atendimento", "content": "Segunda a sexta, das 8h às 18h."}'

curl -X DELETE http://127.0.0.1:8000/api/documents/ID_DO_ITEM -H "X-API-Key: $NEXO_CHAVE"

curl -X POST http://127.0.0.1:8000/api/documents/bulk \
  -H "X-API-Key: $NEXO_CHAVE" -H "Content-Type: application/json" \
  -d '{"action": "move", "ids": ["ID_1", "ID_2"], "base_id": "ID_DA_BASE"}'
```

Em `/api/documents/bulk`, `action` é `reindex`, `delete` ou `move` (este com `base_id`). A ação vale só para os itens que a chave pode alterar; a resposta informa os itens aplicados e os pulados.

Copyright (©) 2026 Erik Pimenta

Importando uma página ou arquivo por link Novo

```
curl -X POST http://127.0.0.1:8000/api/bases/ID_DA_BASE/links \
  -H "X-API-Key: nxk_..." -H "Content-Type: application/json" \
  -d '{"url": "https://empresa.com.br/politica-de-trocas", "title": "Política de trocas"}'

curl -X POST http://127.0.0.1:8000/api/documents/ID_DO_ITEM/refetch -H "X-API-Key: nxk_..."
```

A primeira chamada cria o item e o coloca na fila. A segunda baixa de novo e devolve `changed: true` quando o conteúdo mudou (e o item vai para a fila) ou `false` quando está igual. Rede interna é recusada com 403 `PRIVATE_URL`; um endereço que não responde volta como 502 com `UNREACHABLE` ou `HTTP_ERROR`.

5.4 Busca pela API

```
curl -X POST http://127.0.0.1:8000/api/search \
  -H "X-API-Key: $NEXO_CHAVE" -H "Content-Type: application/json" \
  -d '{"query": "torque dos parafusos", "limit": 5, "rerank": true, "base_id": "ID_DA_BASE"}'
```

A resposta traz `query`, `took_ms` e `results`, cada um com `rank`, `document_id`, `document_title`, `page`, `similarity`, `rerank_score`, `kind` e `excerpt`. Sem documento pronto, devolve 409 `NO_DOCUMENTS`.

5.5 Webhooks

Webhooks avisam outro sistema quando algo acontece no Nexo. Só administradores cadastram webhooks.

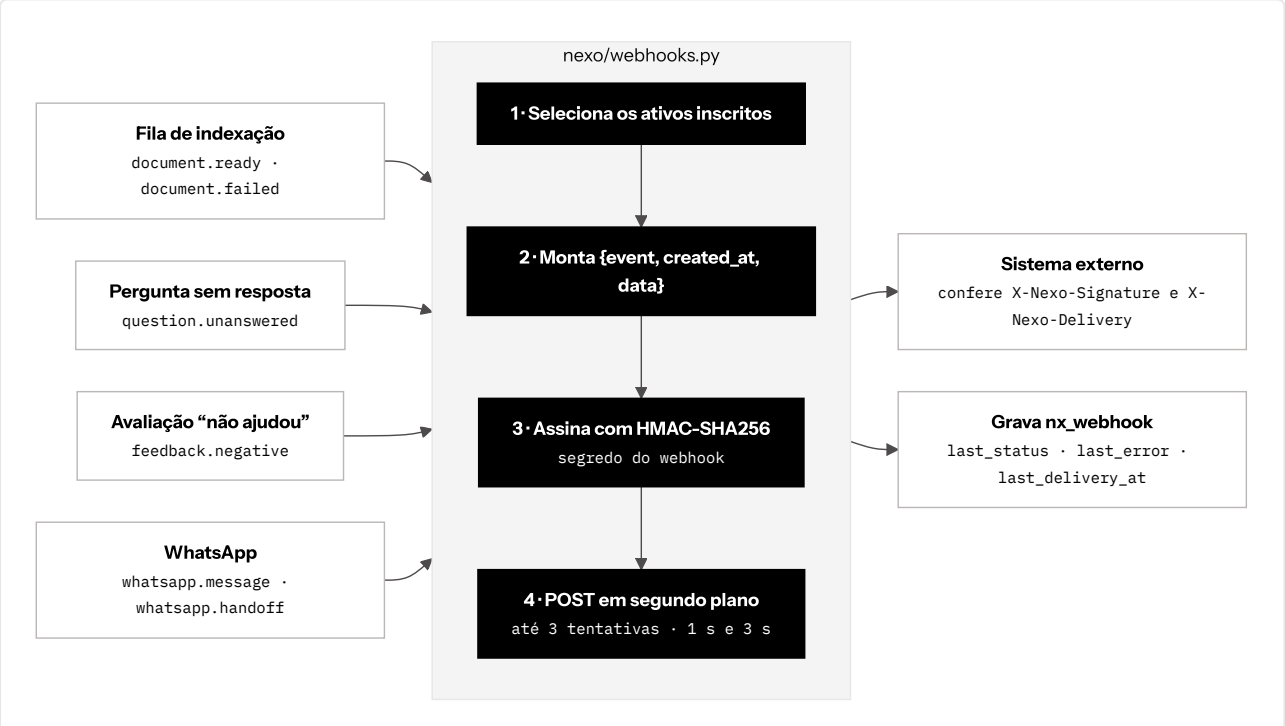


Figura 5.1 De onde vêm os eventos, o que o módulo de webhooks faz e onde o resultado de cada entrega é gravado.

Copyright (©) 2026 Erik Pimenta

Evento	Quando	Dados em data
`document.ready`	Um item termina de indexar	id, title, pages, chunks
`document.failed`	A indexação de um item falha	id, title, error
`question.unanswered`	Uma pergunta fica sem resposta, no chat ou em /api/ask	question, conversation_id, username
`feedback.negative`	Uma avaliação passa a ser "não ajudou"	message_id, question, answer, username
`whatsapp.message`	Chega uma mensagem de cliente no WhatsApp	channel_id, contact_id, phone, name, text
`whatsapp.handoff`	Um contato passa a aguardar atendente	channel_id, contact_id, phone, name, reason, text
`ping`	Botão Testar	Entrega de teste, síncrona

Formato da entrega

```
POST /recebe-nexo HTTP/1.1
Content-Type: application/json
User-Agent: Nexo/2.3.0
X-Nexo-Event: whatsapp.handoff
X-Nexo-Delivery: 7b0e4c2a9f1d4e8b8c3a5d6e7f809a1b
X-Nexo-Attempt: 1
X-Nexo-Signature: sha256=5d2b0c9e...

{"event": "whatsapp.handoff",
 "created_at": "2026-11-12T14:32:08+00:00",
 "data": {"channel_id": "9c1e…", "contact_id": "41ab…", "phone": "5521999990000",
          "name": "Cliente", "reason": "not_found", "text": "Vocês abrem no feriado?"}}
```

O receptor deve recalcular o HMAC sobre o corpo bruto, exatamente como chegou, e comparar em tempo constante.

Python

```
import hashlib
import hmac


def assinatura_valida(corpo: bytes, cabecalho: str, segredo: str) -> bool:
    esperado = "sha256=" + hmac.new(segredo.encode(), corpo, hashlib.sha256).hexdigest()
    return hmac.compare_digest(esperado, cabecalho or "")
```

Novas tentativas

Resultado da tentativa	O que o Nexo faz
Resposta 2xx	Entrega concluída; grava o status

Copyright (©) 2026 Erik Pimenta

Resultado da tentativa	O que o Nexo faz
Erro de rede, tempo esgotado, 5xx ou 429	Tenta de novo: a segunda tentativa sai 1 s depois, a terceira 3 s depois da segunda
Outros 3xx e 4xx	Não tenta de novo; o receptor recusou a entrega
Terceira tentativa sem sucesso	Desiste; o último status e o erro ficam no webhook

`X-Nexo-Delivery` é único por evento e se repete igual em todas as tentativas; `X-Nexo-Attempt` conta 1, 2 e 3. Use o primeiro para descartar repetições: o mesmo evento pode chegar duas vezes se o receptor gravou mas demorou a responder. O resultado da última tentativa aparece na tela Integrações.

Método	Rota	O que faz
`GET`	`/api/webhooks`	Lista os webhooks com eventos, situação e resultado da última entrega
`POST`	`/api/webhooks`	Cria. Corpo {"url", "events", "secret"}; sem secret, um é gerado
`PATCH`	`/api/webhooks/{id}`	Pausa ou reativa: {"active": false}
`DELETE`	`/api/webhooks/{id}`	Exclui
`POST`	`/api/webhooks/{id}/test`	Entrega ping na hora e devolve {"status", "error"}

5.6 Boas práticas

- Uma chave por sistema integrado, com nome claro, a menor permissão que resolve e uma validade. Revogar uma não derruba as outras.
- Trate o 429 esperando o tempo de `Retry-After` antes de tentar de novo.
- Responda ao webhook rápido e faça o trabalho pesado depois, numa fila do seu lado. Uma resposta lenta vira tempo esgotado e uma nova tentativa.
- Guarde os `X-Nexo-Delivery` já processados para ignorar repetições.
- Use HTTPS e confira a assinatura sempre, mesmo em rede interna.
- Use `question.unanswered` e `whatsapp.handoff` para abrir tarefas de curadoria das bases e avisar a equipe de atendimento.
- Registre o `X-Request-ID` de cada resposta do Nexo nos seus logs; ele localiza o pedido nos logs do servidor.

Monitorando com o Prometheus Novo

`GET /api/health/metrics` devolve, no formato de texto do Prometheus, pedidos e erros por rota, tempo de resposta, itens por situação, perguntas, fila de indexação e tempo no ar. A rota exige uma chave completa de um administrador:

Copyright (©) 2026 Erik Pimenta

```
scrape_configs:
  - job_name: nexo
    metrics_path: /api/health/metrics
    authorization: { type: Bearer, credentials: nxk_... }
    static_configs: [{ targets: ["nexo.empresa.com.br:8000"] }]
```

5.7 Exportação de conversas

O ícone de exportar no topo da conversa e a rota `GET /api/conversations/{id}/export` baixam a conversa inteira em `markdown` (padrão) ou `json`, com as fontes de cada resposta. Vale também para as conversas com agentes. Para as perguntas de um período em planilha, use o CSV do painel (seção 4.10).

5.8 Respostas em streaming

`POST /api/conversations/{id}/messages/stream` recebe o mesmo corpo de `POST /api/conversations/{id}/messages` e devolve `text/event-stream` (Server-Sent Events). A rota JSON antiga continua igual.

Evento	Dados	Quando
`status`	{"stage": "searching"} ou {"stage": "writing"}	Antes da busca e quando o modelo começa a escrever
`delta`	{"text": "…"}	Cada pedaço do texto da resposta, na ordem
`done`	{"question", "answer", "conversation"}	Fim: o mesmo JSON da rota sem streaming. Só aqui a troca está gravada
`error`	{"code", "message"}	Falha no meio do caminho; nada é gravado

curl

```
curl -N -X POST http://127.0.0.1:8000/api/conversations/ID_DA_CONVERSA/messages/stream \
  -H "X-API-Key: $NEXO_CHAVE" -H "Content-Type: application/json" \
  -d '{"question": "Qual a temperatura de operação?"}'

event: status
data: {"stage": "searching"}

event: status
data: {"stage": "writing"}

event: delta
data: {"text": "A faixa de operação vai de 5 °C"}

event: delta
data: {"text": " a 40 °C [1]."}

event: done
data: {"question": {...}, "answer": {...}, "conversation": {...}}
```

Copyright (©) 2026 Erik Pimenta

Fechar a conexão antes do `done` cancela a resposta, como o botão Parar: nada é gravado. Para gerar de novo uma resposta já gravada, use `POST /api/messages/{id}/regenerate` com o id da resposta.

Copyright (©) 2026 Erik Pimenta

06

WhatsApp

Conecte um número, escolha o agente que atende e acompanhe os clientes pela caixa de entrada. O Nexo fala com o WhatsApp por três provedores: a Evolution API, com o seu próprio número pelo QR code; a API oficial da Meta; e um simulador para testar sem número.

6.1 Escolhendo o provedor

Provedor	Como conecta	Quando usar
Evolution API	Servidor Evolution API v2 (seu ou contratado) e leitura de um QR code com o celular do número	Usar o seu próprio WhatsApp ou WhatsApp Business já existente, sem aprovação da Meta
API oficial (Meta)	WhatsApp Cloud API: Phone Number ID, token de acesso, app secret e webhook HTTPS	Operação oficial, com número verificado e regras da Meta
Simulador	Nada: as mensagens de cliente são simuladas pela tela	Testar o agente, a passagem para atendente e a caixa de entrada antes de ligar um número real

6.2 Conectando com a Evolution API (QR code)

1. Tenha um servidor Evolution API v2 no ar e crie nele uma instância (por exemplo `atendimento`). Anote o endereço do servidor e a chave de API.
2. No Nexo, abra **WhatsApp › Conexões** e clique em **Nova conexão**. Escolha **Evolution API**, dê um nome, informe **Endereço do servidor**, **Chave da API** e **Instância**, escolha o agente e salve.
3. Clique em **Mostrar QR code**. No celular, abra o WhatsApp › **Aparelhos conectados** › **Conectar um aparelho** e leia o código. A situação muda para **Conectado**.
4. Informe o endereço público do Nexo (ou defina `NEXO_PUBLIC_URL`) e clique em **Registrar webhook**. O Nexo chama `POST /webhook/set/{instância}` com o evento `MESSAGES_UPSERT` e a URL `…/api/whatsapp/webhook/{id}?token=…`.
5. Mande uma mensagem de outro celular para o número. Ela aparece na caixa de entrada e o agente responde.

Envio e QR code. O Nexo envia texto com `POST {servidor}/message/sendText/{instância}` (cabeçalho `apikey`), busca o QR em `GET /instance/connect/{instância}` e a situação em `GET /instance/connectionState/{instância}`. Mensagens de grupos são ignoradas.

Copyright (©) 2026 Erik Pimenta

6.3 Conectando com a API oficial da Meta

1. No painel de desenvolvedores da Meta, crie um app do tipo Business com o produto WhatsApp e anote o **Phone Number ID** do número, um **token de acesso** permanente (usuário do sistema) e o **app secret**.
2. No Nexo, crie a conexão com o provedor **API oficial (Meta)**, preencha esses campos, a versão da API (padrão `v24.0`), escolha o agente e salve. O Nexo gera um **verify token**.
3. Copie a URL do webhook mostrada na conexão (`https://seu-endereco/api/whatsapp/webhook/{id}`) e o verify token. No app da Meta, em **WhatsApp › Configuração › Webhook**, cole os dois e assine o campo **messages**.
4. A Meta confirma com um GET (`hub.mode`, `hub.verify_token`, `hub.challenge`); o Nexo responde o desafio quando o token confere.
5. Mande uma mensagem para o número de teste. O Nexo confere a assinatura `X-Hub-Signature-256` com o app secret e processa a mensagem.

Janela de 24 horas. Pela API oficial, respostas livres só podem ser enviadas até 24 horas depois da última mensagem do cliente. Fora dessa janela, a Meta só aceita modelos aprovados, que o Nexo não envia; a mensagem fica marcada como falhou com o erro devolvido.

6.4 Testando com o simulador

1. Crie uma conexão com o provedor **Simulador** e escolha o agente.
2. Na caixa de entrada, use **Simular mensagem de cliente**: informe um número, um nome e o texto, e envie.
3. O contato aparece como se tivesse escrito pelo WhatsApp, e o agente responde. Teste perguntas fora da base e a palavra "atendente" para ver a passagem para a equipe.

Copyright (©) 2026 Erik Pimenta

6.5 Como o atendimento funciona

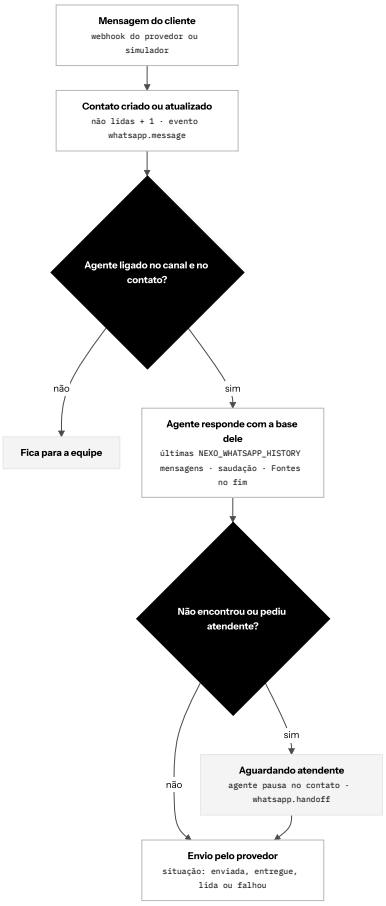


Figura 6.1 Caminho de uma mensagem de cliente até a resposta. A equipe pode assumir em qualquer ponto.

Situação	O que acontece
Cumprimento ("oi", "bom dia")	O agente responde com a saudação dele
Pergunta coberta pela base	Resposta com citações [n] e, se ligado no agente, "Fontes:" com documento e página
Pergunta fora da base	Envia a frase "quando não souber" do agente, marca aguardando atendente e pausa o agente no contato
Cliente pede atendente ou humano	Responde "Certo! Vou chamar uma pessoa da equipe...", marca aguardando atendente e pausa o agente
Mensagem enviada pelo celular do número	Com a Evolution API, entra na conversa como Pelo celular, sem acionar o agente
Confirmação de entrega (API oficial)	As situações sent, delivered, read e failed atualizam a mensagem na tela
Pessoa responde pela tela	Envia como a equipe e pausa o agente naquele contato
Devolver ao agente	Religa a resposta automática no contato

Copyright (©) 2026 Erik Pimenta

Situação	O que acontece
Mensagem que não é texto	Fica registrada como mídia; o agente não responde

6.6 Segurança

- Tokens, app secret e chaves da Evolution ficam no banco e nunca voltam inteiros pela API: a tela mostra só os quatro últimos caracteres. Deixar o campo vazio ao editar mantém o valor.
- Webhook da Meta: verify token na confirmação e assinatura `X-Hub-Signature-256` (HMAC-SHA256 do corpo bruto com o app secret) em cada entrega; assinatura errada recebe 401.
- Webhook da Evolution: a URL leva um token aleatório (`?token=…`) que o Nexo confere a cada entrega.
- Só administradores criam e alteram conexões. Todos os usuários conectados podem atender na caixa de entrada.

6.7 Solução de problemas

Sintoma	Causa provável	O que fazer
QR code não aparece	Endereço, chave ou instância da Evolution errados	Confira os campos e se o servidor responde; veja a mensagem da situação
Mensagens não chegam	Webhook não registrado ou endereço não público	Defina `NEXO_PUBLIC_URL` com HTTPS e clique em Registrar webhook (Evolution) ou confira o webhook no app da Meta
Meta recusa a verificação	Verify token diferente	Copie o verify token exibido na conexão
Entrega recebe 401	App secret errado na conexão	Copie de novo o app secret do app da Meta
Mensagem marcada como falhou	Token vencido ou fora da janela de 24 h	Gere um token permanente; fora da janela, só modelos aprovados
Agente não responde	Sem agente no canal, resposta automática desligada ou contato com a equipe	Escolha o agente, ligue a resposta automática e use Devolver ao agente

Copyright (©) 2026 Erik Pimenta

07

Arquitetura

O Nexo é um único processo Python que serve a API e a interface compilada. Os componentes pesados (modelos e banco vetorial) e o provedor de WhatsApp são plugáveis por configuração.

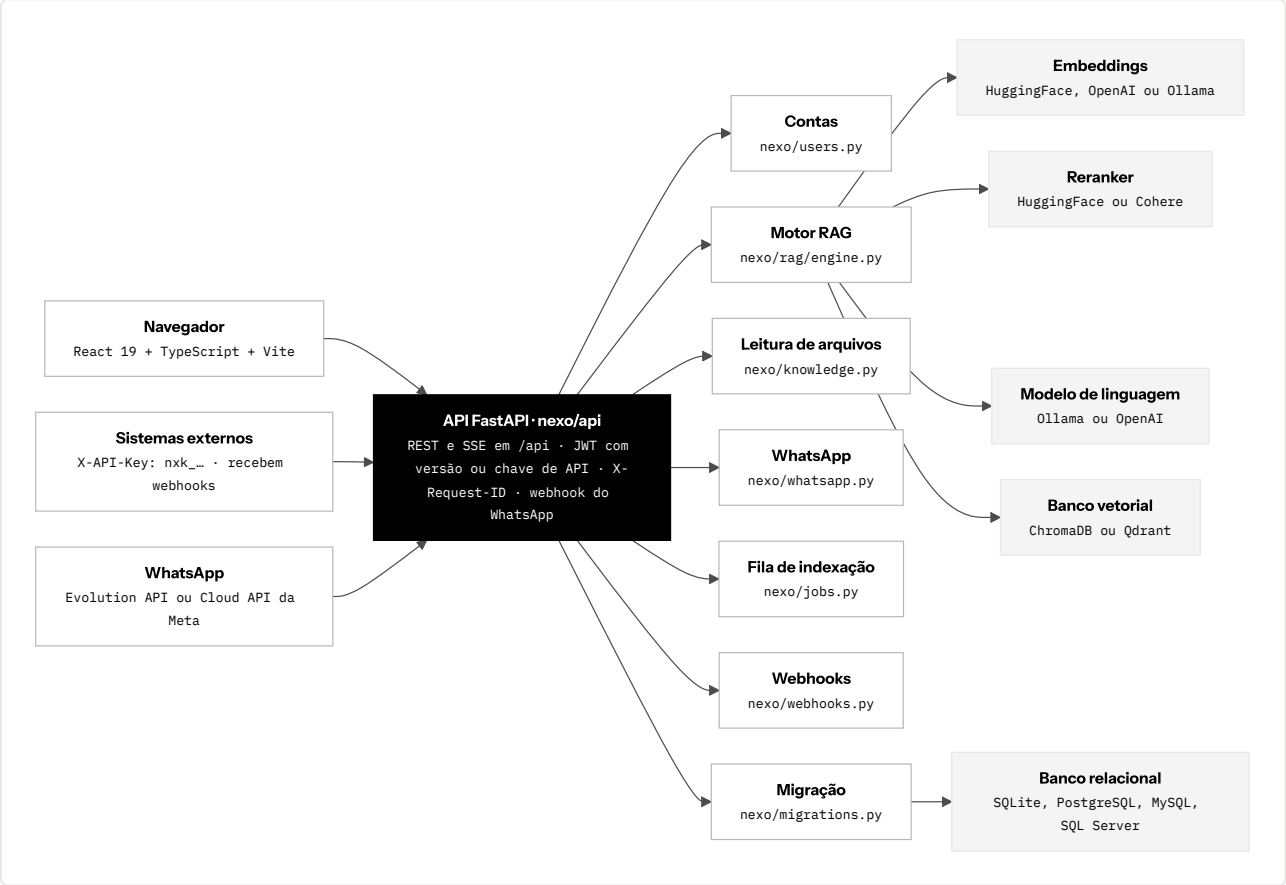


Figura 7.1 Componentes do Nexo 2.3. O WhatsApp entra pelo webhook público e sai pelo provedor configurado em cada conexão.

7.1 Módulos do código

Arquivo	Responsabilidade
`nexo/config.py`	Lê o .env com pydantic-settings e define os caminhos em data/
`nexo/db.py`	Modelos SQLAlchemy das tabelas, criação automática e sessões
`nexo/migrations.py`	Migração automática: bancos da 2.0 (base padrão e única de sha256 por base) e, desde a 2.3, qualquer coluna nova que falte

Copyright (©) 2026 Erik Pimenta

Arquivo	Responsabilidade
`nexo/runtime.py` Novo	Ajustes pela tela: validação, gravação em data/ajustes.json e aplicação sobre o .env
`nexo/maintenance.py` Novo	Diagnóstico, ações de manutenção, retenção automática, backup e restauração
`nexo/audit.py` Novo	Registro de atividades com a conta, a ação, o alvo, os detalhes e o IP
`nexo/links.py` Novo	Download de links com bloqueio da rede interna, checagem de cada redirecionamento e limite de tamanho
`nexo/sample.py` Novo	Criação da Base de teste e do Agente de teste a partir de exemplos/base-de-teste
`nexo/cli.py` Novo	Linha de comando `python -m nexo`: servir, diagnostico, backup, restaurar, reindexar, base-de-teste, contas e versao
`nexo/logs.py` / `nexo/context.py` Novo	Registros em texto ou JSON com o id do pedido, a conta e o IP
`nexo/knowledge.py`	Leitura de DOCX, ODT, EPUB, PPTX, XLSX, TXT, MD, CSV, JSON, HTML e textos em partes para indexar, com o limite de 50 MB por item dos pacotes zip
`nexo/whatsapp.py`	Provedores Evolution, Cloud e simulador, webhook, contatos, resposta do agente e passagem para atendente
`nexo/users.py`	Contas em JSON: cadastro, criação pelo administrador, autenticação, bloqueio, troca e redefinição de senha, versão da sessão, perfil, exclusão e tutorial visto
`nexo/security.py`	Tokens JWT (HS256) com a versão da sessão e chaves de API
`nexo/api/deps.py`	Identifica o usuário pelo token ou pela chave de API, confere a versão da sessão, o perfil, a permissão e a validade da chave e o limite de perguntas
`nexo/jobs.py`	Fila de indexação em uma thread, retomada de pendências e eventos document.*
`nexo/webhooks.py`	Seleciona os webhooks do evento, assina com HMAC e entrega em segundo plano, com até 3 tentativas
`nexo/rag/engine.py`	Divisão em trechos, indexação, busca, reranking, prompt do agente e resposta, inteira ou em pedaços para o streaming
`nexo/rag/providers.py`	Fábrica de LLM, embeddings, banco vetorial e reranker
`nexo/api/routes.py`	Rotas REST de autenticação, sessões, documentos e ações em lote, conversas, streaming, Refazer, busca, métricas e CSV, chaves, webhooks, contas e sistema
`nexo/api/agents.py`	Rotas de bases de conhecimento, textos, formatos e agentes
`nexo/api/whatsapp.py`	Rotas das conexões, do webhook público, dos contatos, das mensagens e das respostas prontas do WhatsApp
`nexo/api/system.py` Novo	Rotas de ajustes, diagnóstico, manutenção, backup, atividades e métricas do Prometheus

Copyright (©) 2026 Erik Pimenta

Arquivo	Responsabilidade
`frontend/src`	Interface React: páginas (Agents, Chats, Bases, WhatsApp e as da 2.0), componentes (Tutorial, paleta, trechos), cliente da API com leitura do streaming e temas

7.2 Indexação de um item

- O envio confere a extensão, o tamanho, o cabeçalho `%PDF` dos PDFs, o tamanho descompactado de cada item dos pacotes zip e o SHA-256 dentro da base; grava o arquivo em `data/uploads/<id>.<extensão>` e a linha em `nx_document` como PENDING.
- A fila lê o texto (pypdf para PDF, `nexo/knowledge.py` para os demais formatos e para os textos) em páginas ou partes.
- O SentenceSplitter do LlamaIndex divide em trechos de `NEXO_CHUNK_SIZE` tokens com sobreposição. Cada trecho guarda `source_id`, `title`, `filename`, `page` e `chunk_index`.
- Reindexar apaga os vetores antigos antes de gravar os novos. Ao terminar, a fila dispara `document.ready` ou `document.failed`.

Copyright (©) 2026 Erik Pimenta

7.3 Respondendo uma pergunta

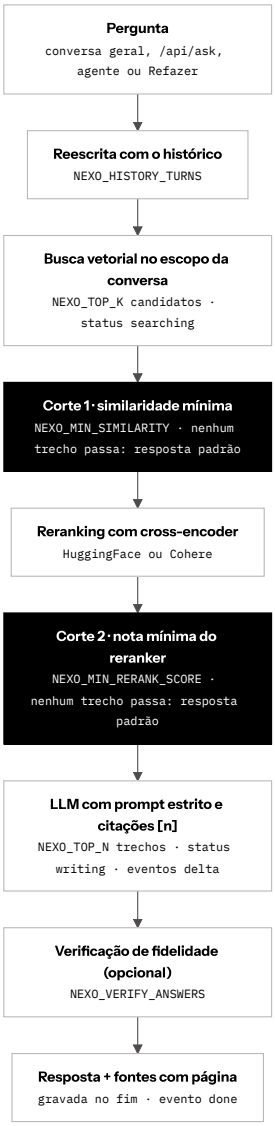


Figura 7.2 Os dois cortes de relevância, em destaque, decidem se o modelo de linguagem é chamado. A busca nos trechos para no reranking e devolve os candidatos sem passar pelo modelo.

Quando nenhum trecho passa pelos cortes, o modelo de linguagem não é chamado: a resposta padrão "Não encontrei essa informação nos documentos selecionados." é gravada com `answered = false`, os webhooks ativos recebem `question.unanswered` e a pergunta entra nas lacunas do painel. Numa conversa geral, o escopo é a lista de documentos escolhida (ou todo o acervo pronto); numa conversa com agente, é a base dele, como mostra a seção seguinte.

Streaming. Na rota `/messages/stream`, o mesmo caminho avisa `status` `searching` antes da busca e `writing` quando o modelo começa, manda o texto em eventos `delta` e só grava a troca no fim, no evento `done`. Se a conexão cair ou o usuário clicar em Parar, nada é gravado.

Copyright (©) 2026 Erik Pimenta

Refazer. `POST /api/messages/{id}/regenerate` roda o pipeline de novo com a pergunta original e só o histórico anterior a ela, e substitui a resposta no mesmo lugar da conversa: o texto, as fontes em `nx_message_source` e a avaliação anterior, que é apagada.

7.4 Como o agente responde

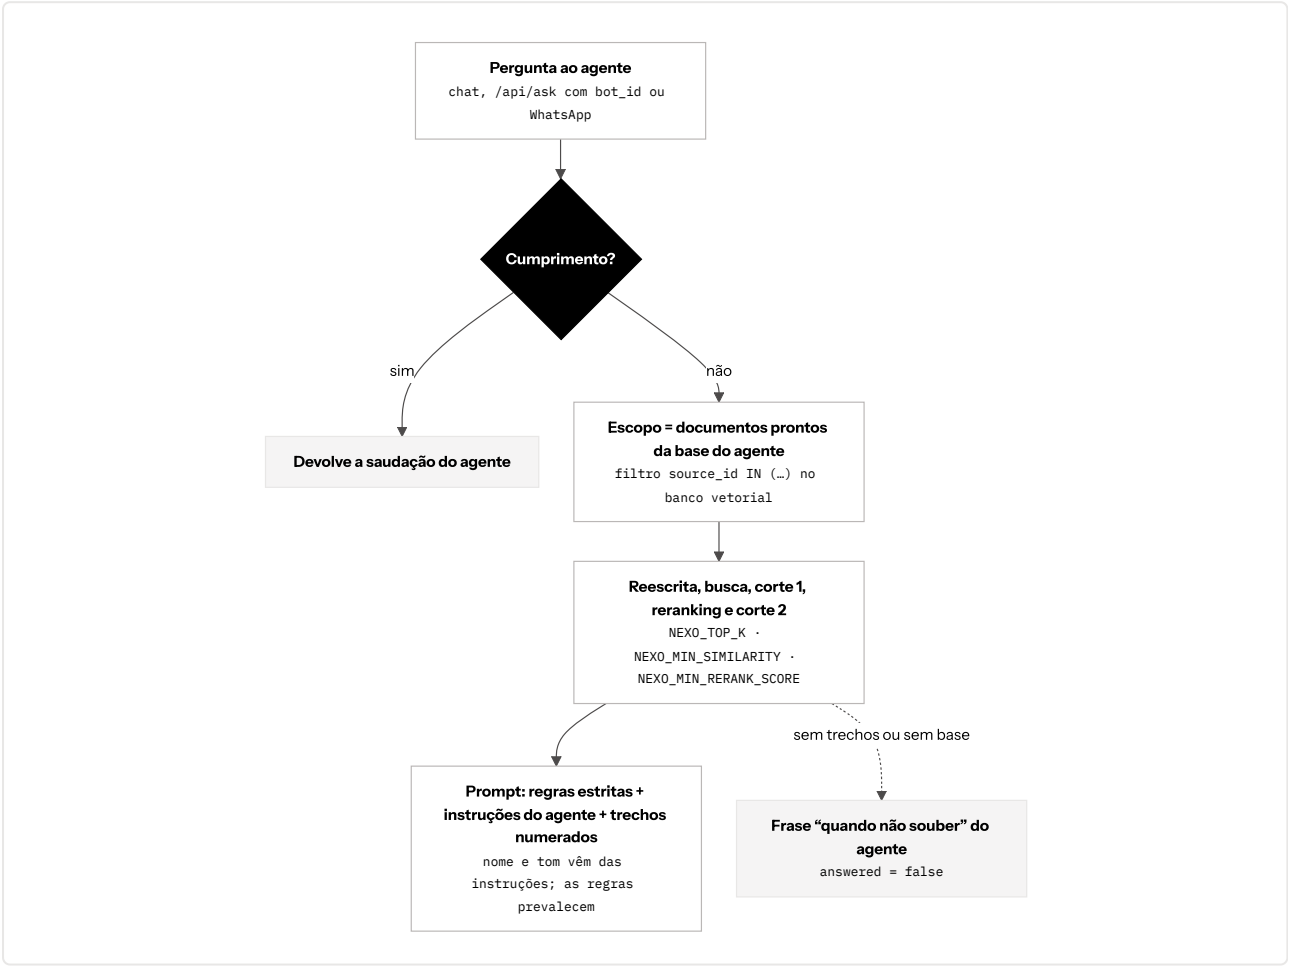


Figura 7.3 O agente usa o mesmo pipeline das conversas, limitado aos documentos da base dele.

A base não é uma coleção vetorial separada: todos os trechos ficam na mesma coleção, e a busca do agente filtra pelos ids dos documentos prontos da base dele. Por isso mover um item entre bases não exige reindexar, e uma base sem conteúdo pronto nunca cai na busca de todo o acervo: o Nexo avisa que a base ainda não tem conteúdo.

7.5 Como as alucinações são reduzidas

Mecanismo	Efeito
Cortes de similaridade e de reranking	Trechos fracos são descartados. Sem trechos, o LLM não é chamado
Reranking com cross-encoder	Reordena os candidatos por relevância real
Prompt estrito	Proíbe conhecimento próprio e exige citação [n]; as instruções do agente não podem mudar essas regras

Copyright (©) 2026 Erik Pimenta

Mecanismo	Efeito
Base por agente	Cada agente só enxerga os documentos da própria base, o que evita misturar assuntos
Temperatura 0,1	Respostas estáveis e próximas do texto
Verificação de fidelidade	Opcional: confere se a resposta é sustentada pelos trechos
Passagem para atendente	No WhatsApp, o que o agente não sabe vai para uma pessoa em vez de virar palpite
Painel de qualidade	Mostra lacunas e respostas mal avaliadas para corrigir as bases

7.6 Segurança

- Senhas só como hash bcrypt; cinco erros seguidos bloqueiam o usuário por 5 minutos. A senha nova precisa ser diferente da atual (`SAME_PASSWORD`).
- Sessões com JWT assinado por `NEXO_SECRET` ; a interface guarda o token só na aba aberta (`sessionStorage`).
- Cada token leva a versão da sessão da conta (`session_version`). Trocar a senha, Sair dos outros dispositivos e a redefinição pelo administrador sobem a versão, e os tokens antigos passam a receber 401 `SESSION_REVOKED` .
- Chaves de API só como hash SHA-256, exibidas uma vez e revogáveis, com permissão (completa, consulta ou alimentação) e validade opcionais.
- Limite de perguntas e buscas por minuto por conta (429 `RATE_LIMITED`) e CORS fechado por padrão.
- Importação de links sem acesso à rede interna: o endereço e cada redirecionamento são conferidos antes da conexão.
- Registro de atividades das ações sensíveis, com a conta e o IP, sem guardar senhas, chaves ou segredos.
- Webhooks assinados com HMAC-SHA256; cadastro restrito a administradores.
- Conexões do WhatsApp criadas só por administradores; segredos mascarados; webhook da Meta com assinatura e o da Evolution com token.
- Conversas visíveis apenas para o dono. Bases e agentes só são alterados por quem criou ou por um administrador; um item pode ser excluído por quem enviou, pelo dono da base ou por um administrador. As ações em lote seguem as mesmas regras, item a item.
- Envios validados pela extensão, pelo tamanho, pelo cabeçalho dos PDFs, pelo SHA-256 e, nos pacotes zip, pelo limite de 50 MB descompactados por item; nomes saneados e arquivos gravados com o id interno.
- Cabeçalhos `X-Content-Type-Options` , `X-Frame-Options` , `Referrer-Policy` e `Permissions-Policy` em todas as respostas; a API não é guardada em cache.
- Cada resposta leva `X-Request-ID` . Um id válido vindo do cliente ou do proxy é reaproveitado; sem ele, o Nexo gera um.

Copyright (©) 2026 Erik Pimenta

08

Banco de dados

Resumo da estrutura dos dados. As tabelas são criadas e migradas automaticamente; a versão detalhada, com índices, restrições, decisões e consultas, está em Banco-de-Dados-Nexo.pdf.

8.1 Onde cada dado fica

Camada	Local padrão	Conteúdo
Banco relacional	`data/nexo.db`	Bases, documentos, agentes, conversas, mensagens, fontes, avaliações, chaves, webhooks, WhatsApp, respostas prontas e o registro de atividades
Ajustes **Novo**	`data/ajustes.json`	Valores alterados pela tela Ajustes, por cima do .env
Banco vetorial	`data/chroma/` ou `data/qdrant/`	Trechos, embeddings e metadados de origem
Arquivos	`data/uploads/<id>.<extensão>`	Arquivos originais enviados às bases
Contas	`data/usuarios.json`	Usuários, perfis, hashes de senha, versão da sessão e tutorial visto
Segredo	`data/.segredo`	Chave das sessões quando NEXO_SECRET está vazio

Copyright (©) 2026 Erik Pimenta

8.2 Diagrama de relacionamentos

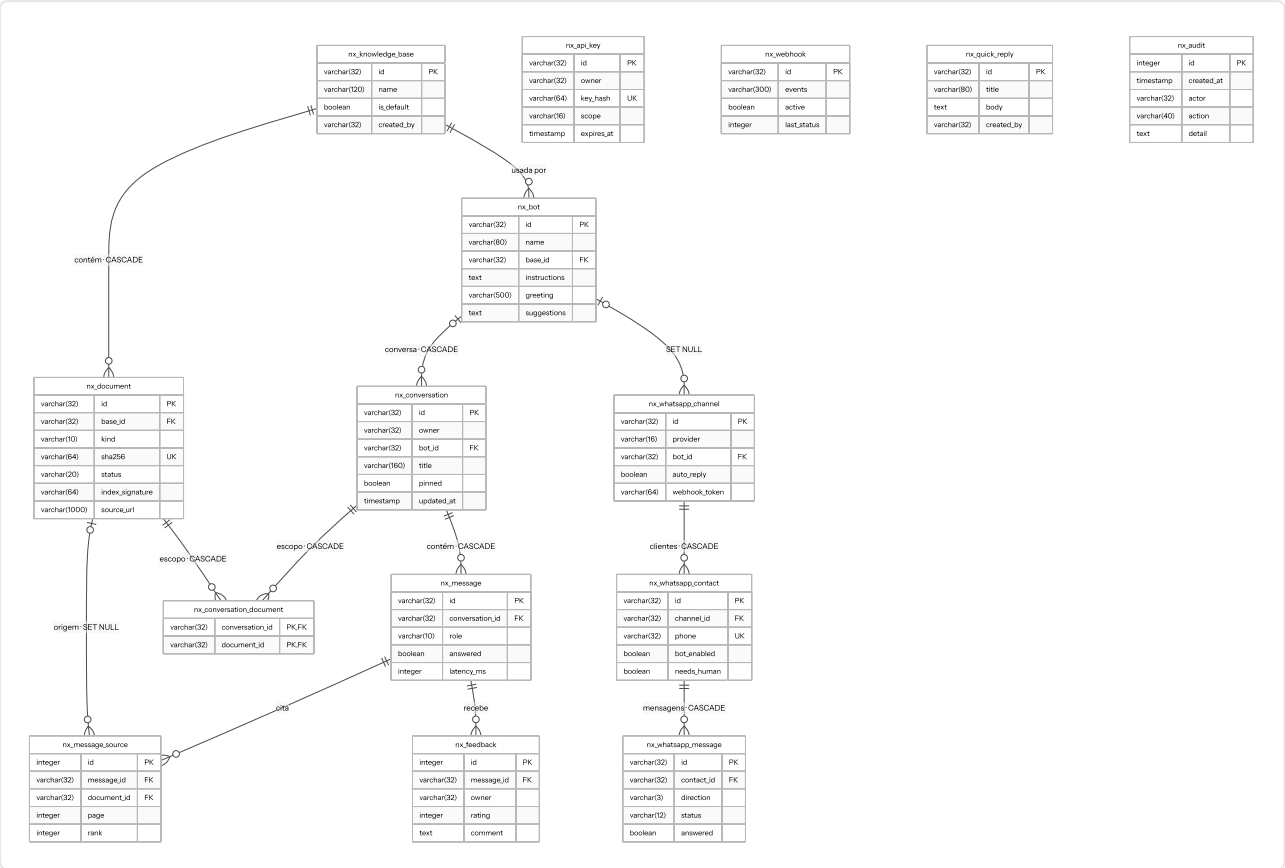


Figura 8.1 As tabelas do Nexo. `nx_api_key`, `nx_webhook`, `nx_quick_reply` e `nx_audit` se ligam às contas pelo nome de usuário, sem chave estrangeira.

8.3 Tabelas

Tabela	Uma linha por	Ligações
`nx_knowledge_base`	Base de conhecimento	Pai de nx_document (CASCADE) e de nx_bot
`nx_document`	Arquivo ou texto de uma base	base_id para nx_knowledge_base; único (base_id, sha256)
`nx_bot`	Agente	base_id para nx_knowledge_base; pai das conversas do agente (CASCADE)
`nx_conversation`	Conversa	bot_id para nx_bot (CASCADE), nulo nas conversas gerais
`nx_conversation_document`	Documento no escopo de uma conversa	CASCADE dos dois lados
`nx_message` / `nx_message_source` / `nx_feedback`	Mensagem, trecho citado, avaliação	Refazer troca a resposta, as fontes e apaga as avaliações dela

Copyright (©) 2026 Erik Pimenta

Tabela	Uma linha por	Ligações
`nx_api_key` / `nx_webhook`	Chave de API (com scope e expires_at), webhook	Pelo nome de usuário, sem chave estrangeira
`nx_quick_reply` Novo	Resposta pronta do WhatsApp	created_by pelo nome de usuário; títulos repetidos recusados pela API
`nx_audit` Novo	Atividade registrada	actor pelo nome de usuário; índices por data, conta e ação
`nx_whatsapp_channel`	Número conectado	bot_id para nx_bot (SET NULL)
`nx_whatsapp_contact`	Cliente de um número	channel_id (CASCADE); único (channel_id, phone)
`nx_whatsapp_message`	Mensagem recebida ou enviada	contact_id (CASCADE)

8.4 Coleção vetorial

Campo	Conteúdo
`id`	UUID v5 calculado de documento + posição do trecho
`embedding`	Vetor do modelo de NEXO_EMBED_MODEL, distância de cosseno
`document`	Texto do trecho
`metadata.source_id`	nx_document.id de origem; usado nos filtros de escopo, no filtro da base de cada agente e na exclusão
`metadata.title` / `filename` / `page` / `chunk_index`	Título, nome do arquivo, página ou parte (a partir de 1) e posição do trecho

8.5 Arquivo de usuários

```
{
  "versao": 1,
  "usuarios": [
    { "username": "admin", "name": "Administrador", "role": "admin",
      "password_hash": "$2b$12$...", "created_at": "2026-01-01T12:00:00+00:00",
      "last_login_at": null, "tutorial_done_at": null,
      "session_version": 0, "password_changed_at": null }
  ]
}
```

O arquivo é regravado de forma atômica. Nomes de usuário têm de 3 a 32 caracteres minúsculos (letras, números, ponto, hífen e sublinhado). O administrador cria contas, redefine senhas, muda perfis e exclui contas pela tela Sistema e conta; o login pré-definido só é recriado se não houver nenhum administrador.

Copyright (©) 2026 Erik Pimenta

`tutorial_done_at` guarda quando a conta viu o tutorial. `session_version` sobe a cada troca ou redefinição de senha e a cada Sair dos outros dispositivos, e `password_changed_at` guarda a última troca de senha. Para redefinir uma senha esquecida sem a tela, rode `python scripts/redefinir_senha.py nome-do-usuario` no servidor.

8.6 Migração automática

Ao subir sobre um banco da 2.0, `nexo/migrations.py` cria as tabelas novas, acrescenta as colunas novas, cria a base "Acervo geral" e liga a ela todos os documentos existentes. No SQLite, a tabela `nx_document` é reconstruída seguindo os 12 passos oficiais (para trocar o único de sha256 pelo único por base); nos outros bancos, `ALTER TABLE`. Nenhum vetor precisa ser recalculado.

Na 2.3.0, a migração compara cada tabela com o modelo e acrescenta as colunas que faltam com `ALTER TABLE ... ADD COLUMN` e o valor padrão: `nx_document.index_signature` e `source_url`, `nx_bot.suggestions`, `nx_conversation.pinned`, `nx_api_key.scope` e `expires_at`. As tabelas `nx_quick_reply` e `nx_audit` são criadas. Depois disso, os documentos prontos sem assinatura recebem a da configuração atual, então nada é reindexado.

8.7 Outro banco relacional

Banco	Driver	NEXO_DATABASE_URL
PostgreSQL	`pip install "psycopg[binary]"`	`postgresql+psycopg://usuario:senha@host:5432/nexo`
MySQL / MariaDB	`pip install pymysql`	`mysql+pymysql://usuario:senha@host:3306/nexo`
SQL Server	`pip install pyodbc`	`mssql+pyodbc://usuario:senha@host/nexo?driver=ODBC+Driver+18+for+SQL+Server`

O DDL de referência está em `docs/schema-postgresql.sql` e `docs/schema-sqlite.sql`, e o resumo em `docs/banco-de-dados.md`.

Copyright (©) 2026 Erik Pimenta

09

API

A interface usa a mesma API REST que fica disponível para integrações. A documentação interativa (OpenAPI) abre em http://127.0.0.1:8000/api/docs.

9.1 Autenticação

Fora `/api/health`, `/api/health/ready`, `/api/auth/options`, `/api/auth/login`, `/api/auth/register` e o webhook público `/api/whatsapp/webhook/{id}`, todas as rotas exigem `Authorization: Bearer <token JWT>` ou uma chave de API. As rotas marcadas como admin devolvem 403 `FORBIDDEN` para os demais. Todas as respostas trazem `X-Request-ID`.

9.2 Rotas

Método	Rota	Descrição
Sessão e conta		
GET	`/api/health`	Situação do servidor e versão
GET	`/api/health/ready`	Prontidão: confere o banco; 503 quando ele não responde
GET	`/api/auth/options`	Cadastro aberto e se o login pré-definido ainda está ativo
POST	`/api/auth/login` · `/api/auth/register`	Entrar e criar conta
GET / PATCH	`/api/auth/me`	Usuário da sessão, com tutorial_done_at; PATCH {"name"} troca o próprio nome
PUT	`/api/auth/password`	Trocar a própria senha. Encerra as outras sessões e devolve uma sessão nova (200)
POST	`/api/auth/sessions/revoke`	Sair dos outros dispositivos; devolve uma sessão nova para este
PUT	`/api/auth/tutorial`	Marcar o tutorial como visto ({"done": true}) ou para rever (false)
GET	`/api/system/status`	Configuração ativa, números do acervo (com desatualizados) e operação
Sistema (admin) Novo		
GET / PUT	`/api/system/settings`	Ajustes pela tela: ler com padrões e grupos, ou alterar {"values": {…}}
POST	`/api/system/settings/reset`	Restaurar padrões do .env, todos ou só os de {"keys": […]}

Copyright (©) 2026 Erik Pimenta

Método	Rota	Descrição
GET	`/api/system/diagnostics?deep=false`	Diagnóstico rápido ou completo (deep=true)
POST	`/api/system/maintenance`	{"action": reindex_failed | reindex_outdated | reindex_all | clean_orphans | purge_conversations | vacuum, "days"?}
GET	`/api/system/backup`	Baixa o backup .zip
GET	`/api/audit` · `/api/audit/export`	Registro de atividades (actor, action, days, offset, limit) e CSV
GET	`/api/health/metrics`	Métricas no formato do Prometheus
Bases de conhecimento		
GET / POST	`/api/bases`	Listar com os números de cada base, ou criar
GET / PATCH / DELETE	`/api/bases/{id}`	Abrir, renomear ou excluir (409 se usada por agente ou se for a padrão)
GET / POST	`/api/bases/{id}/documents`	Listar itens ou enviar arquivos (multipart, campo files)
POST	`/api/bases/{id}/texts`	Criar um texto {"title", "content"}
POST	`/api/bases/{id}/links` Novo	Importar uma página ou arquivo {"url", "title"?}
POST	`/api/bases/sample` Novo	Criar a Base de teste e o Agente de teste (não duplica)
GET	`/api/formats`	Extensões aceitas e tamanho máximo
Documentos		
GET / POST	`/api/documents`	Listar todos ou enviar (campo base_id opcional)
POST	`/api/documents/bulk`	Ações em lote {"action": "reindex" | "delete" | "move", "ids", "base_id"?}; informa os itens pulados
GET / PATCH	`/api/documents/{id}`	Detalhes; renomear (reindexa) ou mover de base (base_id, sem reindexar)
GET / PUT	`/api/documents/{id}/text`	Ler ou editar um texto (reindexa)
GET	`/api/documents/{id}/file`	Baixar o arquivo original
POST	`/api/documents/{id}/reindex`	Reindexar
POST	`/api/documents/{id}/refetch` Novo	Baixar de novo do link de origem; changed diz se mudou
GET	`/api/documents/{id}/chunks` Novo	Trechos indexados, com offset, limit e q
DELETE	`/api/documents/{id}`	Excluir arquivo, vetores e escopos
Agentes, conversas e busca		
GET / POST	`/api/bots`	Listar ou criar agentes

Copyright (©) 2026 Erik Pimenta

Método	Rota	Descrição
`GET / PATCH / DELETE`	`/api/bots/{id}`	Abrir, editar (inclusive suggestions) ou excluir (apaga as conversas do agente)
`POST`	`/api/bots/{id}/duplicate` **Novo**	Criar uma cópia do agente
`GET / POST`	`/api/conversations`	Listar (filtros only=general|bots, bot_id e q, que procura no título e nas mensagens) ou criar (bot_id opcional)
`GET / PATCH / DELETE`	`/api/conversations/{id}`	Abrir; renomear, mudar escopo ou fixar (pinned); excluir
`GET`	`/api/conversations/{id}/export`	Exportar em markdown ou json
`POST`	`/api/conversations/{id}/messages`	Perguntar (resposta JSON)
`POST`	`/api/conversations/{id}/messages/stream`	Perguntar com resposta em Server-Sent Events: status, delta, done e error
`POST`	`/api/messages/{id}/regenerate`	Refazer a resposta no lugar; renova as fontes e apaga a avaliação
`POST`	`/api/messages/{id}/feedback`	Avaliar resposta {"rating", "comment"?}
`POST`	`/api/ask`	Pergunta direta, com bot_id opcional
`POST`	`/api/search`	Busca nos trechos, com base_id opcional
`GET`	`/api/metrics?days=30&bot_id=`	Painel de qualidade, com by_bot e filtro por agente (ou geral)
`GET`	`/api/metrics/export?days=N`	CSV com data, conversa, pergunta, respondida, avaliação, latência, fontes e comentário
WhatsApp		
`GET / POST`	`/api/whatsapp/channels`	Listar conexões ou criar (admin)
`PATCH / DELETE`	`/api/whatsapp/channels/{id}`	Editar, pausar ou excluir (admin)
`GET`	`/api/whatsapp/channels/{id}/status`	Situação da conexão: open, connecting, close ou unknown
`GET`	`/api/whatsapp/channels/{id}/qrcode`	QR code e código de pareamento (Evolution)
`POST`	`/api/whatsapp/channels/{id}/webhook`	Registrar o webhook na Evolution ou obter a URL para a Meta
`POST`	`/api/whatsapp/channels/{id}/simulate`	Simular mensagem de cliente (simulador)
`GET / POST`	`/api/whatsapp/webhook/{id}`	Webhook público chamado pelo WhatsApp
`GET`	`/api/whatsapp/summary`	Números da caixa de entrada
`GET`	`/api/whatsapp/contacts`	Contatos, com channel_id, filter e q
`GET / PATCH`	`/api/whatsapp/contacts/{id}`	Conversa (marca como lida); ligar ou pausar o agente, nome
`POST`	`/api/whatsapp/contacts/{id}/messages`	Responder como a equipe

Copyright (©) 2026 Erik Pimenta

Método	Rota	Descrição
POST	`/api/whatsapp/contacts/{id}/suggest`	Sugestão de resposta do agente, sem enviar
GET / POST	`/api/whatsapp/quick-replies` Novo	Respostas prontas: listar ou criar {title, body}
PATCH / DELETE	`/api/whatsapp/quick-replies/{id}` Novo	Editar ou excluir (quem criou ou admin)
Integrações e contas		
GET / POST / DELETE	`/api/keys` · `/api/keys/{id}`	Chaves de API do usuário; POST {name, scope, expires_days}
GET / POST / PATCH / DELETE	`/api/webhooks` · `/api/webhooks/{id}`	Webhooks (admin)
POST	`/api/webhooks/{id}/test`	Entregar ping (admin)
GET / POST	`/api/users`	Listar contas ou criar uma {name, username, password, role} (admin), mesmo com o cadastro fechado
PUT	`/api/users/{usuario}/password`	Redefinir a senha {password}; encerra as sessões e libera o bloqueio (admin)
PATCH / DELETE	`/api/users/{usuario}`	Mudar perfil ou excluir conta (admin)

9.3 Exemplo com curl

```
curl -X POST http://127.0.0.1:8000/api/auth/login \
  -H "Content-Type: application/json" \
  -d '{"username": "admin", "password": "Nexo@2026"}'

curl -X POST http://127.0.0.1:8000/api/bases \
  -H "Authorization: Bearer SEU_TOKEN" -H "Content-Type: application/json" \
  -d '{"name": "Suporte técnico"}'

curl -X POST http://127.0.0.1:8000/api/bots \
  -H "Authorization: Bearer SEU_TOKEN" -H "Content-Type: application/json" \
  -d '{"name": "Técnico", "base_id": "ID_DA_BASE", "greeting": "Olá! Como posso ajudar?"}'

curl -X POST http://127.0.0.1:8000/api/conversations \
  -H "Authorization: Bearer SEU_TOKEN" -H "Content-Type: application/json" \
  -d '{"bot_id": "ID_DO_AGENTE"}'

curl -X POST http://127.0.0.1:8000/api/users \
  -H "Authorization: Bearer SEU_TOKEN" -H "Content-Type: application/json" \
  -d '{"name": "Ana Souza", "username": "ana", "password": "Troque-1234", "role": "user"}'

curl -X POST http://127.0.0.1:8000/api/auth/sessions/revoke -H "Authorization: Bearer SEU_TOKEN"
```

9.4 Erros

Todo erro volta como JSON com `code`, `message` e, quando for de campo, `fields`.

Copyright (©) 2026 Erik Pimenta

HTTP	code	Quando
400	`EMPTY` / `NO_FILES` / `UNKNOWN_DOCUMENT`	Pergunta vazia, envio sem arquivos ou escopo com documento que não existe
400	`SELF` / `LAST_ADMIN`	Rebaixar ou excluir a própria conta, ou o último administrador
400	`SAME_PASSWORD`	Senha nova igual à atual
400	`INVALID_URL` / `INVALID_EVENTS`	Webhook com URL inválida ou eventos desconhecidos
400	`NOT_A_TEXT` / `INVALID_PROVIDER`	Editar como texto um item que é arquivo; provedor de WhatsApp desconhecido
400	`NOT_A_LINK` / `INVALID_SETTINGS` / `MAINTENANCE` Novo	Atualizar do link um item que não veio de link; ajuste fora das regras (em fields); ação de manutenção desconhecida
401	`UNAUTHENTICATED` / `SESSION_EXPIRED` / `INVALID_API_KEY`	Sem credencial, token vencido ou chave inválida
401	`SESSION_REVOKED`	Sessão encerrada por troca ou redefinição de senha ou por Sair dos outros dispositivos
401	`API_KEY_EXPIRED` Novo	Chave de API vencida
401	`INVALID_SIGNATURE`	Webhook do WhatsApp com assinatura ou token errado
403	`FORBIDDEN` / `REGISTRATION_DISABLED`	Rota de administrador, ação sobre conteúdo de outra pessoa ou cadastro fechado
403	`KEY_SCOPE` / `PRIVATE_URL` Novo	Rota fora da permissão da chave; link para a rede interna
404	`NO_SAMPLE` Novo	Os arquivos de exemplos/base-de-teste não estão no servidor
404	`NOT_FOUND` / `FILE_MISSING`	Registro inexistente ou de outro usuário; arquivo original ausente
409	`DUPLICATE` / `NO_DOCUMENTS` / `BASE_EMPTY`	Arquivo repetido na base, pergunta sem documentos prontos ou agente com base vazia
409	`BASE_IN_USE` / `DEFAULT_BASE`	Excluir base usada por agente ou a base padrão
409	`NAME_TAKEN` Novo	Resposta pronta com título repetido
413 / 415	`FILE_TOO_LARGE` / `NOT_A_PDF` / `UNSUPPORTED`	Arquivo grande demais (inclusive item de pacote zip acima de 50 MB), PDF inválido ou formato não aceito
422	`VALIDATION`	Corpo fora do formato, com os campos em fields
429	`LOCKED`	Cinco senhas erradas seguidas
429	`RATE_LIMITED` Novo	Mais perguntas por minuto que NEXO_RATE_LIMIT; veja Retry-After

Copyright (©) 2026 Erik Pimenta

HTTP	code	Quando
502 / 503	`LLM_FAILURE` / `PROVIDER` / `WHATSAPP`	Modelo fora do ar, provedor ausente ou WhatsApp recusou o pedido
502	`UNREACHABLE` / `HTTP_ERROR` / `TOO_MANY_REDIRECTS` Novo	Link que não abre, responde erro ou redireciona demais

Na rota de streaming, um erro depois do início da resposta chega como evento `error` com os mesmos `code` e `message`, porque o status HTTP 200 já foi enviado.

Copyright (©) 2026 Erik Pimenta

10

Qualidade e manutenção

Testes automatizados, medição da busca, integração contínua, backup, linha de comando, registros e solução de problemas.

10.1 Testes automatizados

```
pip install -r requirements-ci.txt
python -m pytest
```

São 93 testes. Eles rodam sem internet nem modelos (embedding hash, modo extrativo, reranker desligado) e cobrem: login, bloqueio, cadastro, senhas, envio e indexação, resposta com fonte e página, pergunta fora do conteúdo, isolamento entre usuários, avaliação, arquivos inválidos e duplicados, permissões, remoção dos vetores, escopo, reranking, scripts, busca, exportação, métricas, chaves, pergunta direta, webhooks e contas; as bases, os textos, mover entre bases, agentes, conversas com agentes, a migração de um banco da 2.0, o tutorial e o WhatsApp (simulador, webhook da Meta com assinatura, Evolution com token, envio, passagem para atendente e sugestão).

A 2.2 trouxe `tests/test_streaming.py` e `tests/test_formatos.py`. Na 2.3 entram `tests/test_manutencao.py` (migração de um banco da 2.2, ajustes pela tela, índice desatualizado, diagnóstico, manutenção, backup e restauração, registro de atividades, permissão e validade das chaves, limite de perguntas, CORS, métricas, conversas fixadas, comentários, perguntas sugeridas, duplicação, painel por agente, respostas prontas, trechos, linha de comando, logs JSON e base de teste) e `tests/test_links.py` (importação e atualização por link, erros e bloqueio da rede interna, inclusive por redirecionamento).

10.2 Medindo a recuperação

```
{"pergunta": "Como restaurar as configurações de fábrica?", "documento": "manual-exemplo.pdf",
"pagina": 2}
{"pergunta": "Qual a temperatura de operação?", "documento": "manual-exemplo.pdf", "pagina": 5}
```

```
python scripts/avaliar.py exemplos/perguntas-exemplo.jsonl --detalhes
```

O script mostra, para a busca vetorial pura e com reranking, o acerto e o MRR. Repita depois de cada ajuste de parâmetros.

Copyright (©) 2026 Erik Pimenta

10.3 Integração contínua

O workflow `.github/workflows/ci.yml` roda, a cada push e pull request, o `ruff check .` e os testes do Python, o build da interface e o `docker build` da imagem.

10.4 Commit automático diário

O workflow `.github/workflows/diario.yml` acrescenta a data e a hora em `.github/atividade.txt` e faz um commit todos os dias às 11h37 de Brasília. Para ativar, crie os segredos `GIT_NAME` e `GIT_EMAIL` em **Settings › Secrets and variables › Actions** e marque **Read and write permissions** em **Settings › Actions › General**.

10.5 Backup

Use **Baixar backup** em Sistema e conta › Manutenção ou a linha de comando, com o servidor no ar:

```
python -m nexo backup --saida backups/nexo.zip
python -m nexo restaurar backups/nexo.zip --substituir
```

O .zip leva o banco SQLite (copiado de forma consistente, mesmo com o servidor rodando), as contas, os ajustes, o segredo das sessões, os arquivos enviados e um `manifesto.json` com a versão e as contagens. Os vetores não vão: a restauração, feita com o servidor parado, marca os documentos para reindexar quando ele subir. `--substituir` guarda a pasta de dados atual numa cópia antes de restaurar. Com bancos externos, faça o backup deles com a ferramenta do próprio banco no mesmo momento.

Para uma cópia completa, inclusive dos vetores, pare o servidor e copie a pasta `data` inteira.

O backup contém segredos. Os segredos dos webhooks, os tokens do WhatsApp e `data/.segredo` estão nele. Guarde as cópias com o mesmo cuidado de uma senha.

10.6 Linha de comando Novo

Comando	O que faz
`python -m nexo`	Sobe o servidor (o mesmo que `servir` e `scripts/servir.py`)
`python -m nexo diagnostico [--completo]`	O diagnóstico da tela no terminal; termina com erro se houver falha
`python -m nexo backup [--saida arquivo.zip]`	Grava o backup
`python -m nexo restaurar arquivo.zip [--substituir]`	Restaura um backup, com o servidor parado
`python -m nexo reindexar [--desatualizados | --todos]`	Reindexa no terminal, com o servidor parado; sem opção, só os que falharam ou ficaram na fila
`python -m nexo base-de-teste [--conta admin]`	Cria a Base de teste e o Agente de teste, indexando na hora

Copyright (©) 2026 Erik Pimenta

Comando	O que faz
`python -m nexo contas`	Lista as contas com perfil e último acesso
`python -m nexo versao`	Mostra a versão

Com um valor inválido no `.env`, os comandos dizem qual variável está errada e o valor recebido, em vez de um erro técnico.

10.7 Registros e acompanhamento Novo

Cada pedido gera uma linha de registro com o método, a rota, o status, o tempo, a conta e o `X-Request-ID`. Com `NEXO_LOG_FORMAT=json`, cada linha é um objeto JSON, pronto para Loki, Elastic ou CloudWatch; `NEXO_LOG_LEVEL` controla o detalhe. Para acompanhar o servidor, use `/api/health/ready` na checagem de saúde e `/api/health/metrics` no Prometheus (seção 5.6). Quem fez o quê fica no registro de atividades (seção 4.12).

10.8 Atualizando dependências

```
pip install --upgrade -r requirements.txt
cd frontend && npm update && npm run build
```

10.9 Solução de problemas

Sintoma	Causa provável	O que fazer
"O modelo não respondeu"	Ollama desligado ou modelo não baixado	Abra o Ollama e rode `ollama pull llama3.1`
"Instale o pacote ..."	Provedor sem a biblioteca	pip install do pacote indicado
Item em Falhou: sem texto	PDF digitalizado ou arquivo vazio	Aplique OCR (OCRmyPDF) ou envie o texto pela aba Textos
Formato não aceito (415)	Extensão fora da lista	Converta para PDF, DOCX, ODT, EPUB, PPTX, XLSX, TXT, MD, CSV, JSON ou HTML
EPUB, PPTX, XLSX ou ODT recusado (413)	Algum item do pacote passa de 50 MB descompactado	Divida o arquivo ou reduza as imagens embutidas
Agente diz que a base não tem conteúdo	Base vazia ou itens ainda indexando	Envie arquivos ou textos e aguarde Pronto
Respostas sempre "Não encontrei"	Cortes de relevância altos	Veja as notas na aba Testar e baixe os cortes
Resposta aparece só no fim, de uma vez	Proxy guardando a resposta em buffer	Desligue o buffer da rota de streaming (seção 3.5)

Copyright (©) 2026 Erik Pimenta

Sintoma	Causa provável	O que fazer
Sessão encerrada de repente	Senha trocada ou redefinida, ou Sair dos outros dispositivos (401 SESSION_REVOKED)	Entre de novo com a senha atual
Não consigo excluir uma base	Algum agente usa a base, ou é a padrão	Troque a base do agente antes
Integração recebe 401	Chave revogada ou errada	Crie uma chave nova e confira o cabeçalho X-API-Key
Receptor recusa a assinatura	HMAC sobre o JSON reformatado	Calcule sobre o corpo bruto e confira o segredo
Receptor recebe o mesmo evento duas vezes	Nova tentativa depois de uma resposta lenta	Ignore repetições pelo X-Nexo-Delivery
WhatsApp não recebe mensagens	Webhook não registrado	Veja a seção 6.7
Tutorial não aparece mais	Já foi visto pela conta	Use Ver tutorial na paleta ou em Sistema e conta
Tela em branco em /	Interface não compilada	cd frontend, npm ci e npm run build
Esqueci a senha do admin	Senha trocada e perdida	Outro administrador usa Redefinir senha; sem nenhum, rode `python scripts/redefinir_senha.py admin`
Integração recebe 429	Limite de perguntas por minuto atingido	Espere o Retry-After ou aumente o limite em Ajustes
Integração recebe 403 KEY_SCOPE	Chave sem permissão para a rota	Crie uma chave com a permissão certa
Documentos "índice desatualizado"	Modelo de embeddings ou tamanho do trecho mudou	Reindexar desatualizados em Manutenção
Importar link recusado (403)	Endereço da rede interna	Ligue NEXO_ALLOW_PRIVATE_URLS se for confiável
Não sei o que está errado	Vários motivos	Rode o diagnóstico (tela ou `python -m nexo diagnostico`)

Copyright (©) 2026 Erik Pimenta