Documentação técnica · Versão 2.0.0

Nexo

Manual técnico

Chatbot que responde dúvidas sobre manuais técnicos e livros em PDF usando só o que está escrito neles, sempre citando a página. Instalação, configuração, cada tela, integrações, arquitetura, banco de dados, API e manutenção, passo a passo.

01 Visão geral
02 Instalação
03 Configuração
04 Usando o Nexo
05 Integrações
06 Arquitetura
07 Banco de dados
08 API
09 Qualidade e manutenção

Versão 2.0.0
Outubro de 2026

Copyright (©) 2026 Erik Pimenta

Sumário

01 Visão geral 4

1.1 Para que serve 4
1.2 O que há de novo na 2.0 5
1.3 O que o projeto entrega 5
1.4 Funcionalidades 6
1.5 Identidade visual 6

02 Instalação 8

2.1 Pré-requisitos 8
2.2 Caminho rápido 8
2.3 Passo a passo manual 9
2.4 Primeiro acesso 9
2.5 Atualizando a partir da 1.5 9

03 Configuração 10

3.1 Modos prontos 10
3.2 Todas as variáveis 10
3.3 Calibrando a precisão 12
3.4 Serviços externos com Docker 12
3.5 Acesso pela rede 12

04 Usando o Nexo 13

4.1 Entrada 13
4.2 Conversas 14
4.3 Busca nos trechos Novo 16
4.4 Documentos 17
4.5 Painel de qualidade Novo 18
4.6 Integrações Novo 19
4.7 Sistema e conta 21
4.8 Paleta de comandos e atalhos Novo 22
4.9 Tema e celular 23

05 Integrações 25

5.1 Autenticação por chave de API 25
5.2 Pergunta direta: /api/ask 25

Copyright (©) 2026 Erik Pimenta

5.3 Busca pela API 27
5.4 Webhooks 27
5.5 Boas práticas 29
5.6 Exportação de conversas 30

06 Arquitetura 31
6.1 Módulos do código 31
6.2 Indexação de um PDF 32
6.3 Respondendo uma pergunta 33
6.4 Como as alucinações são reduzidas 33
6.5 Segurança 34

07 Banco de dados 35
7.1 Onde cada dado fica 35
7.2 Diagrama de relacionamentos 36
7.3 Tabelas 36
7.4 Coleção vetorial 38
7.5 Arquivo de usuários 38
7.6 Outro banco relacional 38

08 API 39
8.1 Autenticação 39
8.2 Rotas 39
8.3 Exemplo com curl 40
8.4 Erros 40

09 Qualidade e manutenção 42
9.1 Testes automatizados 42
9.2 Medindo a recuperação 42
9.3 Integração contínua 42
9.4 Commit automático diário 43
9.5 Backup 43
9.6 Atualizando dependências 43
9.7 Solução de problemas 43

Copyright (©) 2026 Erik Pimenta

01

Visão geral

O Nexo é uma aplicação web em que você envia manuais técnicos ou livros em PDF e conversa com um chatbot que responde só com o que está escrito neles. Cada resposta mostra os trechos usados, com documento e página. Quando a informação não está nos PDFs, o Nexo diz isso em vez de inventar.



Figura 1 — Conversa com citações numeradas e o painel de trechos usados, com a passagem citada em marca-texto e o link para o PDF na página.

1.1 Para que serve

- Consultar manuais de equipamentos, normas, procedimentos internos e livros técnicos sem folhear centenas de páginas.
- Dar a uma equipe um ponto único de consulta, em que cada resposta pode ser conferida no documento original.
- Estudar um livro complexo fazendo perguntas e indo direto à página que trata do assunto.

Copyright (©) 2026 Erik Pimenta

- Levar as respostas para outros sistemas (portal interno, central de atendimento, automações) pela API com chave própria.

1.2 O que há de novo na 2.0

A versão 2.0.0 abre o Nexo para integrações, mede a qualidade das respostas e troca a identidade visual. A API antiga continua igual: nada do que funcionava na 1.5 deixou de funcionar.

Busca nos trechos tela e POST /api/search

Procura direto nos trechos indexados, sem chamar o modelo de linguagem. Mostra documento, página, similaridade e nota do reranker.

Exportar conversa Markdown ou JSON

Baixa a conversa inteira com perguntas, respostas e a lista de fontes de cada resposta.

Painel de qualidade tela e GET /api/metrics

Taxa de resposta, latência média e p95, avaliações, documentos mais citados e as lacunas do acervo.

Chaves de API nxk_...

Cada usuário cria chaves para integrações. O Nexo guarda só o hash SHA-256 da chave.

Pergunta direta POST /api/ask

Uma chamada, uma resposta com fontes. Sem estado, ou dentro de uma conversa existente.

Webhooks somente admin

Avisos assinados com HMAC quando um documento fica pronto ou falha, quando uma pergunta fica sem resposta e quando uma resposta é mal avaliada.

Gestão de contas somente admin

Promover, rebaixar e excluir contas, com proteção para não ficar sem administrador.

Paleta de comandos Ctrl + K

Vai para qualquer tela e executa as ações principais pelo teclado.

Tema automático

Além de claro e escuro, o tema pode seguir o sistema operacional.

Nova identidade

"Manual de bancada": folha branca, tinta azul-escura e marca-texto amarelo nas citações.

1.3 O que o projeto entrega

O Nexo é entregue como estrutura pronta: interfaces, arquitetura, banco de dados e documentação. Quem instala decide quais PDFs enviar, quais modelos usar e onde hospedar. Nenhum documento real ou dado pessoal vem no repositório; o único PDF incluído é um manual fictício para testes.

Camada	Tecnologia	Papel
Interface	React 19, TypeScript, Vite	Telas de entrada, conversas, busca, documentos, painel, integrações, sistema e conta
API	Python 3.11+, FastAPI, Uvicorn	Rotas REST, autenticação por sessão ou chave de API, envio de arquivos e fila de indexação
Pipeline de dados	LlamaIndex, pypdf	Leitura dos PDFs, divisão em trechos, busca e montagem das respostas
Banco vetorial	ChromaDB (padrão) ou Qdrant	Embeddings dos trechos e metadados de origem
Embeddings	HuggingFace, OpenAI ou Ollama	Transformam texto em vetores para a busca semântica

Copyright (©) 2026 Erik Pimenta

Camada	Tecnologia	Papel
Reranking	Cross-encoder HuggingFace ou Cohere Rerank	Reordenam os candidatos antes de chegarem ao modelo
Modelo de linguagem	Ollama (local) ou OpenAI	Redige a resposta a partir dos trechos
Banco relacional	SQLAlchemy com SQLite (padrão), PostgreSQL, MySQL ou SQL Server	Documentos, conversas, mensagens, fontes, avaliações, chaves de API e webhooks
Contas	Arquivo JSON com bcrypt, sessões JWT	Login pré-definido, cadastro próprio e gestão pelo administrador
Integrações	Chaves `nxk_`, webhooks com HMAC-SHA256	Perguntas e buscas vindas de outros sistemas e avisos de eventos

1.4 Funcionalidades

- Envio de PDFs por arrastar e soltar ou seletor de arquivos, vários de uma vez, com limite de tamanho, checagem de formato e bloqueio de duplicados por SHA-256.
- Indexação em segundo plano com os estados Na fila, Indexando, Pronto e Falhou. A tela se atualiza sozinha.
- Renomear, reindexar, abrir e excluir documentos, com filtro e ordenação da lista. Excluir apaga o PDF e todos os vetores dele.
- Conversas salvas por usuário, com título automático, renomeação, exclusão, filtro e exportação em Markdown ou JSON.
- Escopo: cada conversa pode consultar todos os documentos ou só os escolhidos.
- Citações [n] clicáveis que abrem o trecho usado, com a passagem em marca-texto, e o PDF na página certa. Botão para copiar a resposta.
- Resposta padrão quando nada relevante é encontrado: "Não encontrei essa informação nos documentos selecionados."
- Busca direta nos trechos, sem o modelo de linguagem, para conferir o que o acervo tem sobre um assunto.
- Avaliação de cada resposta (útil ou não ajudou) e painel de qualidade com as perguntas que ficaram sem resposta.
- Integrações por chave de API, pergunta direta em `/api/ask` e webhooks assinados.
- Contas: login pré-definido de administrador, cadastro de novos usuários, troca de senha e gestão de perfis pelo administrador.
- Paleta de comandos com `Ctrl` + `K`, tema claro, escuro ou automático e layout para celular.

1.5 Identidade visual

O Nexo lê manuais e livros e cita a página. A identidade da 2.0, chamada **manual de bancada**, imita um manual impresso marcado com marca-texto: folha clara, tinta escura, linhas finas e um único elemento ousado, o amarelo das citações.

Copyright (©) 2026 Erik Pimenta

Papel
#F1F2EE · fundo

Folha
#FFFFFF · áreas de leitura

Tinta
#14233A · texto e botões

Aço
#5A6676 · texto secundário

Régua
#D5D9D4 · linhas

Marca-texto
#F4E74B · citações

Ok
#2F6B45

Erro
#B3261E · aviso #8A6100

Elemento	Como ficou
Títulos e números	Barlow Semi Condensed, pesos 500 e 600
Interface	Barlow, pesos 400, 500 e 600
Respostas e trechos	Literata, uma serifa de livro, para tudo o que vem dos documentos
Código e chaves	IBM Plex Mono, só para código, rotas e chaves
Formas	Cantos discretos (4 a 6 px), linhas de 1 px, sem sombras pesadas nem gradientes; rótulos em caixa normal
Tema escuro	Papel #0D1522, folha #142033, texto #E8ECF2, aço #9AA6B6, régua #26344A; o marca-texto continua #F4E74B, com texto #14233A em cima
Logo	O mesmo "N" de contraste da versão anterior, sempre em uma cor só

Copyright (©) 2026 Erik Pimenta

02
Instalação

Este capítulo leva do download à primeira pergunta respondida. O caminho mais curto é o script de inicialização; os passos manuais vêm logo depois.

2.1 Pré-requisitos

Item	Versão	Para quê
Python	3.11 ou mais recente	Servidor, indexação e respostas
Node.js	20.19 ou mais recente	Compilar a interface (uma vez)
Ollama	Atual	Modelo de linguagem local e gratuito (modo padrão)
Espaço em disco	Cerca de 3 GB	Dependências do Python, modelos de embeddings e reranking
Memória	8 GB ou mais	Rodar o llama3.1 local com folga

Sem Ollama ou sem GPU? Use a OpenAI como modelo de linguagem (seção 3.1) ou o modo de teste sem modelos para validar a instalação. Os modelos de embeddings e reranking padrão rodam bem em CPU.

2.2 Caminho rápido

1. Baixe o repositório (botão **Code › Download ZIP** no GitHub ou `git clone`) e extraia em uma pasta.
2. Instale o Ollama em ollama.com e, num terminal, rode `ollama pull llama3.1`.
3. No Windows, dê dois cliques em `iniciar.cmd`. No Linux ou macOS, rode `./iniciar.sh`.
4. Espere a instalação terminar. Na primeira vez ela leva alguns minutos.
5. Abra `http://127.0.0.1:8000` no navegador e entre com `admin` / `Nexo@2026`.
6. Vá em **Documentos**, envie um PDF e, quando aparecer **Pronto**, faça uma pergunta em **Conversas**.

O script cria o ambiente virtual `.venv`, instala `requirements.txt`, copia `.env.example` para `.env`, compila a interface em `frontend/dist` e sobe o servidor. Nas próximas vezes ele só sobe o servidor.

Copyright (©) 2026 Erik Pimenta

2.3 Passo a passo manual

```
python -m venv .venv
.venv\Scripts\activate                # Windows
source .venv/bin/activate             # Linux / macOS
pip install -r requirements.txt
copy .env.example .env                # Windows; no Linux/macOS use cp
cd frontend
npm install
npm run build
cd ..
python -m nexo
```

Para desenvolver a interface com recarga automática, rode `python -m nexo` em um terminal e `npm run dev` dentro de `frontend` em outro. A interface abre em `http://localhost:5173` e repassa as chamadas `/api` para a porta 8000.

2.4 Primeiro acesso

O login pré-definido é criado quando não há nenhum administrador, como na primeira execução. O aviso some da tela de entrada (seção 4.1) assim que a senha do admin é trocada. Troque-a em **Sistema e conta** no primeiro acesso.

Usuário	Senha	Perfil	Pode
`admin`	`Nexo@2026`	Administrador	Tudo: excluir documentos de outras pessoas, ver o painel de todos, gerenciar contas e webhooks
contas novas	definida no cadastro	Usuário	Enviar PDFs, conversar, buscar, ver o próprio painel e criar as próprias chaves de API

2.5 Atualizando a partir da 1.5

1. Pare o servidor e faça uma cópia da pasta `data` (seção 9.5).
2. Substitua os arquivos do projeto pelos da 2.0.0, mantendo `data` e o seu `.env`.
3. Rode `pip install -r requirements.txt` e, em `frontend`, `npm install` e `npm run build`.
4. Se quiser, acrescente `NEXO_WEBHOOK_TIMEOUT=5` ao `.env`. Sem a linha, vale o padrão de 5 segundos.
5. Suba o servidor. As tabelas novas `nx_api_key` e `nx_webhook` são criadas sozinhas na primeira conexão; as tabelas existentes não mudam.

Copyright (©) 2026 Erik Pimenta

03
Configuração

Toda a configuração fica no arquivo `.env` na raiz do projeto. Altere, salve e reinicie o servidor. A tela Sistema e conta mostra o que está valendo.

3.1 Modos prontos

Modo	Linhas no .env	Quando usar

Local e gratuito (padrão)	`NEXO_LLM_PROVIDER=ollama`
	`NEXO_LLM_MODEL=llama3.1`
	`NEXO_EMBED_PROVIDER=huggingface`
	`NEXO_RERANKER=huggingface`
		Documentos sigilosos que não podem sair da máquina

OpenAI	`NEXO_LLM_PROVIDER=openai`
	`NEXO_LLM_MODEL=gpt-4o-mini`
	`OPENAI_API_KEY=sua-chave`
		Respostas mais elaboradas sem precisar de GPU

Embeddings da OpenAI	`NEXO_EMBED_PROVIDER=openai`
	`NEXO_EMBED_MODEL=text-embedding-3-small`
	`NEXO_EMBED_QUERY_PREFIX=`
	`NEXO_EMBED_TEXT_PREFIX=`
		Acervos grandes, sem baixar modelos locais

Reranking Cohere	`NEXO_RERANKER=cohere` `COHERE_API_KEY=sua-chave`	Melhor ordenação em vários idiomas sem custo de CPU
Qdrant	`NEXO_VECTOR_STORE=qdrant` `NEXO_QDRANT_URL=http://localhost:6333`	Acervos com muitos milhares de trechos ou servidor dedicado

Teste sem modelos	`NEXO_EMBED_PROVIDER=hash`
	`NEXO_LLM_PROVIDER=extrativo`
	`NEXO_RERANKER=none`
	`NEXO_MIN_SIMILARITY=0.1`
		Validar a instalação e rodar os testes automatizados

> **Trocou o modelo de embeddings?** Vetores de modelos diferentes não são comparáveis. Depois de mudar `NEXO_EMBED_PROVIDER` ou `NEXO_EMBED_MODEL`, use uma coleção nova (`NEXO_COLLECTION`) ou reindexe todos os documentos pela tela Documentos.

3.2 Todas as variáveis

Variável	Padrão	Descrição
Servidor e contas		
`NEXO_HOST / NEXO_PORT`	`127.0.0.1 / 8000`	Endereço do servidor. Use `0.0.0.0` para aceitar acessos da rede
`NEXO_DATA_DIR`	`data`	Pasta do banco SQLite, PDFs, vetores locais e usuários

Copyright (©) 2026 Erik Pimenta

Variável	Padrão	Descrição
NEXO_SECRET	gerado	Chave das sessões. Vazia: o Nexo cria `data/.segredo`
NEXO_TOKEN_HOURS	8	Duração da sessão em horas (1 a 168)
NEXO_ALLOW_REGISTRATION	true	Permite criar contas na tela de entrada
NEXO_MAX_UPLOAD_MB	100	Tamanho máximo de cada PDF (1 a 2048)
NEXO_DATABASE_URL	vazio	URL SQLAlchemy de outro banco relacional. Vazio: `data/nexo.db`
NEXO_WEBHOOK_TIMEOUT Novo	5	Tempo máximo de cada entrega de webhook, em segundos (até 120)
Modelo de linguagem		
NEXO_LLM_PROVIDER	ollama	`ollama`, `openai` ou `extrativo`
NEXO_LLM_MODEL	llama3.1	Nome do modelo no provedor escolhido
NEXO_LLM_TEMPERATURE	0.1	Criatividade do modelo (0 a 1). Mantenha baixa
NEXO_LLM_TIMEOUT	120	Tempo máximo de resposta do modelo, em segundos
NEXO_OLLAMA_URL	http://localhost:11434	Endereço do Ollama
OPENAI_API_KEY	vazio	Chave da OpenAI (também aceita `NEXO_OPENAI_API_KEY`)
NEXO_OPENAI_BASE_URL	vazio	Endpoint compatível com a OpenAI (Azure, LM Studio, vLLM)
Embeddings e banco vetorial		
NEXO_EMBED_PROVIDER	huggingface	`huggingface`, `openai`, `ollama` ou `hash`
NEXO_EMBED_MODEL	intfloat/multilingual-e5-small	Modelo de embeddings
NEXO_EMBED_QUERY_PREFIX / _TEXT_PREFIX	"query: " / "passage: "	Prefixos exigidos pela família E5. Deixe vazio em outros modelos
NEXO_VECTOR_STORE	chroma	`chroma` ou `qdrant`
NEXO_COLLECTION	nexo_trechos	Nome da coleção vetorial
NEXO_CHROMA_HOST / _PORT	vazio / 8001	Servidor ChromaDB. Vazio: arquivos em `data/chroma`
NEXO_QDRANT_URL / _API_KEY	vazio	Servidor Qdrant. Vazio: arquivos em `data/qdrant`
Reranking e recuperação		
NEXO_RERANKER	huggingface	`huggingface`, `cohere` ou `none`
NEXO_RERANK_MODEL	cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	Cross-encoder multilíngue do HuggingFace
NEXO_COHERE_MODEL / COHERE_API_KEY	rerank-v3.5 / vazio	Reranking da Cohere
NEXO_CHUNK_SIZE / _OVERLAP	512 / 64	Tamanho dos trechos e sobreposição, em tokens
NEXO_TOP_K	12	Candidatos trazidos pela busca vetorial
NEXO_TOP_N	4	Trechos enviados ao modelo depois do reranking

Copyright (©) 2026 Erik Pimenta

Variável	Padrão	Descrição
NEXO_MIN_SIMILARITY	0.15	Corte 1: similaridade de cosseno mínima para um trecho ser considerado
NEXO_MIN_RERANK_SCORE	0.1	Corte 2: nota mínima do reranker (0 a 1)
NEXO_HISTORY_TURNS	3	Trocas anteriores usadas para reescrever a pergunta (0 a 10)
NEXO_VERIFY_ANSWERS	false	Liga a verificação de fidelidade, uma segunda chamada ao modelo

3.3 Calibrando a precisão

- **Respostas dizendo que não encontrou, mas a informação existe:** baixe `NEXO_MIN_SIMILARITY` (por exemplo `0.1`) e `NEXO_MIN_RERANK_SCORE` (`0.05`), ou aumente `NEXO_TOP_K`.
- **Respostas misturando assuntos:** suba `NEXO_MIN_RERANK_SCORE` (`0.3`) e reduza `NEXO_TOP_N` para 3.
- **Tabelas e listas longas cortadas:** aumente `NEXO_CHUNK_SIZE` para 768 ou 1024 e reindexe.
- **Antes de mexer:** use a **Busca nos trechos** (seção 4.3) para ver as notas reais dos trechos e o **Painel de qualidade** (seção 4.5) para acompanhar a taxa de resposta depois do ajuste.
- **Medir em vez de adivinhar:** use `scripts/avaliar.py` (seção 9.2) antes e depois de cada ajuste.

3.4 Serviços externos com Docker

O `docker-compose.yml` traz serviços opcionais, cada um em um perfil:

```
docker compose --profile chroma up -d     # ChromaDB em http://localhost:8001
docker compose --profile qdrant up -d     # Qdrant em http://localhost:6333
docker compose --profile ollama up -d     # Ollama em http://localhost:11434
docker compose --profile postgres up -d   # PostgreSQL em localhost:5432
```

Depois aponte o `.env` para eles, por exemplo `NEXO_CHROMA_HOST=localhost` ou `NEXO_DATABASE_URL=postgresql+psycopg://nexo:troque-esta-senha@localhost:5432/nexo` (instale `pip install "psycopg[binary]"`). Troque a senha do PostgreSQL no arquivo antes de usar.

3.5 Acesso pela rede

Para outras máquinas acessarem, use `NEXO_HOST=0.0.0.0`, libere a porta no firewall e defina `NEXO_SECRET` com um valor longo e aleatório. Em produção, coloque o Nexo atrás de um proxy com HTTPS (Nginx, Caddy ou IIS) e desligue o cadastro aberto se o acesso deve ser restrito.

Com integrações, o HTTPS deixa de ser opcional: chaves de API viajam em cada pedido e precisam de transporte cifrado. Para webhooks, o servidor do Nexo precisa conseguir abrir conexões de saída até as URLs cadastradas.

Copyright (©) 2026 Erik Pimenta

04

Usando o Nexo

As telas seguem o caminho natural de uso: entrar, enviar documentos, conversar, conferir a qualidade e integrar. O menu lateral separa Consulta (Conversas, Busca e Documentos), Qualidade e integração (Painel e Integrações) e Conta (Sistema e conta) e traz no rodapé o tema, a saída e o usuário conectado.

4.1 Entrada

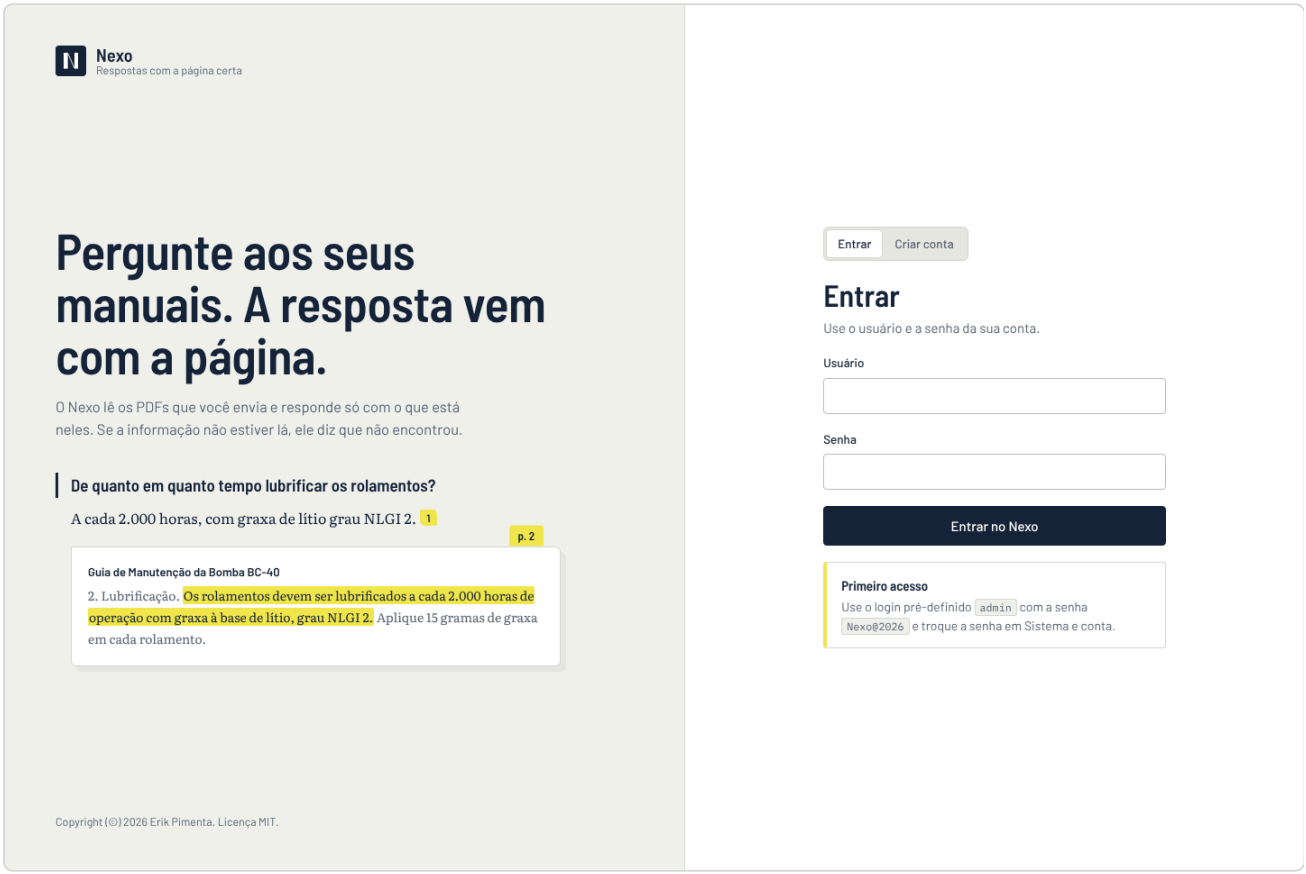


Figura 2 — Entrada, com as abas Entrar e Criar conta e o aviso do login pré-definido enquanto a senha do admin não for trocada.

- **Entrar** pede usuário e senha. Cinco erros seguidos bloqueiam o usuário por 5 minutos.
- **Criar conta** aparece quando `NEXO_ALLOW_REGISTRATION=true`. O nome de usuário tem de 3 a 32 caracteres minúsculos; a senha, de 8 a 72 caracteres, com letras e números, sem conter o nome de usuário.
- A sessão dura `NEXO_TOKEN_HOURS` horas e fica só na aba aberta.

4.2 Conversas



Figura 3 — Duas perguntas na mesma conversa, com os trechos da primeira resposta abertos e a passagem citada em marca-texto.

- **Nova** abre uma conversa vazia. O título vem da primeira pergunta e pode ser editado no lápis.
- Enter envia, Shift + Enter quebra a linha.
- Os números **[n]** no texto indicam de qual trecho veio cada informação. Clique para destacá-lo no painel **Trechos usados**.
- Cada trecho mostra a página, a similaridade da busca, a nota do reranker e o link **Abrir o PDF na página**. O texto citado aparece em Literata, com a passagem em marca-texto.
- **Copiar** leva a resposta para a área de transferência. As setas para cima e para baixo avaliam a resposta; clique de novo para desfazer.
- O campo de filtro no topo da lista de conversas encontra conversas pelo título.
- **Exportar** baixa a conversa em Markdown ou JSON, com as fontes de cada resposta (seção 5.6).
- Perguntas seguintes podem usar "isso", "esse passo" ou "e depois?": o Nexo reescreve a pergunta com o histórico antes de buscar.

Escolhendo os documentos consultados

A linha **Consultando** mostra o escopo atual. Clique em **Escolher documentos** e marque os PDFs que a conversa deve usar. Sem nenhum marcado, todos os documentos prontos são consultados, inclusive os que forem enviados depois.

Copyright (©) 2026 Erik Pimenta

Quando a resposta não está nos PDFs

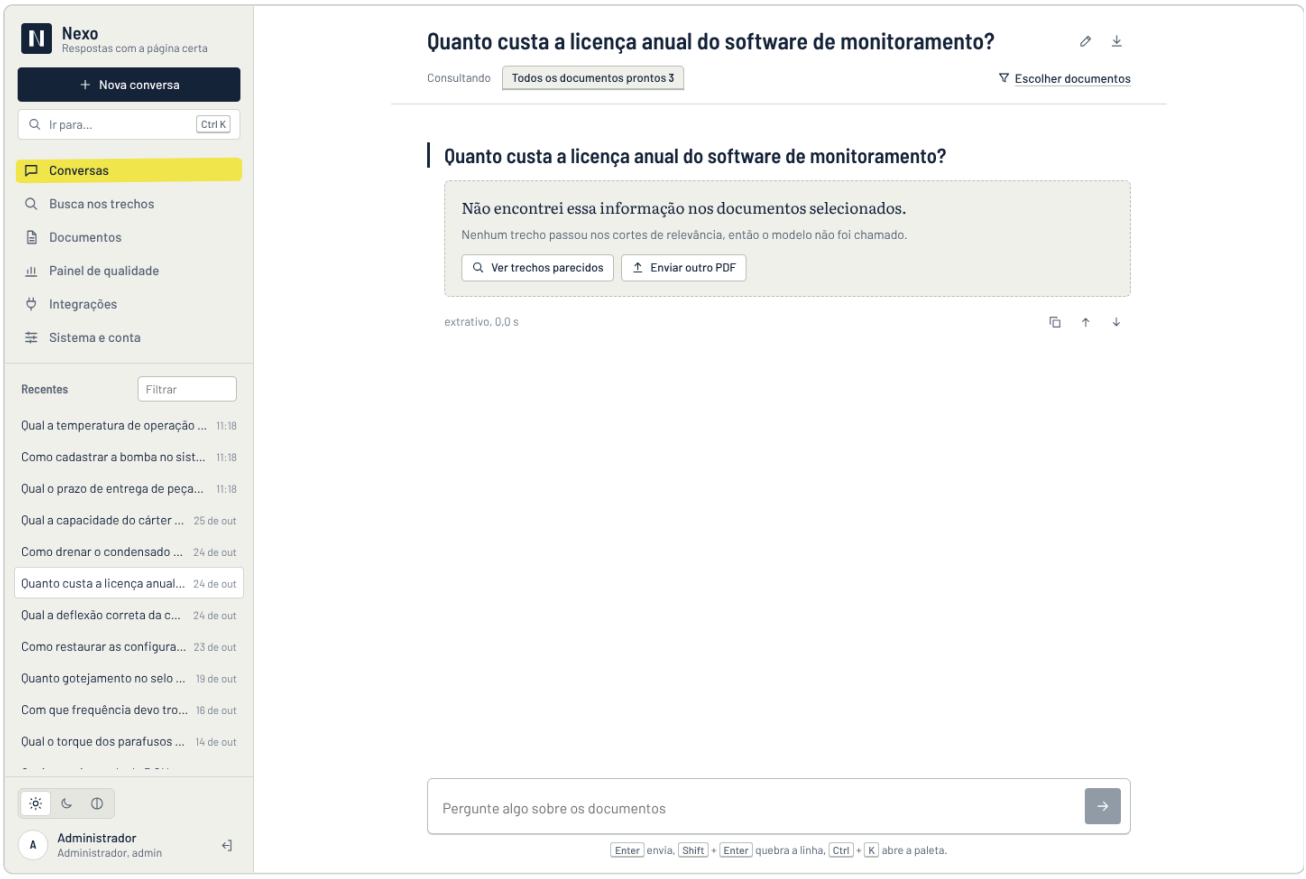


Figura 4 — Pergunta fora do conteúdo dos documentos: o Nexo responde que não encontrou e sugere como reformular.

Se nenhum trecho passar pelos cortes de relevância, o modelo nem é chamado e a resposta aparece num quadro marcado com um ponto de aviso, com sugestões para reformular. Isso é o comportamento esperado: o Nexo prefere não responder a responder sem base. A pergunta entra na lista de lacunas do painel de qualidade e, se houver webhook inscrito, dispara o evento `question.unanswered`.

Copyright (©) 2026 Erik Pimenta

4.3 Busca nos trechos Novo

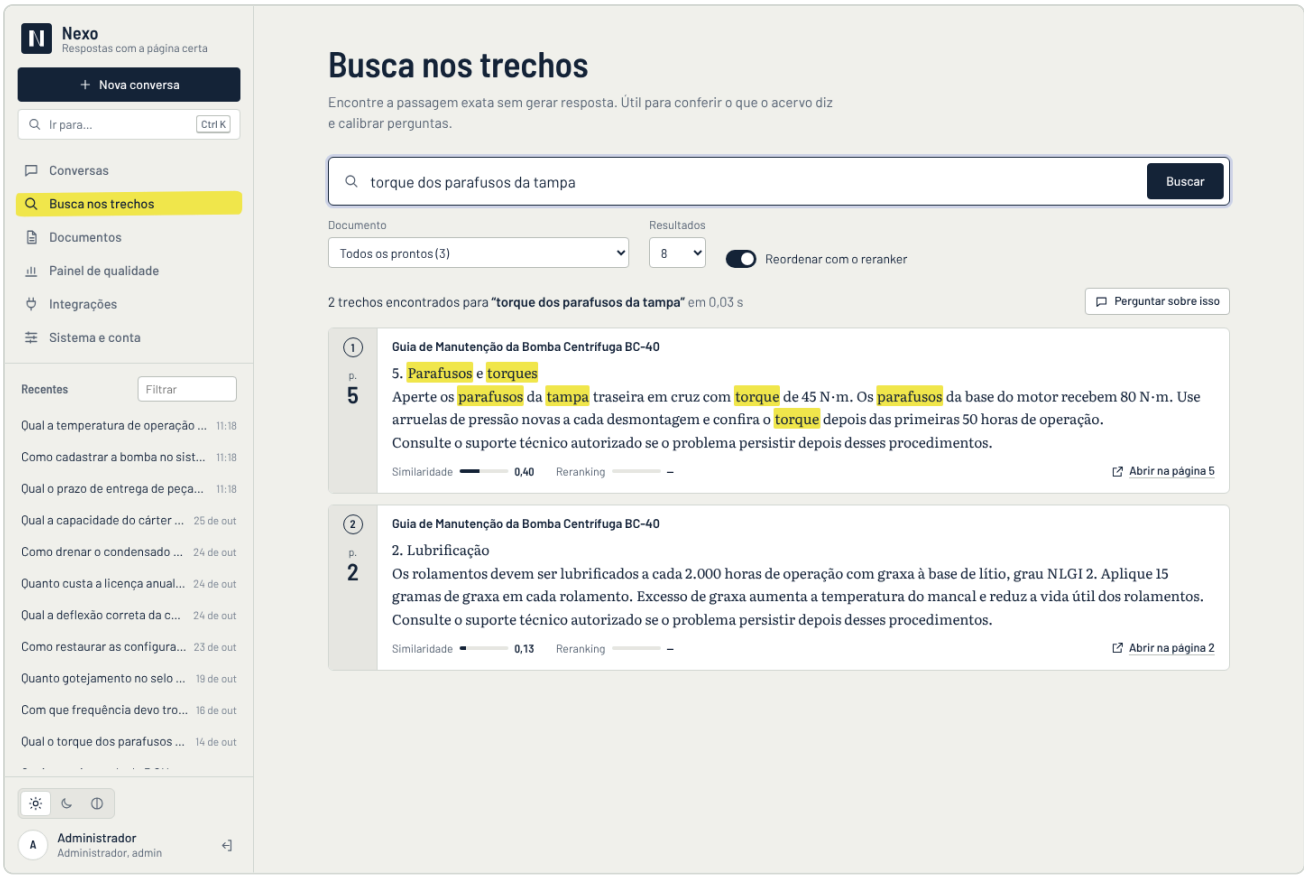


Figura 5 — Busca nos trechos: resultados em ordem de relevância, com documento, página, similaridade, nota do reranker e o trecho.

A busca mostra o que o acervo tem sobre um assunto sem chamar o modelo de linguagem. É rápida, não gasta tokens e serve para conferir se um assunto está nos PDFs antes de perguntar, ou para calibrar os cortes de relevância.

1. Abra **Busca** no menu lateral.
2. Escreva o que procura (até 500 caracteres) e, se quiser, limite a busca a alguns documentos.
3. Deixe **Reordenar com o reranker** ligado para a ordem mais precisa, ou desligue para ver a ordem da busca vetorial pura.
4. Escolha quantos resultados quer ver (1 a 20; o padrão é 8) e tecle `Enter`.
5. Clique num resultado para abrir o PDF na página do trecho.

Sem nenhum documento pronto, a busca avisa que é preciso enviar e indexar um PDF antes. O tempo gasto aparece acima dos resultados.

Copyright (©) 2026 Erik Pimenta

4.4 Documentos

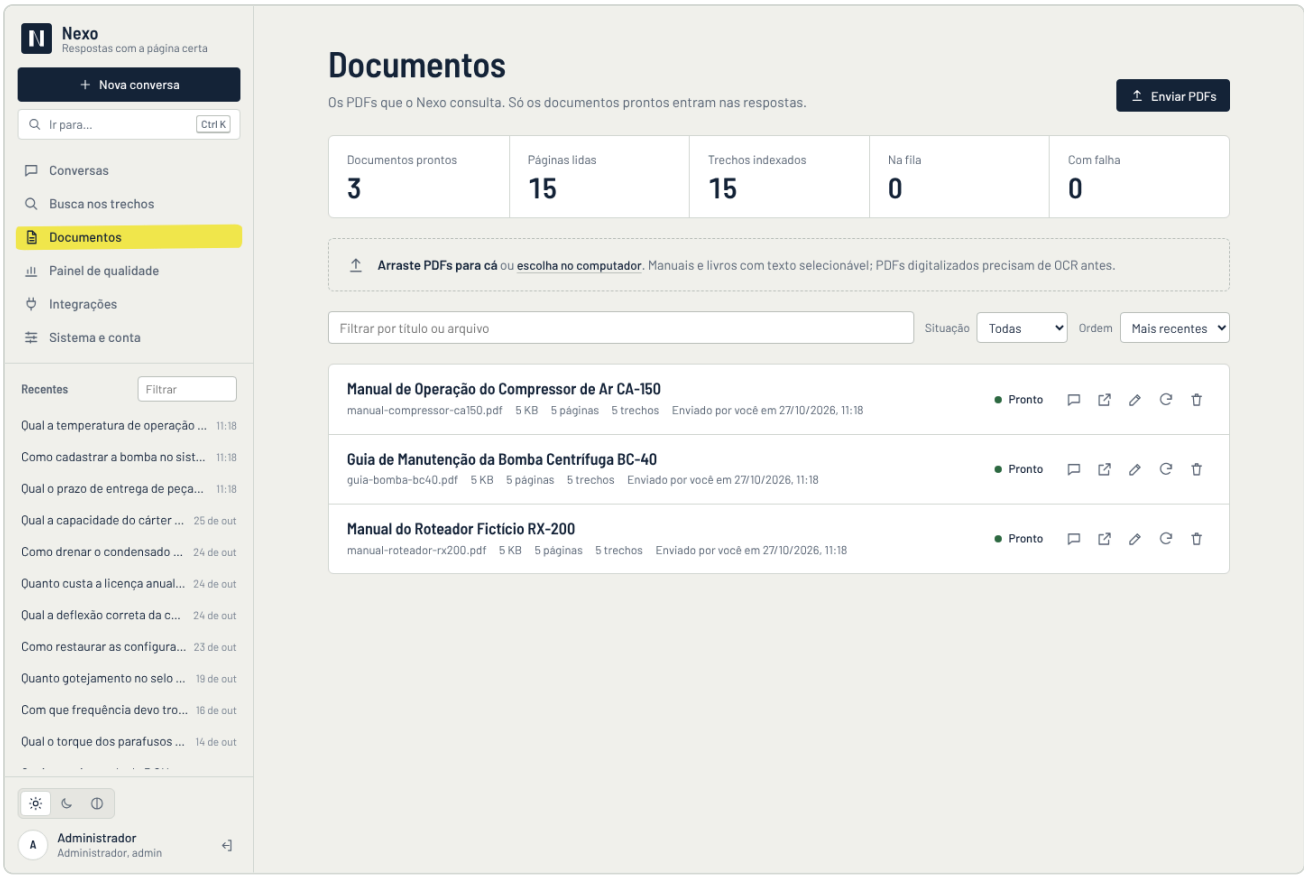


Figura 6 — Documentos: o resumo do acervo, a área de envio e a lista com páginas, trechos, autor do envio, filtro, ordenação e ações.

1. Arraste PDFs para a área **Arraste PDFs para cá** ou clique em **Escolher PDFs**.
2. Cada arquivo entra como **Na fila**, passa a **Indexando** e termina em **Pronto**. Uma barra indica o trabalho em andamento.
3. Se aparecer **Falhou**, o motivo fica logo abaixo do título. O caso mais comum é PDF digitalizado sem texto: aplique OCR e envie de novo.
4. Use os ícones à direita para abrir o PDF, renomear, reindexar e excluir. Renomear reindexa, porque o título faz parte da busca.

O resumo no topo mostra trechos indexados, documentos prontos, páginas lidas, arquivos na fila e com falha, e se atualiza sozinho enquanto há documentos sendo indexados. Use o filtro para achar um documento pelo título ou nome do arquivo e a situação (prontos, indexando, na fila, com falha) e a ordem (mais recentes, título ou mais páginas) para organizar a lista.

Copyright (©) 2026 Erik Pimenta

4.5 Painel de qualidade Novo

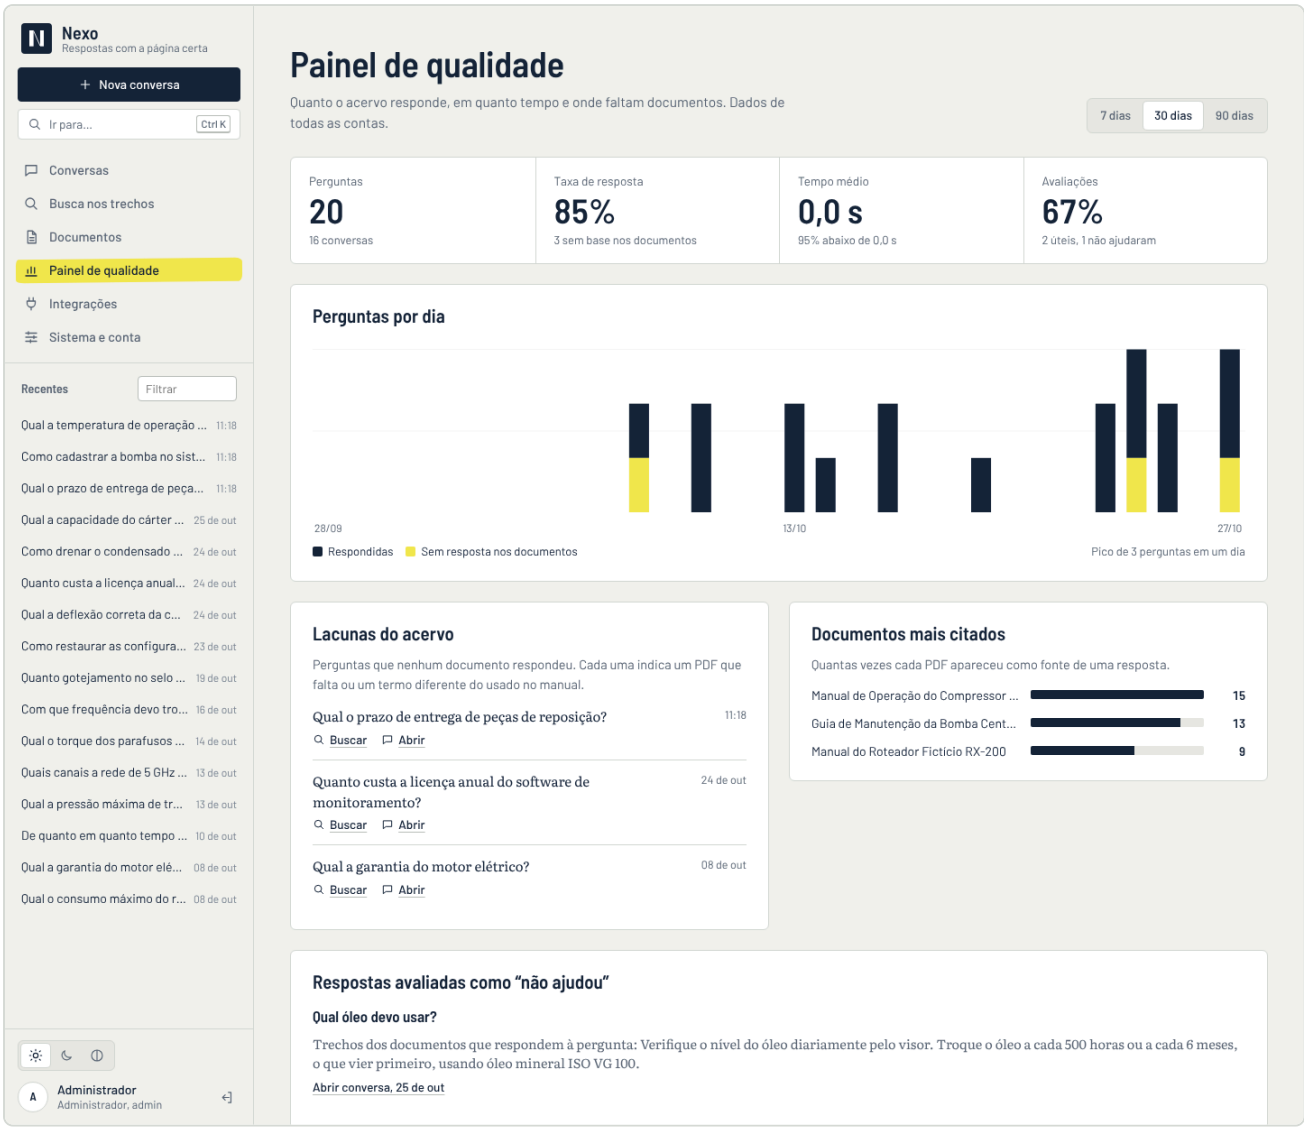


Figura 7 — Painel de qualidade com os números do período, o gráfico diário e as lacunas do acervo.

O painel responde a duas perguntas: o Nexo está respondendo bem? E o que falta no acervo? O administrador vê os números de todas as conversas; os demais usuários veem só os das próprias conversas. Escolha o período (1 a 365 dias; o padrão é 30).

Indicador	Como ler
Perguntas	Total de perguntas feitas no período
Taxa de resposta	Respondidas ÷ perguntas. Caindo, o acervo não cobre o que as pessoas procuram ou os cortes estão altos
Latência média e p95	Tempo de resposta típico e o dos 5% mais lentos
Avaliações	Respostas marcadas como úteis e como "não ajudou"
Conversas	Conversas com atividade no período
Por dia	Perguntas e perguntas sem resposta de cada dia, do mais antigo ao mais novo

Copyright (©) 2026 Erik Pimenta

Indicador	Como ler
Documentos mais citados	Os seis documentos que mais embasaram respostas
Lacunas do acervo	As 10 perguntas sem resposta mais recentes, com link para a conversa
Avaliações negativas	As 10 respostas mais recentes marcadas como "não ajudou", com a pergunta

Rotina sugerida. Uma vez por semana, leia as lacunas. Se a pergunta é legítima e o assunto não está nos PDFs, envie o documento que falta. Se está, confira na busca nos trechos se os cortes estão descartando o trecho certo.

4.6 Integrações Novo

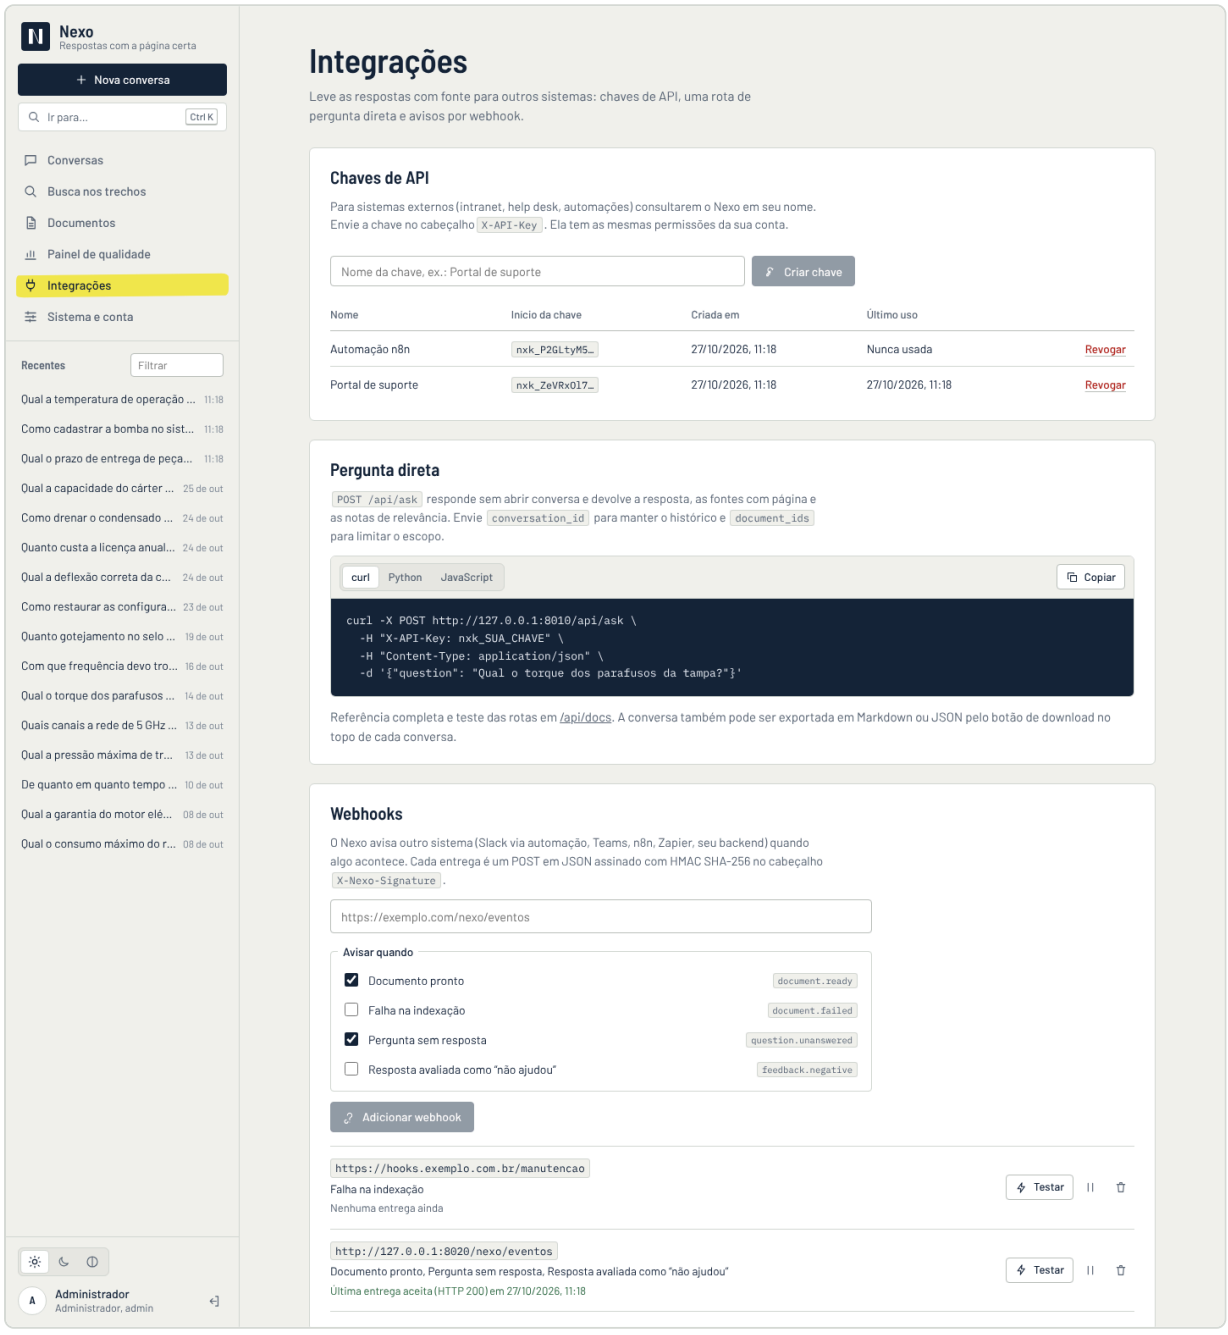


Figura 8 — Integrações: chaves de API do usuário, exemplos prontos em curl, Python e JavaScript e, para administradores, os webhooks.

Copyright (©) 2026 Erik Pimenta

Criar uma chave de API

1. Abra **Integrações** e, em **Chaves de API**, escreva um nome que diga onde a chave será usada, por exemplo "Portal interno".
2. Clique em **Criar chave**.
3. Copie a chave exibida. Ela começa com `nxk_` e aparece **uma única vez**; depois a tela mostra só o prefixo.
4. Guarde a chave no cofre de segredos do sistema que vai usá-la e teste com um dos exemplos da tela.

A lista mostra nome, prefixo, data de criação e último uso de cada chave. **Revogar** apaga a chave na hora; pedidos com ela passam a receber 401 `INVALID_API_KEY`.

Cadastrar um webhook (administrador)

1. Na seção **Webhooks**, informe a URL `http` ou `https` que vai receber os avisos.
2. Em **Avisar quando**, marque ao menos um evento e clique em **Adicionar webhook**.
3. Copie o segredo de assinatura exibido (ele aparece uma única vez): o receptor precisa dele para conferir a assinatura. Pela API, é possível informar o próprio segredo no campo `secret`.
4. Clique em **Testar**. O Nexo entrega o evento `ping` na hora e mostra o status HTTP ou o erro.

Cada webhook mostra o resultado da última entrega e pode ser pausado e reativado sem perder a configuração. Os detalhes técnicos estão no capítulo 5.

Copyright (©) 2026 Erik Pimenta

4.7 Sistema e conta

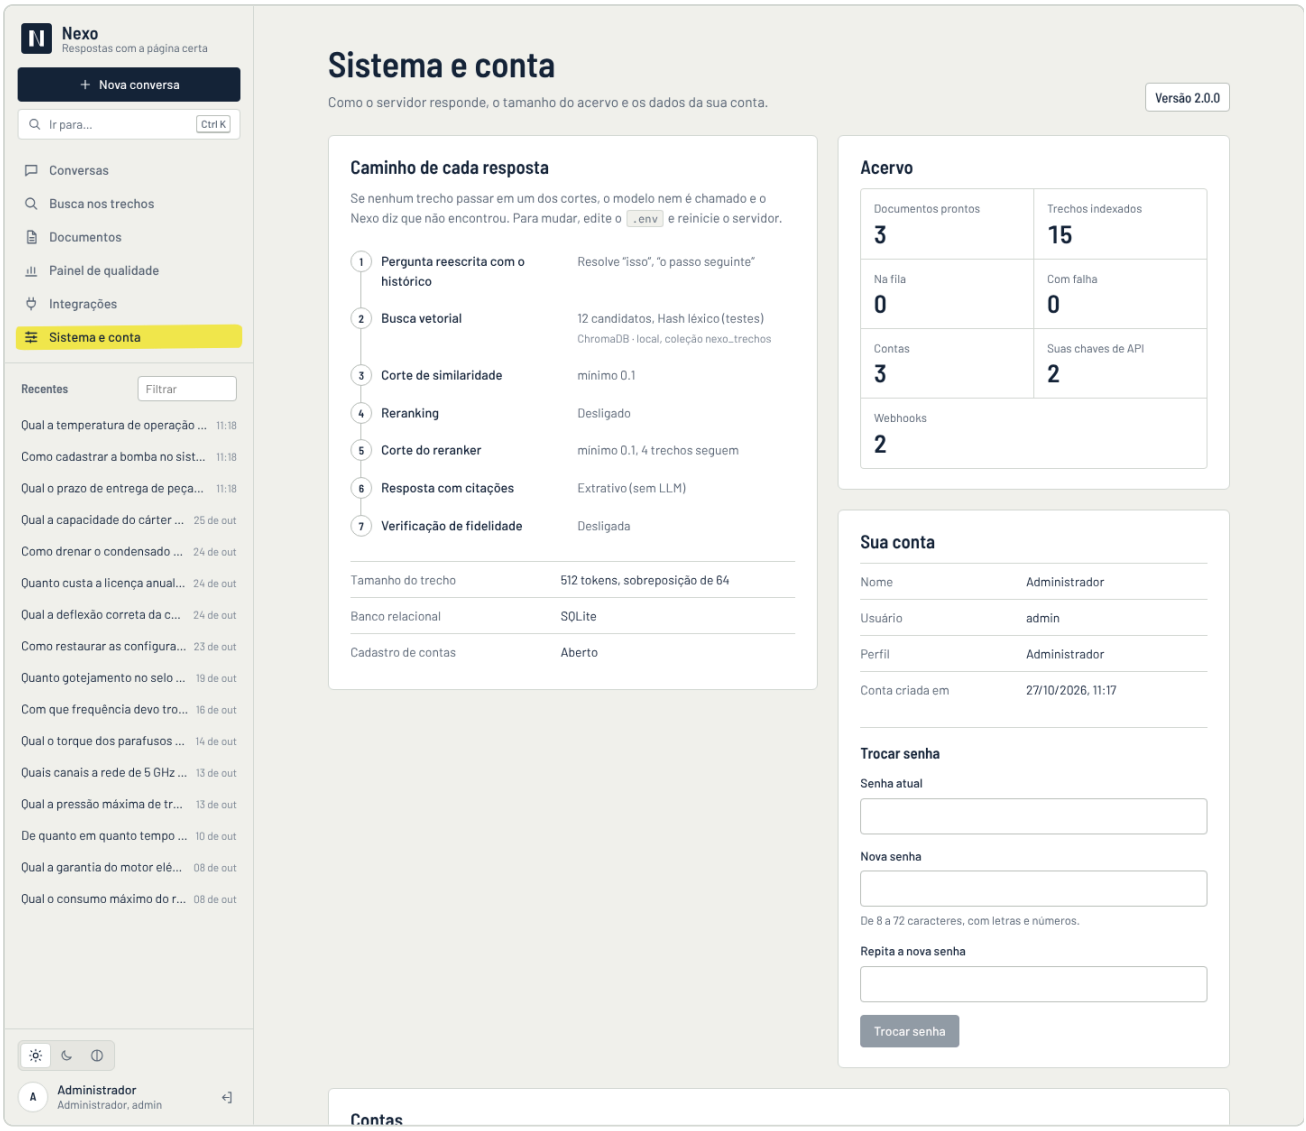


Figura 9 — Sistema e conta: o pipeline em fluxo com os provedores em uso, os números do acervo e das integrações e os dados da conta.

A tela mostra o pipeline na ordem em que a pergunta passa por ele (embeddings, banco vetorial, reranker, modelo de linguagem) com os parâmetros de busca, a contagem de documentos e trechos e as integrações: quantas chaves de API o usuário tem e, para administradores, quantos webhooks existem. Na seção **Sua conta** fica a troca de senha (8 a 72 caracteres, com letras e números, sem conter o nome de usuário).

Gestão de contas (administrador)

O administrador vê a lista de contas com perfil, data de criação e último acesso, e pode:

- **Promover** um usuário a administrador ou **rebaixar** um administrador a usuário.
- **Excluir** uma conta. A exclusão apaga também as chaves de API e as conversas dela.

Proteções. Ninguém rebaixa nem exclui a própria conta, e o último administrador não pode ser rebaixado. Assim o Nexo nunca fica sem alguém capaz de administrá-lo.

Copyright (©) 2026 Erik Pimenta

4.8 Paleta de comandos e atalhos Novo

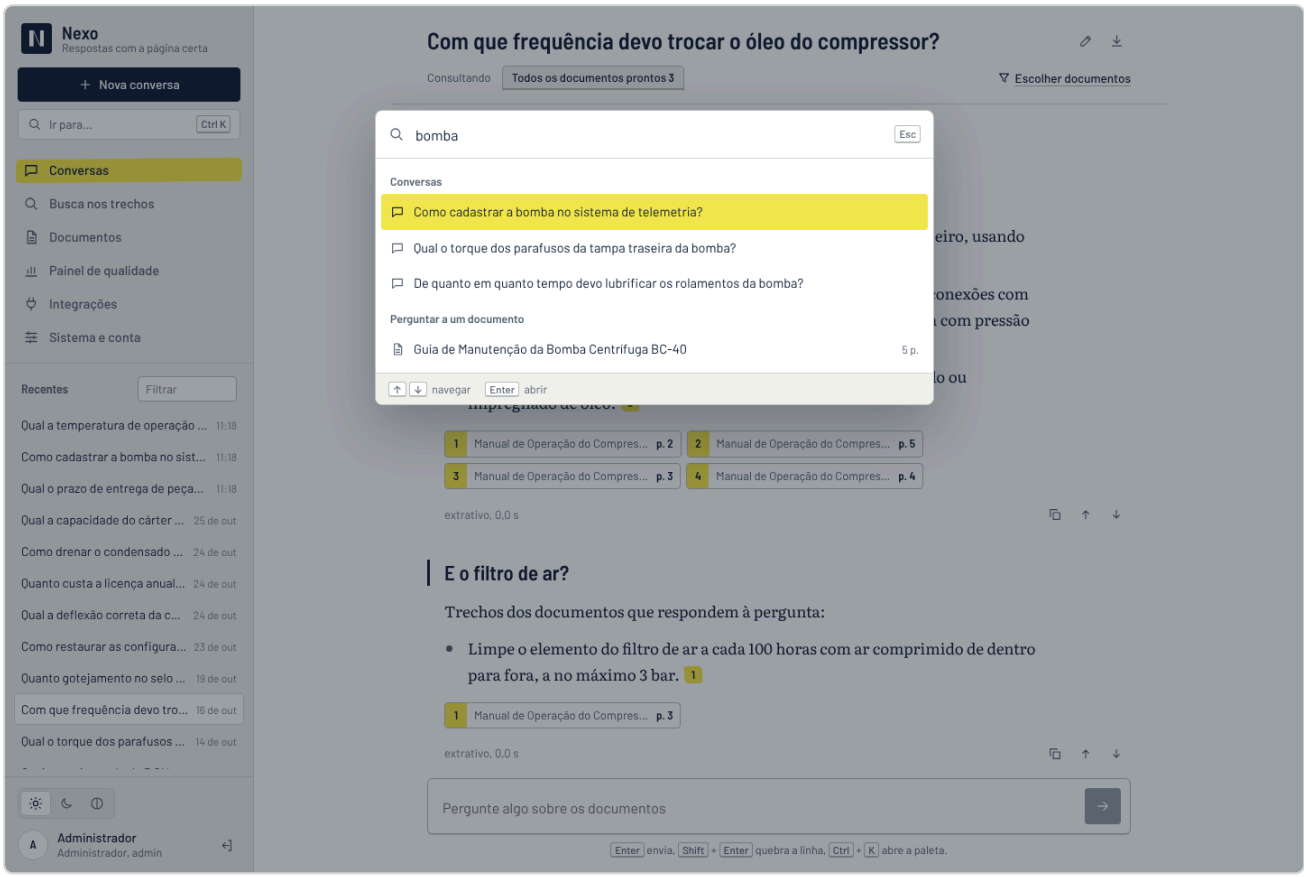


Figura 10 — Paleta de comandos aberta com Ctrl + K sobre a tela de conversas.

Tecle Ctrl + K em qualquer tela, escreva parte do nome do que procura e tecle Enter. A paleta leva a qualquer tela e executa as ações principais, como abrir uma nova conversa ou trocar o tema, sem tirar as mãos do teclado.

Atalho	O que faz
Ctrl + K	Abre a paleta de comandos
Setas para cima e para baixo e Enter	Escolhem e executam um comando da paleta
Esc	Fecha a paleta
Enter	Envia a pergunta na conversa e a busca na tela de busca
Shift + Enter	Quebra a linha na pergunta

Copyright (©) 2026 Erik Pimenta

4.9 Tema e celular



Figura 11 — Tema escuro: papel azul-noite, folha um tom acima e o mesmo marca-texto nas citações.

O menu lateral tem três opções de tema: **Claro**, **Escuro** e **Automático**, que segue a preferência do sistema operacional e muda sozinho quando ela muda. A escolha fica guardada no navegador.

Copyright (©) 2026 Erik Pimenta

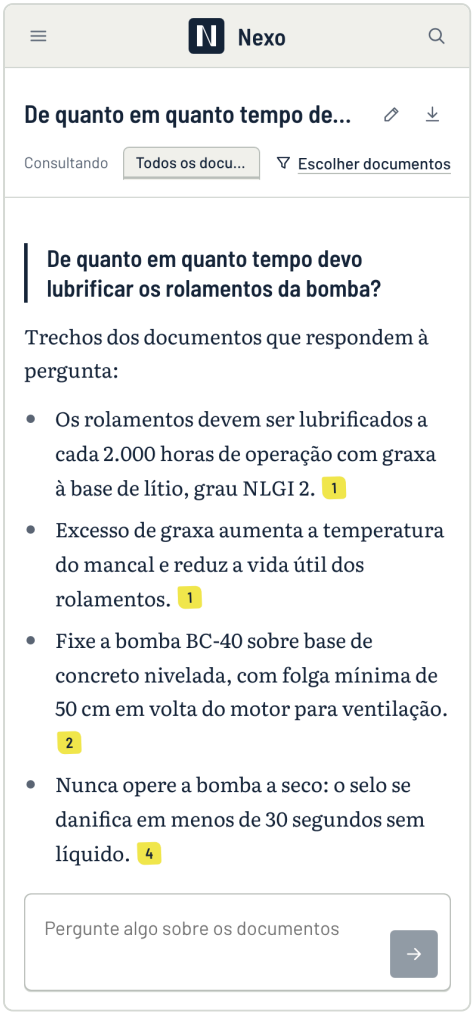


Figura 12 — Conversa no celular, com o menu recolhido.

No celular

- O menu lateral recolhe para o botão no topo.
- A lista de conversas abre pelo botão **Conversas**.
- Conversa, citações em marca-texto e escolha de documentos ficam numa coluna só.

A captura ao lado foi feita com 390 px de largura. Não há aplicativo separado: é a mesma interface, servida pelo mesmo endereço.

Copyright (©) 2026 Erik Pimenta

05

Integrações

Outros sistemas podem perguntar ao Nexo, buscar nos trechos e receber avisos. Este capítulo mostra como autenticar com uma chave de API, como usar a pergunta direta e como receber e conferir webhooks.

5.1 Autenticação por chave de API

Toda rota que aceita a sessão da interface também aceita uma chave de API. Envie a chave num destes cabeçalhos:

```
X-API-Key: nxk_Q2x5...                      # recomendado
Authorization: Bearer nxk_Q2x5...           # alternativa, para clientes que só enviam Bearer
```

- A chave age em nome de quem a criou, com as mesmas permissões. Uma chave de administrador pode tudo o que o administrador pode.
- Formato: `nxk_` seguido de 43 caracteres. O **prefixo** (os 12 primeiros caracteres) identifica a chave nas telas sem expô-la.
- O Nexo guarda só o hash SHA-256 da chave. Se ela se perder, revogue e crie outra: não há como recuperá-la.
- Cada uso atualiza a data de último uso. Chave inválida ou revogada recebe 401 `INVALID_API_KEY`. Excluir a conta apaga as chaves dela.

Método	Rota	O que faz
GET	`/api/keys`	Lista as chaves do usuário: `id`, `name`, `prefix`, `created_at`, `last_used_at`
POST	`/api/keys`	Cria uma chave. Corpo `{"name": "..."}` (1 a 80 caracteres). Devolve 201 com o campo `key`, exibido só aqui
DELETE	`/api/keys/{id}`	Revoga a chave. Só o dono. Devolve 204

5.2 Pergunta direta: /api/ask

Uma chamada, uma resposta com fontes. Sem `conversation_id`, a pergunta é respondida **sem estado**: nada é gravado no banco. Com `conversation_id`, o Nexo usa o histórico daquela conversa e grava pergunta e resposta, exatamente como no chat.

Campo do corpo	Tipo	Regra
`question`	texto	Obrigatório, 1 a 4000 caracteres
`document_ids`	lista de ids	Opcional. Vazio consulta todos os documentos prontos

Copyright (©) 2026 Erik Pimenta

Campo do corpo	Tipo	Regra
`conversation_id`	id ou null	Opcional. Conversa do próprio usuário cujo histórico será usado e onde a troca será gravada

curl

```
curl -X POST http://127.0.0.1:8000/api/ask \
  -H "X-API-Key: $NEXO_CHAVE" \
  -H "Content-Type: application/json" \
  -d '{"question": "Qual a temperatura de operação do equipamento?"}'
```

Resposta

```
{
  "answer": "A faixa de operação vai de 5 °C a 40 °C [1].",
  "answered": true,
  "grounded": null,
  "model": "llama3.1",
  "latency_ms": 2140,
  "conversation_id": null,
  "sources": [
    { "rank": 1, "document_id": "3f2a…", "document_title": "Manual de exemplo",
      "page": 5, "similarity": 0.71, "rerank_score": 0.93,
      "excerpt": "Temperatura de operação: 5 °C a 40 °C…" }
  ]
}
```

Quando nada relevante é encontrado, `answered` vem `false`, `sources` vem vazia e `answer` traz a resposta padrão. `grounded` só é preenchido com `NEXO_VERIFY_ANSWERS=true`.

Python

```
import os
import requests   # pip install requests

resp = requests.post(
    "http://127.0.0.1:8000/api/ask",
    headers={"X-API-Key": os.environ["NEXO_CHAVE"]},
    json={"question": "Como restaurar as configurações de fábrica?"},
    timeout=180,
)
resp.raise_for_status()
dados = resp.json()
print(dados["answer"])
for f in dados["sources"]:
    print(f"[{f['rank']}] {f['document_title']}, página {f['page']}")
```

Copyright (©) 2026 Erik Pimenta

JavaScript (Node.js 18+ ou navegador)

```
const resp = await fetch("http://127.0.0.1:8000/api/ask", {
  method: "POST",
  headers: { "X-API-Key": process.env.NEXO_CHAVE, "Content-Type": "application/json" },
  body: JSON.stringify({ question: "Como restaurar as configurações de fábrica?" }),
});
if (!resp.ok) throw new Error((await resp.json()).message);
const dados = await resp.json();
console.log(dados.answer);
dados.sources.forEach(f => console.log(`[${f.rank}] ${f.document_title}, página ${f.page}`));
```

Tempo de resposta. A pergunta direta passa pelo mesmo pipeline do chat e pode levar o tempo do modelo de linguagem (até `NEXO_LLM_TIMEOUT`). Configure o tempo limite do cliente com folga.

5.3 Busca pela API

A busca nos trechos (seção 4.3) também está na API e não chama o modelo de linguagem.

```
curl -X POST http://127.0.0.1:8000/api/search \
  -H "X-API-Key: $NEXO_CHAVE" -H "Content-Type: application/json" \
  -d '{"query": "torque dos parafusos", "limit": 5, "rerank": true}'
```

A resposta traz `query`, `took_ms` e `results`, cada um com `rank`, `document_id`, `document_title`, `page`, `similarity`, `rerank_score` e `excerpt`. Sem documento pronto, devolve 409 `NO_DOCUMENTS`.

5.4 Webhooks

Webhooks avisam outro sistema quando algo acontece no Nexo. Só administradores cadastram webhooks; para os demais, as rotas devolvem 403 `FORBIDDEN`.

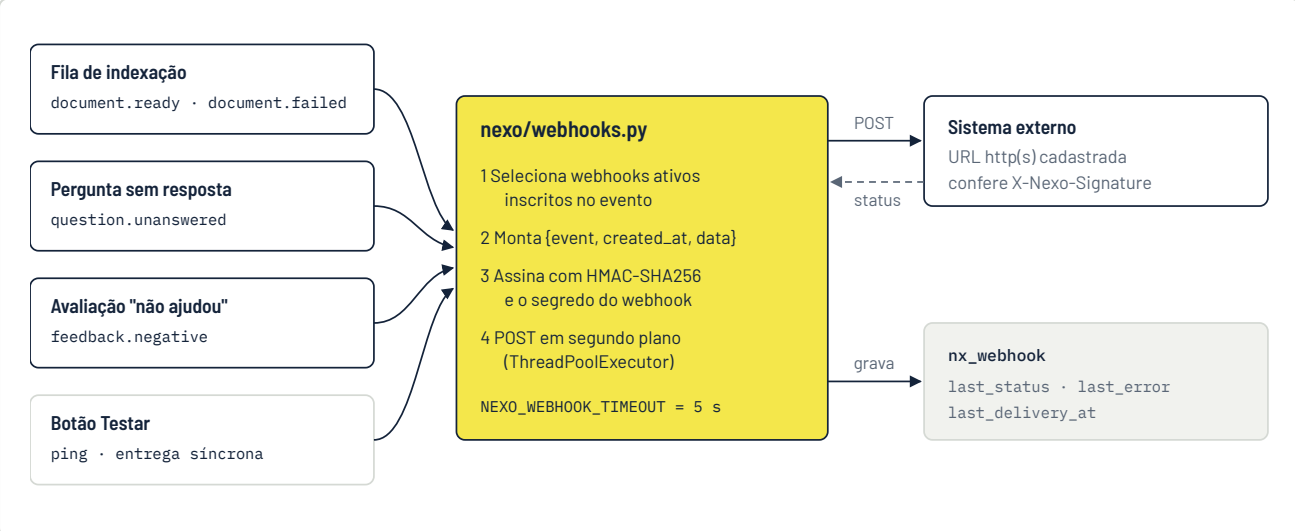


Figura 13 — De onde vêm os eventos, o que o módulo de webhooks faz e onde o resultado de cada entrega é gravado.

Copyright (©) 2026 Erik Pimenta

Evento	Quando	Dados em `data`
`document.ready`	Um documento termina de indexar	`id`, `title`, `pages`, `chunks`
`document.failed`	A indexação de um documento falha	`id`, `title`, `error`
`question.unanswered`	Uma pergunta fica sem resposta (`answered = false`), no chat ou em `/api/ask`	`question`, `conversation_id` (nulo em `/api/ask` sem conversa), `username`
`feedback.negative`	Uma avaliação passa a ser "não ajudou" (rating –1); repetir –1 não dispara de novo	`message_id`, `question`, `answer`, `username`
`ping`	Botão **Testar** ou `POST /api/webhooks/{id}/test`	Entrega de teste, síncrona

Formato da entrega

Cada entrega é um `POST` com corpo JSON de três campos: `event`, `created_at` e `data`.

```
POST /recebe-nexo HTTP/1.1
Content-Type: application/json
User-Agent: Nexo/2.0.0
X-Nexo-Event: document.ready
X-Nexo-Signature: sha256=5d2b0c9e...

{"event": "document.ready",
 "created_at": "2026-10-27T14:32:08+00:00",
 "data": {"id": "3f2a…", "title": "Manual de exemplo", "pages": 12, "chunks": 41}}
```

Cabeçalho	Conteúdo
`Content-Type`	`application/json`
`User-Agent`	`Nexo/<versão>`, por exemplo `Nexo/2.0.0`
`X-Nexo-Event`	O nome do evento, igual ao campo `event` do corpo
`X-Nexo-Signature`	`sha256=` seguido do HMAC-SHA256 do corpo, em hexadecimal, calculado com o segredo do webhook

As entregas saem em segundo plano, sem atrasar a resposta ao usuário, e cada uma espera no máximo `NEXO_WEBHOOK_TIMEOUT` segundos (5 por padrão). Cada evento é entregue uma vez. O status HTTP, o erro e a data da última entrega ficam gravados no webhook e aparecem na tela Integrações.

Conferindo a assinatura

O receptor deve recalcular o HMAC sobre o **corpo bruto**, exatamente como chegou, antes de interpretar o JSON, e comparar em tempo constante. Pedidos com assinatura diferente devem ser recusados.

Copyright (©) 2026 Erik Pimenta

Python

```python
import hashlib
import hmac

def assinatura_valida(corpo: bytes, cabecalho: str, segredo: str) -> bool:
    esperado = "sha256=" + hmac.new(segredo.encode(), corpo, hashlib.sha256).hexdigest()
    return hmac.compare_digest(esperado, cabecalho or "")

# Exemplo com FastAPI
@app.post("/recebe-nexo")
async def recebe(request: Request):
    corpo = await request.body()
    if not assinatura_valida(corpo, request.headers.get("X-Nexo-Signature", ""), SEGREDO):
        raise HTTPException(401, "assinatura inválida")
    evento = json.loads(corpo)
    ...
```

Node.js

```node
const crypto = require("node:crypto");
const express = require("express");

function assinaturaValida(corpo, cabecalho, segredo) {
  const esperado = "sha256=" + crypto.createHmac("sha256", segredo).update(corpo).digest("hex");
  const a = Buffer.from(esperado);
  const b = Buffer.from(cabecalho || "");
  return a.length === b.length && crypto.timingSafeEqual(a, b);
}

const app = express();
app.post("/recebe-nexo", express.raw({ type: "application/json" }), (req, res) => {
  if (!assinaturaValida(req.body, req.get("X-Nexo-Signature"), process.env.NEXO_SEGREDO)) {
    return res.status(401).send("assinatura inválida");
  }
  const evento = JSON.parse(req.body.toString("utf8"));
  res.sendStatus(204);
});
```

Rotas de webhooks

Método	Rota	O que faz
GET	`/api/webhooks`	Lista os webhooks com eventos, situação e resultado da última entrega
POST	`/api/webhooks`	Cria. Corpo `{"url", "events", "secret"}`; sem `secret`, um é gerado. Devolve 201 com o segredo
PATCH	`/api/webhooks/{id}`	Pausa ou reativa: `{"active": false}`
DELETE	`/api/webhooks/{id}`	Exclui. Devolve 204
POST	`/api/webhooks/{id}/test`	Entrega `ping` na hora e devolve `{"status", "error"}`

5.5 Boas práticas

- Uma chave por sistema integrado, com nome claro. Revogar uma não derruba as outras.

Copyright (©) 2026 Erik Pimenta

- Responda ao webhook rápido (em menos de `NEXO_WEBHOOK_TIMEOUT`) e faça o trabalho pesado depois, numa fila do seu lado.
- Use HTTPS na URL do webhook e confira a assinatura sempre, mesmo em rede interna.
- Use `question.unanswered` para abrir tarefas de curadoria do acervo, e `feedback.negative` para revisar respostas.

5.6 Exportação de conversas

O botão **Exportar** da conversa e a rota `GET /api/conversations/{id}/export` baixam a conversa inteira. O formato padrão é Markdown.

Formato	Arquivo	Conteúdo
`markdown`	`nexo-<título-da-conversa>.md`	Título, data e escopo; cada pergunta como um título `##`, a resposta e a lista "Fontes" com documento e página
`json`	`nexo-<título-da-conversa>.json`	O mesmo conteúdo de `GET /api/conversations/{id}`, mais `exported_at`

```
curl -OJ "http://127.0.0.1:8000/api/conversations/ID/export?format=markdown" \
  -H "X-API-Key: $NEXO_CHAVE"
```

Trecho de uma exportação em Markdown

```
# Manutenção da bomba

Exportada em 27/10/2026 · Consultando: Manual de exemplo

## Como restaurar as configurações de fábrica?

Mantenha o botão RESET pressionado por 10 segundos com o equipamento ligado [1].

Fontes
- [1] Manual de exemplo, página 2
```

O nome do arquivo usa uma versão simplificada do título (minúsculas, sem acentos, palavras separadas por hífen) e vem no cabeçalho `Content-Disposition`.

Copyright (©) 2026 Erik Pimenta

06

Arquitetura

O Nexo é um único processo Python que serve a API e a interface compilada. Os componentes pesados (modelos e banco vetorial) são plugáveis por configuração.

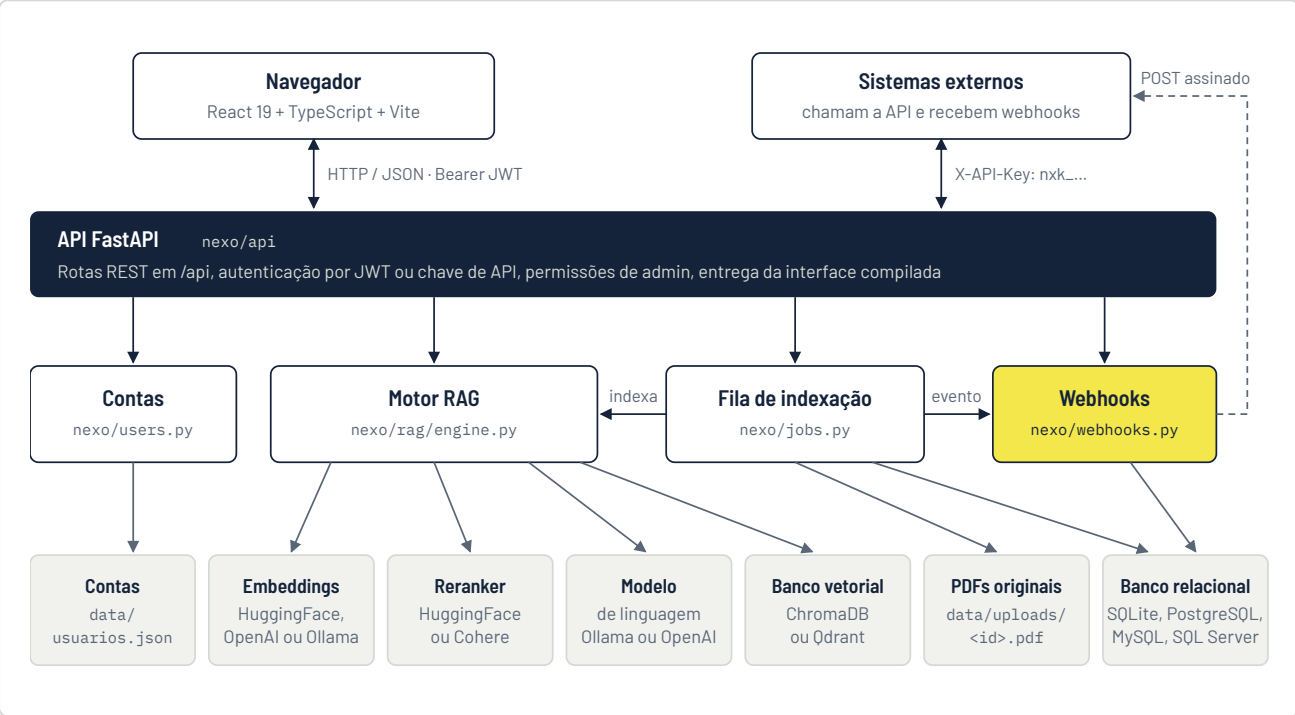


Figura 14 — Componentes do Nexo 2.0. A API autentica por sessão ou chave de API; o módulo de webhooks avisa sistemas externos. O banco relacional é usado pela API, pela fila e pelos webhooks.

6.1 Módulos do código

Arquivo	Responsabilidade
`nexo/config.py`	Lê o `.env` com pydantic-settings e define os caminhos em `data/`
`nexo/db.py`	Modelos SQLAlchemy das oito tabelas, criação automática e sessões
`nexo/users.py`	Contas em JSON: cadastro, autenticação com bcrypt, bloqueio após 5 erros, troca de senha, mudança de perfil e exclusão
`nexo/security.py`	Emissão e leitura de tokens JWT (HS256)
`nexo/api/deps.py`	Identifica o usuário do pedido pelo token JWT ou pela chave de API e confere o perfil de administrador
`nexo/jobs.py`	Fila de indexação em uma thread, retomada de pendências ao iniciar, disparo de `document.ready` e `document.failed`

Copyright (©) 2026 Erik Pimenta

Arquivo	Responsabilidade
`nexo/webhooks.py` **Novo**	Seleciona os webhooks do evento, assina com HMAC, entrega em segundo plano e grava o resultado
`nexo/rag/engine.py`	Leitura dos PDFs, divisão em trechos, indexação, busca, reranking, prompt e resposta
`nexo/rag/providers.py`	Fábrica de LLM, embeddings, banco vetorial e reranker conforme o `.env`
`nexo/rag/hash_embedding.py`	Embedding léxico sem rede, usado nos testes e no modo de teste
`nexo/api/routes.py`	Rotas REST de autenticação, documentos, conversas, busca, métricas, chaves, webhooks, contas e sistema
`nexo/api/app.py`	Aplicação FastAPI, tratamento de erros, cabeçalhos de segurança e entrega da interface
`frontend/src`	Interface React: páginas, componentes, cliente da API, paleta de comandos, temas e a identidade visual

6.2 Indexação de um PDF

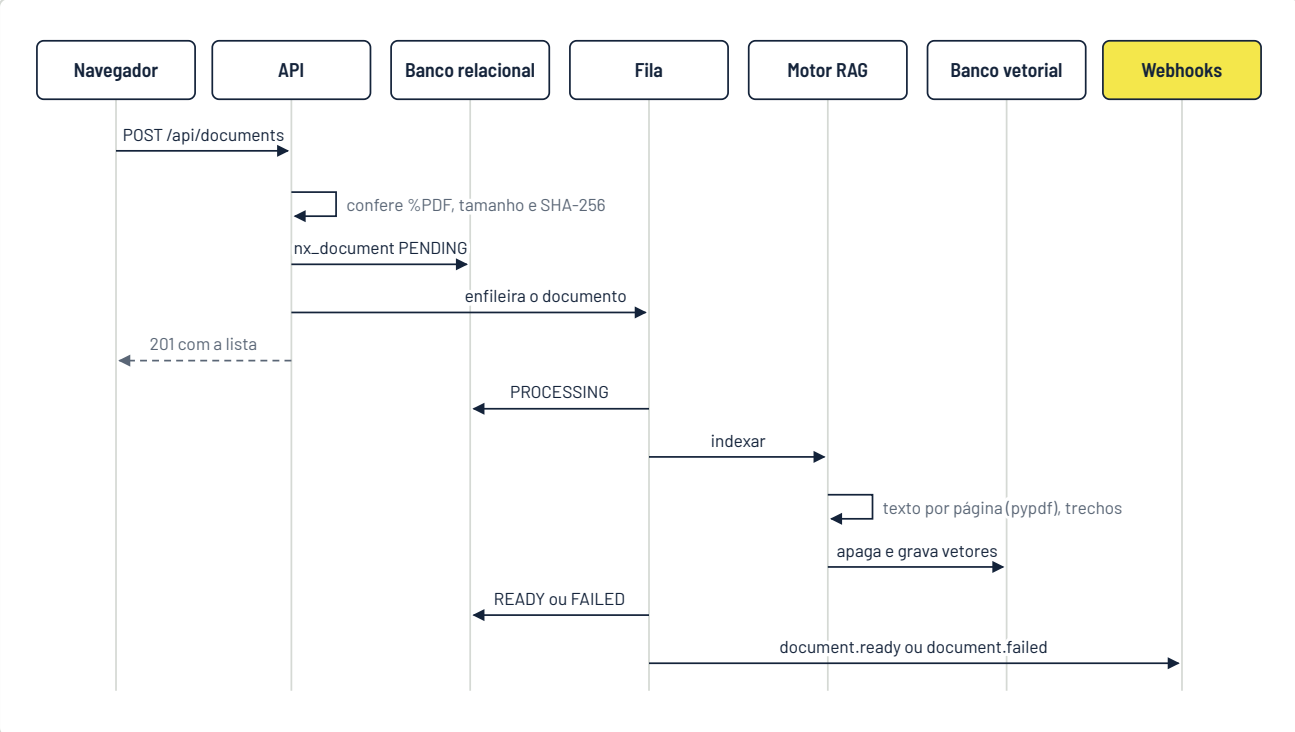


Figura 15 — Sequência do envio à indexação. A resposta ao navegador sai logo depois do enfileiramento; o resto acontece em segundo plano.

- O texto de cada página é extraído com pypdf, com hifenizações desfeitas e quebras de linha do layout unidas.
- O SentenceSplitter do LlamaIndex divide o texto em trechos de `NEXO_CHUNK_SIZE` tokens respeitando frases, com sobreposição para não perder contexto na fronteira.
- Cada trecho guarda `source_id`, `title`, `filename`, `page` e `chunk_index`. Só o título entra no texto do embedding, junto com o conteúdo.
- Reindexar apaga os vetores antigos do documento antes de gravar os novos, então nunca há duplicação.
- Ao terminar, a fila dispara `document.ready` ou `document.failed` para os webhooks inscritos.

Copyright (©) 2026 Erik Pimenta

6.3 Respondendo uma pergunta

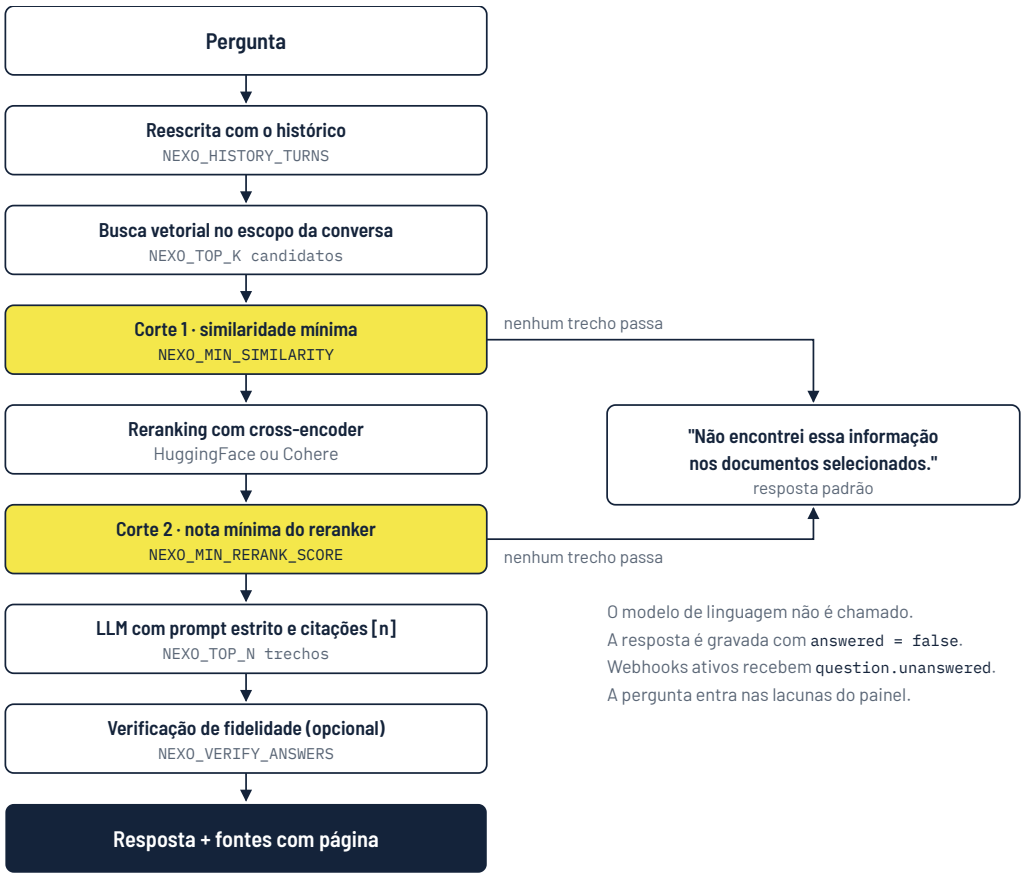


Figura 16 — Os dois cortes de relevância, em marca-texto, decidem se o modelo de linguagem é chamado. A busca nos trechos para no reranking e devolve os candidatos sem passar pelo modelo.

6.4 Como as alucinações são reduzidas

Mecanismo	Efeito
Cortes de similaridade e de reranking	Trechos fracos são descartados. Sem trechos, o LLM não é chamado e a resposta padrão é devolvida
Reranking com cross-encoder	Lê pergunta e trecho juntos e reordena os candidatos por relevância real, não só proximidade vetorial
Prompt estrito	Proíbe conhecimento próprio, exige citação [n] em cada afirmação e define a frase exata para quando falta base
Temperatura 0,1	Respostas estáveis e próximas do texto
Escopo por conversa	Evita misturar manuais de equipamentos diferentes
Verificação de fidelidade	Opcional: uma segunda chamada confere se a resposta é sustentada pelos trechos e marca a mensagem quando não é
Fontes gravadas	Cada resposta guarda os trechos usados, o que permite auditar respostas antigas
Painel de qualidade	Mostra as perguntas sem resposta e as respostas mal avaliadas, para corrigir o acervo e os cortes

Copyright (©) 2026 Erik Pimenta

6.5 Segurança

- Senhas guardadas só como hash bcrypt. Cinco erros seguidos bloqueiam o usuário por 5 minutos.
- Sessões com JWT assinado por `NEXO_SECRET`, com validade de `NEXO_TOKEN_HOURS` horas. A interface guarda o token só na aba aberta (`sessionStorage`).
- Chaves de API guardadas só como hash SHA-256, exibidas uma única vez e revogáveis a qualquer momento. Excluir uma conta apaga as chaves e as conversas dela.
- Webhooks assinados com HMAC-SHA256 e um segredo por webhook; cadastro restrito a administradores.
- Conversas visíveis apenas para o dono. Documentos só podem ser alterados por quem enviou ou por um administrador. O painel mostra a cada usuário só os próprios números.
- Gestão de contas restrita a administradores, sem permitir excluir a si mesmo nem ficar sem administrador.
- Uploads validados pelo cabeçalho `%PDF`, pelo tamanho e pelo SHA-256. Nomes de arquivo são saneados e os PDFs são gravados com o id interno.
- Cabeçalhos `X-Content-Type-Options`, `X-Frame-Options` e `Referrer-Policy` em todas as respostas. A API não é guardada em cache.
- Chaves de provedores ficam só no `.env`, que está no `.gitignore`. A interface não carrega nada de fora: fontes, ícones e scripts vêm do próprio servidor.

Copyright (©) 2026 Erik Pimenta

07

Banco de dados

Resumo da estrutura dos dados. As tabelas são criadas automaticamente; a versão detalhada, com índices, restrições, decisões de arquitetura, consultas e escala, está em `Banco-de-Dados-Nexo.pdf`.

7.1 Onde cada dado fica

Camada	Local padrão	Conteúdo
Banco relacional	`data/nexo.db`	Documentos, conversas, mensagens, fontes citadas, avaliações, chaves de API e webhooks
Banco vetorial	`data/chroma/ ou data/qdrant/`	Trechos, embeddings e metadados de origem
Arquivos	`data/uploads/<id>.pdf`	PDFs originais
Contas	`data/usuarios.json`	Usuários, perfis e hashes de senha
Segredo	`data/.segredo`	Chave das sessões quando `NEXO_SECRET` está vazio

Copyright (©) 2026 Erik Pimenta

7.2 Diagrama de relacionamentos

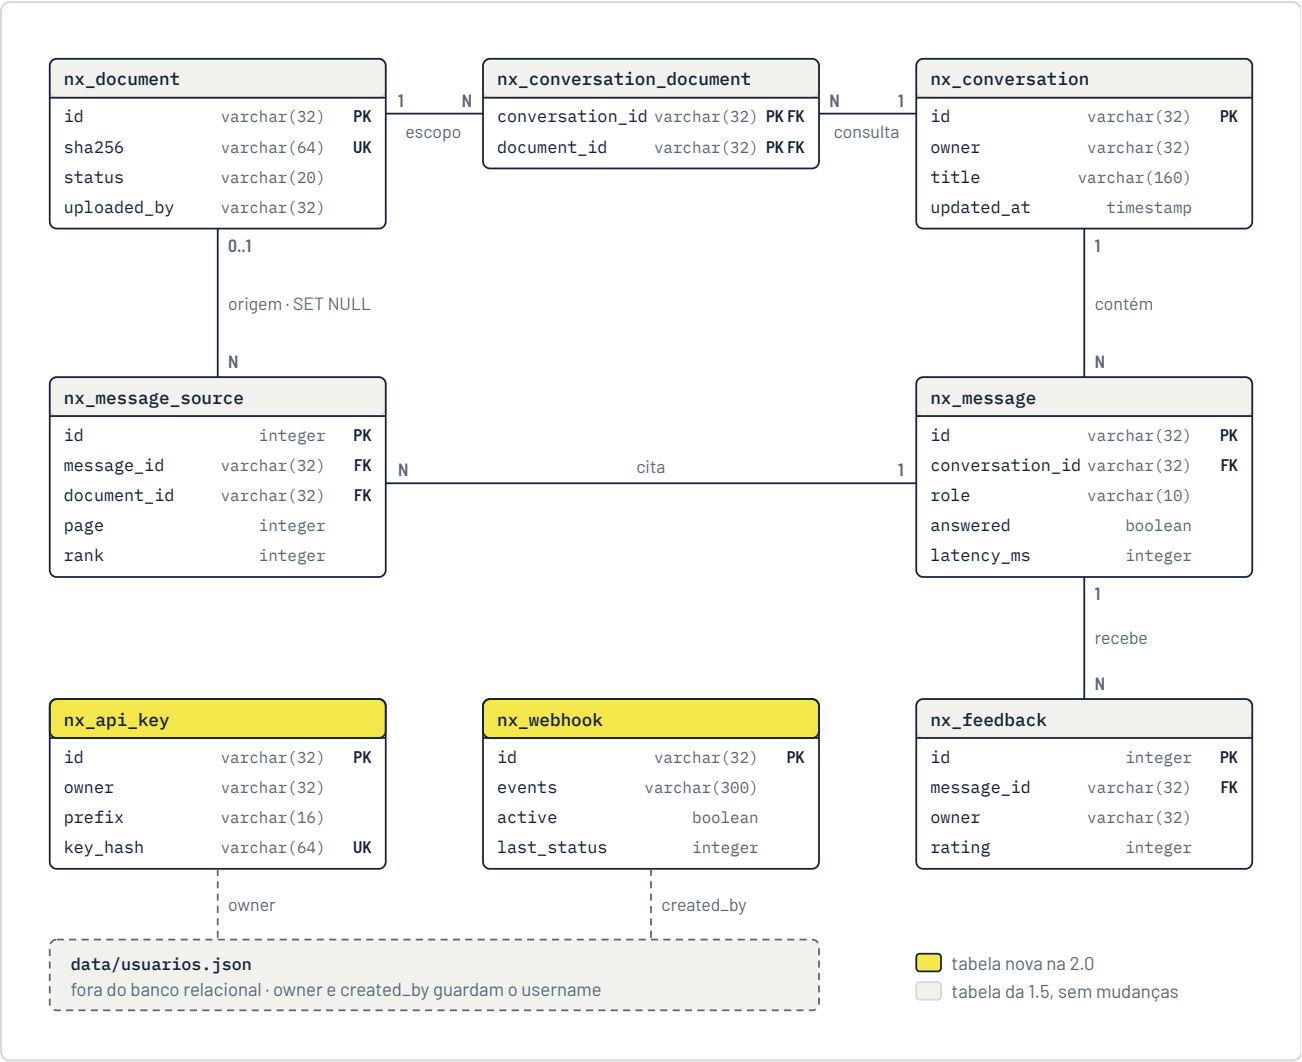


Figura 17 — As oito tabelas. As duas novas, de integração, não têm chave estrangeira: ligam-se às contas pelo nome de usuário.

7.3 Tabelas

nx_document · um registro por PDF enviado

Coluna	Tipo	Regra
`id`	`varchar(32)`	PK. UUID em hexadecimal; nome do arquivo em `data/uploads`
`title / filename`	`varchar(200) / (255)`	Título dos metadados do PDF ou nome do arquivo; nome original saneado
`sha256`	`varchar(64)`	Único. Bloqueia envios repetidos
`size_bytes / pages / chunks`	`integer`	Tamanho, páginas do PDF e trechos indexados
`status / error`	`varchar(20) / text`	PENDING, PROCESSING, READY ou FAILED (indexado) e o motivo da falha
`uploaded_by`	`varchar(32)`	Usuário que enviou (indexado)
`created_at / indexed_at`	`timestamp`	Envio e fim da indexação, em UTC

Copyright (©) 2026 Erik Pimenta

nx_conversation e nx_conversation_document · conversas e escopo

Coluna	Tipo	Regra
id / owner	varchar(32)	PK; usuário dono (indexado)
title	varchar(160)	Padrão "Nova conversa"; recebe a primeira pergunta
created_at / updated_at	timestamp	`updated_at` indexado para ordenar a lista
conversation_id + document_id	varchar(32)	Escopo: PK composta, FKs com ON DELETE CASCADE. Sem linhas, consulta todos os prontos

nx_message · perguntas e respostas

Coluna	Tipo	Regra
id / conversation_id	varchar(32)	PK; FK para `nx_conversation`, ON DELETE CASCADE
role / content	varchar(10) / text	`user` ou `assistant`; texto com as citações [n]
answered / grounded	boolean	Falso quando não encontrou; resultado da verificação de fidelidade
model / latency_ms	varchar(120) / integer	Modelo que respondeu e tempo gasto
created_at	timestamp	Índice composto com `conversation_id`

nx_message_source e nx_feedback · fontes citadas e avaliações

Coluna	Tipo	Regra
message_id	varchar(32)	FK para `nx_message`, ON DELETE CASCADE (nas duas tabelas)
document_id / document_title	varchar(32) / (200)	FK com ON DELETE SET NULL; cópia do título para o histórico
chunk_id / page / rank	varchar(80) / integer	Id do trecho no banco vetorial, página e número da citação
similarity / rerank_score / excerpt	float / text	Notas da busca e texto do trecho (até 1.200 caracteres)
owner / rating / comment	varchar(32) / int / text	Avaliação: 1 útil, −1 não ajudou; única por usuário e resposta

nx_api_key Novo · chaves de API

Coluna	Tipo	Regra
id	varchar(32)	PK
owner	varchar(32)	Usuário dono (indexado)
name / prefix	varchar(80) / (16)	Nome dado pelo usuário; 12 primeiros caracteres da chave
key_hash	varchar(64)	Único. SHA-256 da chave em hexadecimal; a chave nunca é gravada
created_at / last_used_at	timestamp	Criação e último uso (nulo até o primeiro uso)

nx_webhook Novo · destinos dos avisos

Coluna	Tipo	Regra
id / url	varchar(32) / (500)	PK; URL http(s) de destino

Copyright (©) 2026 Erik Pimenta

Coluna	Tipo	Regra
`events`	`varchar(300)`	Eventos inscritos, separados por vírgula
`secret / active`	`varchar(80) / boolean`	Segredo do HMAC; webhook ligado (padrão verdadeiro)
`created_by / created_at`	`varchar(32) / timestamp`	Administrador que cadastrou e quando
`last_status / last_error / last_delivery_at`	`int / text / timestamp`	Resultado da última entrega; nulos até a primeira

7.4 Coleção vetorial

Campo	Conteúdo
`id`	UUID v5 calculado de documento + posição do trecho
`embedding`	Vetor do modelo de `NEXO_EMBED_MODEL`, distância de cosseno
`document`	Texto do trecho
`metadata.source_id`	`nx_document.id` de origem; usado nos filtros de escopo e na exclusão
`metadata.title / filename / page / chunk_index`	Título, nome do arquivo, página (a partir de 1) e posição do trecho

7.5 Arquivo de usuários

```
{
  "versao": 1,
  "usuarios": [
    { "username": "admin", "name": "Administrador", "role": "admin",
      "password_hash": "$2b$12$...", "created_at": "2026-01-01T12:00:00+00:00",
      "last_login_at": null }
  ]
}
```

O arquivo é regravado de forma atômica. Nomes de usuário têm de 3 a 32 caracteres minúsculos (letras, números, ponto, hífen e sublinhado). O administrador muda perfis e exclui contas pela tela Sistema e conta; o login pré-definido só é recriado se não houver nenhum administrador. Para redefinir uma senha esquecida, rode `python scripts/redefinir_senha.py nome-do-usuario` no servidor.

7.6 Outro banco relacional

Banco	Driver	NEXO_DATABASE_URL
PostgreSQL	`pip install "psycopg[binary]"`	`postgresql+psycopg://usuario:senha@host:5432/nexo`
MySQL / MariaDB	`pip install pymysql`	`mysql+pymysql://usuario:senha@host:3306/nexo`
SQL Server	`pip install pyodbc`	`mssql+pyodbc://usuario:senha@host/nexo?driver=ODBC+Driver+18+for+SQL+Server`

O DDL de referência está em `docs/schema-postgresql.sql` e `docs/schema-sqlite.sql`. O resumo deste capítulo também está em `docs/banco-de-dados.md`.

Copyright (©) 2026 Erik Pimenta

08

API

A interface usa a mesma API REST que fica disponível para integrações. A documentação interativa (OpenAPI) abre em `http://127.0.0.1:8000/api/docs`.

8.1 Autenticação

Fora `/api/health`, `/api/auth/options`, `/api/auth/login` e `/api/auth/register`, todas as rotas exigem um destes cabeçalhos: `Authorization: Bearer <token JWT>`, recebido no login, ou uma chave de API em `X-API-Key` ou `Authorization: Bearer nxk_...` (seção 5.1). As rotas marcadas como admin devolvem 403 `FORBIDDEN` para os demais usuários.

8.2 Rotas

Método	Rota	Descrição
Sessão e conta		
GET	`/api/health`	Situação do servidor e versão
GET	`/api/auth/options`	Cadastro aberto e se o login pré-definido ainda está ativo
POST	`/api/auth/login`	Entrar. Devolve token, validade e usuário
POST	`/api/auth/register`	Criar conta e entrar
GET	`/api/auth/me`	Usuário da sessão
PUT	`/api/auth/password`	Trocar a própria senha
GET	`/api/system/status`	Configuração ativa, números do acervo e `integrations` (chaves do usuário; webhooks para admin)
Documentos		
GET	`/api/documents`	Listar documentos
POST	`/api/documents`	Enviar um ou mais PDFs (multipart, campo `files`)
GET	`/api/documents/{id}`	Detalhes de um documento
PATCH	`/api/documents/{id}`	Renomear (reindexa)
GET	`/api/documents/{id}/file`	Baixar o PDF original
POST	`/api/documents/{id}/reindex`	Reindexar
DELETE	`/api/documents/{id}`	Excluir PDF, vetores e escopos
Conversas, perguntas e busca		
GET	`/api/conversations`	Listar as conversas do usuário
POST	`/api/conversations`	Criar conversa, com `document_ids` opcional

Copyright (©) 2026 Erik Pimenta

Método	Rota	Descrição
GET / PATCH / DELETE	`/api/conversations/{id}`	Abrir com mensagens, renomear ou mudar escopo, excluir
GET	`/api/conversations/{id}/export` Novo	Exportar em `markdown` (padrão) ou `json`
POST	`/api/conversations/{id}/messages`	Perguntar. Devolve pergunta, resposta com fontes e conversa
POST	`/api/messages/{id}/feedback`	Avaliar resposta: rating 1, −1 ou 0 para remover
POST	`/api/ask` Novo	Pergunta direta para integrações, com ou sem conversa
POST	`/api/search` Novo	Busca nos trechos, sem o modelo de linguagem
GET	`/api/metrics?days=30` Novo	Painel de qualidade (1 a 365 dias). Admin vê tudo; demais, só as próprias conversas
Integrações e contas		
GET / POST	`/api/keys` Novo	Listar ou criar chaves de API do usuário
DELETE	`/api/keys/{id}` Novo	Revogar chave (só o dono)
GET / POST	`/api/webhooks` Novo	Listar ou criar webhooks (admin)
PATCH / DELETE	`/api/webhooks/{id}` Novo	Pausar, reativar ou excluir (admin)
POST	`/api/webhooks/{id}/test` Novo	Entregar `ping` na hora (admin)
GET	`/api/users` Novo	Listar contas (admin)
PATCH	`/api/users/{username}` Novo	Mudar perfil: `{"role": "admin"}` ou `"user"` (admin)
DELETE	`/api/users/{username}` Novo	Excluir conta (admin)

8.3 Exemplo com curl

```
curl -X POST http://127.0.0.1:8000/api/auth/login \
  -H "Content-Type: application/json" \
  -d '{"username": "admin", "password": "Nexo@2026"}'

curl -X POST http://127.0.0.1:8000/api/documents \
  -H "Authorization: Bearer SEU_TOKEN" \
  -F "files=@manual.pdf"

curl -X POST http://127.0.0.1:8000/api/conversations \
  -H "Authorization: Bearer SEU_TOKEN" \
  -H "Content-Type: application/json" -d '{}'

curl -X POST http://127.0.0.1:8000/api/conversations/ID/messages \
  -H "Authorization: Bearer SEU_TOKEN" \
  -H "Content-Type: application/json" \
  -d '{"content": "Como restaurar as configurações de fábrica?"}'

curl "http://127.0.0.1:8000/api/metrics?days=7" -H "X-API-Key: $NEXO_CHAVE"
```

8.4 Erros

Todo erro volta como JSON com `code`, `message` e, quando for de campo, `fields`:

Copyright (©) 2026 Erik Pimenta

```
{"code": "NO_DOCUMENTS", "message": "Envie e aguarde a indexação de ao menos um PDF antes de perguntar.", "fields": null}
```

HTTP	code	Quando
400	`EMPTY / NO_FILES / UNKNOWN_DOCUMENT`	Pergunta vazia, envio sem arquivos ou escopo com documento que não existe mais
400	`SELF / LAST_ADMIN`	Rebaixar ou excluir a própria conta, ou rebaixar o último administrador
400	`INVALID_URL / INVALID_EVENTS`	Webhook com URL que não é http(s) ou com lista de eventos vazia ou desconhecida
401	`UNAUTHENTICATED / SESSION_EXPIRED`	Sem credencial, usuário inexistente ou token vencido
401	`INVALID_API_KEY`	Chave de API inválida, revogada ou de conta excluída
401	`INVALID_CREDENTIALS`	Usuário ou senha errados no login
403	`FORBIDDEN / REGISTRATION_DISABLED`	Rota de administrador, ação sobre documento de outra pessoa ou cadastro fechado
404	`NOT_FOUND / FILE_MISSING`	Registro inexistente ou de outro usuário; PDF original ausente
409	`DUPLICATE / NO_DOCUMENTS / USERNAME_TAKEN`	PDF repetido, pergunta ou busca sem documentos prontos, usuário existente
413 / 415	`FILE_TOO_LARGE / NOT_A_PDF`	Arquivo grande demais ou que não é PDF
422	—	Corpo fora do formato (por exemplo `limit` fora de 1 a 20), com os campos em `fields`
429	`LOCKED`	Cinco senhas erradas seguidas
502 / 503	`LLM_FAILURE / PROVIDER`	Modelo fora do ar, ou pacote ou chave de provedor ausente

Copyright (©) 2026 Erik Pimenta

09

Qualidade e manutenção

Testes automatizados, medição da busca, acompanhamento pelo painel, integração contínua, backup e solução de problemas.

9.1 Testes automatizados

```
pip install -r requirements-ci.txt
python -m pytest
```

Os testes rodam sem internet nem modelos (embedding hash, modo extrativo, reranker desligado) e cobrem: login pré-definido, bloqueio após cinco erros, cadastro gravado no arquivo com bcrypt, validações de senha e usuário, troca e redefinição de senha, envio e indexação do PDF de exemplo, resposta com fonte e página corretas, pergunta fora do conteúdo, isolamento de conversas entre usuários, avaliação, rejeição de arquivos inválidos e duplicados, permissões de exclusão, remoção dos vetores, filtro de escopo, reordenação e corte do reranker e os scripts auxiliares. Na 2.0 entram também a busca nos trechos, a exportação, as métricas, as chaves de API, a pergunta direta, os webhooks e a gestão de contas.

9.2 Medindo a recuperação

Crie um arquivo JSONL com uma pergunta por linha e a página onde a resposta está:

```
{"pergunta": "Como restaurar as configurações de fábrica?", "documento": "manual-exemplo.pdf",
"pagina": 2}
{"pergunta": "Qual a temperatura de operação?", "documento": "manual-exemplo.pdf", "pagina": 5}
```

```
python scripts/avaliar.py exemplos/perguntas-exemplo.jsonl --detalhes
```

O script usa o banco e a configuração do `.env` e mostra, para a busca vetorial pura e com reranking, o **acerto** (a página certa apareceu entre os trechos enviados ao modelo) e o **MRR** (quanto mais perto do primeiro lugar, mais perto de 1). Repita depois de cada ajuste de parâmetros.

Do painel para o teste. As lacunas do painel de qualidade são boas candidatas a novas linhas do arquivo de avaliação: quando o documento certo é enviado, a pergunta passa a medir se o Nexo a encontra.

9.3 Integração contínua

O workflow `.github/workflows/ci.yml` roda os testes do Python e o build da interface a cada push e pull request.

Copyright (©) 2026 Erik Pimenta

9.4 Commit automático diário

O workflow `.github/workflows/diario.yml` acrescenta a data e a hora em `.github/atividade.txt` e faz um commit todos os dias às 11h37 de Brasília (14h37 UTC). Para ativar:

1. No repositório, abra **Settings › Secrets and variables › Actions › New repository secret**.
2. Crie `GIT_NAME` com o seu nome de usuário do GitHub e `GIT_EMAIL` com o e-mail da conta (ou o endereço `...@users.noreply.github.com`).
3. Em **Settings › Actions › General › Workflow permissions**, marque **Read and write permissions** e salve.
4. Em **Actions › Atividade diaria**, clique em **Run workflow** para testar.

9.5 Backup

Pare o servidor e copie a pasta `data` inteira. Ela contém tudo: banco SQLite (com chaves de API e webhooks), vetores locais, PDFs, usuários e segredo. Com bancos externos, faça também o backup deles pelas ferramentas próprias, no mesmo momento.

> **O backup contém segredos.** Os segredos dos webhooks ficam no banco, e `data/.segredo` assina as sessões. Guarde as cópias com o mesmo cuidado de uma senha.

9.6 Atualizando dependências

```
pip install --upgrade -r requirements.txt
cd frontend && npm update && npm run build
```

9.7 Solução de problemas

Sintoma	Causa provável	O que fazer
"O modelo não respondeu"	Ollama desligado ou modelo não baixado	Abra o Ollama e rode `ollama pull llama3.1`
"Instale o pacote ..."	Provedor configurado sem a biblioteca	`pip install` do pacote indicado na mensagem
"Defina OPENAI_API_KEY"	Provedor OpenAI sem chave	Preencha a chave no `.env` e reinicie
Documento em Falhou: sem texto	PDF digitalizado (imagem)	Aplique OCR (por exemplo OCRmyPDF) e envie de novo
Primeira pergunta demora	Download dos modelos do HuggingFace	Aguarde; as próximas são rápidas
Respostas sempre "Não encontrei"	Cortes de relevância altos para o modelo	Veja as notas na busca nos trechos e baixe `NEXO_MIN_SIMILARITY` e `NEXO_MIN_RERANK_SCORE`
Taxa de resposta caindo no painel	Perguntas sobre assuntos fora do acervo	Leia as lacunas e envie os documentos que faltam
Integração recebe 401 `INVALID_API_KEY`	Chave revogada, digitada errada ou de conta excluída	Crie uma chave nova em Integrações; confira o cabeçalho `X-API-Key`

Copyright (©) 2026 Erik Pimenta

Sintoma	Causa provável	O que fazer
Integração recebe 403	Rota de administrador com chave de usuário comum	Use uma chave criada por um administrador
Webhook com status vazio e erro de tempo	Receptor lento ou fora do ar	Responda em menos de `NEXO_WEBHOOK_TIMEOUT` segundos ou aumente o valor
Receptor recusa a assinatura	HMAC calculado sobre o JSON reformatado ou segredo errado	Calcule sobre o corpo bruto (seção 5.4) e confira o segredo
Não consigo rebaixar um admin	Ele é o último administrador	Promova outra conta antes
Tela em branco em /	Interface não compilada	`cd frontend`, `npm install` e `npm run build`
Sessão cai ao reiniciar	`NEXO_SECRET` vazio e pasta `data` apagada	Defina `NEXO_SECRET` fixo no `.env`
Esqueci a senha do admin	Senha trocada e perdida	`python scripts/redefinir_senha.py admin`

Copyright (©) 2026 Erik Pimenta