Nexo

Manual técnico

Chatbot de manuais técnicos e livros em PDF com respostas baseadas somente nos documentos enviados. Instalação, configuração, cada tela, arquitetura, banco de dados, API e manutenção, passo a passo.

Versão 1.5.0
Outubro de 2026

Copyright (©) 2026 Erik Pimenta

Sumário

01 Visão geral 4

1.1 Para que serve 4
1.2 O que o projeto entrega 5
1.3 Funcionalidades 5
1.4 Identidade visual 5

02 Instalação 7

2.1 Pré-requisitos 7
2.2 Caminho rápido 7
2.3 Passo a passo manual 7
2.4 Primeiro acesso 8

03 Configuração 10

3.1 Modos prontos 10
3.2 Todas as variáveis 11
3.3 Calibrando a precisão 13
3.4 Serviços externos com Docker 13
3.5 Acesso pela rede 13

04 Usando o Nexo 14

4.1 Documentos 14
4.2 Conversas 16
4.3 Sistema e conta 19
4.4 Tema escuro e celular 20

05 Arquitetura 23

5.1 Módulos do código 24
5.2 Indexação de um PDF 24
5.3 Respondendo uma pergunta 25
5.4 Como as alucinações são reduzidas 26
5.5 Segurança 26

06 Banco de dados 27

6.1 Onde cada dado fica 27
6.2 Diagrama de relacionamentos 28
6.3 Tabelas 28
6.4 Coleção vetorial 31
6.5 Arquivo de usuários 31
6.6 Outro banco relacional 31
6.7 Backup 32

Copyright (©) 2026 Erik Pimenta

07 API 33

7.1 Exemplo com curl 33

7.2 Erros 34

08 Qualidade e manutenção 35

8.1 Testes automatizados 35

8.2 Medindo a recuperação 35

8.3 Integração contínua 35

8.4 Commit automático diário 35

8.5 Atualizando dependências 36

8.6 Solução de problemas 36

Copyright (©) 2026 Erik Pimenta

01

Visão geral

O Nexo é uma aplicação web em que você envia manuais técnicos ou livros em PDF e conversa com um chatbot que responde só com o que está escrito neles. Cada resposta mostra os trechos usados, com documento e página. Quando a informação não está nos PDFs, o Nexo diz isso em vez de inventar.

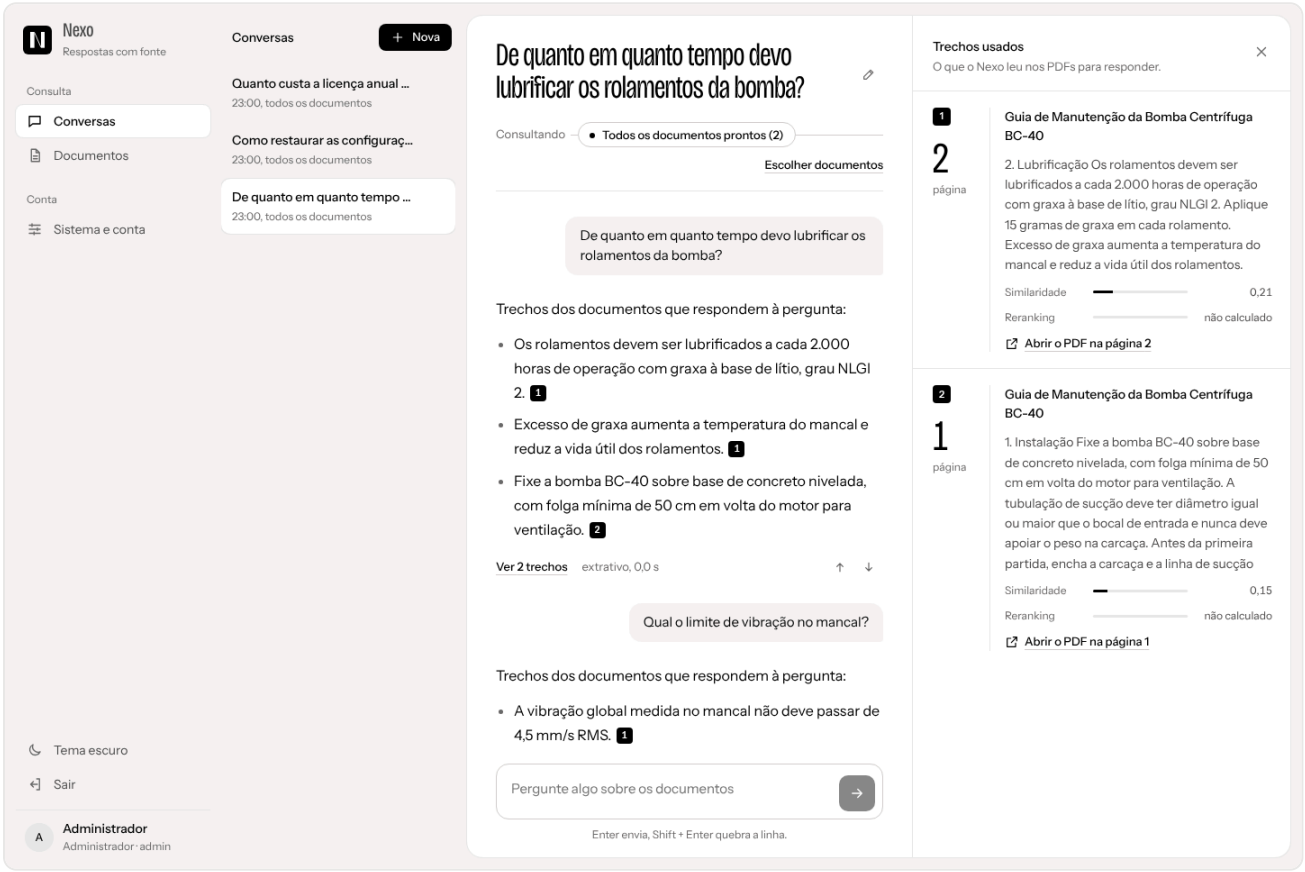


Figura 1.1 Conversa com citações numeradas e o painel de trechos usados, com página, similaridade e link para o PDF.

1.1 Para que serve

- Consultar manuais de equipamentos, normas, procedimentos internos e livros técnicos sem folhear centenas de páginas.
- Dar a uma equipe um ponto único de consulta, em que cada resposta pode ser conferida no documento original.
- Estudar um livro complexo fazendo perguntas e indo direto à página que trata do assunto.

Copyright (©) 2026 Erik Pimenta

1.2 O que o projeto entrega

O Nexo é entregue como estrutura pronta: interfaces, arquitetura, banco de dados e documentação. Quem instala decide quais PDFs enviar, quais modelos usar e onde hospedar. Nenhum documento real ou dado pessoal vem no repositório; o único PDF incluído é um manual fictício para testes.

Camada	Tecnologia	Papel
Interface	React 19, TypeScript, Vite	Telas de entrada, documentos, conversas, sistema e conta
API	Python 3.11+, FastAPI, Uvicorn	Rotas REST, autenticação, envio de arquivos e fila de indexação
Pipeline de dados	LlamaIndex, pypdf	Leitura dos PDFs, divisão em trechos, busca e montagem das respostas
Banco vetorial	ChromaDB (padrão) ou Qdrant	Embeddings dos trechos e metadados de origem
Embeddings	HuggingFace, OpenAI ou Ollama	Transformam texto em vetores para a busca semântica
Reranking	Cross-encoder HuggingFace ou Cohere Rerank	Reordenam os candidatos antes de chegarem ao modelo
Modelo de linguagem	Ollama (local) ou OpenAI	Redige a resposta a partir dos trechos
Banco relacional	SQLAlchemy com SQLite (padrão), PostgreSQL, MySQL ou SQL Server	Documentos, conversas, mensagens, fontes e avaliações
Contas	Arquivo JSON com bcrypt, sessões JWT	Login pré-definido e cadastro próprio

1.3 Funcionalidades

- Envio de PDFs por arrastar e soltar ou seletor de arquivos, vários de uma vez, com limite de tamanho, checagem de formato e bloqueio de duplicados por SHA-256.
- Indexação em segundo plano com estados Na fila, Indexando, Pronto e Falhou. A tela se atualiza sozinha.
- Renomear, reindexar, abrir e excluir documentos. Excluir apaga o PDF e todos os vetores dele.
- Conversas salvas por usuário, com título automático, renomeação e exclusão.
- Escopo: cada conversa pode consultar todos os documentos ou só os escolhidos.
- Citações [n] clicáveis que abrem o trecho usado e o PDF na página certa.
- Resposta padrão quando nada relevante é encontrado: "Não encontrei essa informação nos documentos selecionados."
- Avaliação de cada resposta (útil ou não ajudou), guardada no banco.
- Contas: login pré-definido de administrador e cadastro de novos usuários, com troca de senha.
- Tema claro e escuro e layout para celular.

1.4 Identidade visual

A versão 1.5.0 adota a identidade "caixa única", a mesma do painel Bento (Data-Driven-Admin-Panel), sem mudar nenhuma funcionalidade nem a API.

Copyright (©) 2026 Erik Pimenta

Elemento	Como ficou
Mesa	Fundo, menu lateral e lista de conversas no mesmo tom `#F5F4F4`, sem bordas
Caixa	A conversa e o painel de trechos dividem uma parede fina de 1 px dentro de uma só caixa branca de cantos arredondados
Tampa	O resumo do acervo (Documentos e Sistema e conta) e a lateral da tela de entrada ficam no bloco preto
Tipografia	Títulos e números em Bricolage Grotesque fina e condensada, textos em Instrument Sans, código em IBM Plex Mono
Status	Um ponto de cor e o texto neutro: verde para Pronto, azul para Indexando, cinza para Na fila, vermelho para Falhou
Paleta	`#FFFFFF`, `#4D4B4B`, `#000000`, `#333232` e `#BAB7B6`; a logo é sempre em preto e branco

Copyright (©) 2026 Erik Pimenta

02

Instalação

Este capítulo leva do download à primeira pergunta respondida. O caminho mais curto é o script de inicialização; os passos manuais vêm logo depois.

2.1 Pré-requisitos

Item	Versão	Para quê
Python	3.11 ou mais recente	Servidor, indexação e respostas
Node.js	20.19 ou mais recente	Compilar a interface (uma vez)
Ollama	Atual	Modelo de linguagem local e gratuito (modo padrão)
Espaço em disco	Cerca de 3 GB	Dependências do Python, modelos de embeddings e reranking
Memória	8 GB ou mais	Rodar o llama3.1 local com folga

Sem Ollama ou sem GPU? Use a OpenAI como modelo de linguagem (seção 3.1) ou o modo de teste sem modelos para validar a instalação. Os modelos de embeddings e reranking padrão rodam bem em CPU.

2.2 Caminho rápido

1. Baixe o repositório (botão **Code › Download ZIP** no GitHub ou `git clone`) e extraia em uma pasta.
2. Instale o Ollama em ollama.com e, num terminal, rode `ollama pull llama3.1`.
3. No Windows, dê dois cliques em `iniciar.cmd`. No Linux ou macOS, rode `./iniciar.sh`.
4. Espere a instalação terminar. Na primeira vez ela leva alguns minutos.
5. Abra http://127.0.0.1:8000 no navegador e entre com `admin` / `Nexo@2026`.
6. Vá em **Documentos**, envie um PDF e, quando aparecer **Pronto**, faça uma pergunta em **Conversas**.

O script cria o ambiente virtual `.venv`, instala `requirements.txt`, copia `.env.example` para `.env`, compila a interface em `frontend/dist` e sobe o servidor. Nas próximas vezes ele só sobe o servidor.

2.3 Passo a passo manual

```
python -m venv .venv
.venv\Scripts\activate                    # Windows
source .venv/bin/activate                 # Linux / macOS
pip install -r requirements.txt
copy .env.example .env                    # Windows; no Linux/macOS use cp
cd frontend
npm install
```

Copyright (©) 2026 Erik Pimenta

```
npm run build
cd ..
python -m nexo
```

Para desenvolver a interface com recarga automática, rode `python -m nexo` em um terminal e `npm run dev` dentro de `frontend` em outro. A interface abre em http://localhost:5173 e repassa as chamadas `/api` para a porta 8000.

2.4 Primeiro acesso

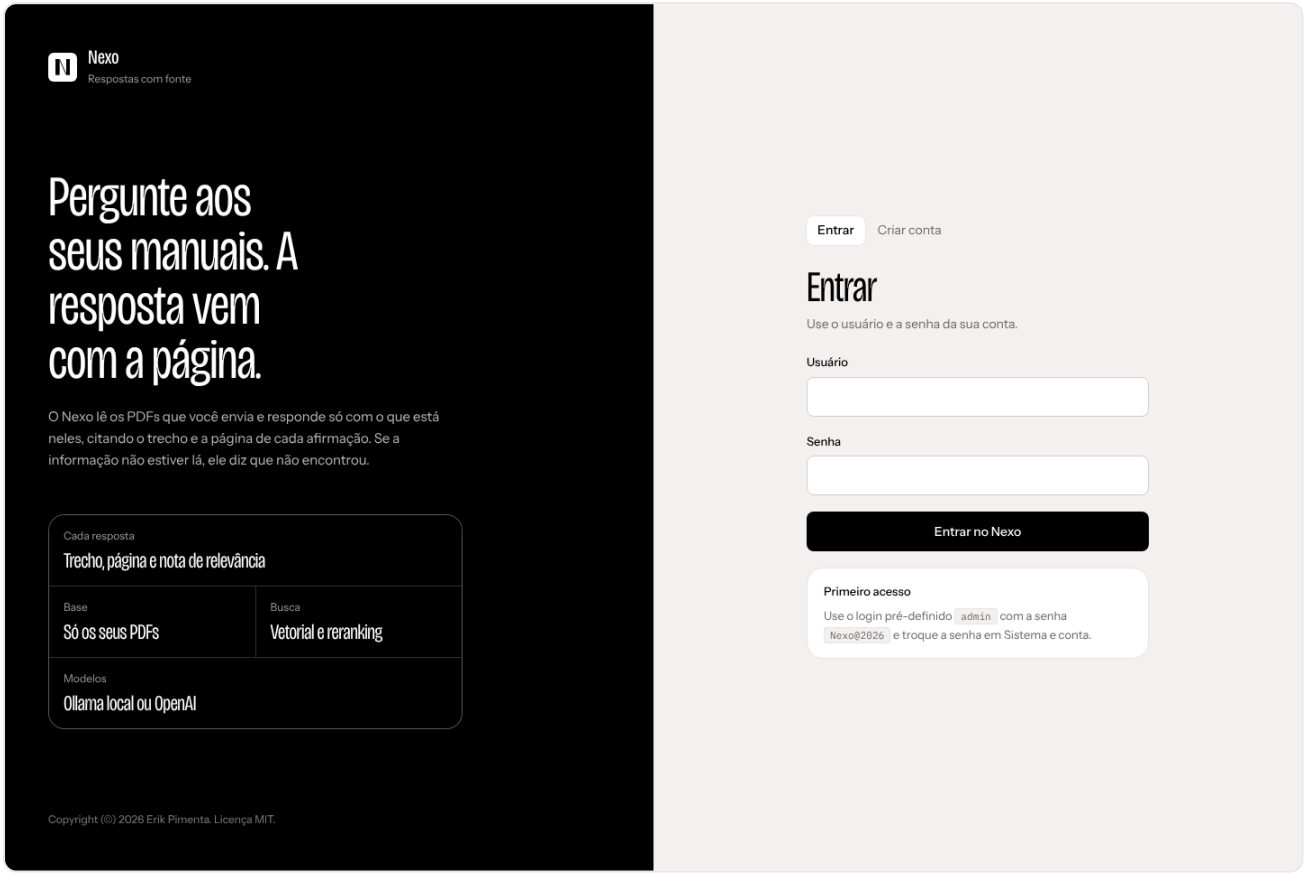


Figura 2.1 Entrada com o aviso do login pré-definido.

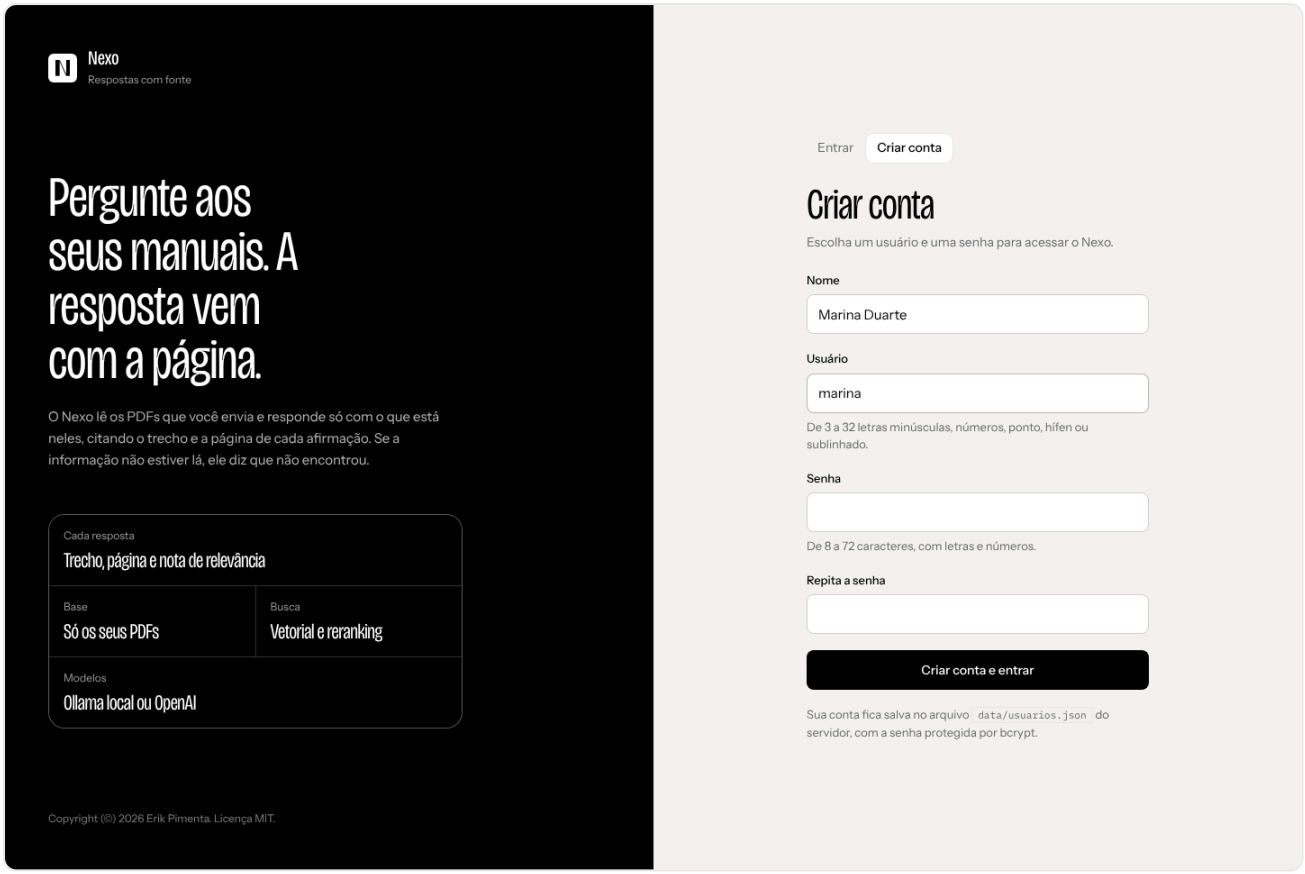


Figura 2.2 Criação de conta pela própria tela.

O login pré-definido é criado quando `data/usuarios.json` ainda não existe. O aviso some da tela de entrada assim que a senha do admin é trocada. Troque-a em **Sistema e conta** no primeiro acesso.

Usuário	Senha	Perfil	Pode
`admin`	`Nexo@2026`	Administrador	Tudo, inclusive excluir documentos de outras pessoas e ver o total de contas
contas novas	definida no cadastro	Usuário	Enviar PDFs, conversar e gerenciar os próprios documentos

Copyright (©) 2026 Erik Pimenta

03

Configuração

Toda a configuração fica no arquivo `.env` na raiz do projeto. Altere, salve e reinicie o servidor. A tela Sistema e conta mostra o que está valendo.

3.1 Modos prontos

Modo	Linhas no `.env`	Quando usar

Local e gratuito (padrão)	`NEXO_LLM_PROVIDER=ollama`
	`NEXO_LLM_MODEL=llama3.1`
	`NEXO_EMBED_PROVIDER=huggingface`
	`NEXO_RERANKER=huggingface`
		Documentos sigilosos que não podem sair da máquina

OpenAI	`NEXO_LLM_PROVIDER=openai`
	`NEXO_LLM_MODEL=gpt-4o-mini`
	`OPENAI_API_KEY=sua-chave`
		Respostas mais elaboradas sem precisar de GPU

Embeddings da OpenAI	`NEXO_EMBED_PROVIDER=openai`
	`NEXO_EMBED_MODEL=text-embedding-3-small`
	`NEXO_EMBED_QUERY_PREFIX=`
	`NEXO_EMBED_TEXT_PREFIX=`
		Acervos grandes, sem baixar modelos locais

Reranking Cohere	`NEXO_RERANKER=cohere` `COHERE_API_KEY=sua-chave`	Melhor ordenação em vários idiomas sem custo de CPU
Qdrant	`NEXO_VECTOR_STORE=qdrant` `NEXO_QDRANT_URL=http://localhost:6333`	Acervos com muitos milhares de trechos ou servidor dedicado

Teste sem modelos	`NEXO_EMBED_PROVIDER=hash`
	`NEXO_LLM_PROVIDER=extrativo`
	`NEXO_RERANKER=none`
	`NEXO_MIN_SIMILARITY=0.1`
		Validar a instalação e rodar os testes automatizados

Trocou o modelo de embeddings? Vetores de modelos diferentes não são comparáveis. Depois de mudar `NEXO_EMBED_PROVIDER` ou `NEXO_EMBED_MODEL`, use uma coleção nova (`NEXO_COLLECTION`) ou reindexe todos os documentos pela tela Documentos.

Copyright (©) 2026 Erik Pimenta

3.2 Todas as variáveis

Variável	Padrão	Descrição
NEXO_HOST / NEXO_PORT	127.0.0.1 / 8000	Endereço do servidor. Use 0.0.0.0 para aceitar acessos da rede
NEXO_DATA_DIR	data	Pasta do banco SQLite, PDFs, vetores locais e usuários
NEXO_SECRET	gerado	Chave das sessões. Vazia: o Nexo cria data/.segredo
NEXO_TOKEN_HOURS	8	Duração da sessão em horas
NEXO_ALLOW_REGISTRATION	true	Permite criar contas na tela de entrada
NEXO_MAX_UPLOAD_MB	100	Tamanho máximo de cada PDF
NEXO_DATABASE_URL	vazio	URL SQLAlchemy de outro banco relacional
NEXO_LLM_PROVIDER	ollama	ollama, openai ou extrativo
NEXO_LLM_MODEL	llama3.1	Nome do modelo no provedor escolhido
NEXO_LLM_TEMPERATURE	0.1	Criatividade do modelo. Mantenha baixa
NEXO_LLM_TIMEOUT	120	Tempo máximo de resposta do modelo, em segundos
NEXO_OLLAMA_URL	http://localhost:11434	Endereço do Ollama
OPENAI_API_KEY	vazio	Chave da OpenAI
NEXO_OPENAI_BASE_URL	vazio	Endpoint compatível com a OpenAI (Azure, LM Studio, vLLM)
NEXO_EMBED_PROVIDER	huggingface	huggingface, openai, ollama ou hash
NEXO_EMBED_MODEL	intfloat/multilingual-e5-small	Modelo de embeddings
NEXO_EMBED_QUERY_PREFIX / _TEXT_PREFIX	query: / passage:	Prefixos exigidos pela família E5. Deixe vazio em outros modelos
NEXO_VECTOR_STORE	chroma	chroma ou qdrant
NEXO_COLLECTION	nexo_trechos	Nome da coleção vetorial
NEXO_CHROMA_HOST / _PORT	vazio / 8001	Servidor ChromaDB. Vazio: arquivos em data/chroma
NEXO_QDRANT_URL / _API_KEY	vazio	Servidor Qdrant. Vazio: arquivos em data/qdrant
NEXO_RERANKER	huggingface	huggingface, cohere ou none
NEXO_RERANK_MODEL	cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	Cross-encoder multilíngue do HuggingFace
NEXO_COHERE_MODEL / COHERE_API_KEY	rerank-v3.5 / vazio	Reranking da Cohere
NEXO_CHUNK_SIZE / _OVERLAP	512 / 64	Tamanho dos trechos e sobreposição, em tokens
NEXO_TOP_K	12	Candidatos trazidos pela busca vetorial
NEXO_TOP_N	4	Trechos enviados ao modelo depois do reranking

Copyright (©) 2026 Erik Pimenta

Variável	Padrão	Descrição
NEXO_HOST / NEXO_PORT	127.0.0.1 / 8000	Endereço do servidor. Use 0.0.0.0 para aceitar acessos da rede
NEXO_DATA_DIR	data	Pasta do banco SQLite, PDFs, vetores locais e usuários
NEXO_SECRET	gerado	Chave das sessões. Vazia: o Nexo cria data/.segredo
NEXO_TOKEN_HOURS	8	Duração da sessão em horas
NEXO_ALLOW_REGISTRATION	true	Permite criar contas na tela de entrada
NEXO_MAX_UPLOAD_MB	100	Tamanho máximo de cada PDF
NEXO_DATABASE_URL	vazio	URL SQLAlchemy de outro banco relacional
NEXO_LLM_PROVIDER	ollama	ollama, openai ou extrativo
NEXO_LLM_MODEL	llama3.1	Nome do modelo no provedor escolhido
NEXO_LLM_TEMPERATURE	0.1	Criatividade do modelo. Mantenha baixa
NEXO_LLM_TIMEOUT	120	Tempo máximo de resposta do modelo, em segundos
NEXO_OLLAMA_URL	http://localhost:11434	Endereço do Ollama
OPENAI_API_KEY	vazio	Chave da OpenAI
NEXO_OPENAI_BASE_URL	vazio	Endpoint compatível com a OpenAI (Azure, LM Studio, vLLM)
NEXO_EMBED_PROVIDER	huggingface	huggingface, openai, ollama ou hash
NEXO_EMBED_MODEL	intfloat/multilingual-e5-small	Modelo de embeddings
NEXO_EMBED_QUERY_PREFIX / _TEXT_PREFIX	query: / passage:	Prefixos exigidos pela família E5. Deixe vazio em outros modelos
NEXO_VECTOR_STORE	chroma	chroma ou qdrant
NEXO_COLLECTION	nexo_trechos	Nome da coleção vetorial
NEXO_CHROMA_HOST / _PORT	vazio / 8001	Servidor ChromaDB. Vazio: arquivos em data/chroma
NEXO_QDRANT_URL / _API_KEY	vazio	Servidor Qdrant. Vazio: arquivos em data/qdrant
NEXO_RERANKER	huggingface	huggingface, cohere ou none
NEXO_RERANK_MODEL	cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	Cross-encoder multilíngue do HuggingFace
NEXO_COHERE_MODEL / COHERE_API_KEY	rerank-v3.5 / vazio	Reranking da Cohere
NEXO_CHUNK_SIZE / _OVERLAP	512 / 64	Tamanho dos trechos e sobreposição, em tokens
NEXO_TOP_K	12	Candidatos trazidos pela busca vetorial
NEXO_TOP_N	4	Trechos enviados ao modelo depois do reranking
NEXO_MIN_SIMILARITY	0.15	Similaridade de cosseno mínima para um trecho ser considerado

Copyright (©) 2026 Erik Pimenta

3.3 Calibrando a precisão

- Respostas dizendo que não encontrou, mas a informação existe: baixe `NEXO_MIN_SIMILARITY` (por exemplo `0.1`) e `NEXO_MIN_RERANK_SCORE` (`0.05`), ou aumente `NEXO_TOP_K`.
- Respostas misturando assuntos: suba `NEXO_MIN_RERANK_SCORE` (`0.3`) e reduza `NEXO_TOP_N` para 3.
- Tabelas e listas longas cortadas: aumente `NEXO_CHUNK_SIZE` para 768 ou 1024 e reindexe.
- Medir em vez de adivinhar: use `scripts/avaliar.py` (capítulo 8) antes e depois de cada ajuste.

3.4 Serviços externos com Docker

O `docker-compose.yml` traz serviços opcionais, cada um em um perfil:

```
docker compose --profile chroma up -d         # ChromaDB em http://localhost:8001
docker compose --profile qdrant up -d         # Qdrant em http://localhost:6333
docker compose --profile ollama up -d         # Ollama em http://localhost:11434
docker compose --profile postgres up -d       # PostgreSQL em localhost:5432
```

Depois aponte o `.env` para eles, por exemplo `NEXO_CHROMA_HOST=localhost` ou `NEXO_DATABASE_URL=postgresql+psycopg://nexo:troque-esta-senha@localhost:5432/nexo` (instale `pip install "psycopg[binary]"`). Troque a senha do PostgreSQL no arquivo antes de usar.

3.5 Acesso pela rede

Para outras máquinas acessarem, use `NEXO_HOST=0.0.0.0`, libere a porta no firewall e defina `NEXO_SECRET` com um valor longo e aleatório. Em produção, coloque o Nexo atrás de um proxy com HTTPS (Nginx, Caddy ou IIS) e desligue o cadastro aberto se o acesso deve ser restrito.

Copyright (©) 2026 Erik Pimenta

04

Usando o Nexo

As telas seguem o caminho natural de uso: entrar, enviar documentos, conversar e conferir a configuração. O menu lateral, impresso no fundo da tela, separa Consulta (Conversas e Documentos) de Conta (Sistema e conta) e traz no rodapé a troca de tema, a saída e o usuário conectado.

4.1 Documentos

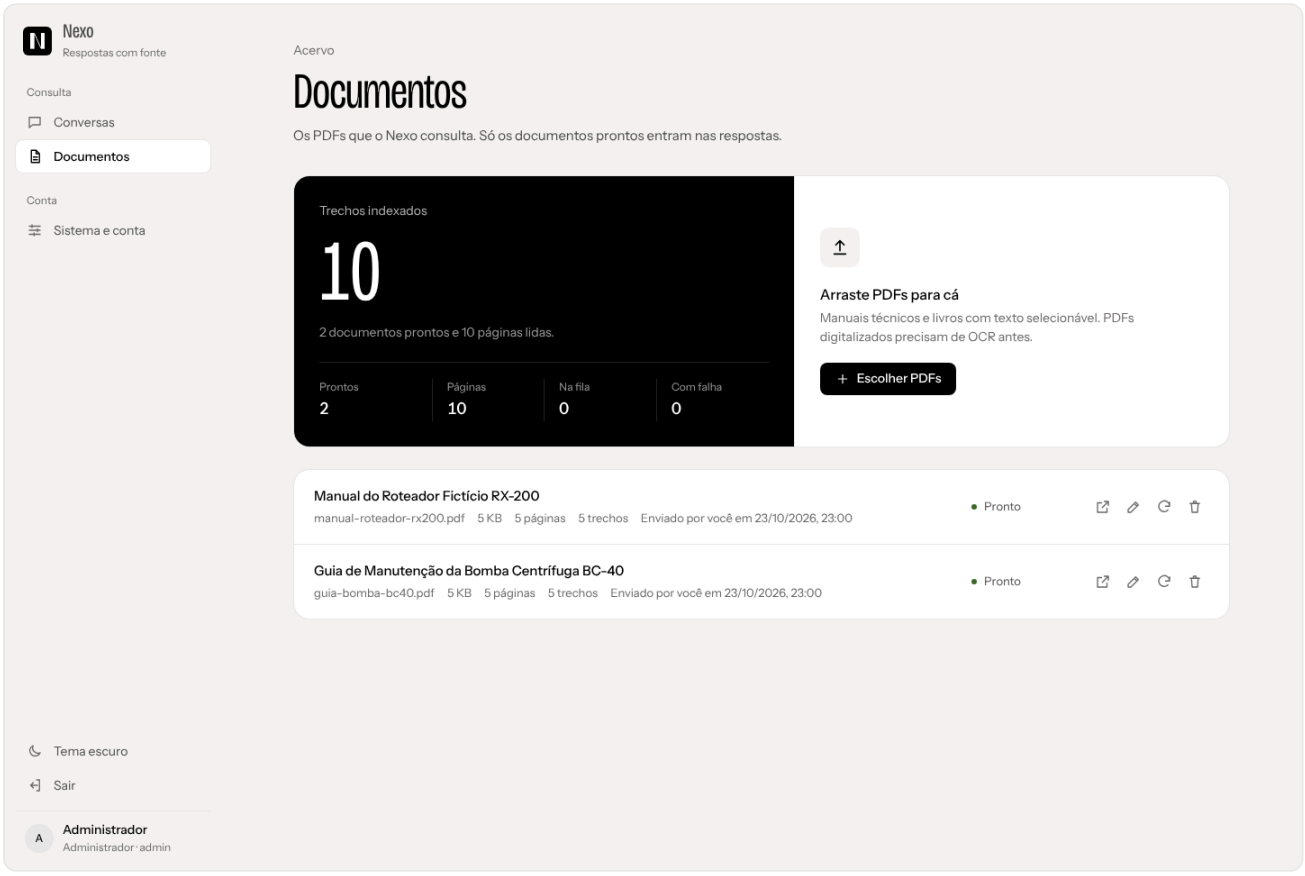


Figura 4.1 Documentos: o resumo do acervo na tampa preta, a área de envio ao lado e a lista com páginas, trechos, autor do envio e ações.

1. Arraste PDFs para a área **Arraste PDFs para cá** ou clique em **Escolher PDFs**.
2. Cada arquivo entra como **Na fila**, passa a **Indexando** e termina em **Pronto**. Uma barra animada indica o trabalho em andamento.
3. Se aparecer **Falhou**, o motivo fica logo abaixo do título. O caso mais comum é PDF digitalizado sem texto: aplique OCR e envie de novo.
4. Use os ícones à direita para abrir o PDF, renomear, reindexar e excluir. Renomear reindexa, porque o título faz parte da busca.

Copyright (©) 2026 Erik Pimenta

O bloco preto à esquerda resume o acervo: trechos indexados em destaque, documentos prontos, páginas lidas, arquivos na fila e com falha. Ele se atualiza sozinho enquanto há documentos sendo indexados.

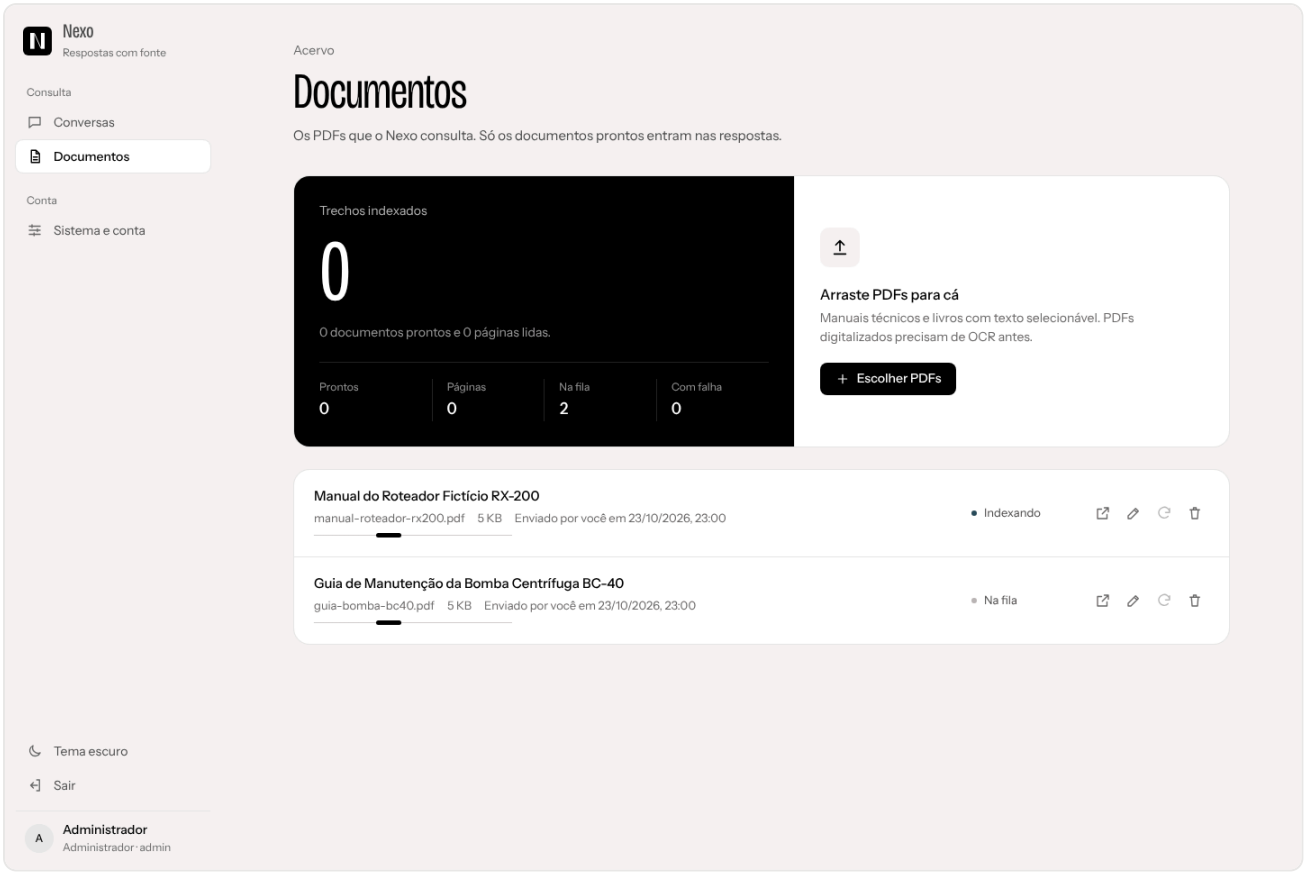


Figura 4.2 Documentos sendo indexados logo após o envio.

Copyright (©) 2026 Erik Pimenta

4.2 Conversas

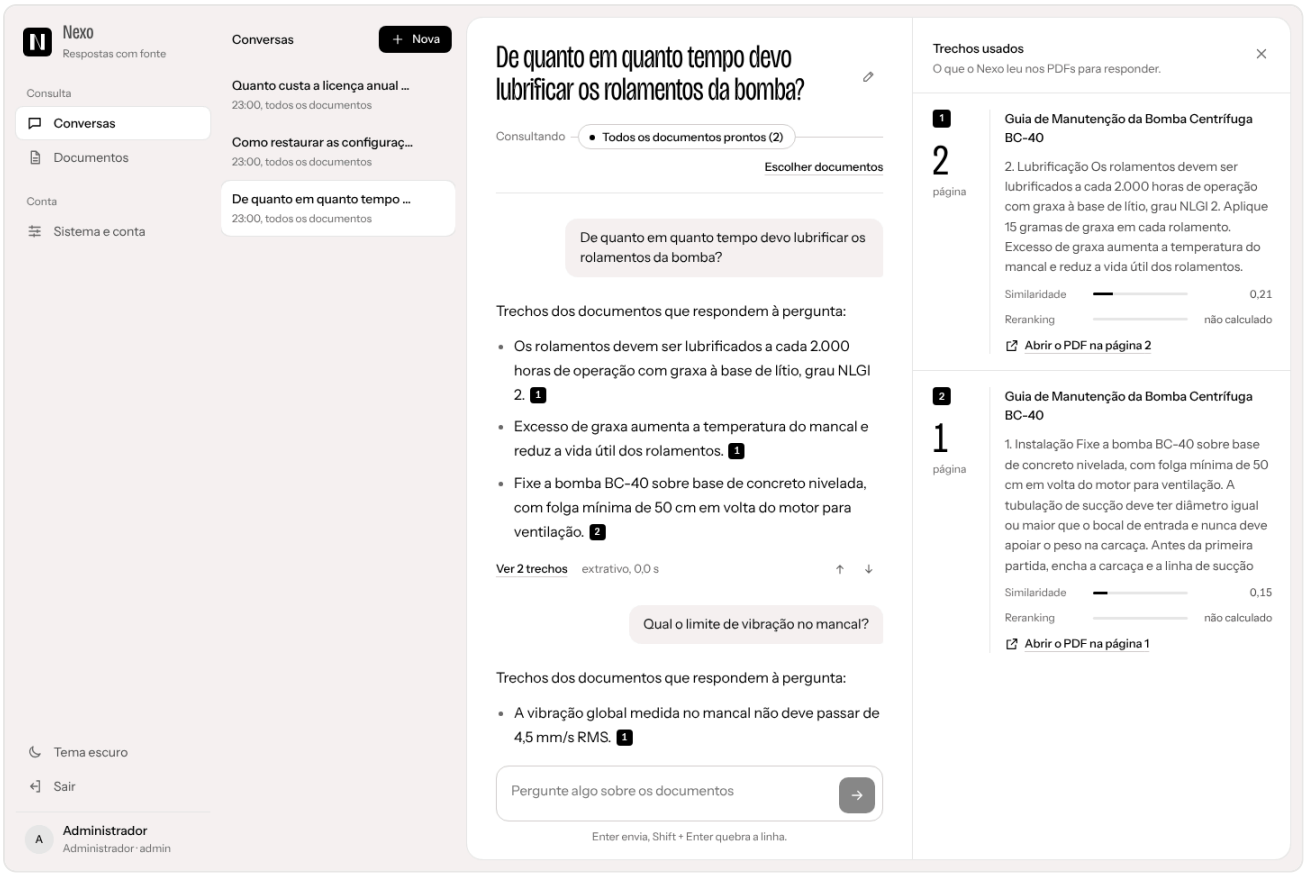


Figura 4.3 Duas perguntas na mesma conversa, com os trechos da primeira resposta abertos.

- **Nova** abre uma conversa vazia. O título vem da primeira pergunta e pode ser editado no lápis.
- Enter envia, Shift + Enter quebra a linha.
- Os números pretos [n] no texto indicam de qual trecho veio cada informação. Clique para destacá-lo no painel **Trechos usados**.
- Cada trecho mostra a página, a similaridade da busca, a nota do reranker e o link **Abrir o PDF na página**.
- Use as setas para cima e para baixo para avaliar a resposta. Clique de novo para desfazer.
- Perguntas seguintes podem usar "isso", "esse passo" ou "e depois?": o Nexo reescreve a pergunta com o histórico antes de buscar.

Copyright (©) 2026 Erik Pimenta

Escolhendo os documentos consultados



Figura 4.4 Seletor de documentos da conversa.

A linha **Consultando** mostra o escopo atual. Clique em **Escolher documentos** e marque os PDFs que a conversa deve usar. Sem nenhum marcado, todos os documentos prontos são consultados.

Copyright (©) 2026 Erik Pimenta

Quando a resposta não está nos PDFs

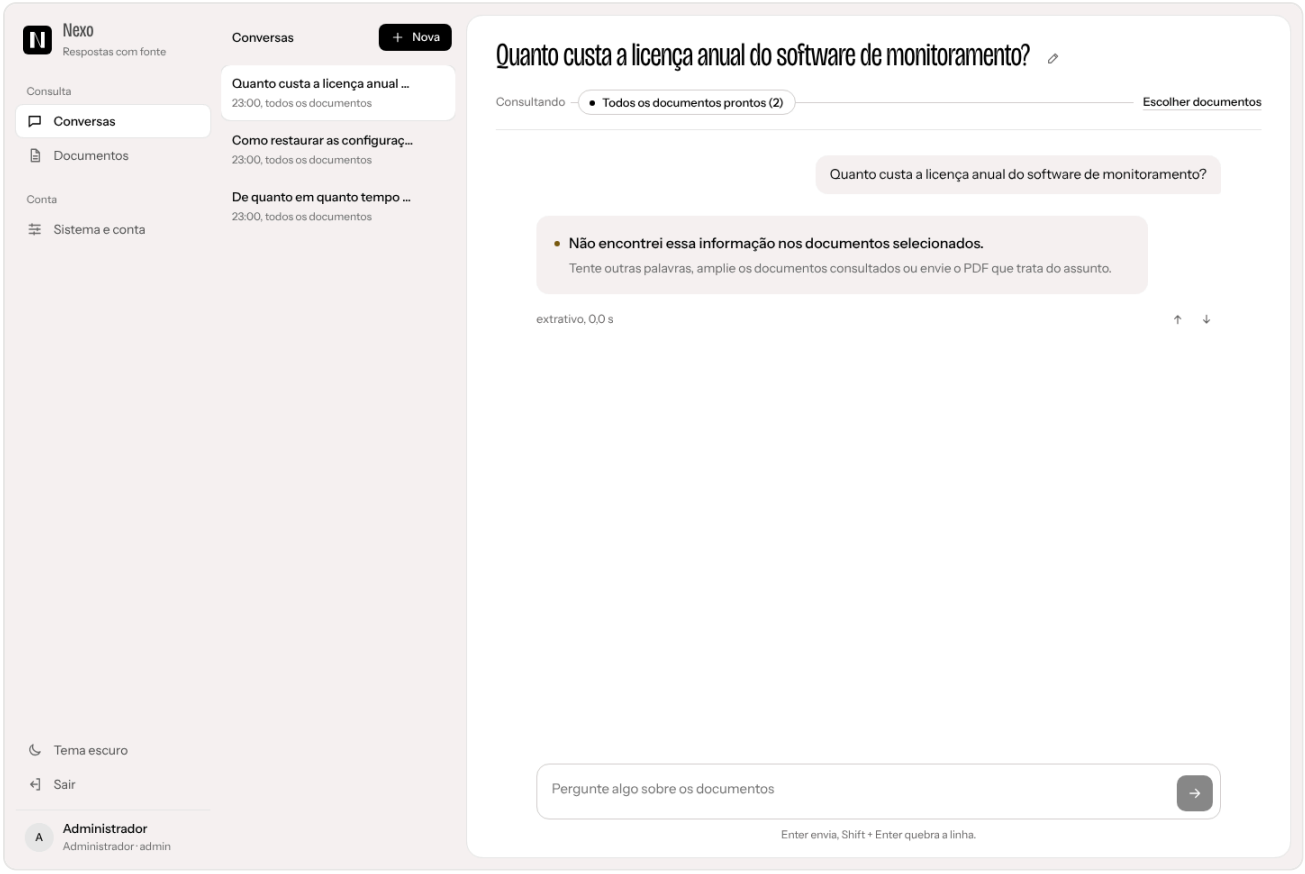


Figura 4.5 Pergunta fora do conteúdo dos documentos.

Se nenhum trecho passar pelos cortes de relevância, o modelo nem é chamado e a resposta aparece em um quadro cinza, marcado com um ponto de aviso, com sugestões para reformular. Isso é o comportamento esperado: o Nexo prefere não responder a responder sem base.

Copyright (©) 2026 Erik Pimenta

4.3 Sistema e conta

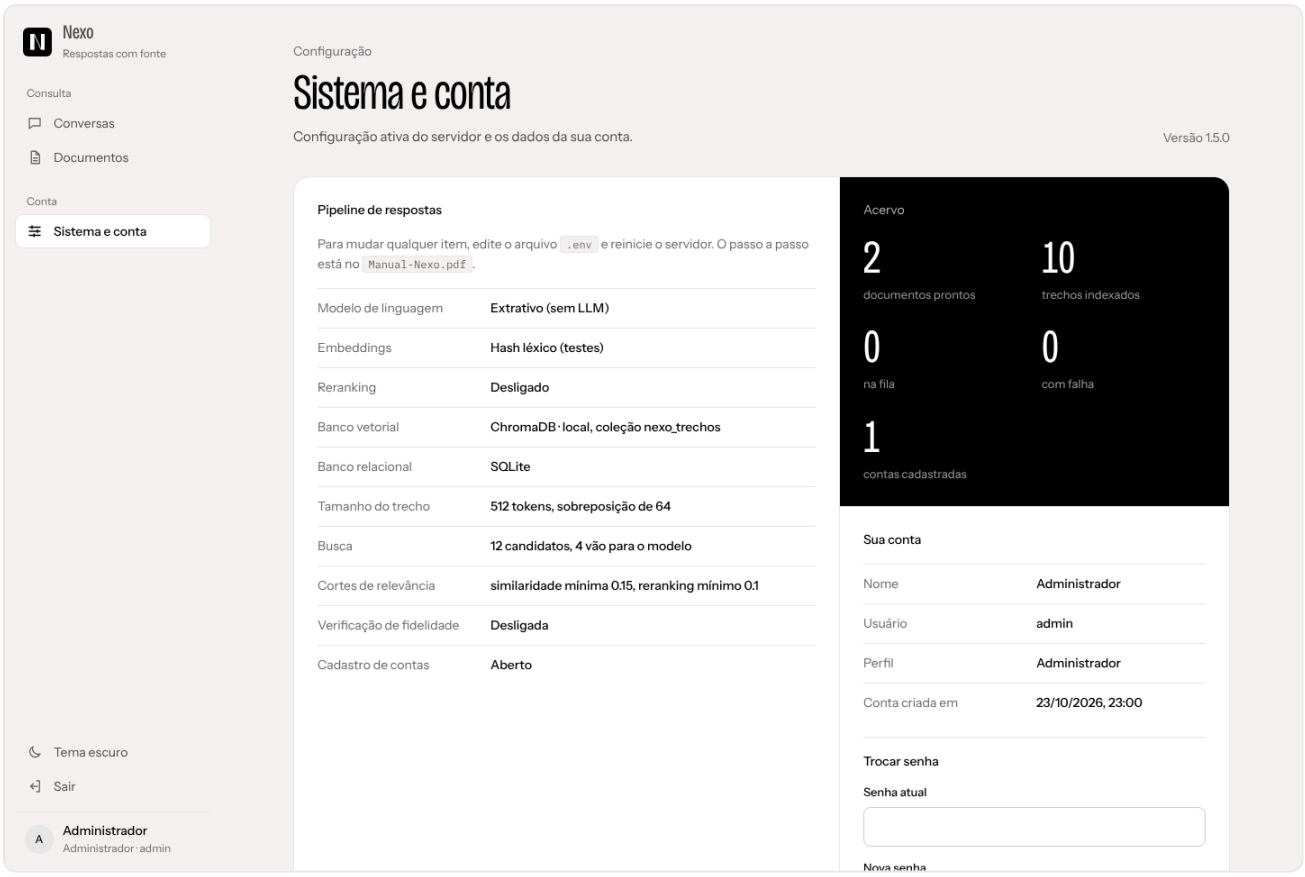


Figura 4.6 Configuração ativa, números do acervo e dados da conta.

A tela mostra os provedores em uso, os parâmetros de busca, a contagem de documentos e trechos e, para administradores, o total de contas. Na seção **Sua conta** fica o formulário de troca de senha (8 a 72 caracteres, com letras e números, sem conter o nome de usuário).

Copyright (©) 2026 Erik Pimenta

4.4 Tema escuro e celular

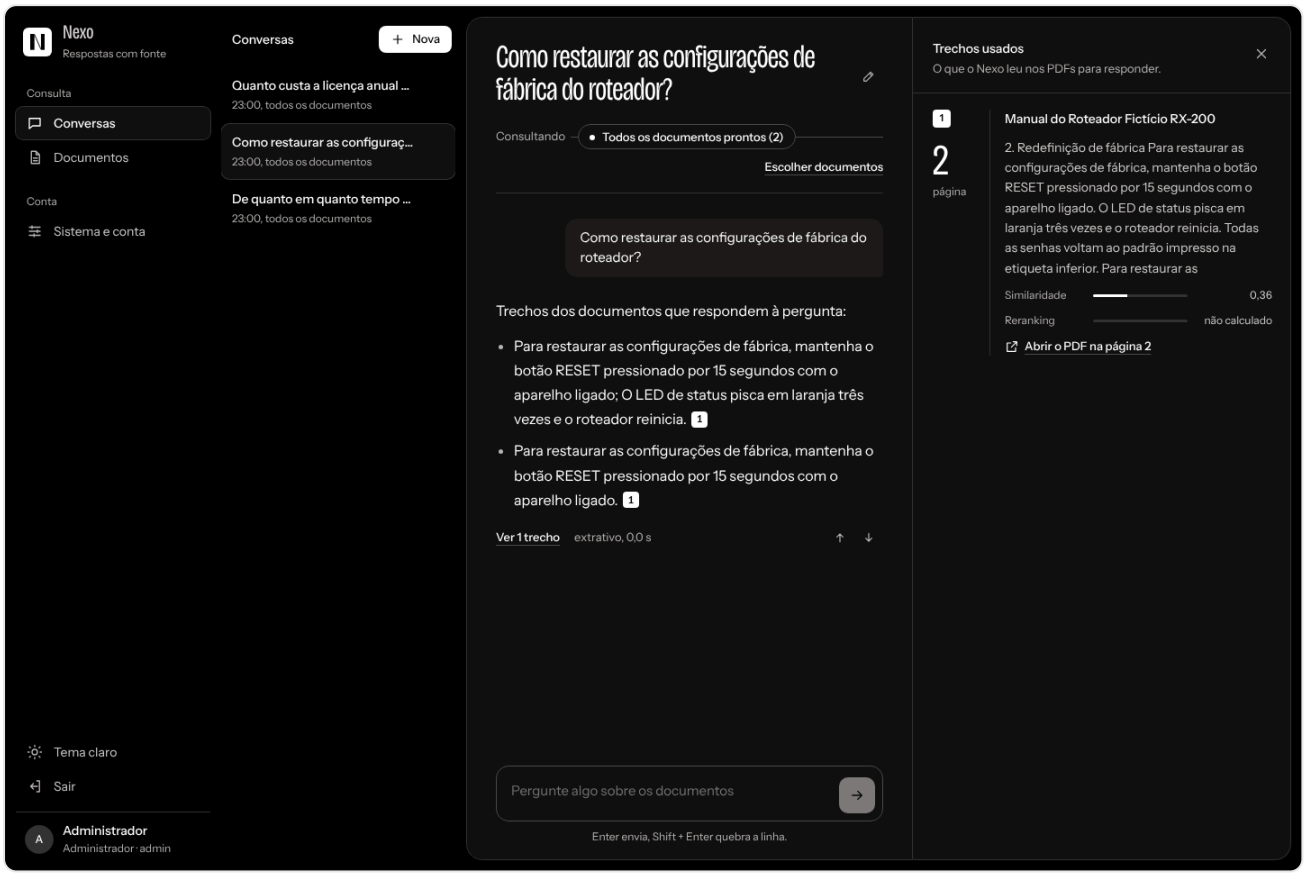


Figura 4.7 Tema escuro, escolhido no menu lateral.

O tema escuro usa os mesmos materiais em tons escuros e a escolha fica guardada no navegador. No celular, o menu lateral recolhe para o botão no topo e a lista de conversas abre pelo botão **Conversas**.

Copyright (©) 2026 Erik Pimenta

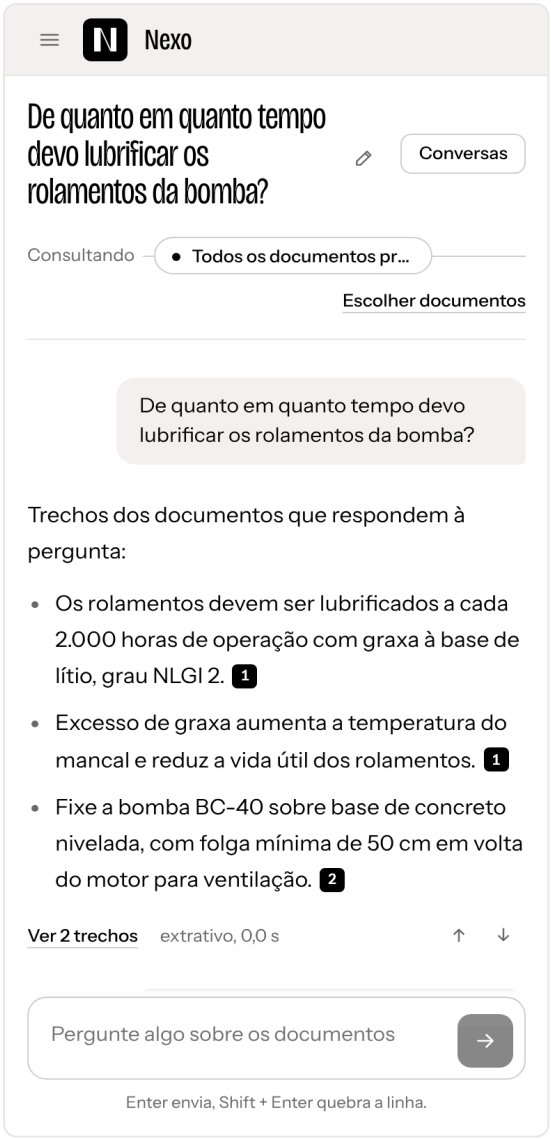


Figura 4.8 Layout de celular com o menu recolhido.

Copyright (©) 2026 Erik Pimenta

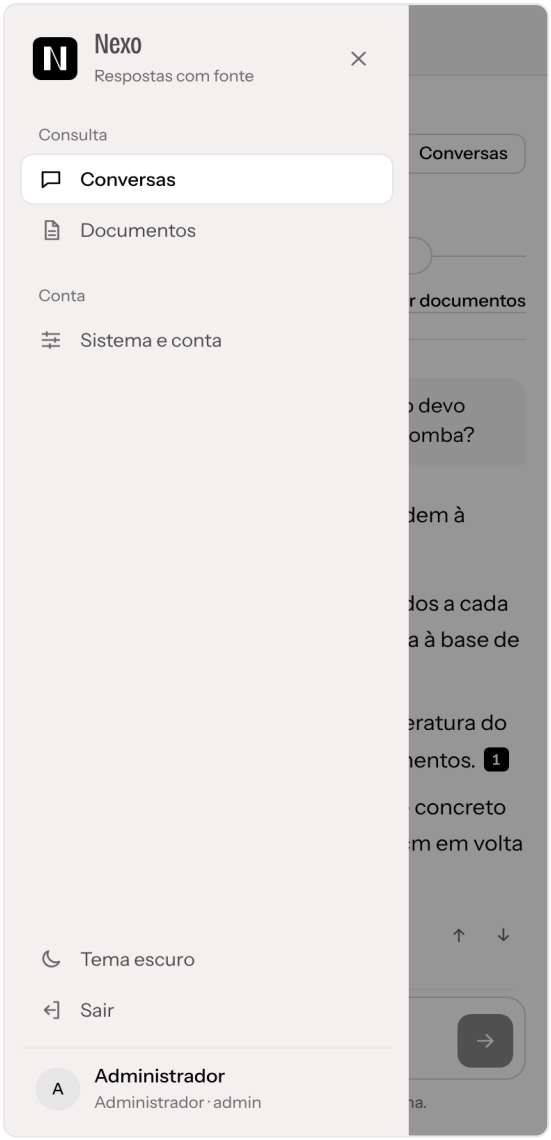


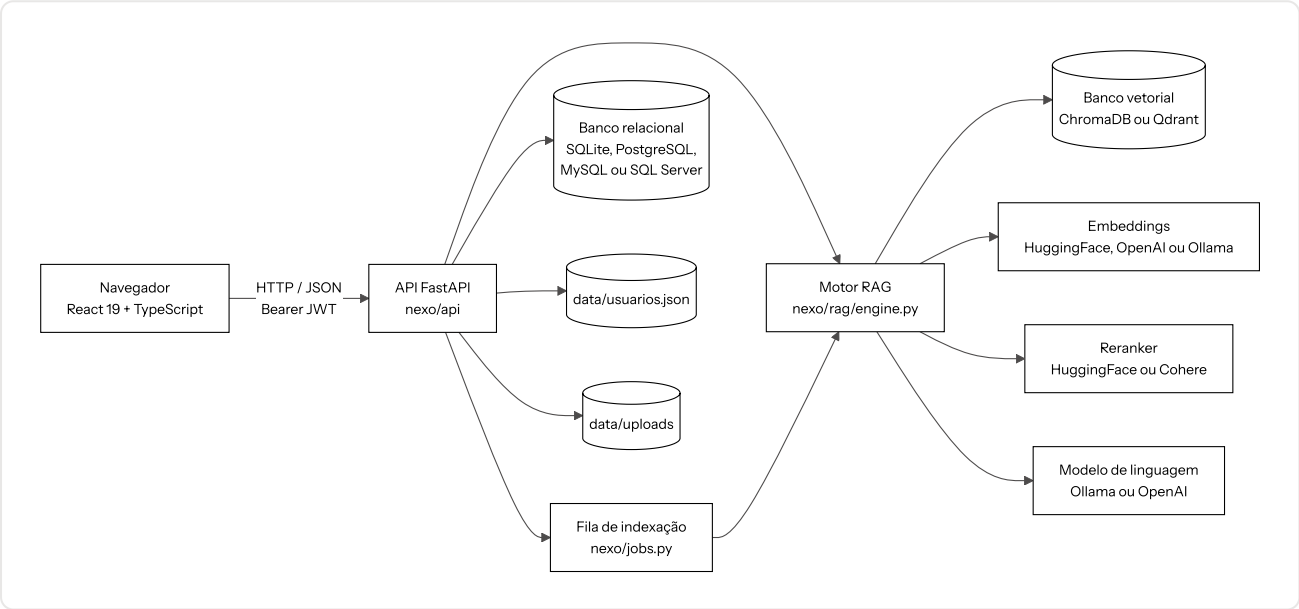
Figura 4.9 Menu lateral aberto no celular.

Copyright (©) 2026 Erik Pimenta

05

Arquitetura

O Nexo é um único processo Python que serve a API e a interface compilada. Os componentes pesados (modelos e banco vetorial) são plugáveis por configuração.

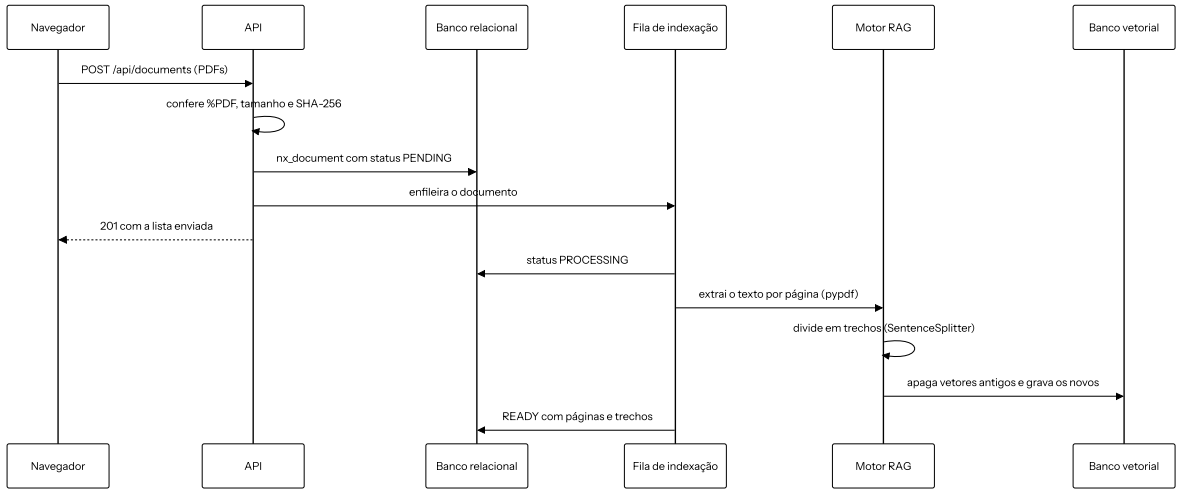


Copyright (©) 2026 Erik Pimenta

5.1 Módulos do código

Arquivo	Responsabilidade
`nexo/config.py`	Lê o `.env` com pydantic-settings e define os caminhos em `data/`
`nexo/db.py`	Modelos SQLAlchemy, criação das tabelas e sessões
`nexo/users.py`	Contas em JSON: cadastro, autenticação com bcrypt, bloqueio após 5 erros, troca de senha
`nexo/security.py`	Emissão e leitura de tokens JWT (HS256)
`nexo/jobs.py`	Fila de indexação em uma thread, retomada de pendências ao iniciar
`nexo/rag/engine.py`	Leitura dos PDFs, divisão em trechos, indexação, busca, reranking, prompt e resposta
`nexo/rag/providers.py`	Fábrica de LLM, embeddings, banco vetorial e reranker conforme o `.env`
`nexo/rag/hash_embedding.py`	Embedding léxico sem rede, usado nos testes e no modo de teste
`nexo/api/routes.py`	Rotas REST de autenticação, documentos, conversas, mensagens e sistema
`nexo/api/app.py`	Aplicação FastAPI, tratamento de erros, cabeçalhos de segurança e entrega da interface
`frontend/src`	Interface React: páginas, componentes, cliente da API, tema e a identidade visual em `styles.css`

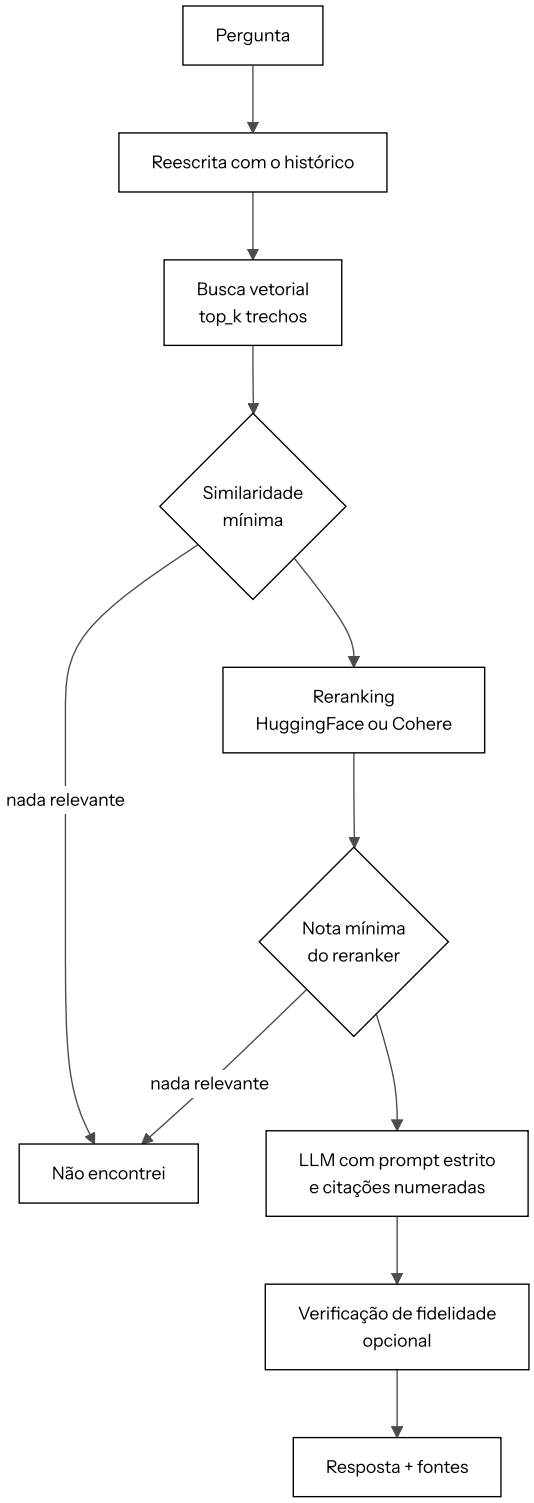
5.2 Indexação de um PDF



- O texto de cada página é extraído com pypdf, com hifenizações desfeitas e quebras de linha do layout unidas.
- O SentenceSplitter do LlamaIndex divide o texto em trechos de `NEXO_CHUNK_SIZE` tokens respeitando frases, com sobreposição para não perder contexto na fronteira.
- Cada trecho guarda `source_id`, `title`, `filename`, `page` e `chunk_index`. Só o título entra no texto do embedding, junto com o conteúdo.
- Reindexar apaga os vetores antigos do documento antes de gravar os novos, então nunca há duplicação.

Copyright (©) 2026 Erik Pimenta

5.3 Respondendo uma pergunta



Copyright (©) 2026 Erik Pimenta

5.4 Como as alucinações são reduzidas

Mecanismo	Efeito
Cortes de similaridade e de reranking	Trechos fracos são descartados. Sem trechos, o LLM não é chamado e a resposta padrão é devolvida
Reranking com cross-encoder	Lê pergunta e trecho juntos e reordena os candidatos por relevância real, não só proximidade vetorial
Prompt estrito	Proíbe conhecimento próprio, exige citação [n] em cada afirmação e define a frase exata para quando falta base
Temperatura 0,1	Respostas estáveis e próximas do texto
Escopo por conversa	Evita misturar manuais de equipamentos diferentes
Verificação de fidelidade	Opcional: uma segunda chamada confere se a resposta é sustentada pelos trechos e marca a mensagem quando não é
Fontes gravadas	Cada resposta guarda os trechos usados, o que permite auditar respostas antigas

5.5 Segurança

- Senhas guardadas só como hash bcrypt. Cinco erros seguidos bloqueiam o usuário por 5 minutos.
- Sessões com JWT assinado por `NEXO_SECRET`, com validade de `NEXO_TOKEN_HOURS` horas. A interface guarda o token só na aba aberta (`sessionStorage`).
- Conversas visíveis apenas para o dono. Documentos só podem ser alterados por quem enviou ou por um administrador.
- Uploads validados pelo cabeçalho `%PDF`, pelo tamanho e pelo SHA-256. Nomes de arquivo são saneados e os PDFs são gravados com o id interno.
- Cabeçalhos `X-Content-Type-Options`, `X-Frame-Options` e `Referrer-Policy` em todas as respostas. A API não é guardada em cache.
- Chaves de API ficam só no `.env`, que está no `.gitignore`.
- A interface não carrega nada de fora: fontes, ícones e scripts vêm do próprio servidor.

Copyright (©) 2026 Erik Pimenta

06

Banco de dados

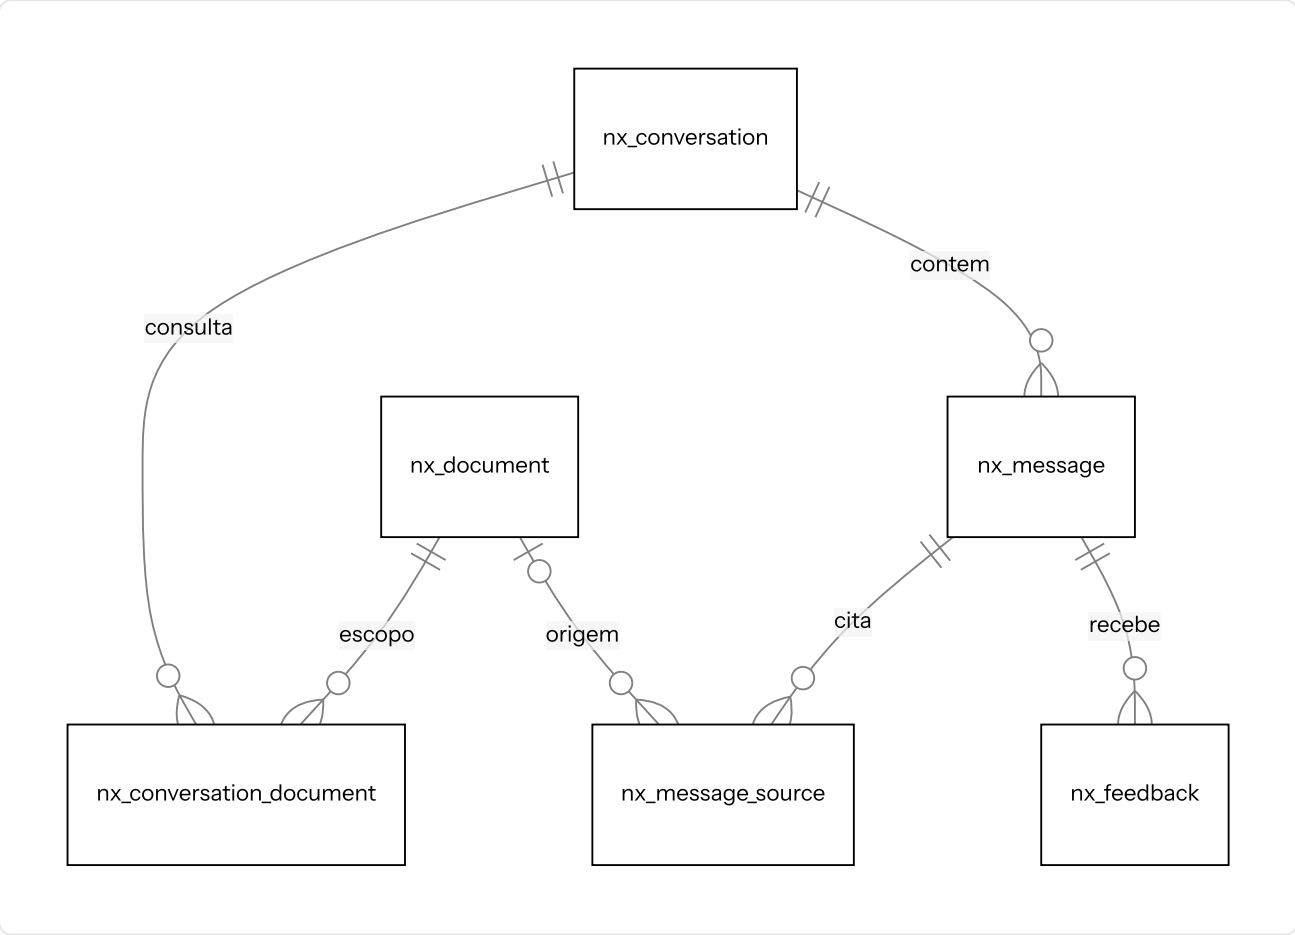
Este capítulo descreve a estrutura que os dados devem seguir. As tabelas são criadas automaticamente, mas quem administra o banco, migra para outro servidor ou integra com outros sistemas encontra aqui o modelo completo. A versão detalhada, com índices, restrições, decisões de arquitetura e escala, está em `Banco-de-Dados-Nexo.pdf`.

6.1 Onde cada dado fica

Camada	Local padrão	Conteúdo
Banco relacional	`data/nexo.db`	Documentos, conversas, mensagens, fontes citadas e avaliações
Banco vetorial	`data/chroma/` ou `data/qdrant/`	Trechos, embeddings e metadados de origem
Arquivos	`data/uploads/<id>.pdf`	PDFs originais
Contas	`data/usuarios.json`	Usuários, perfis e hashes de senha
Segredo	`data/.segredo`	Chave das sessões quando `NEXO_SECRET` está vazio

Copyright (©) 2026 Erik Pimenta

6.2 Diagrama de relacionamentos



6.3 Tabelas

nx_document

Um registro por PDF enviado.

Copyright (©) 2026 Erik Pimenta

Coluna	Tipo	Regra
`id`	varchar(32)	PK. UUID em hexadecimal; nome do arquivo em `data/uploads`
`title`	varchar(200)	Título dos metadados do PDF ou nome do arquivo
`filename`	varchar(255)	Nome original saneado
`sha256`	varchar(64)	Único. Bloqueia envios repetidos
`size_bytes`	integer	Tamanho do arquivo
`pages` / `chunks`	integer	Páginas do PDF e trechos indexados
`status`	varchar(20)	PENDING, PROCESSING, READY ou FAILED (indexado)
`error`	text	Motivo da falha
`uploaded_by`	varchar(32)	Usuário que enviou (indexado)
`created_at` / `indexed_at`	timestamp	Envio e fim da indexação, em UTC

nx_conversation

Conversas, cada uma de um único usuário.

Coluna	Tipo	Regra
`id`	varchar(32)	PK
`owner`	varchar(32)	Usuário dono (indexado)
`title`	varchar(160)	Padrão "Nova conversa"; recebe a primeira pergunta
`created_at` / `updated_at`	timestamp	`updated_at` indexado para ordenar a lista

nx_conversation_document

Escopo da conversa. Sem linhas, todos os documentos prontos são consultados.

Coluna	Tipo	Regra
`conversation_id`	varchar(32)	PK e FK para `nx_conversation`, ON DELETE CASCADE
`document_id`	varchar(32)	PK e FK para `nx_document`, ON DELETE CASCADE

nx_message

Perguntas e respostas.

Copyright (©) 2026 Erik Pimenta

Coluna	Tipo	Regra
`id`	varchar(32)	PK
`conversation_id`	varchar(32)	FK para `nx_conversation`, ON DELETE CASCADE
`role`	varchar(10)	`user` ou `assistant`
`content`	text	Texto da pergunta ou resposta
`answered`	boolean	false quando o Nexo não encontrou a informação
`grounded`	boolean	Resultado da verificação de fidelidade; nulo se desligada
`model` / `latency_ms`	varchar(120) / integer	Modelo que respondeu e tempo gasto
`created_at`	timestamp	Índice composto com `conversation_id`

nx_message_source

Trechos efetivamente enviados ao modelo, na ordem das citações.

Coluna	Tipo	Regra
`id`	integer	PK autoincremento
`message_id`	varchar(32)	FK para `nx_message`, ON DELETE CASCADE
`document_id`	varchar(32)	FK para `nx_document`, ON DELETE SET NULL
`document_title`	varchar(200)	Cópia do título, mantém o histórico legível após exclusões
`chunk_id`	varchar(80)	Id do trecho no banco vetorial
`page` / `rank`	integer	Página do PDF e número da citação [n]
`similarity` / `rerank_score`	float	Similaridade de cosseno e nota do reranker
`excerpt`	text	Texto do trecho (até 1.200 caracteres)

nx_feedback

Avaliações das respostas. Uma por usuário e resposta.

Coluna	Tipo	Regra
`id`	integer	PK autoincremento
`message_id`	varchar(32)	FK para `nx_message`, ON DELETE CASCADE
`owner`	varchar(32)	Usuário que avaliou; único junto com `message_id`
`rating`	integer	1 útil, -1 não ajudou
`comment`	text	Comentário opcional (via API)
`created_at`	timestamp	Data da avaliação

Copyright (©) 2026 Erik Pimenta

6.4 Coleção vetorial

Campo	Conteúdo
`id`	UUID v5 calculado de documento + posição do trecho
`embedding`	Vetor do modelo de `NEXO_EMBED_MODEL`, distância de cosseno
`document`	Texto do trecho
`metadata.source_id`	`nx_document.id` de origem; usado nos filtros de escopo e na exclusão
`metadata.title` / `filename`	Título e nome do arquivo
`metadata.page`	Página do PDF, a partir de 1
`metadata.chunk_index`	Posição do trecho no documento

6.5 Arquivo de usuários

```
{
  "versao": 1,
  "usuarios": [
    {
      "username": "admin",
      "name": "Administrador",
      "role": "admin",
      "password_hash": "$2b$12$...",
      "created_at": "2026-01-01T12:00:00+00:00",
      "last_login_at": null
    }
  ]
}
```

O arquivo é regravado de forma atômica. Nomes de usuário têm de 3 a 32 caracteres minúsculos (letras, números, ponto, hífen e sublinhado). Para redefinir uma senha esquecida, rode `python scripts/redefinir_senha.py nome-do-usuario` no servidor.

6.6 Outro banco relacional

Banco	Driver	`NEXO_DATABASE_URL`
PostgreSQL	`pip install "psycopg[binary]"`	`postgresql+psycopg://usuario:senha@host:5432/nexo`
MySQL / MariaDB	`pip install pymysql`	`mysql+pymysql://usuario:senha@host:3306/nexo`
SQL Server	`pip install pyodbc`	`mssql+pyodbc://usuario:senha@host/nexo?driver=ODBC+Driver+18+for+SQL+Server`

O DDL de referência está em `docs/schema-postgresql.sql` e `docs/schema-sqlite.sql`. O resumo deste capítulo também está em `docs/banco-de-dados.md`.

Copyright (©) 2026 Erik Pimenta

6.7 Backup

Pare o servidor e copie a pasta `data` inteira. Ela contém tudo: banco SQLite, vetores locais, PDFs, usuários e segredo. Com bancos externos, faça também o backup deles pelas ferramentas próprias.

Copyright (©) 2026 Erik Pimenta

07

API

A interface usa a mesma API REST que fica disponível para integrações. A documentação interativa (OpenAPI) abre em http://127.0.0.1:8000/api/docs.

Método	Rota	Descrição
GET	`/api/health`	Situação do servidor e versão
GET	`/api/auth/options`	Cadastro aberto e se o login pré-definido ainda está ativo
POST	`/api/auth/login`	Entrar. Devolve token, validade e usuário
POST	`/api/auth/register`	Criar conta e entrar
GET	`/api/auth/me`	Usuário da sessão
PUT	`/api/auth/password`	Trocar a própria senha
GET	`/api/system/status`	Configuração ativa e números do acervo
GET	`/api/documents`	Listar documentos
POST	`/api/documents`	Enviar um ou mais PDFs (multipart, campo `files`)
GET	`/api/documents/{id}`	Detalhes de um documento
PATCH	`/api/documents/{id}`	Renomear (reindexa)
GET	`/api/documents/{id}/file`	Baixar o PDF original
POST	`/api/documents/{id}/reindex`	Reindexar
DELETE	`/api/documents/{id}`	Excluir PDF, vetores e escopos
GET	`/api/conversations`	Listar as conversas do usuário
POST	`/api/conversations`	Criar conversa, com `document_ids` opcional
GET / PATCH / DELETE	`/api/conversations/{id}`	Abrir com mensagens, renomear ou mudar escopo, excluir
POST	`/api/conversations/{id}/messages`	Perguntar. Devolve pergunta, resposta com fontes e conversa
POST	`/api/messages/{id}/feedback`	Avaliar resposta: `rating` 1, -1 ou 0 para remover

7.1 Exemplo com curl

```
curl -X POST http://127.0.0.1:8000/api/auth/login \
  -H "Content-Type: application/json" \
```

Copyright (©) 2026 Erik Pimenta

```
curl -X POST http://127.0.0.1:8000/api/documents \
  -H "Authorization: Bearer SEU_TOKEN" \
  -F "files=@manual.pdf"

curl -X POST http://127.0.0.1:8000/api/conversations \
  -H "Authorization: Bearer SEU_TOKEN" \
  -H "Content-Type: application/json" -d '{}'

curl -X POST http://127.0.0.1:8000/api/conversations/ID/messages \
  -H "Authorization: Bearer SEU_TOKEN" \
  -H "Content-Type: application/json" \
  -d '{"content": "Como restaurar as configurações de fábrica?"}'
```

7.2 Erros

Todo erro volta como JSON com `code`, `message` e, quando for de campo, `fields`. Exemplos:

HTTP	code	Quando
401	`INVALID_CREDENTIALS` / `SESSION_EXPIRED`	Login errado ou token vencido
429	`LOCKED`	Cinco senhas erradas seguidas
403	`FORBIDDEN` / `REGISTRATION_DISABLED`	Ação sobre documento de outra pessoa ou cadastro fechado
409	`DUPLICATE` / `NO_DOCUMENTS` / `USERNAME_TAKEN`	PDF repetido, pergunta sem documentos prontos, usuário existente
413 / 415	`FILE_TOO_LARGE` / `NOT_A_PDF`	Arquivo grande demais ou que não é PDF
503 / 502	`PROVIDER` / `LLM_FAILURE`	Pacote ou chave de provedor ausente, ou modelo fora do ar

Copyright (©) 2026 Erik Pimenta

08

Qualidade e manutenção

Testes automatizados, medição da busca, integração contínua e a rotina de commits diários.

8.1 Testes automatizados

```
pip install -r requirements-ci.txt
python -m pytest
```

Os testes rodam sem internet nem modelos (embedding hash, modo extrativo, reranker desligado) e cobrem: login pré-definido, bloqueio após cinco erros, cadastro gravado no arquivo com bcrypt, validações de senha e usuário, troca e redefinição de senha, envio e indexação do PDF de exemplo, resposta com fonte e página corretas, pergunta fora do conteúdo, isolamento de conversas entre usuários, avaliação, rejeição de arquivos inválidos e duplicados, permissões de exclusão, remoção dos vetores, filtro de escopo, reordenação e corte do reranker e os scripts auxiliares.

8.2 Medindo a recuperação

Crie um arquivo JSONL com uma pergunta por linha e a página onde a resposta está:

```
{"pergunta": "Como restaurar as configurações de fábrica?", "documento": "manual-exemplo.pdf", "pagina": 2}
{"pergunta": "Qual a temperatura de operação?", "documento": "manual-exemplo.pdf", "pagina": 5}
```

```
python scripts/avaliar.py exemplos/perguntas-exemplo.jsonl --detalhes
```

O script usa o banco e a configuração do `.env` e mostra, para a busca vetorial pura e com reranking, o acerto (a página certa apareceu entre os trechos enviados ao modelo) e o MRR (quanto mais perto do primeiro lugar, mais perto de 1). Repita depois de cada ajuste de parâmetros.

8.3 Integração contínua

O workflow `.github/workflows/ci.yml` roda os testes do Python e o build da interface a cada push e pull request.

8.4 Commit automático diário

O workflow `.github/workflows/diario.yml` acrescenta a data e a hora em `.github/atividade.txt` e faz um commit todos os dias às 11h37 de Brasília (14h37 UTC). O minuto quebrado evita a fila de execuções que o GitHub forma na virada das horas. Para ativar:

1. No repositório, abra **Settings › Secrets and variables › Actions › New repository secret**.
2. Crie `GIT_NAME` com o seu nome de usuário do GitHub.

Copyright (©) 2026 Erik Pimenta

3. Crie `GIT_EMAIL` com o e-mail da conta, ou o endereço `...@users.noreply.github.com` mostrado em **Settings › Emails** do seu perfil. Só commits com um e-mail da sua conta contam no gráfico de contribuições.
4. Em **Settings › Actions › General › Workflow permissions**, marque **Read and write permissions** e salve.
5. Em **Actions › Atividade diaria**, clique em **Run workflow** para testar. O commit aparece em segundos.

Atrasos: o GitHub pode atrasar execuções agendadas em alguns minutos e desativa agendamentos de repositórios sem atividade por 60 dias. Como o próprio workflow gera um commit por dia, o agendamento se mantém ativo.

8.5 Atualizando dependências

```
pip install --upgrade -r requirements.txt
cd frontend && npm update && npm run build
```

8.6 Solução de problemas

Sintoma	Causa provável	O que fazer
"O modelo não respondeu"	Ollama desligado ou modelo não baixado	Abra o Ollama e rode `ollama pull llama3.1`
"Instale o pacote ..."	Provedor configurado sem a biblioteca	`pip install` do pacote indicado na mensagem
"Defina OPENAI_API_KEY"	Provedor OpenAI sem chave	Preencha a chave no `.env` e reinicie
Documento em Falhou: sem texto	PDF digitalizado (imagem)	Aplique OCR (por exemplo OCRmyPDF) e envie de novo
Primeira pergunta demora	Download dos modelos do HuggingFace	Aguarde; as próximas são rápidas
Respostas sempre "Não encontrei"	Cortes de relevância altos para o modelo	Baixe `NEXO_MIN_SIMILARITY` e `NEXO_MIN_RERANK_SCORE`
Tela em branco em /	Interface não compilada	`cd frontend`, `npm install` e `npm run build`
Sessão cai ao reiniciar	`NEXO_SECRET` vazio e pasta `data` apagada	Defina `NEXO_SECRET` fixo no `.env`
Esqueci a senha do admin	Senha trocada e perdida	`python scripts/redefinir_senha.py admin`

Copyright (©) 2026 Erik Pimenta