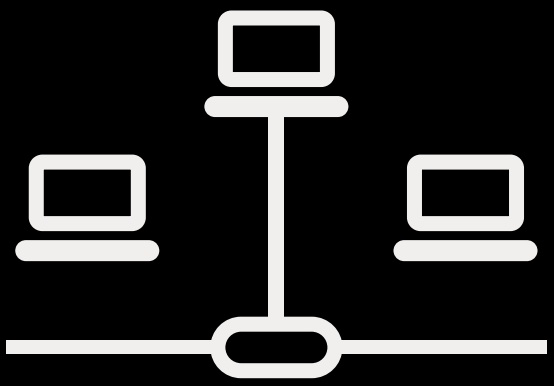


Nexo

Manual do projeto
Chatbot de manuais técnicos e livros em PDF com respostas baseadas somente nos documentos enviados

Versão 1.0.0 | Outubro de 2026 | Licença MIT

Sumário

Visão geral 4

Para que serve 4

O que o projeto entrega 4

Funcionalidades 5

Instalação 6

Pré-requisitos 6

Caminho rápido 6

Passo a passo manual 6

Primeiro acesso 7

Configuração 8

Modos prontos 8

Todas as variáveis 8

Calibrando a precisão 10

Serviços externos com Docker 10

Acesso pela rede 10

Usando o Nexo 11

Documentos 11

Conversas 13

Sistema e conta 16

Tema escuro e celular 17

Arquitetura 18

Módulos do código 18

Indexação de um PDF 19

Respondendo uma pergunta 20

Como as alucinações são reduzidas 20

Segurança 21

Banco de dados 22

Onde cada dado fica 22

Diagrama de relacionamentos 23

Tabelas 23

Coleção vetorial 26

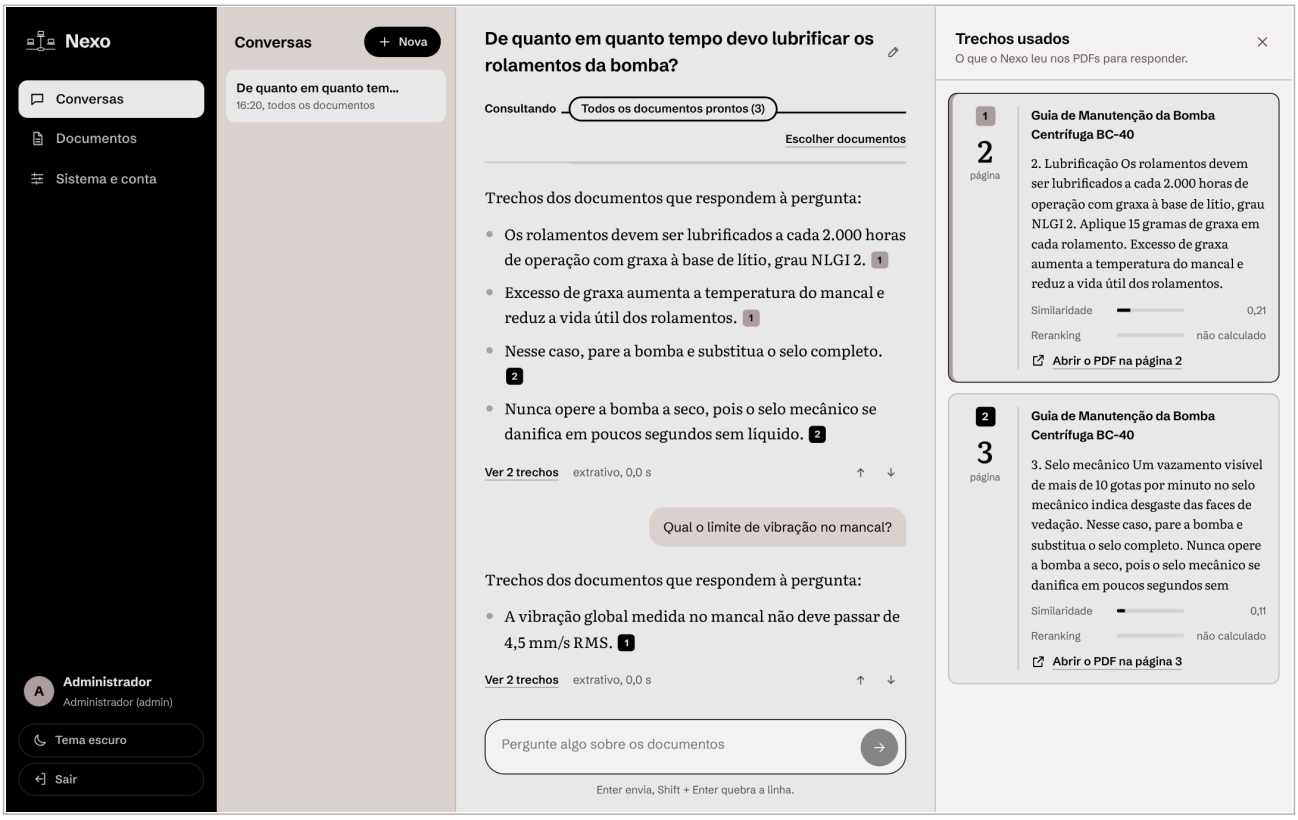
Arquivo de usuários 26

Outro banco relacional 26
Backup 27
API 28
Exemplo com curl 28
Erros 29
Qualidade e manutenção 30
Testes automatizados 30
Medindo a recuperação 30
Integração contínua 30
Commit automático diário 30
Atualizando dependências 31
Solução de problemas 31

Capítulo 1

Visão geral

O Nexo é uma aplicação web em que você envia manuais técnicos ou livros em PDF e conversa com um chatbot que responde só com o que está escrito neles. Cada resposta mostra os trechos usados, com documento e página. Quando a informação não está nos PDFs, o Nexo diz isso em vez de inventar.



Conversa com citações numeradas e o painel de trechos usados, com página, similaridade e link para o PDF.

Para que serve

- Consultar manuais de equipamentos, normas, procedimentos internos e livros técnicos sem folhear centenas de páginas.
- Dar a uma equipe um ponto único de consulta, em que cada resposta pode ser conferida no documento original.
- Estudar um livro complexo fazendo perguntas e indo direto à página que trata do assunto.

O que o projeto entrega

O Nexo é entregue como estrutura pronta: interfaces, arquitetura, banco de dados e documentação. Quem instala decide quais PDFs enviar, quais modelos usar e onde hospedar. Nenhum documento real ou dado pessoal vem no repositório; o único PDF incluído é um manual fictício para testes.

Camada	Tecnologia	Papel
Interface	React 19, TypeScript, Vite	Telas de entrada, documentos, conversas, sistema e conta
API	Python 3.11+, FastAPI, Uvicorn	Rotas REST, autenticação, envio de arquivos e fila de indexação
Pipeline de dados	LlamaIndex, pypdf	Leitura dos PDFs, divisão em trechos, busca e montagem das respostas
Banco vetorial	ChromaDB (padrão) ou Qdrant	Embeddings dos trechos e metadados de origem
Embeddings	HuggingFace, OpenAI ou Ollama	Transformam texto em vetores para a busca semântica
Reranking	Cross-encoder HuggingFace ou Cohere Rerank	Reordenam os candidatos antes de chegarem ao modelo
Modelo de linguagem	Ollama (local) ou OpenAI	Redige a resposta a partir dos trechos
Banco relacional	SQLAlchemy com SQLite (padrão), PostgreSQL, MySQL ou SQL Server	Documentos, conversas, mensagens, fontes e avaliações
Contas	Arquivo JSON com bcrypt, sessões JWT	Login pré-definido e cadastro próprio

Funcionalidades

- **Envio de PDFs** por arrastar e soltar ou seletor de arquivos, vários de uma vez, com limite de tamanho, checagem de formato e bloqueio de duplicados por SHA-256.
- **Indexação em segundo plano** com estados Na fila, Indexando, Pronto e Falhou. A tela se atualiza sozinha.
- **Renomear, reindexar, abrir e excluir** documentos. Excluir apaga o PDF e todos os vetores dele.
- **Conversas** salvas por usuário, com título automático, renomeação e exclusão.
- **Escopo**: cada conversa pode consultar todos os documentos ou só os escolhidos.
- **Citações [n]** clicáveis que abrem o trecho usado e o PDF na página certa.
- **Resposta padrão** quando nada relevante é encontrado: "Não encontrei essa informação nos documentos selecionados."
- **Avaliação** de cada resposta (útil ou não ajudou), guardada no banco.
- **Contas**: login pré-definido de administrador e cadastro de novos usuários, com troca de senha.
- **Tema claro e escuro** e layout para celular.

Capítulo 2

Instalação

Este capítulo leva do download à primeira pergunta respondida. O caminho mais curto é o script de inicialização; os passos manuais vêm logo depois.

Pré-requisitos

Item	Versão	Para quê
Python	3.11 ou mais recente	Servidor, indexação e respostas
Node.js	20.19 ou mais recente	Compilar a interface (uma vez)
Ollama	Atual	Modelo de linguagem local e gratuito (modo padrão)
Espaço em disco	Cerca de 3 GB	Dependências do Python, modelos de embeddings e reranking
Memória	8 GB ou mais	Rodar o llama3.1 local com folga

> **Sem Ollama ou sem GPU?**
> Use a OpenAI como modelo de linguagem (seção 3.2) ou o modo de teste sem modelos para validar a instalação. Os modelos de embeddings e reranking padrão rodam bem em CPU.

Caminho rápido

1. Baixe o repositório (botão **Code › Download ZIP** no GitHub ou `git clone`) e extraia em uma pasta.
2. Instale o Ollama em **ollama.com** e, num terminal, rode `ollama pull llama3.1`.
3. No Windows, dê dois cliques em `iniciar.cmd`. No Linux ou macOS, rode `./iniciar.sh`.
4. Espere a instalação terminar. Na primeira vez ela leva alguns minutos.
5. Abra **http://127.0.0.1:8000** no navegador e entre com `admin` / `Nexo@2026`.
6. Vá em **Documentos**, envie um PDF e, quando aparecer **Pronto**, faça uma pergunta em **Conversas**.

O script cria o ambiente virtual `.venv`, instala `requirements.txt`, copia `.env.example` para `.env`, compila a interface em `frontend/dist` e sobe o servidor. Nas próximas vezes ele só sobe o servidor.

Passo a passo manual

```
python -m venv .venv
.venv\Scripts\activate            (Windows)
source .venv/bin/activate         (Linux / macOS)
pip install -r requirements.txt
copy .env.example .env            (Windows; no Linux/macOS use cp)
cd frontend
npm install
npm run build
cd ..
python -m nexo
```

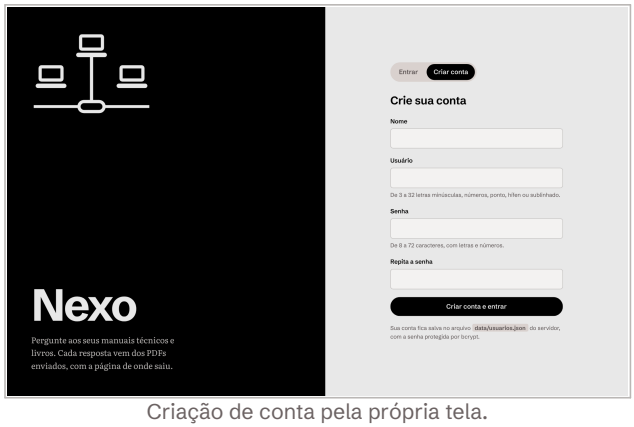
Para desenvolver a interface com recarga automática, rode `python -m nexo` em um terminal e `npm run dev` dentro de `frontend` em outro. A interface abre em **http://localhost:5173** e repassa as chamadas `/api` para a

porta 8000.

Primeiro acesso



Entrada com o aviso do login pré-definido.



Criação de conta pela própria tela.

O login pré-definido é criado quando `data/usuarios.json` ainda não existe. O aviso some da tela de entrada assim que a senha do `admin` é trocada. Troque-a em **Sistema e conta** no primeiro acesso.

Usuário	Senha	Perfil	Pode
`admin`	`Nexo@2026`	Administrador	Tudo, inclusive excluir documentos de outras pessoas e ver o total de contas
`contas novas`	`definida no cadastro`	Usuário	Enviar PDFs, conversar e gerenciar os próprios documentos

Capítulo 3

Configuração

Toda a configuração fica no arquivo .env na raiz do projeto. Altere, salve e reinicie o servidor. A tela Sistema e conta mostra o que está valendo.

Modos prontos

Modo	Linhas no .env	Quando usar

Local e gratuito (padrão)	`NEXO_LLM_PROVIDER=ollama`
	`NEXO_LLM_MODEL=llama3.1`
	`NEXO_EMBED_PROVIDER=huggingface`
	`NEXO_RERANKER=huggingface`
		Documentos sigilosos que não podem sair da máquina

OpenAI	`NEXO_LLM_PROVIDER=openai`
	`NEXO_LLM_MODEL=gpt-4o-mini`
	`OPENAI_API_KEY=sua-chave`
		Respostas mais elaboradas sem precisar de GPU

Embeddings da OpenAI	`NEXO_EMBED_PROVIDER=openai`
	`NEXO_EMBED_MODEL=text-embedding-3-small`
	`NEXO_EMBED_QUERY_PREFIX=`
	`NEXO_EMBED_TEXT_PREFIX=`
		Acervos grandes, sem baixar modelos locais

Reranking Cohere	`NEXO_RERANKER=cohere` `COHERE_API_KEY=sua-chave`	Melhor ordenação em vários idiomas sem custo de CPU
Qdrant	`NEXO_VECTOR_STORE=qdrant` `NEXO_QDRANT_URL=http://localhost:6333`	Acervos com muitos milhares de trechos ou servidor dedicado

Teste sem modelos	`NEXO_EMBED_PROVIDER=hash`
	`NEXO_LLM_PROVIDER=extrativo`
	`NEXO_RERANKER=none`
	`NEXO_MIN_SIMILARITY=0.1`
		Validar a instalação e rodar os testes automatizados

Trocou o modelo de embeddings?
Vetores de modelos diferentes não são comparáveis. Depois de mudar NEXO_EMBED_PROVIDER ou NEXO_EMBED_MODEL, use uma coleção nova (NEXO_COLLECTION) ou reindexe todos os documentos pela tela Documentos.

Todas as variáveis

Variável	Padrão	Descrição
`NEXO_HOST / NEXO_PORT`	`127.0.0.1 / 8000`	Endereço do servidor. Use 0.0.0.0 para aceitar acessos da rede
`NEXO_DATA_DIR`	`data`	Pasta do banco SQLite, PDFs, vetores locais e usuários
`NEXO_SECRET`	`gerado`	Chave das sessões. Vazia: o Nexo cria data/.segredo
`NEXO_TOKEN_HOURS`	`8`	Duração da sessão em horas
`NEXO_ALLOW_REGISTRATION`	`true`	Permite criar contas na tela de entrada

Variável	Padrão	Descrição
NEXO_MAX_UPLOAD_MB	100	Tamanho máximo de cada PDF
NEXO_DATABASE_URL	vazio	URL SQLAlchemy de outro banco relacional
NEXO_LLM_PROVIDER	ollama	ollama, openai ou extrativo
NEXO_LLM_MODEL	llama3.1	Nome do modelo no provedor escolhido
NEXO_LLM_TEMPERATURE	0.1	Criatividade do modelo. Mantenha baixa
NEXO_LLM_TIMEOUT	120	Tempo máximo de resposta do modelo, em segundos
NEXO_OLLAMA_URL	http://localhost:11434	Endereço do Ollama
OPENAI_API_KEY	vazio	Chave da OpenAI
NEXO_OPENAI_BASE_URL	vazio	Endpoint compatível com a OpenAI (Azure, LM Studio, vLLM)
NEXO_EMBED_PROVIDER	huggingface	huggingface, openai, ollama ou hash
NEXO_EMBED_MODEL	intfloat/multilingual-e5-small	Modelo de embeddings
NEXO_EMBED_QUERY_PREFIX / _TEXT_PREFIX	query: / passage:	Prefixos exigidos pela família E5. Deixe vazio em outros modelos
NEXO_VECTOR_STORE	chroma	chroma ou qdrant
NEXO_COLLECTION	nexo_trechos	Nome da coleção vetorial
NEXO_CHROMA_HOST / _PORT	vazio / 8001	Servidor ChromaDB. Vazio: arquivos em data/chroma
NEXO_QDRANT_URL / _API_KEY	vazio	Servidor Qdrant. Vazio: arquivos em data/qdrant
NEXO_RERANKER	huggingface	huggingface, cohere ou none
NEXO_RERANK_MODEL	cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	Cross-encoder multilíngue do HuggingFace
NEXO_COHERE_MODEL / COHERE_API_KEY	rerank-v3.5 / vazio	Reranking da Cohere
NEXO_CHUNK_SIZE / _OVERLAP	512 / 64	Tamanho dos trechos e sobreposição, em tokens
NEXO_TOP_K	12	Candidatos trazidos pela busca vetorial
NEXO_TOP_N	4	Trechos enviados ao modelo depois do reranking
NEXO_MIN_SIMILARITY	0.15	Similaridade de cosseno mínima para um trecho ser considerado
NEXO_MIN_RERANK_SCORE	0.1	Nota mínima do reranker (0 a 1)
NEXO_HISTORY_TURNS	3	Pares de pergunta e resposta usados para entender a pergunta atual
NEXO_VERIFY_ANSWERS	false	Confere a resposta com o FaithfulnessEvaluator (dobra as chamadas ao LLM)

Calibrando a precisão

- **Respostas dizendo que não encontrou, mas a informação existe:** baixe `NEXO_MIN_SIMILARITY` (por exemplo 0.1) e `NEXO_MIN_RERANK_SCORE` (0.05), ou aumente `NEXO_TOP_K`.
- **Respostas misturando assuntos:** suba `NEXO_MIN_RERANK_SCORE` (0.3) e reduza `NEXO_TOP_N` para 3.
- **Tabelas e listas longas cortadas:** aumente `NEXO_CHUNK_SIZE` para 768 ou 1024 e reindexe.
- **Medir em vez de adivinhar:** use `scripts/avaliar.py` (capítulo 8) antes e depois de cada ajuste.

Serviços externos com Docker

O `docker-compose.yml` traz serviços opcionais, cada um em um perfil:

```
docker compose --profile chroma up -d     ChromaDB em http://localhost:8001
docker compose --profile qdrant up -d     Qdrant em http://localhost:6333
docker compose --profile ollama up -d     Ollama em http://localhost:11434
docker compose --profile postgres up -d   PostgreSQL em localhost:5432
```

Depois aponte o `.env` para eles, por exemplo `NEXO_CHROMA_HOST=localhost` ou `NEXO_DATABASE_URL=postgresql+psycopg://nexo:troque-esta-senha@localhost:5432/nexo` (instale `pip install "psycopg[binary]"`). Troque a senha do PostgreSQL no arquivo antes de usar.

Acesso pela rede

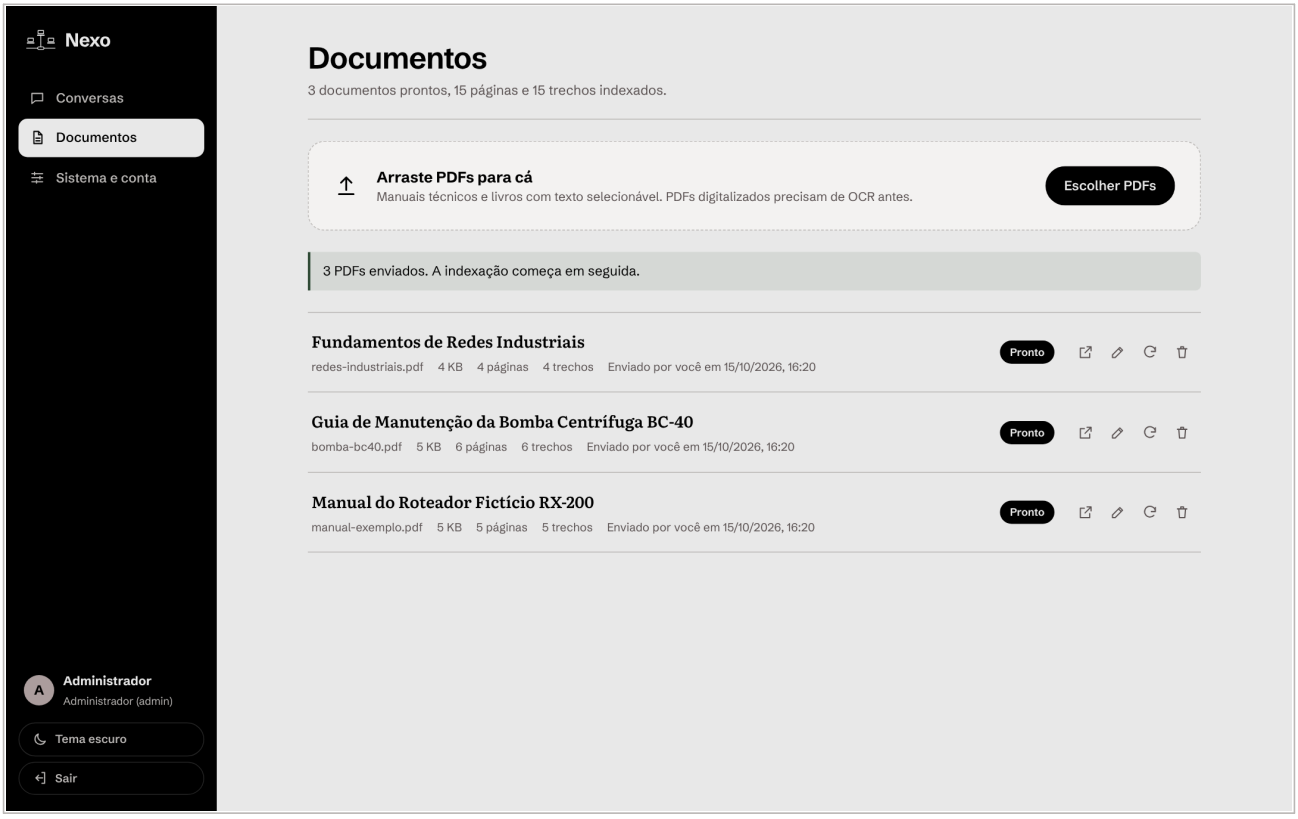
Para outras máquinas acessarem, use `NEXO_HOST=0.0.0.0`, libere a porta no firewall e defina `NEXO_SECRET` com um valor longo e aleatório. Em produção, coloque o Nexo atrás de um proxy com HTTPS (Nginx, Caddy ou IIS) e desligue o cadastro aberto se o acesso deve ser restrito.

Capítulo 4

Usando o Nexo

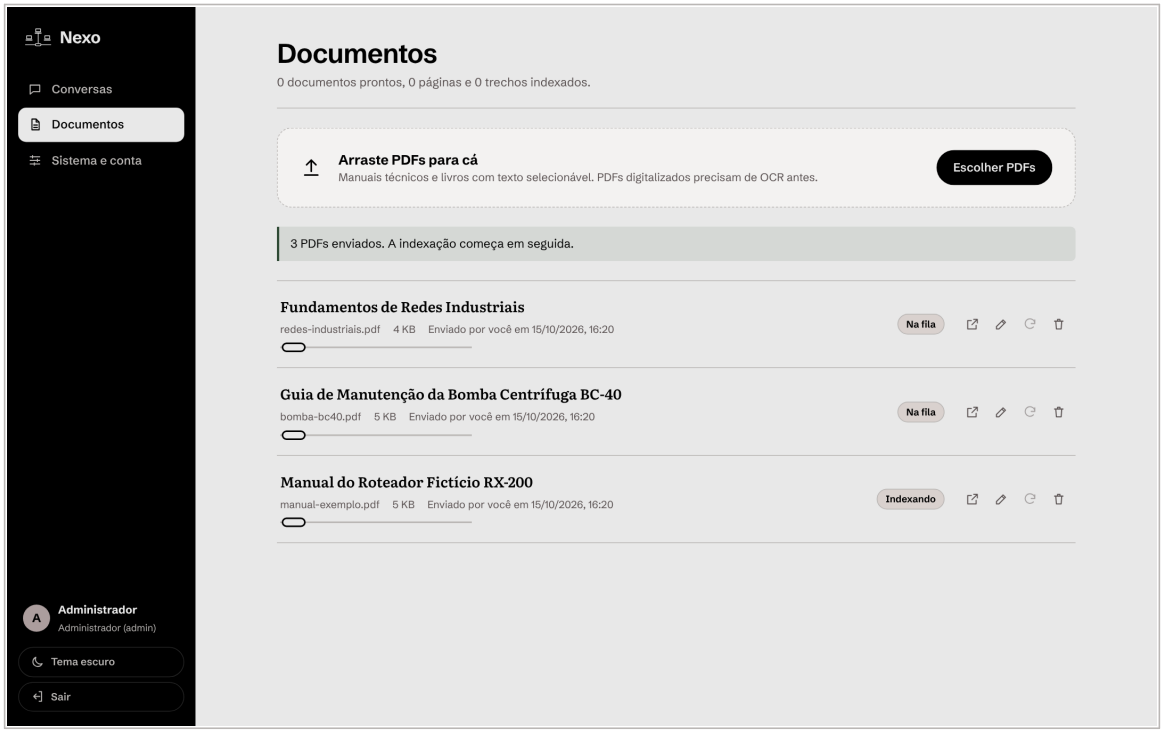
As telas seguem o caminho natural de uso: entrar, enviar documentos, conversar e conferir a configuração.

Documentos



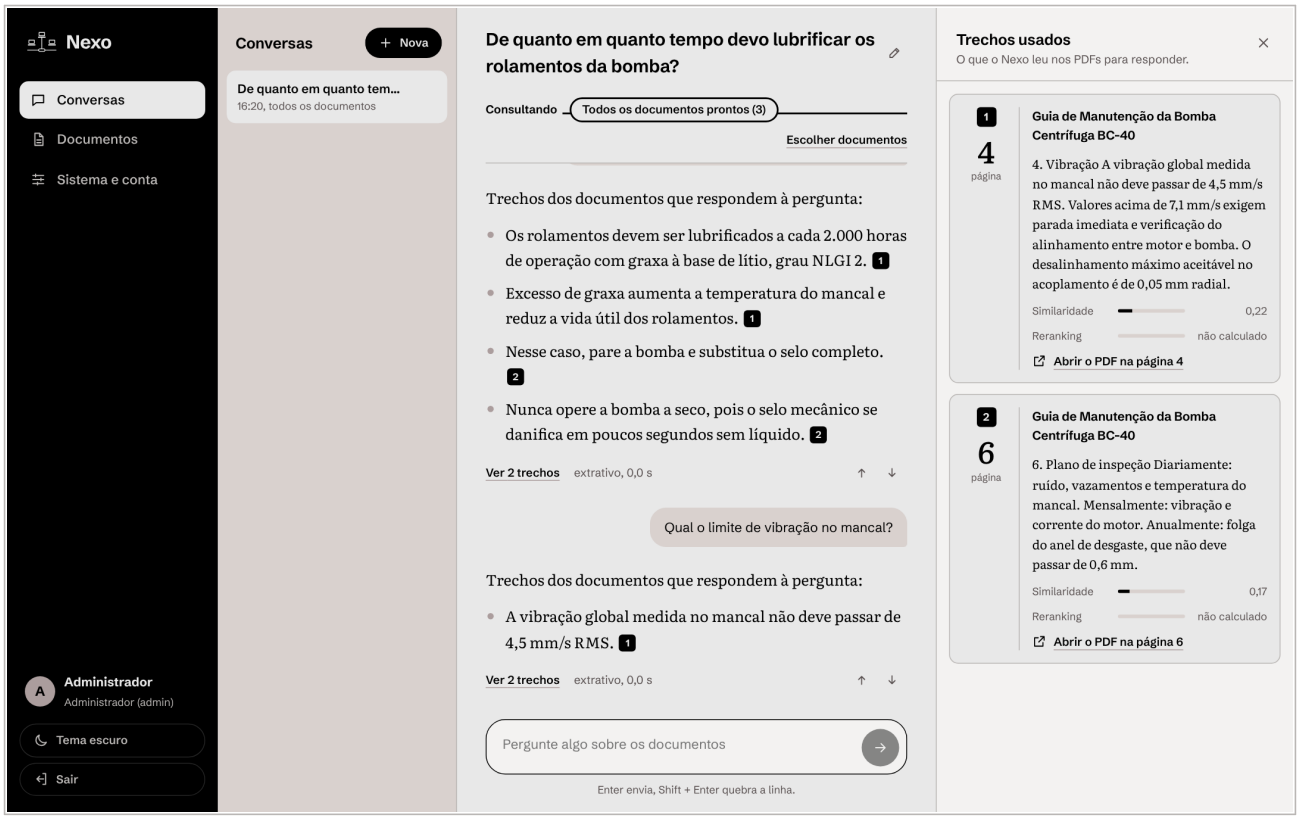
Lista de documentos com páginas, trechos, autor do envio e ações.

1. Arraste PDFs para a área tracejada ou clique em **Escolher PDFs**.
2. Cada arquivo entra como **Na fila**, passa a **Indexando** e termina em **Pronto**. Uma barra animada indica o trabalho em andamento.
3. Se aparecer **Falhou**, o motivo fica logo abaixo do título. O caso mais comum é PDF digitalizado sem texto: aplique OCR e envie de novo.
4. Use os ícones à direita para abrir o PDF, renomear, reindexar e excluir. Renomear reindexa, porque o título faz parte da busca.



Documentos sendo indexados logo após o envio.

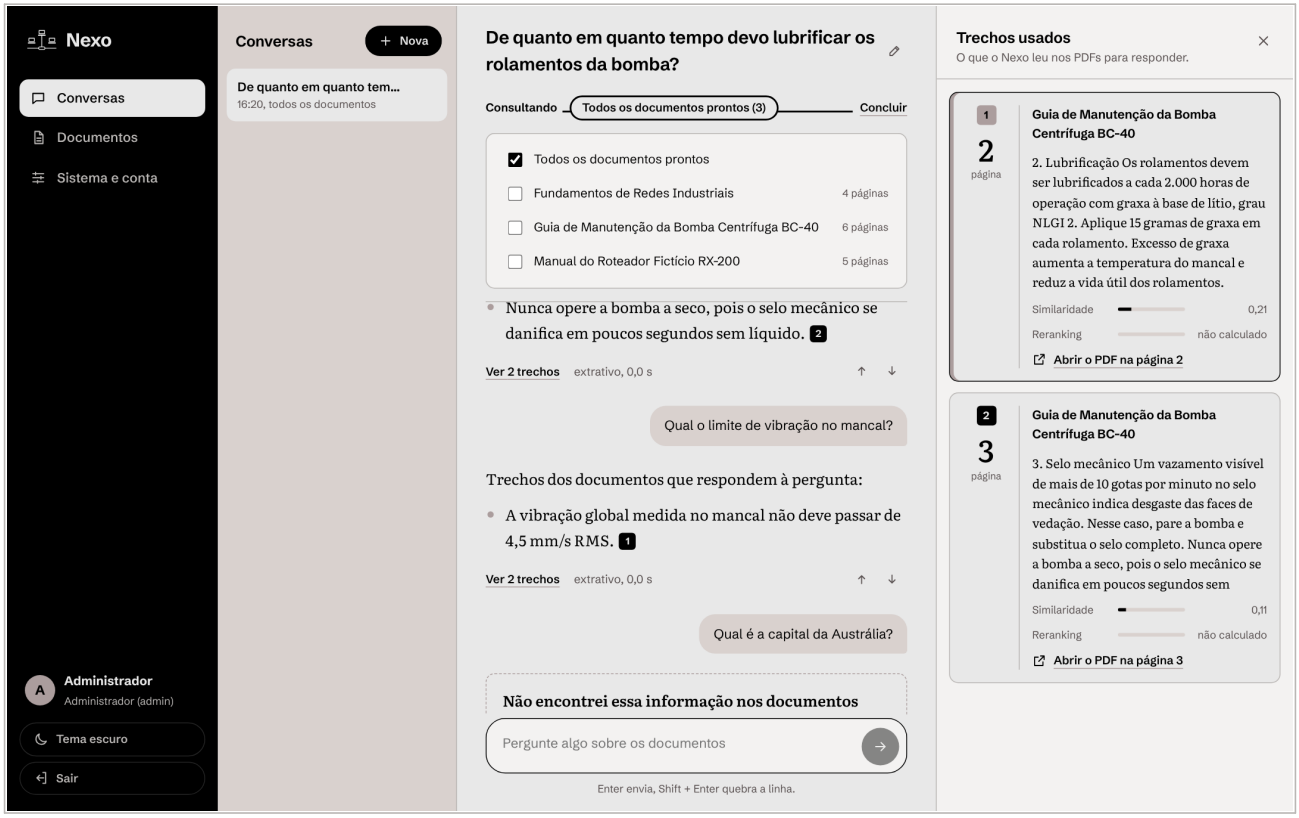
Conversas



Duas perguntas na mesma conversa, com os trechos da última resposta abertos.

- **Nova** abre uma conversa vazia. O título vem da primeira pergunta e pode ser editado no lápis.
- **Enter** envia, **Shift + Enter** quebra a linha.
- Os números pretos **[n]** no texto indicam de qual trecho veio cada informação. Clique para destacá-lo no painel **Trechos usados**.
- Cada trecho mostra a página, a similaridade da busca, a nota do reranker e o link **Abrir o PDF na página**.
- Use as setas para cima e para baixo para avaliar a resposta. Clique de novo para desfazer.
- Perguntas seguintes podem usar "isso", "esse passo" ou "e depois?": o Nexo reescreve a pergunta com o histórico antes de buscar.

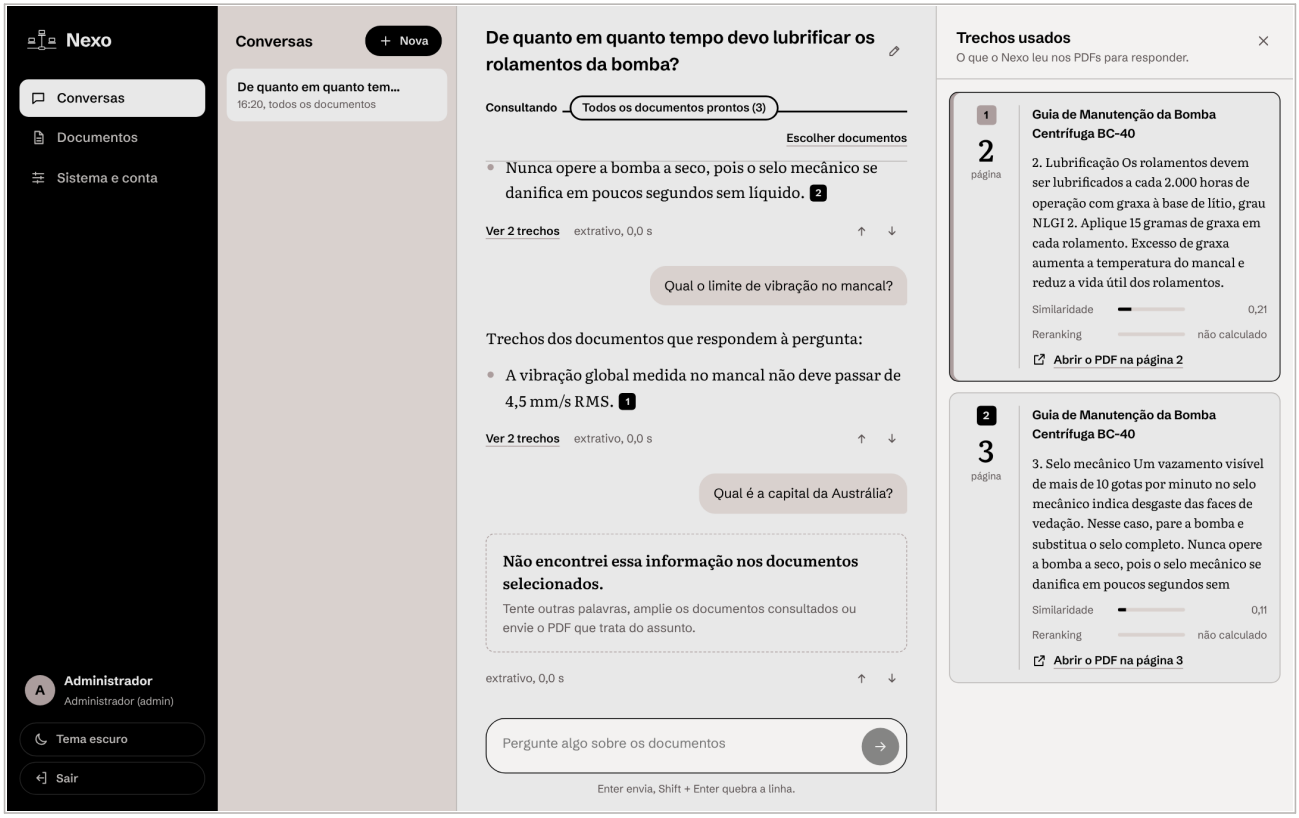
Escolhendo os documentos consultados



Seletor de documentos da conversa.

A linha **Consultando** mostra o escopo atual. Clique em **Escolher documentos** e marque os PDFs que a conversa deve usar. Sem nenhum marcado, todos os documentos prontos são consultados.

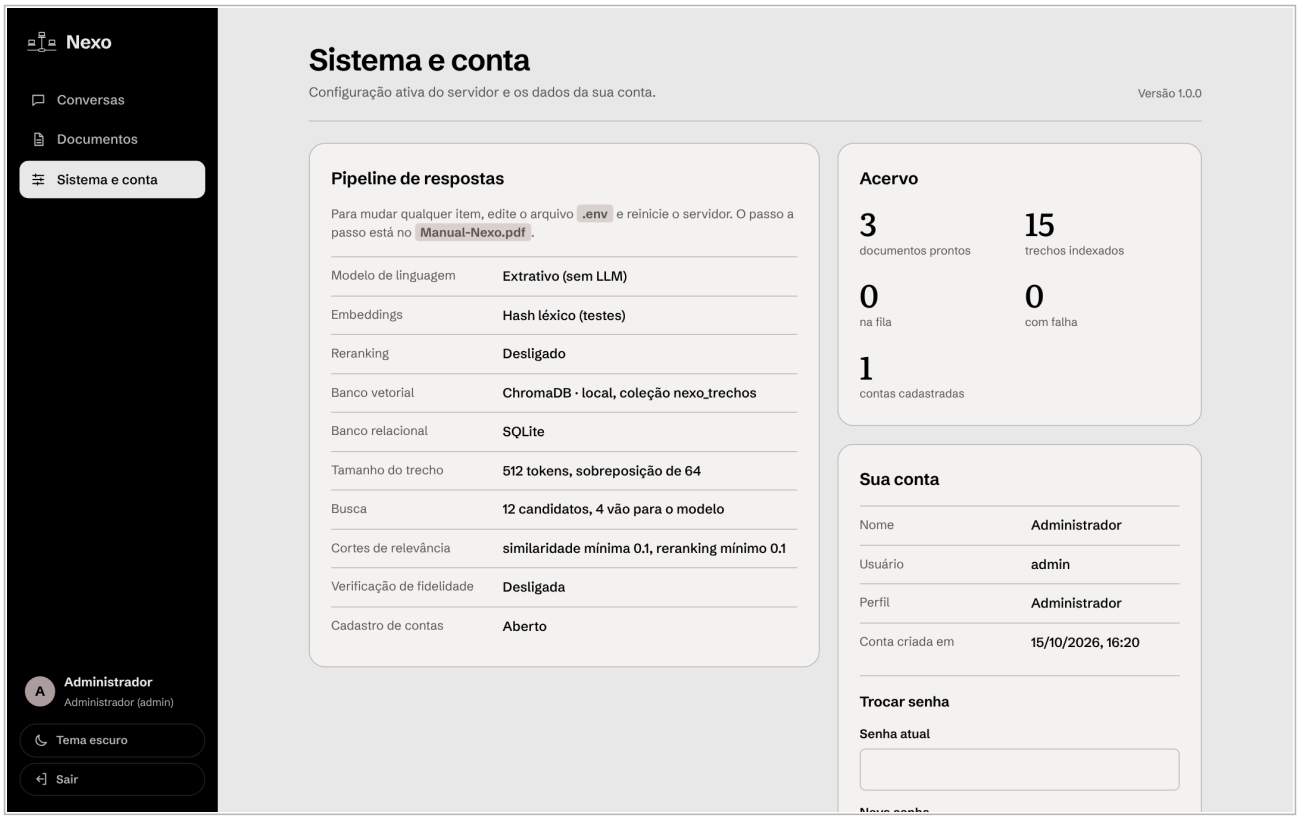
Quando a resposta não está nos PDFs



Pergunta fora do conteúdo dos documentos.

Se nenhum trecho passar pelos cortes de relevância, o modelo nem é chamado e a resposta aparece em um quadro tracejado. Isso é o comportamento esperado: o Nexo prefere não responder a responder sem base.

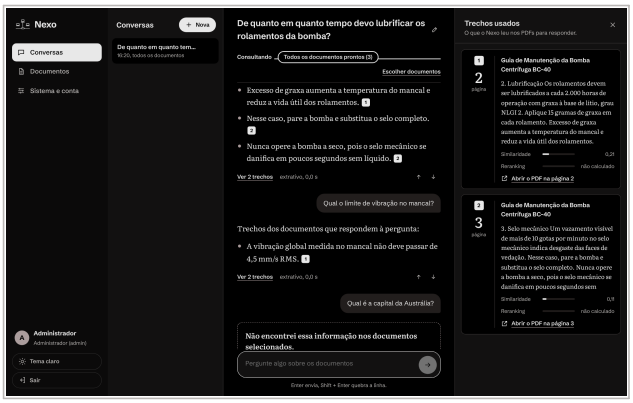
Sistema e conta



Configuração ativa, números do acervo e dados da conta.

A tela mostra os provedores em uso, os parâmetros de busca, a contagem de documentos e trechos e, para administradores, o total de contas. Na seção **Sua conta** fica o formulário de troca de senha (8 a 72 caracteres, com letras e números, sem conter o nome de usuário).

Tema escuro e celular



Tema escuro, escolhido no menu lateral.

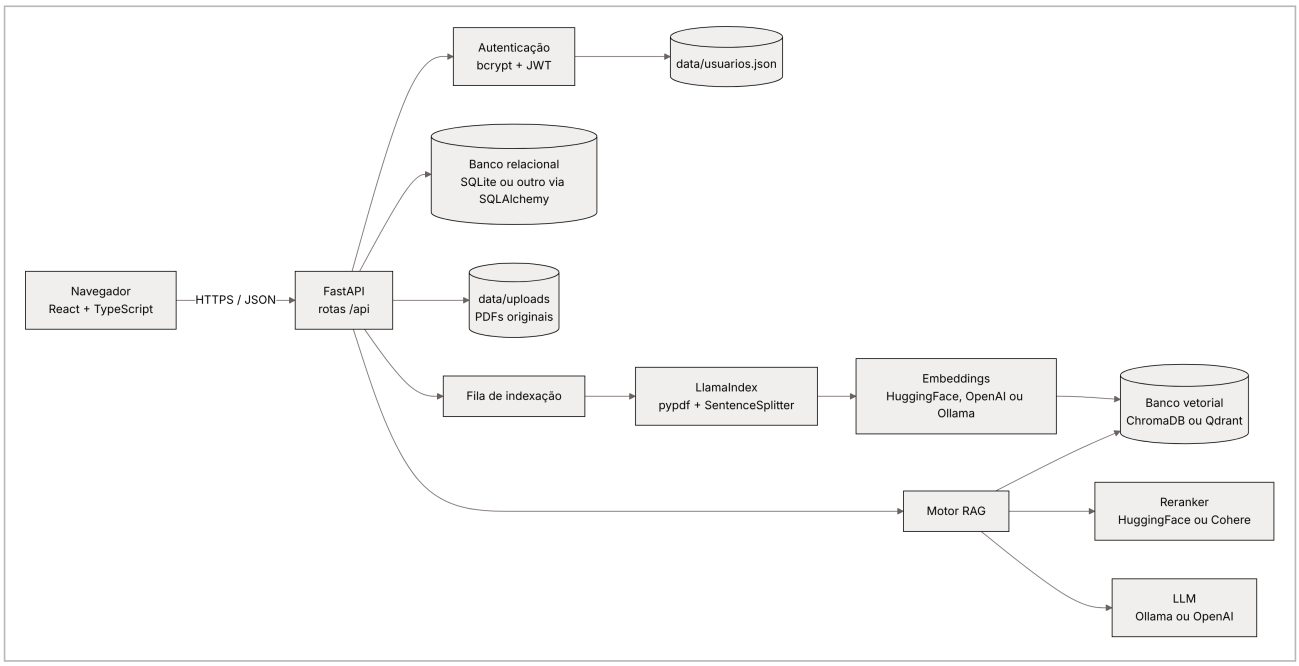


Layout de celular com menu recolhido.

Capítulo 5

Arquitetura

O Nexo é um único processo Python que serve a API e a interface compilada. Os componentes pesados (modelos e banco vetorial) são plugáveis por configuração.

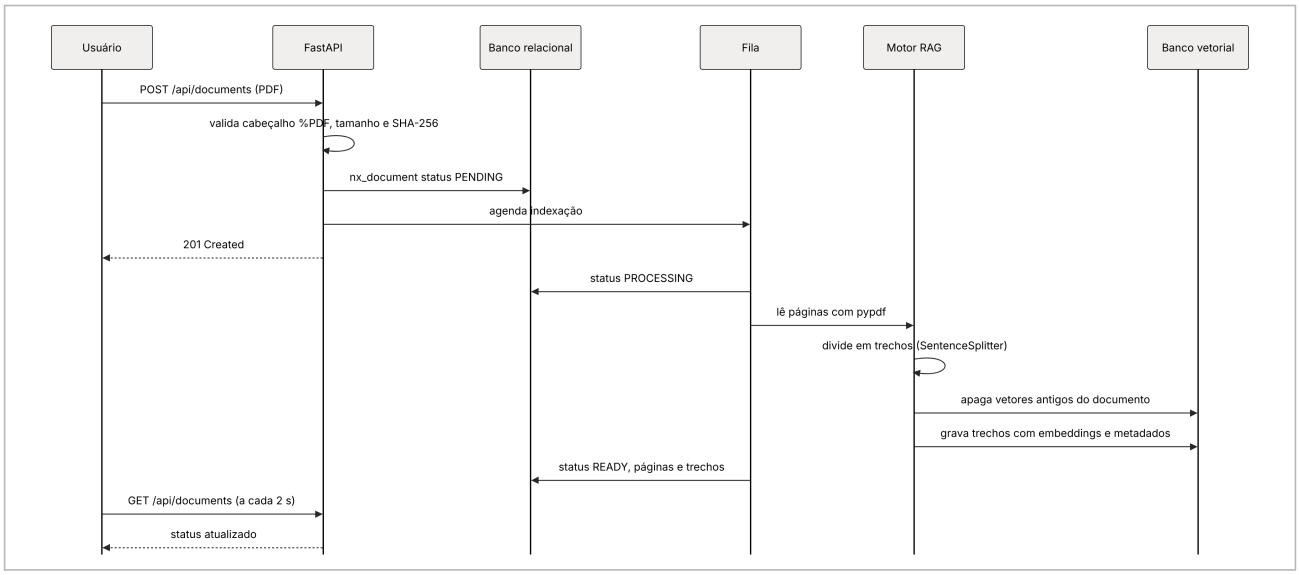


Componentes e dependências.

Módulos do código

Arquivo	Responsabilidade
`nexo/config.py`	Lê o .env com pydantic-settings e define os caminhos em data/
`nexo/db.py`	Modelos SQLAlchemy, criação das tabelas e sessões
`nexo/users.py`	Contas em JSON: cadastro, autenticação com bcrypt, bloqueio após 5 erros, troca de senha
`nexo/security.py`	Emissão e leitura de tokens JWT (HS256)
`nexo/jobs.py`	Fila de indexação em uma thread, retomada de pendências ao iniciar
`nexo/rag/engine.py`	Leitura dos PDFs, divisão em trechos, indexação, busca, reranking, prompt e resposta
`nexo/rag/providers.py`	Fábrica de LLM, embeddings, banco vetorial e reranker conforme o .env
`nexo/rag/hash_embedding.py`	Embedding léxico sem rede, usado nos testes e no modo de teste
`nexo/api/routes.py`	Rotas REST de autenticação, documentos, conversas, mensagens e sistema
`nexo/api/app.py`	Aplicação FastAPI, tratamento de erros, cabeçalhos de segurança e entrega da interface
`frontend/src`	Interface React: páginas, componentes, cliente da API e tema

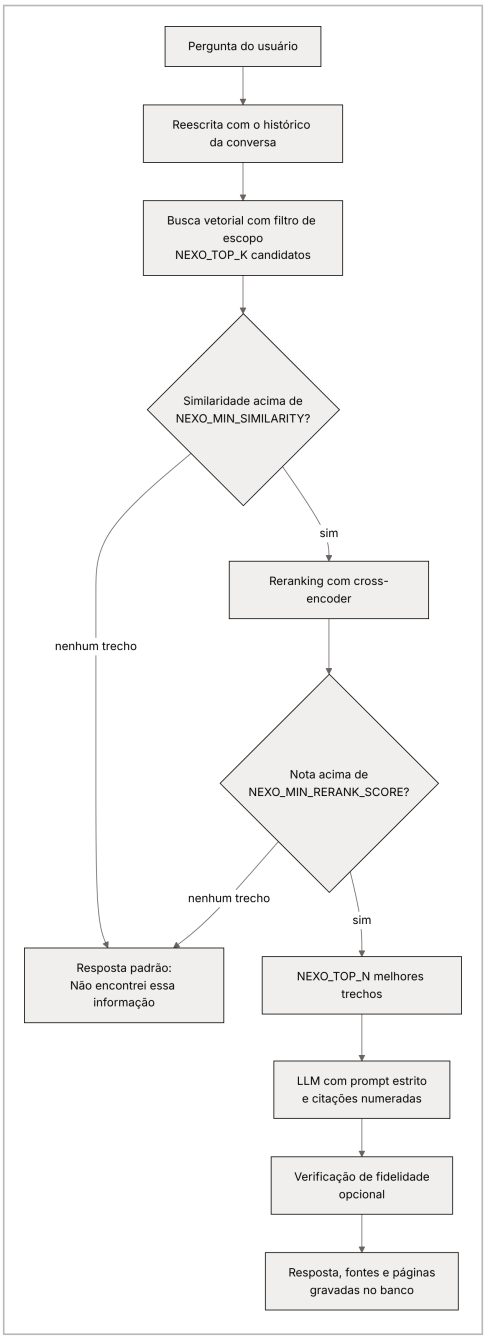
Indexação de um PDF



Sequência do envio até o documento ficar pronto.

- O texto de cada página é extraído com **pypdf**, com hifenizações desfeitas e quebras de linha do layout unidas.
- O **SentenceSplitter** do LlamaIndex divide o texto em trechos de `NEXO_CHUNK_SIZE` tokens respeitando frases, com sobreposição para não perder contexto na fronteira.
- Cada trecho guarda `source_id`, `title`, `filename`, `page` e `chunk_index`. Só o título entra no texto do embedding, junto com o conteúdo.
- Reindexar apaga os vetores antigos do documento antes de gravar os novos, então nunca há duplicação.

Respondendo uma pergunta



Etapas da pergunta até a resposta.

Como as alucinações são reduzidas

Mecanismo	Efeito
Cortes de similaridade e de reranking	Trechos fracos são descartados. Sem trechos, o LLM não é chamado e a resposta padrão é devolvida
Reranking com cross-encoder	Lê pergunta e trecho juntos e reordena os candidatos por relevância real, não só proximidade vetorial
Prompt estrito	Proíbe conhecimento próprio, exige citação [n] em cada afirmação e define a frase exata para quando falta base

Mecanismo	Efeito
Temperatura 0,1	Respostas estáveis e próximas do texto
Escopo por conversa	Evita misturar manuais de equipamentos diferentes
Verificação de fidelidade	Opcional: uma segunda chamada confere se a resposta é sustentada pelos trechos e marca a mensagem quando não é
Fontes gravadas	Cada resposta guarda os trechos usados, o que permite auditar respostas antigas

Segurança

- Senhas guardadas só como hash **bcrypt**. Cinco erros seguidos bloqueiam o usuário por 5 minutos.
- Sessões com **JWT** assinado por `NEXO_SECRET`, com validade de `NEXO_TOKEN_HOURS` horas. A interface guarda o token só na aba aberta (sessionStorage).
- Conversas visíveis apenas para o dono. Documentos só podem ser alterados por quem enviou ou por um administrador.
- Uploads validados pelo cabeçalho `%PDF`, pelo tamanho e pelo SHA-256. Nomes de arquivo são saneados e os PDFs são gravados com o id interno.
- Cabeçalhos `X-Content-Type-Options`, `X-Frame-Options` e `Referrer-Policy` em todas as respostas. A API não é guardada em cache.
- Chaves de API ficam só no `.env`, que está no `.gitignore`.

Capítulo 6

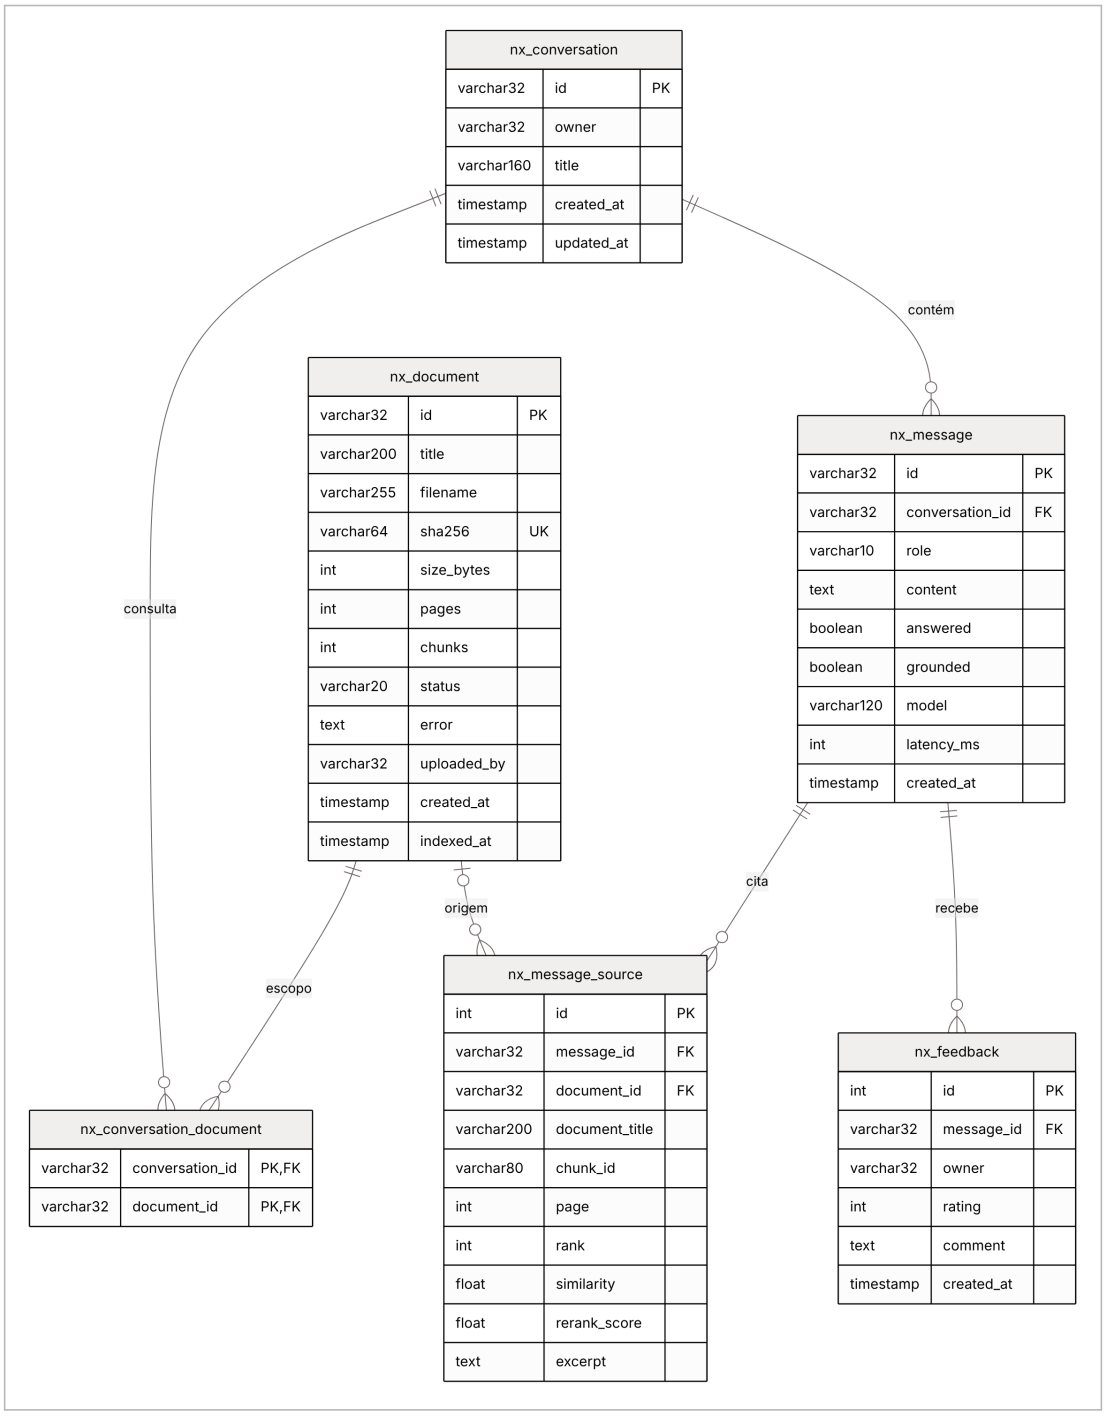
Banco de dados

Este capítulo descreve a estrutura que os dados devem seguir. As tabelas são criadas automaticamente, mas quem administra o banco, migra para outro servidor ou integra com outros sistemas encontra aqui o modelo completo.

Onde cada dado fica

Camada	Local padrão	Conteúdo
Banco relacional	`data/nexo.db`	Documentos, conversas, mensagens, fontes citadas e avaliações
Banco vetorial	`data/chroma/ ou data/qdrant/`	Trechos, embeddings e metadados de origem
Arquivos	`data/uploads/<id>.pdf`	PDFs originais
Contas	`data/usuarios.json`	Usuários, perfis e hashes de senha
Segredo	`data/.segredo`	Chave das sessões quando NEXO_SECRET está vazio

Diagrama de relacionamentos



Tabelas do banco relacional e suas ligações.

Tabelas

nx_document

Um registro por PDF enviado.

Coluna	Tipo	Regra
id	varchar(32)	PK. UUID em hexadecimal; nome do arquivo em data/uploads
title	varchar(200)	Título dos metadados do PDF ou nome do arquivo
filename	varchar(255)	Nome original saneado
sha256	varchar(64)	Único. Bloqueia envios repetidos
size_bytes	integer	Tamanho do arquivo
pages / chunks	integer	Páginas do PDF e trechos indexados
status	varchar(20)	PENDING, PROCESSING, READY ou FAILED (indexado)
error	text	Motivo da falha
uploaded_by	varchar(32)	Usuário que enviou (indexado)
created_at / indexed_at	timestamp	Envio e fim da indexação, em UTC

nx_conversation

Conversas, cada uma de um único usuário.

Coluna	Tipo	Regra
id	varchar(32)	PK
owner	varchar(32)	Usuário dono (indexado)
title	varchar(160)	Padrão "Nova conversa"; recebe a primeira pergunta
created_at / updated_at	timestamp	updated_at indexado para ordenar a lista

nx_conversation_document

Escopo da conversa. Sem linhas, todos os documentos prontos são consultados.

Coluna	Tipo	Regra
conversation_id	varchar(32)	PK e FK para nx_conversation, ON DELETE CASCADE
document_id	varchar(32)	PK e FK para nx_document, ON DELETE CASCADE

nx_message

Perguntas e respostas.

Coluna	Tipo	Regra
id	varchar(32)	PK
conversation_id	varchar(32)	FK para nx_conversation, ON DELETE CASCADE
role	varchar(10)	user ou assistant
content	text	Texto da pergunta ou resposta
answered	boolean	false quando o Nexo não encontrou a informação
grounded	boolean	Resultado da verificação de fidelidade; nulo se desligada
model / latency_ms	varchar(120) / integer	Modelo que respondeu e tempo gasto
created_at	timestamp	Índice composto com conversation_id

nx_message_source

Trechos efetivamente enviados ao modelo, na ordem das citações.

Coluna	Tipo	Regra
id	integer	PK autoincremento
message_id	varchar(32)	FK para nx_message, ON DELETE CASCADE
document_id	varchar(32)	FK para nx_document, ON DELETE SET NULL
document_title	varchar(200)	Cópia do título, mantém o histórico legível após exclusões
chunk_id	varchar(80)	Id do trecho no banco vetorial
page / rank	integer	Página do PDF e número da citação [n]
similarity / rerank_score	float	Similaridade de cosseno e nota do reranker
excerpt	text	Texto do trecho (até 1.200 caracteres)

nx_feedback

Avaliações das respostas. Uma por usuário e resposta.

Coluna	Tipo	Regra
id	integer	PK autoincremento
message_id	varchar(32)	FK para nx_message, ON DELETE CASCADE
owner	varchar(32)	Usuário que avaliou; único junto com message_id
rating	integer	1 útil, -1 não ajudou
comment	text	Comentário opcional (via API)
created_at	timestamp	Data da avaliação

Coleção vetorial

Campo	Conteúdo
`id`	UUID v5 calculado de documento + posição do trecho
`embedding`	Vetor do modelo de NEXO_EMBED_MODEL, distância de cosseno
`document`	Texto do trecho
`metadata.source_id`	nx_document.id de origem; usado nos filtros de escopo e na exclusão
`metadata.title / filename`	Título e nome do arquivo
`metadata.page`	Página do PDF, a partir de 1
`metadata.chunk_index`	Posição do trecho no documento

Arquivo de usuários

```
{
  "versao": 1,
  "usuarios": [
    {
      "username": "admin",
      "name": "Administrador",
      "role": "admin",
      "password_hash": "$2b$12$...",
      "created_at": "2026-01-01T12:00:00+00:00",
      "last_login_at": null
    }
  ]
}
```

O arquivo é regravado de forma atômica. Nomes de usuário têm de 3 a 32 caracteres minúsculos (letras, números, ponto, hífen e sublinhado). Para redefinir uma senha esquecida, rode `python scripts/redefinir_senha.py nome-do-usuario` no servidor.

Outro banco relacional

Banco	Driver	NEXO_DATABASE_URL
PostgreSQL	`pip install "psycopg[binary]"`	`postgresql+psycopg://usuario:senha@host:5432/nexo`
MySQL / MariaDB	`pip install pymysql`	`mysql+pymysql://usuario:senha@host:3306/nexo`
SQL Server	`pip install pyodbc`	`mssql+pyodbc://usuario:senha@host/nexo?driver=ODBC+Driver+18+for+SQL+Server`

O DDL de referência está em `docs/schema-postgresql.sql` e `docs/schema-sqlite.sql`. O mesmo conteúdo deste capítulo está em `docs/banco-de-dados.md`.

Backup

Pare o servidor e copie a pasta `data` inteira. Ela contém tudo: banco SQLite, vetores locais, PDFs, usuários e segredo. Com bancos externos, faça também o backup deles pelas ferramentas próprias.

Capítulo 7

API

A interface usa a mesma API REST que fica disponível para integrações. A documentação interativa (OpenAPI) abre em http://127.0.0.1:8000/api/docs.

Método	Rota	Descrição
GET	/api/health	Situação do servidor e versão
GET	/api/auth/options	Cadastro aberto e se o login pré-definido ainda está ativo
POST	/api/auth/login	Entrar. Devolve token, validade e usuário
POST	/api/auth/register	Criar conta e entrar
GET	/api/auth/me	Usuário da sessão
PUT	/api/auth/password	Trocar a própria senha
GET	/api/system/status	Configuração ativa e números do acervo
GET	/api/documents	Listar documentos
POST	/api/documents	Enviar um ou mais PDFs (multipart, campo files)
GET	/api/documents/{id}	Detalhes de um documento
PATCH	/api/documents/{id}	Renomear (reindexa)
GET	/api/documents/{id}/file	Baixar o PDF original
POST	/api/documents/{id}/reindex	Reindexar
DELETE	/api/documents/{id}	Excluir PDF, vetores e escopos
GET	/api/conversations	Listar as conversas do usuário
POST	/api/conversations	Criar conversa, com document_ids opcional
GET / PATCH / DELETE	/api/conversations/{id}	Abrir com mensagens, renomear ou mudar escopo, excluir
POST	/api/conversations/{id}/messages	Perguntar. Devolve pergunta, resposta com fontes e conversa
POST	/api/messages/{id}/feedback	Avaliar resposta: rating 1, -1 ou 0 para remover

Exemplo com curl

```
curl -X POST http://127.0.0.1:8000/api/auth/login \
     -H "Content-Type: application/json" \
     -d '{"username": "admin", "password": "Nexo@2026"}'

curl -X POST http://127.0.0.1:8000/api/documents \
     -H "Authorization: Bearer SEU_TOKEN" \
     -F "files=@manual.pdf"

curl -X POST http://127.0.0.1:8000/api/conversations \
     -H "Authorization: Bearer SEU_TOKEN" \
     -H "Content-Type: application/json" -d '{}'
```

```
curl -X POST http://127.0.0.1:8000/api/conversations/ID/messages \
     -H "Authorization: Bearer SEU_TOKEN" \
     -H "Content-Type: application/json" \
     -d '{"content": "Como restaurar as configurações de fábrica?"}'
```

Erros

Todo erro volta como JSON com `code`, `message` e, quando for de campo, `fields`. Exemplos:

HTTP	code	Quando
401	INVALID_CREDENTIALS / SESSION_EXPIRED	Login errado ou token vencido
429	LOCKED	Cinco senhas erradas seguidas
403	FORBIDDEN / REGISTRATION_DISABLED	Ação sobre documento de outra pessoa ou cadastro fechado
409	DUPLICATE / NO_DOCUMENTS / USERNAME_TAKEN	PDF repetido, pergunta sem documentos prontos, usuário existente
413 / 415	FILE_TOO_LARGE / NOT_A_PDF	Arquivo grande demais ou que não é PDF
503 / 502	PROVIDER / LLM_FAILURE	Pacote ou chave de provedor ausente, ou modelo fora do ar

Capítulo 8

Qualidade e manutenção

Testes automatizados, medição da busca, integração contínua e a rotina de commits diários.

Testes automatizados

```
pip install -r requirements-ci.txt
python -m pytest
```

Os testes rodam sem internet nem modelos (embedding hash, modo extrativo, reranker desligado) e cobrem: login pré-definido, bloqueio após cinco erros, cadastro gravado no arquivo com bcrypt, validações de senha e usuário, troca e redefinição de senha, envio e indexação do PDF de exemplo, resposta com fonte e página corretas, pergunta fora do conteúdo, isolamento de conversas entre usuários, avaliação, rejeição de arquivos inválidos e duplicados, permissões de exclusão, remoção dos vetores, filtro de escopo, reordenação e corte do reranker e os scripts auxiliares.

Medindo a recuperação

Crie um arquivo JSONL com uma pergunta por linha e a página onde a resposta está:

```
{"pergunta": "Como restaurar as configurações de fábrica?", "documento": "manual-exemplo.pdf", "pagina": 2}
{"pergunta": "Qual a temperatura de operação?", "documento": "manual-exemplo.pdf", "pagina": 5}

python scripts/avaliar.py exemplos/perguntas-exemplo.jsonl --detalhes
```

O script usa o banco e a configuração do `.env` e mostra, para a busca vetorial pura e com reranking, o **acerto** (a página certa apareceu entre os trechos enviados ao modelo) e o **MRR** (quanto mais perto do primeiro lugar, mais perto de 1). Repita depois de cada ajuste de parâmetros.

Integração contínua

O workflow `.github/workflows/ci.yml` roda os testes do Python e o build da interface a cada push e pull request.

Commit automático diário

O workflow `.github/workflows/diario.yml` acrescenta a data e a hora em `.github/atividade.txt` e faz um commit todos os dias às **11h37** de Brasília (14h37 UTC). O minuto quebrado evita a fila de execuções que o GitHub forma na virada das horas. Para ativar:

1. No repositório, abra **Settings › Secrets and variables › Actions › New repository secret**.
2. Crie `GIT_NAME` com o seu nome de usuário do GitHub.
3. Crie `GIT_EMAIL` com o e-mail da conta, ou o endereço `...@users.noreply.github.com` mostrado em **Settings › Emails** do seu perfil. Só commits com um e-mail da sua conta contam no gráfico de contribuições.
4. Em **Settings › Actions › General › Workflow permissions**, marque **Read and write permissions** e salve.
5. Em **Actions › Atividade diaria**, clique em **Run workflow** para testar. O commit aparece em segundos.

> **Atrasos**
> O GitHub pode atrasar execuções agendadas em alguns minutos e desativa agendamentos de repositórios sem atividade por 60 dias. Como o próprio workflow gera um commit por dia, o agendamento se mantém ativo.

Atualizando dependências

```
pip install --upgrade -r requirements.txt
cd frontend && npm update && npm run build
```

Solução de problemas

Sintoma	Causa provável	O que fazer
"O modelo não respondeu"	Ollama desligado ou modelo não baixado	Abra o Ollama e rode ollama pull llama3.1
"Instale o pacote ..."	Provedor configurado sem a biblioteca	pip install do pacote indicado na mensagem
"Defina OPENAI_API_KEY"	Provedor OpenAI sem chave	Preencha a chave no .env e reinicie
Documento em Falhou: sem texto	PDF digitalizado (imagem)	Aplique OCR (por exemplo OCRmyPDF) e envie de novo
Primeira pergunta demora	Download dos modelos do HuggingFace	Aguarde; as próximas são rápidas
Respostas sempre "Não encontrei"	Cortes de relevância altos para o modelo	Baixe NEXO_MIN_SIMILARITY e NEXO_MIN_RERANK_SCORE
Tela em branco em /	Interface não compilada	cd frontend, npm install e npm run build
Sessão cai ao reiniciar	NEXO_SECRET vazio e pasta data apagada	Defina NEXO_SECRET fixo no .env
Esqueci a senha do admin	Senha trocada e perdida	python scripts/redefinir_senha.py admin