Nexo

Manual técnico

Chatbot de manuais técnicos e livros em PDF com respostas baseadas somente nos documentos enviados. Instalação, configuração, cada tela, integrações, arquitetura, banco de dados, API e manutenção, passo a passo.

Versão 2.0.1
Outubro de 2026

Copyright (©) 2026 Erik Pimenta

Sumário

01 Visão geral 4

1.1 Para que serve 4
1.2 O que há de novo na 2.0.1 5
1.3 O que o projeto entrega 5
1.4 Funcionalidades 6
1.5 Identidade visual 7

02 Instalação 8

2.1 Pré-requisitos 8
2.2 Caminho rápido 8
2.3 Passo a passo manual 9
2.4 Primeiro acesso 9
2.5 Atualizando a partir da 1.5 9

03 Configuração 10

3.1 Modos prontos 10
3.2 Todas as variáveis 11
3.3 Calibrando a precisão 12
3.4 Serviços externos com Docker 12
3.5 Acesso pela rede 12

04 Usando o Nexo 14

4.1 Entrada 15
4.2 Conversas 16
4.3 Busca nos trechos 18
4.4 Documentos 19
4.5 Painel de qualidade 20
4.6 Integrações 22
4.7 Sistema e conta 23
4.8 Paleta de comandos e atalhos 24
4.9 Tema e celular 25

05 Integrações 27

5.1 Autenticação por chave de API 27
5.2 Pergunta direta: /api/ask 27
5.3 Busca pela API 29
5.4 Webhooks 29
5.5 Boas práticas 32

Copyright (©) 2026 Erik Pimenta

5.6 Exportação de conversas 32

06 Arquitetura 33

6.1 Módulos do código 33
6.2 Indexação de um PDF 34
6.3 Respondendo uma pergunta 35
6.4 Como as alucinações são reduzidas 35
6.5 Segurança 36

07 Banco de dados 37

7.1 Onde cada dado fica 37
7.2 Diagrama de relacionamentos 38
7.3 Tabelas 38
7.4 Coleção vetorial 40
7.5 Arquivo de usuários 40
7.6 Outro banco relacional 40

08 API 42

8.1 Autenticação 42
8.2 Rotas 42
8.3 Exemplo com curl 44
8.4 Erros 44

09 Qualidade e manutenção 46

9.1 Testes automatizados 46
9.2 Medindo a recuperação 46
9.3 Integração contínua 47
9.4 Commit automático diário 47
9.5 Backup 47
9.6 Atualizando dependências 47
9.7 Solução de problemas 47

Copyright (©) 2026 Erik Pimenta

01

Visão geral

O Nexo é uma aplicação web em que você envia manuais técnicos ou livros em PDF e conversa com um chatbot que responde só com o que está escrito neles. Cada resposta mostra os trechos usados, com documento e página. Quando a informação não está nos PDFs, o Nexo diz isso em vez de inventar.

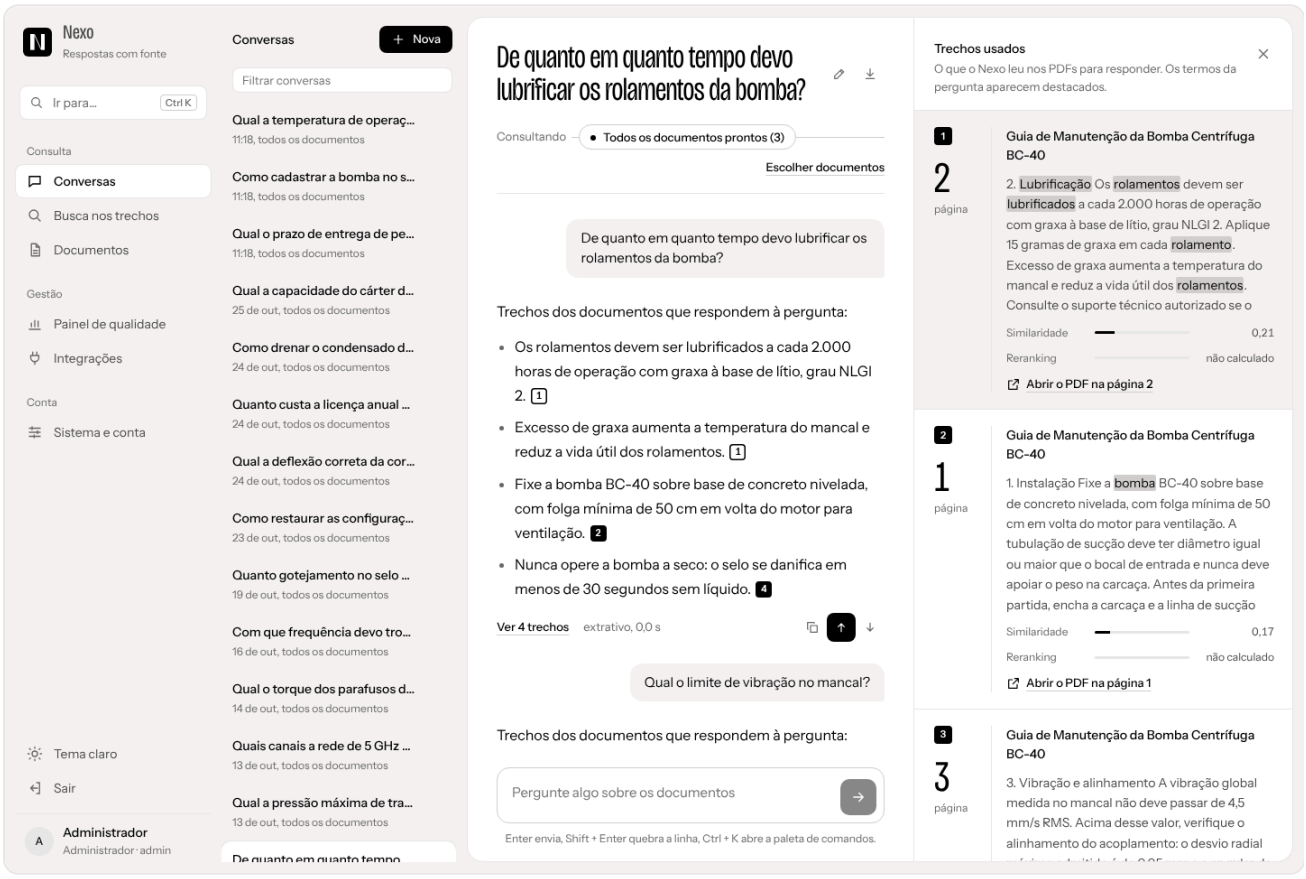


Figura 1.1 Conversa com citações numeradas e o painel de trechos usados, com os termos da pergunta destacados e o link para o PDF na página.

1.1 Para que serve

- Consultar manuais de equipamentos, normas, procedimentos internos e livros técnicos sem folhear centenas de páginas.
- Dar a uma equipe um ponto único de consulta, em que cada resposta pode ser conferida no documento original.
- Estudar um livro complexo fazendo perguntas e indo direto à página que trata do assunto.

Copyright (©) 2026 Erik Pimenta

- Levar as respostas para outros sistemas (portal interno, central de atendimento, automações) pela API com chave própria.

1.2 O que há de novo na 2.0.1

A versão 2.0.1 mantém a identidade "caixa única", a mesma do painel Bento, e traz as ferramentas da 2.0: o Nexo se abre para integrações, mede a qualidade das respostas e ganha atalhos de trabalho. A API antiga continua igual: nada do que funcionava na 1.5 deixou de funcionar.

Busca nos trechos tela e POST /api/search
Procura direto nos trechos indexados, sem chamar o modelo de linguagem. Mostra documento, página, similaridade e nota do reranker.

Exportar conversa Markdown ou JSON
Baixa a conversa inteira com perguntas, respostas e a lista de fontes de cada resposta.

Painel de qualidade tela e GET /api/metrics
Taxa de resposta, tempo médio e p95, avaliações, documentos mais citados e as lacunas do acervo.

Chaves de API nxk_...
Cada usuário cria chaves para integrações. O Nexo guarda só o hash SHA-256 da chave.

Pergunta direta POST /api/ask
Uma chamada, uma resposta com fontes. Sem estado, ou dentro de uma conversa existente.

Webhooks somente admin
Avisos assinados com HMAC quando um documento fica pronto ou falha, quando uma pergunta fica sem resposta e quando uma resposta é mal avaliada.

Gestão de contas somente admin
Promover, rebaixar e excluir contas, com proteção para não ficar sem administrador.

Paleta de comandos Ctrl + K
Vai para qualquer tela e executa as ações principais pelo teclado.

Filtro e ordenação tela Documentos
Acha um documento pelo título ou arquivo e organiza a lista por situação e ordem.

Copiar resposta com as fontes
Leva a resposta para a área de transferência junto com documento e página de cada fonte.

Tema claro, escuro ou automático
O tema automático segue o sistema operacional e muda sozinho quando ele muda.

Identidade "caixa única"
A mesma da 1.5 e do Bento: mesa #F5F4F4, caixa branca, tampa preta e logo em preto e branco.

1.3 O que o projeto entrega

O Nexo é entregue como estrutura pronta: interfaces, arquitetura, banco de dados e documentação. Quem instala decide quais PDFs enviar, quais modelos usar e onde hospedar. Nenhum documento real ou dado pessoal vem no repositório; o único PDF incluído é um manual fictício para testes.

Camada	Tecnologia	Papel
Interface	React 19, TypeScript, Vite	Telas de entrada, conversas, busca, documentos, painel, integrações, sistema e conta
API	Python 3.11+, FastAPI, Uvicorn	Rotas REST, autenticação por sessão ou chave de API, envio de arquivos e fila de indexação

Copyright (©) 2026 Erik Pimenta

Camada	Tecnologia	Papel
Pipeline de dados	LlamaIndex, pypdf	Leitura dos PDFs, divisão em trechos, busca e montagem das respostas
Banco vetorial	ChromaDB (padrão) ou Qdrant	Embeddings dos trechos e metadados de origem
Embeddings	HuggingFace, OpenAI ou Ollama	Transformam texto em vetores para a busca semântica
Reranking	Cross-encoder HuggingFace ou Cohere Rerank	Reordenam os candidatos antes de chegarem ao modelo
Modelo de linguagem	Ollama (local) ou OpenAI	Redige a resposta a partir dos trechos
Banco relacional	SQLAlchemy com SQLite (padrão), PostgreSQL, MySQL ou SQL Server	Documentos, conversas, mensagens, fontes, avaliações, chaves de API e webhooks
Contas	Arquivo JSON com bcrypt, sessões JWT	Login pré-definido, cadastro próprio e gestão pelo administrador
Integrações	Chaves `nxk_`, webhooks com HMAC-SHA256	Perguntas e buscas vindas de outros sistemas e avisos de eventos

1.4 Funcionalidades

- Envio de PDFs por arrastar e soltar ou seletor de arquivos, vários de uma vez, com limite de tamanho, checagem de formato e bloqueio de duplicados por SHA-256.
- Indexação em segundo plano com os estados Na fila, Indexando, Pronto e Falhou. A tela se atualiza sozinha.
- Renomear, reindexar, abrir e excluir documentos, com filtro e ordenação da lista. Excluir apaga o PDF e todos os vetores dele.
- Conversas salvas por usuário, com título automático, renomeação, exclusão, filtro e exportação em Markdown ou JSON.
- Escopo: cada conversa pode consultar todos os documentos ou só os escolhidos.
- Citações [n] clicáveis que abrem o trecho usado, com os termos da pergunta destacados, e o PDF na página certa. Botão para copiar a resposta com as fontes.
- Resposta padrão quando nada relevante é encontrado: "Não encontrei essa informação nos documentos selecionados."
- Busca direta nos trechos, sem o modelo de linguagem, para conferir o que o acervo tem sobre um assunto.
- Avaliação de cada resposta (útil ou não ajudou) e painel de qualidade com as perguntas que ficaram sem resposta.
- Integrações por chave de API, pergunta direta em `/api/ask` e webhooks assinados.
- Contas: login pré-definido de administrador, cadastro de novos usuários, troca de senha e gestão de perfis pelo administrador.
- Paleta de comandos pelo botão Ir para... ou Ctrl + K, tema claro, escuro ou automático e layout para celular.

Copyright (©) 2026 Erik Pimenta

1.5 Identidade visual

A versão 2.0.1 mantém a identidade "caixa única", a mesma do painel Bento (Data-Driven-Admin-Panel), adotada na 1.5.0. As telas novas da 2.0 seguem os mesmos materiais.

Elemento	Como ficou
Mesa	Fundo, menu lateral e cabeçalhos no mesmo tom #F5F4F4, sem bordas
Caixa	A conversa e o painel de trechos dividem uma parede fina de 1 px dentro de uma só caixa branca de cantos arredondados
Tampa	O resumo do acervo (Documentos e Sistema e conta), os números do Painel de qualidade e a lateral da tela de entrada ficam no bloco preto
Tipografia	Títulos e números em Bricolage Grotesque fina e condensada, textos em Instrument Sans, código em IBM Plex Mono
Status	Um ponto de cor e o texto neutro: verde para Pronto, azul para Indexando, cinza para Na fila, vermelho para Falhou
Destaques	Os termos da pergunta aparecem destacados, com fundo cinza, nos trechos citados e na busca
Temas	Claro, escuro ou automático; o escuro usa os mesmos materiais em tons escuros
Paleta	#FFFFFF, #4D4B4B, #000000, #333232 e #BAB7B6; a logo é sempre em preto e branco

Copyright (©) 2026 Erik Pimenta

02

Instalação

Este capítulo leva do download à primeira pergunta respondida. O caminho mais curto é o script de inicialização; os passos manuais vêm logo depois.

2.1 Pré-requisitos

Item	Versão	Para quê
Python	3.11 ou mais recente	Servidor, indexação e respostas
Node.js	20.19 ou mais recente	Compilar a interface (uma vez)
Ollama	Atual	Modelo de linguagem local e gratuito (modo padrão)
Espaço em disco	Cerca de 3 GB	Dependências do Python, modelos de embeddings e reranking
Memória	8 GB ou mais	Rodar o llama3.1 local com folga

Sem Ollama ou sem GPU? Use a OpenAI como modelo de linguagem (seção 3.1) ou o modo de teste sem modelos para validar a instalação. Os modelos de embeddings e reranking padrão rodam bem em CPU.

2.2 Caminho rápido

1. Baixe o repositório (botão **Code › Download ZIP** no GitHub ou `git clone`) e extraia em uma pasta.
2. Instale o Ollama em ollama.com e, num terminal, rode `ollama pull llama3.1`.
3. No Windows, dê dois cliques em `iniciar.cmd`. No Linux ou macOS, rode `./iniciar.sh`.
4. Espere a instalação terminar. Na primeira vez ela leva alguns minutos.
5. Abra `http://127.0.0.1:8000` no navegador e entre com `admin` / `Nexo@2026`.
6. Vá em **Documentos**, envie um PDF e, quando aparecer **Pronto**, faça uma pergunta em **Conversas**.

O script cria o ambiente virtual `.venv`, instala `requirements.txt`, copia `.env.example` para `.env`, compila a interface em `frontend/dist` e sobe o servidor. Nas próximas vezes ele só sobe o servidor.

Copyright (©) 2026 Erik Pimenta

2.3 Passo a passo manual

```
python -m venv .venv
.venv\Scripts\activate                # Windows
source .venv/bin/activate             # Linux / macOS
pip install -r requirements.txt
copy .env.example .env                # Windows; no Linux/macOS use cp
cd frontend
npm install
npm run build
cd ..
python -m nexo
```

Para desenvolver a interface com recarga automática, rode `python -m nexo` em um terminal e `npm run dev` dentro de `frontend` em outro. A interface abre em `http://localhost:5173` e repassa as chamadas `/api` para a porta 8000.

2.4 Primeiro acesso

O login pré-definido é criado quando não há nenhum administrador, como na primeira execução. O aviso some da tela de entrada (seção 4.1) assim que a senha do admin é trocada. Troque-a em **Sistema e conta** no primeiro acesso.

Usuário	Senha	Perfil	Pode
`admin`	`Nexo@2026`	Administrador	Tudo: excluir documentos de outras pessoas, ver o painel de todos, gerenciar contas e webhooks
contas novas	definida no cadastro	Usuário	Enviar PDFs, conversar, buscar, ver o próprio painel e criar as próprias chaves de API

2.5 Atualizando a partir da 1.5

1. Pare o servidor e faça uma cópia da pasta `data` (seção 9.5).
2. Substitua os arquivos do projeto pelos da 2.0.1, mantendo `data` e o seu `.env`.
3. Rode `pip install -r requirements.txt` e, em `frontend`, `npm install` e `npm run build`.
4. Se quiser, acrescente `NEXO_WEBHOOK_TIMEOUT=5` ao `.env`. Sem a linha, vale o padrão de 5 segundos.
5. Suba o servidor. As tabelas novas `nx_api_key` e `nx_webhook` são criadas sozinhas na primeira conexão; as tabelas existentes não mudam.

Copyright (©) 2026 Erik Pimenta

03

Configuração

Toda a configuração fica no arquivo `.env` na raiz do projeto. Altere, salve e reinicie o servidor. A tela Sistema e conta mostra o que está valendo.

3.1 Modos prontos

Modo	Linhas no .env	Quando usar

Local e gratuito (padrão)	`NEXO_LLM_PROVIDER=ollama`
	`NEXO_LLM_MODEL=llama3.1`
	`NEXO_EMBED_PROVIDER=huggingface`
	`NEXO_RERANKER=huggingface`
		Documentos sigilosos que não podem sair da máquina

OpenAI	`NEXO_LLM_PROVIDER=openai`
	`NEXO_LLM_MODEL=gpt-4o-mini`
	`OPENAI_API_KEY=sua-chave`
		Respostas mais elaboradas sem precisar de GPU

Embeddings da OpenAI	`NEXO_EMBED_PROVIDER=openai`
	`NEXO_EMBED_MODEL=text-embedding-3-small`
	`NEXO_EMBED_QUERY_PREFIX=`
	`NEXO_EMBED_TEXT_PREFIX=`
		Acervos grandes, sem baixar modelos locais

Reranking Cohere	`NEXO_RERANKER=cohere` `COHERE_API_KEY=sua-chave`	Melhor ordenação em vários idiomas sem custo de CPU
Qdrant	`NEXO_VECTOR_STORE=qdrant` `NEXO_QDRANT_URL=http://localhost:6333`	Acervos com muitos milhares de trechos ou servidor dedicado

Teste sem modelos	`NEXO_EMBED_PROVIDER=hash`
	`NEXO_LLM_PROVIDER=extrativo`
	`NEXO_RERANKER=none`
	`NEXO_MIN_SIMILARITY=0.1`
		Validar a instalação e rodar os testes automatizados

Trocou o modelo de embeddings? Vetores de modelos diferentes não são comparáveis. Depois de mudar `NEXO_EMBED_PROVIDER` ou `NEXO_EMBED_MODEL`, use uma coleção nova (`NEXO_COLLECTION`) ou reindexe todos os documentos pela tela Documentos.

Copyright (©) 2026 Erik Pimenta

3.2 Todas as variáveis

Variável	Padrão	Descrição
Servidor e contas		
`NEXO_HOST / NEXO_PORT`	`127.0.0.1 / 8000`	Endereço do servidor. Use `0.0.0.0` para aceitar acessos da rede
`NEXO_DATA_DIR`	`data`	Pasta do banco SQLite, PDFs, vetores locais e usuários
`NEXO_SECRET`	gerado	Chave das sessões. Vazia: o Nexo cria `data/.segredo`
`NEXO_TOKEN_HOURS`	`8`	Duração da sessão em horas (1 a 168)
`NEXO_ALLOW_REGISTRATION`	`true`	Permite criar contas na tela de entrada
`NEXO_MAX_UPLOAD_MB`	`100`	Tamanho máximo de cada PDF (1 a 2048)
`NEXO_DATABASE_URL`	vazio	URL SQLAlchemy de outro banco relacional. Vazio: `data/nexo.db`
`NEXO_WEBHOOK_TIMEOUT` Novo	`5`	Tempo máximo de cada entrega de webhook, em segundos (até 120)
Modelo de linguagem		
`NEXO_LLM_PROVIDER`	`ollama`	`ollama`, `openai` ou `extrativo`
`NEXO_LLM_MODEL`	`llama3.1`	Nome do modelo no provedor escolhido
`NEXO_LLM_TEMPERATURE`	`0.1`	Criatividade do modelo (0 a 1). Mantenha baixa
`NEXO_LLM_TIMEOUT`	`120`	Tempo máximo de resposta do modelo, em segundos
`NEXO_OLLAMA_URL`	`http://localhost:11434`	Endereço do Ollama
`OPENAI_API_KEY`	vazio	Chave da OpenAI (também aceita `NEXO_OPENAI_API_KEY`)
`NEXO_OPENAI_BASE_URL`	vazio	Endpoint compatível com a OpenAI (Azure, LM Studio, vLLM)
Embeddings e banco vetorial		
`NEXO_EMBED_PROVIDER`	`huggingface`	`huggingface`, `openai`, `ollama` ou `hash`
`NEXO_EMBED_MODEL`	`intfloat/multilingual-e5-small`	Modelo de embeddings
`NEXO_EMBED_QUERY_PREFIX / _TEXT_PREFIX`	`"query: " / "passage: "`	Prefixos exigidos pela família E5. Deixe vazio em outros modelos
`NEXO_VECTOR_STORE`	`chroma`	`chroma` ou `qdrant`
`NEXO_COLLECTION`	`nexo_trechos`	Nome da coleção vetorial
`NEXO_CHROMA_HOST / _PORT`	vazio / 8001	Servidor ChromaDB. Vazio: arquivos em `data/chroma`
`NEXO_QDRANT_URL / _API_KEY`	vazio	Servidor Qdrant. Vazio: arquivos em `data/qdrant`
Reranking e recuperação		
`NEXO_RERANKER`	`huggingface`	`huggingface`, `cohere` ou `none`
`NEXO_RERANK_MODEL`	`cross-encoder/mmarco-mMiniLMv2-L12-H384-v1`	Cross-encoder multilíngue do HuggingFace

Copyright (©) 2026 Erik Pimenta

Variável	Padrão	Descrição
`NEXO_COHERE_MODEL / COHERE_API_KEY`	`rerank-v3.5 / vazio`	Reranking da Cohere
`NEXO_CHUNK_SIZE / _OVERLAP`	`512 / 64`	Tamanho dos trechos e sobreposição, em tokens
`NEXO_TOP_K`	`12`	Candidatos trazidos pela busca vetorial
`NEXO_TOP_N`	`4`	Trechos enviados ao modelo depois do reranking
`NEXO_MIN_SIMILARITY`	`0.15`	Corte 1: similaridade de cosseno mínima para um trecho ser considerado
`NEXO_MIN_RERANK_SCORE`	`0.1`	Corte 2: nota mínima do reranker (0 a 1)
`NEXO_HISTORY_TURNS`	`3`	Trocas anteriores usadas para reescrever a pergunta (0 a 10)
`NEXO_VERIFY_ANSWERS`	`false`	Liga a verificação de fidelidade, uma segunda chamada ao modelo

3.3 Calibrando a precisão

- **Respostas dizendo que não encontrou, mas a informação existe:** baixe `NEXO_MIN_SIMILARITY` (por exemplo `0.1`) e `NEXO_MIN_RERANK_SCORE` (`0.05`), ou aumente `NEXO_TOP_K`.
- **Respostas misturando assuntos:** suba `NEXO_MIN_RERANK_SCORE` (`0.3`) e reduza `NEXO_TOP_N` para 3.
- **Tabelas e listas longas cortadas:** aumente `NEXO_CHUNK_SIZE` para 768 ou 1024 e reindexe.
- **Antes de mexer:** use a **Busca nos trechos** (seção 4.3) para ver as notas reais dos trechos e o **Painel de qualidade** (seção 4.5) para acompanhar a taxa de resposta depois do ajuste.
- **Medir em vez de adivinhar:** use `scripts/avaliar.py` (seção 9.2) antes e depois de cada ajuste.

3.4 Serviços externos com Docker

O `docker-compose.yml` traz serviços opcionais, cada um em um perfil:

```
docker compose --profile chroma up -d     # ChromaDB em http://localhost:8001
docker compose --profile qdrant up -d     # Qdrant em http://localhost:6333
docker compose --profile ollama up -d     # Ollama em http://localhost:11434
docker compose --profile postgres up -d   # PostgreSQL em localhost:5432
```

Depois aponte o `.env` para eles, por exemplo `NEXO_CHROMA_HOST=localhost` ou `NEXO_DATABASE_URL=postgresql+psycopg://nexo:troque-esta-senha@localhost:5432/nexo` (instale `pip install "psycopg[binary]"`). Troque a senha do PostgreSQL no arquivo antes de usar.

3.5 Acesso pela rede

Para outras máquinas acessarem, use `NEXO_HOST=0.0.0.0`, libere a porta no firewall e defina `NEXO_SECRET` com um valor longo e aleatório. Em produção, coloque o Nexo atrás de um proxy com HTTPS (Nginx, Caddy ou IIS) e desligue o cadastro aberto se o acesso deve ser restrito.

Copyright (©) 2026 Erik Pimenta

Com integrações, o HTTPS deixa de ser opcional: chaves de API viajam em cada pedido e precisam de transporte cifrado. Para webhooks, o servidor do Nexo precisa conseguir abrir conexões de saída até as URLs cadastradas.

Copyright (©) 2026 Erik Pimenta

04

Usando o Nexo

As telas seguem o caminho natural de uso: entrar, enviar documentos, conversar, conferir a qualidade e integrar. O menu lateral agrupa as telas em Consulta, Gestão e Conta.

Grupo	Telas	Para quê
Consulta	Conversas, Busca nos trechos, Documentos	Perguntar, procurar no acervo e enviar PDFs
Gestão	Painel de qualidade, Integrações	Acompanhar as respostas e ligar outros sistemas
Conta	Sistema e conta	Pipeline, acervo, senha e, para administradores, as contas

No topo do menu, o botão **Ir para...** (Ctrl K) abre a paleta de comandos. No rodapé ficam o usuário conectado, o botão de tema, que alterna **Tema claro**, **Tema escuro** e **Tema automático**, e **Sair**.

Copyright (©) 2026 Erik Pimenta

4.1 Entrada

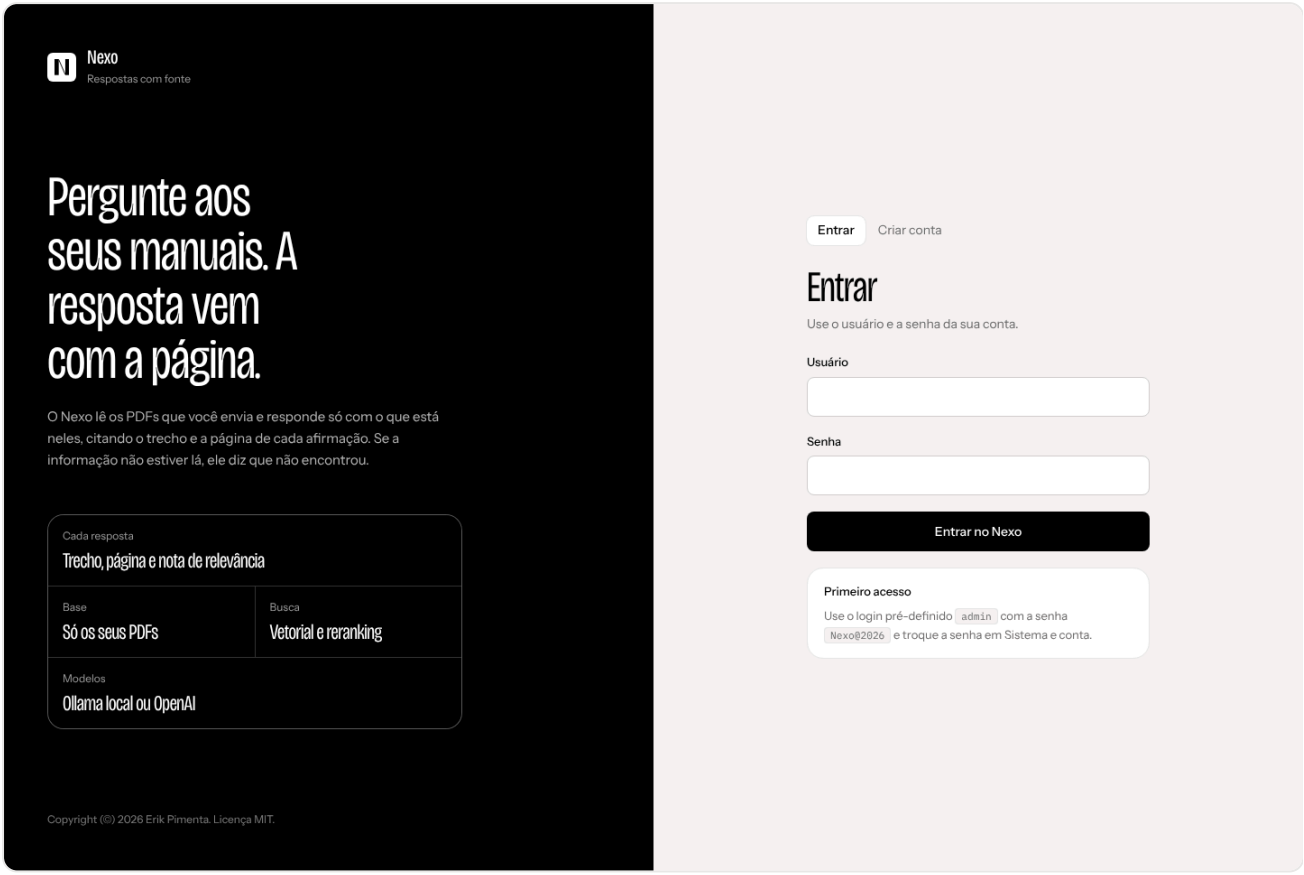


Figura 4.1 Entrada, com as abas Entrar e Criar conta e o aviso do login pré-definido enquanto a senha do admin não for trocada.

- **Entrar** pede usuário e senha. Cinco erros seguidos bloqueiam o usuário por 5 minutos.
- **Criar conta** aparece quando `NEXO_ALLOW_REGISTRATION=true`. O nome de usuário tem de 3 a 32 caracteres minúsculos; a senha, de 8 a 72 caracteres, com letras e números, sem conter o nome de usuário.
- A sessão dura `NEXO_TOKEN_HOURS` horas e fica só na aba aberta.

Copyright (©) 2026 Erik Pimenta

4.2 Conversas

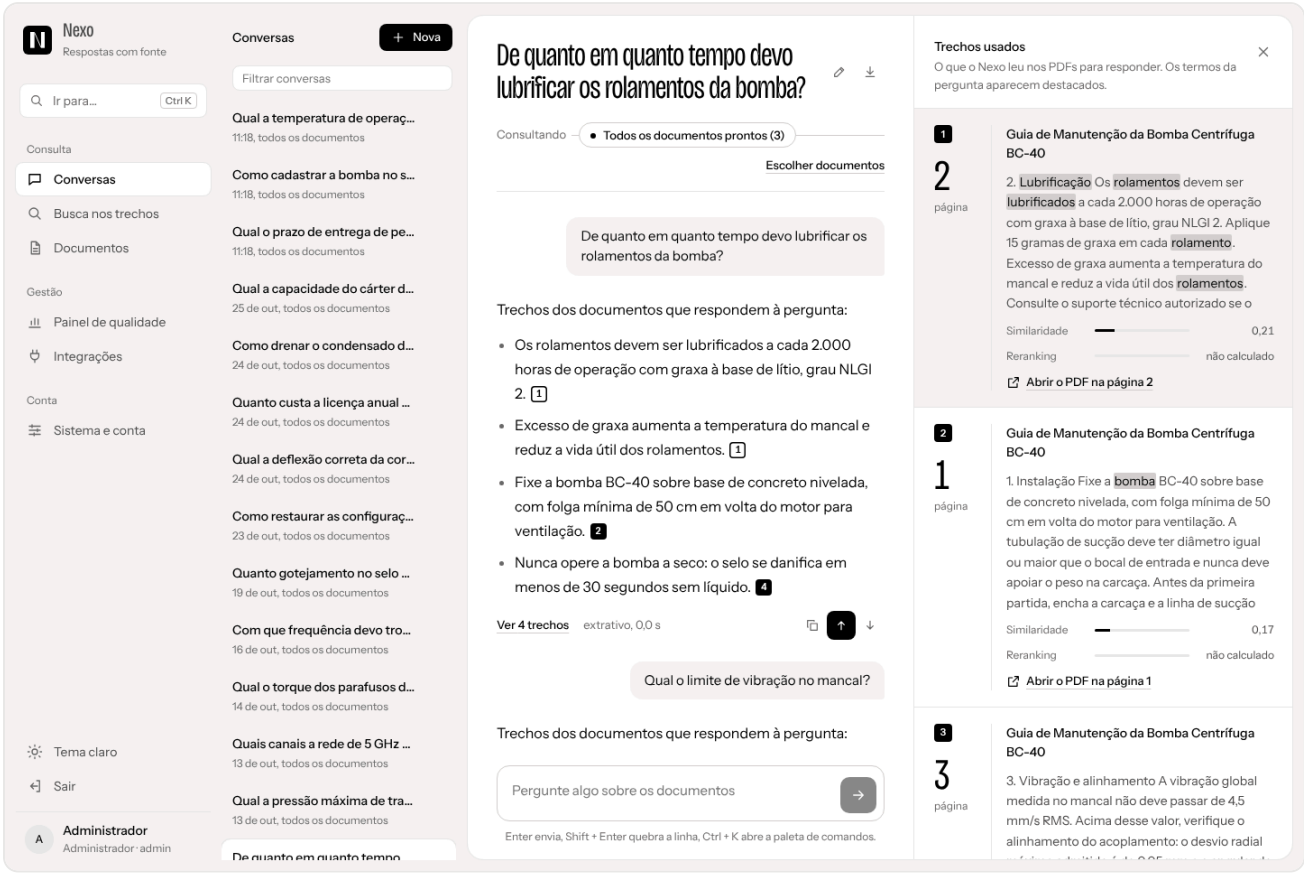


Figura 4.2 Duas perguntas na mesma conversa, com os trechos da primeira resposta abertos e os termos da pergunta destacados.

- **Nova** abre uma conversa vazia. O campo **Filtrar conversas**, no topo da lista, encontra conversas pelo título.
- O título vem da primeira pergunta. No topo da conversa, o ícone de renomear edita o título e o ícone de exportar abre o menu **Markdown** / **JSON**, que baixa a conversa com as fontes de cada resposta (seção 5.6).
- Enter envia, Shift + Enter quebra a linha.
- Os números **[n]** no texto indicam de qual trecho veio cada informação. Clique para destacá-lo no painel **Trechos usados**.
- Abaixo de cada resposta ficam **Ver N trechos**, que abre o painel, o ícone de copiar, que leva a resposta para a área de transferência com as fontes, e a avaliação útil / não ajudou; clique de novo para desfazer.
- Cada trecho mostra a página, a similaridade da busca, a nota do reranker e o link **Abrir o PDF na página**. Os termos da pergunta aparecem destacados.
- Perguntas seguintes podem usar "isso", "esse passo" ou "e depois?": o Nexo reescreve a pergunta com o histórico antes de buscar.

Escolhendo os documentos consultados

A linha **Consultando** mostra o escopo atual. Clique em **Escolher documentos** e marque os PDFs que a conversa deve usar. Sem nenhum marcado, todos os documentos prontos são consultados, inclusive os que forem enviados depois.

Copyright (©) 2026 Erik Pimenta

Quando a resposta não está nos PDFs

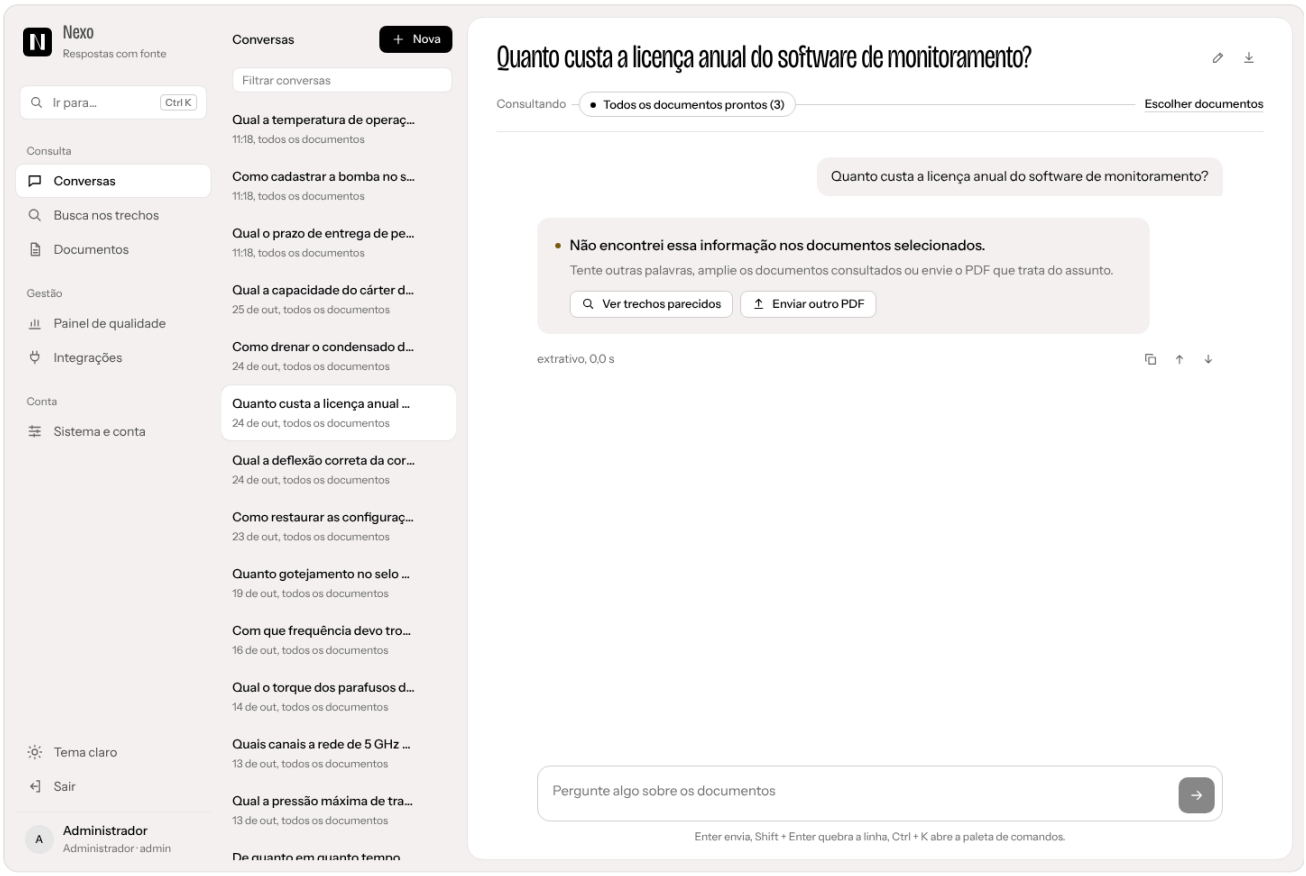


Figura 4.3 Pergunta fora do conteúdo dos documentos: o Nexo responde que não encontrou e sugere como reformular.

Se nenhum trecho passar pelos cortes de relevância, o modelo nem é chamado e a resposta aparece num quadro marcado com um ponto de aviso, com sugestões para reformular. Logo abaixo vêm três saídas: **Ver trechos parecidos**, **Consultar todos os documentos** (quando a conversa tem escopo) e **Enviar outro PDF**. Isso é o comportamento esperado: o Nexo prefere não responder a responder sem base. A pergunta entra na lista de lacunas do painel de qualidade e, se houver webhook inscrito, dispara o evento `question.unanswered`.

Copyright (©) 2026 Erik Pimenta

4.3 Busca nos trechos Novo

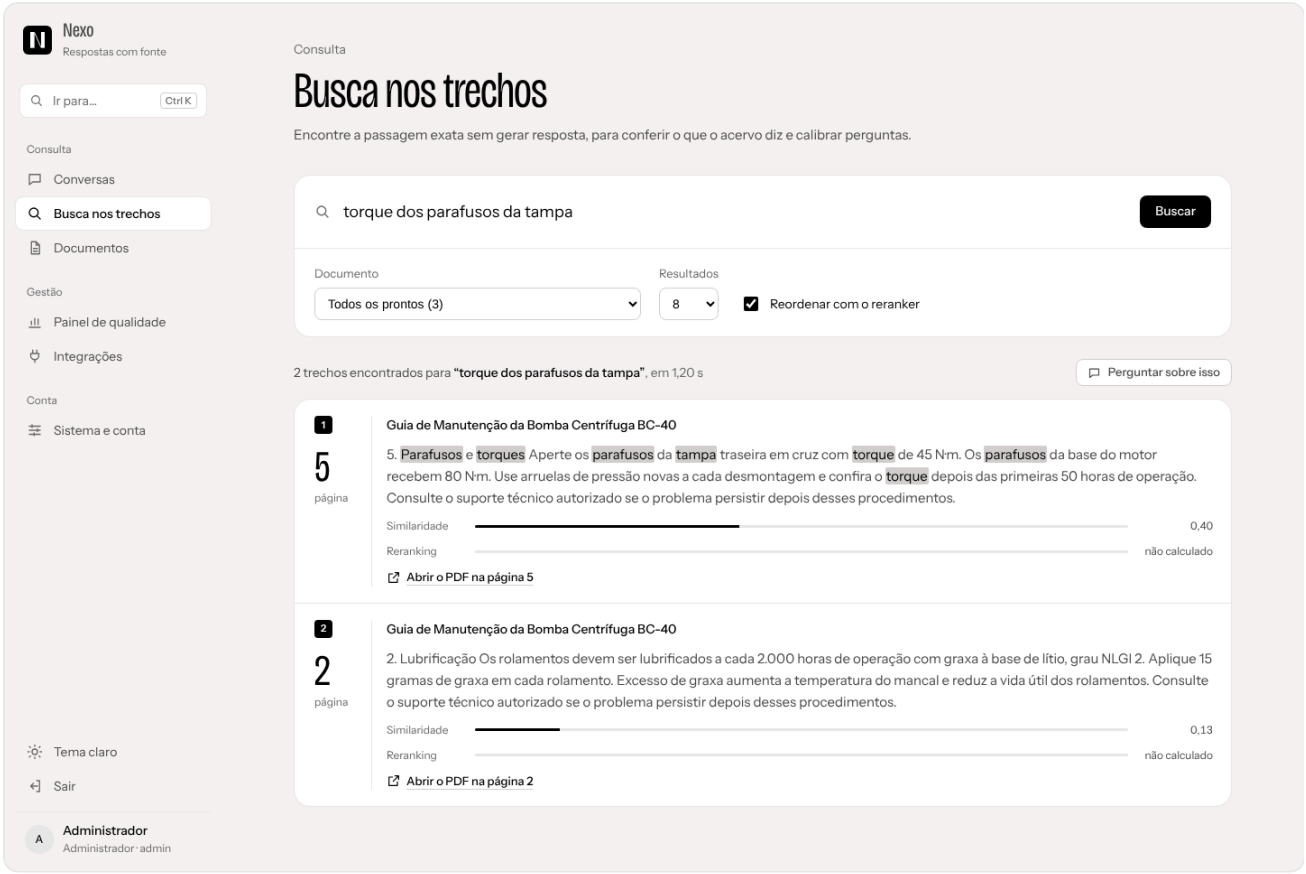


Figura 4.4 Busca nos trechos: resultados em ordem de relevância, com documento, página, similaridade, nota do reranker e o trecho.

A busca mostra o que o acervo tem sobre um assunto sem chamar o modelo de linguagem. É rápida, não gasta tokens e serve para conferir se um assunto está nos PDFs antes de perguntar, ou para calibrar os cortes de relevância.

1. Abra **Busca nos trechos** no menu lateral.
2. Escreva o que procura no campo de busca (até 500 caracteres) e, se quiser, limite a busca a alguns documentos em **Documento**.
3. Deixe **Reordenar com o reranker** ligado para a ordem mais precisa, ou desligue para ver a ordem da busca vetorial pura.
4. Escolha em **Resultados** quantos quer ver (1 a 20; o padrão é 8) e clique em **Buscar** ou tecle Enter.
5. Clique num resultado para abrir o PDF na página do trecho, ou em **Perguntar sobre isso** para levar o assunto a uma conversa.

Sem nenhum documento pronto, a busca avisa que é preciso enviar e indexar um PDF antes. O tempo gasto aparece acima dos resultados.

Copyright (©) 2026 Erik Pimenta

4.4 Documentos

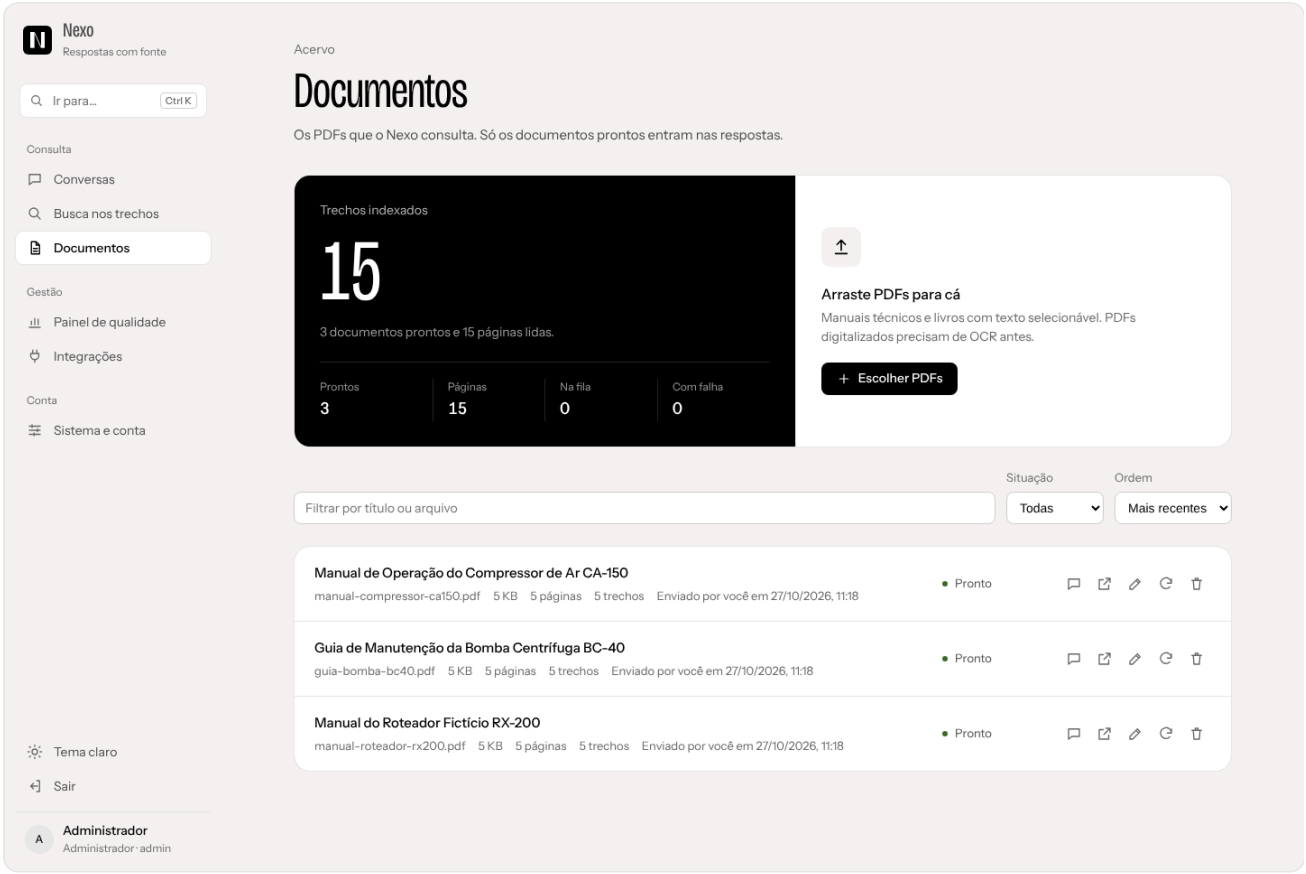


Figura 4.5 Documentos: o resumo do acervo na tampa preta, a área de envio e a lista com filtro, situação, ordem e ações.

1. Arraste PDFs para a área **Arraste PDFs para cá** ou clique em **Escolher PDFs**.
2. Cada arquivo entra como **Na fila**, passa a **Indexando** e termina em **Pronto**. Uma barra indica o trabalho em andamento.
3. Se aparecer **Falhou**, o motivo fica logo abaixo do título. O caso mais comum é PDF digitalizado sem texto: aplique OCR e envie de novo.
4. Use os ícones à direita para abrir o PDF, **Perguntar a este documento** (abre uma conversa já limitada a ele), renomear, reindexar e excluir. Renomear reindexa, porque o título faz parte da busca.

A tampa preta no topo mostra trechos indexados, documentos prontos, páginas lidas, arquivos na fila e com falha, e se atualiza sozinha enquanto há documentos sendo indexados. Na barra acima da lista, **Filtrar por título ou arquivo** acha um documento, **Situação** separa prontos, indexando, na fila e com falha, e **Ordem** organiza por **Mais recentes**, **Título** ou **Mais páginas**.

Copyright (©) 2026 Erik Pimenta

4.5 Painel de qualidade Novo

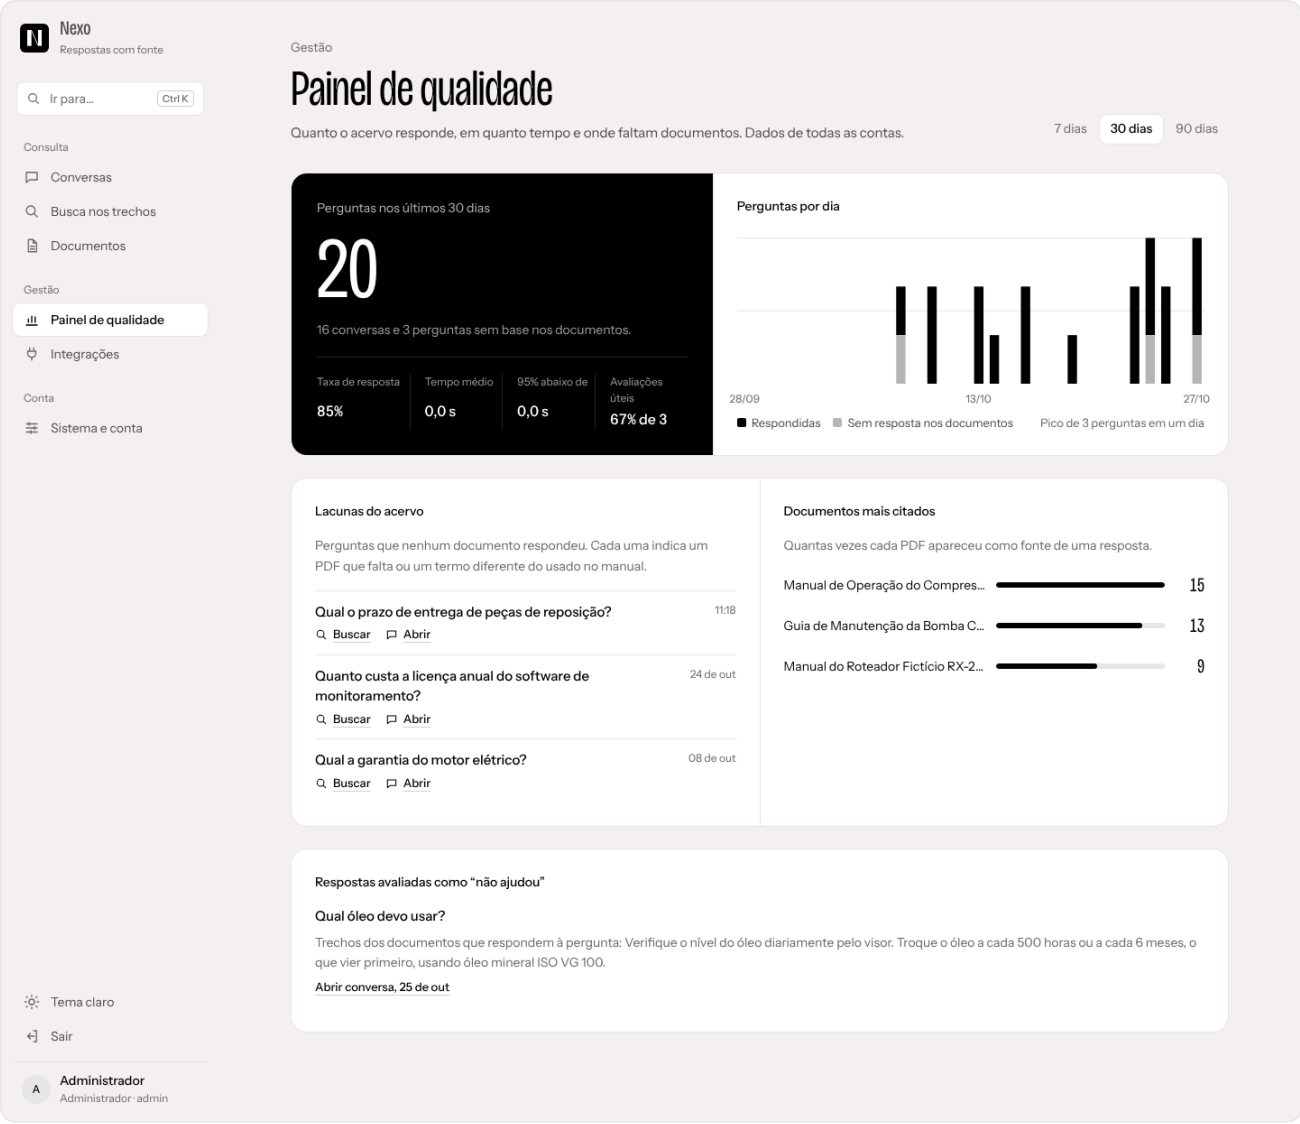


Figura 4.6 Painel de qualidade com os números do período na tampa preta, as perguntas por dia e as lacunas do acervo.

O painel responde a duas perguntas: o Nexo está respondendo bem? E o que falta no acervo? O administrador vê os números de todas as conversas; os demais usuários veem só os das próprias conversas. Escolha o período em **7 dias**, **30 dias** ou **90 dias**; o padrão é 30 (pela API, de 1 a 365 dias).

Indicador	Como ler
Na tampa preta	
Perguntas	Total de perguntas feitas no período
Taxa de resposta	Respondidas ÷ perguntas. Caindo, o acervo não cobre o que as pessoas procuram ou os cortes estão altos
Tempo médio e p95	Tempo de resposta típico e o dos 5% mais lentos
Avaliações	Respostas marcadas como úteis e como "não ajudou"

Copyright (©) 2026 Erik Pimenta

Indicador	Como ler
Abaixo da tampa	
Perguntas por dia	Perguntas e perguntas sem resposta de cada dia, do mais antigo ao mais novo
Documentos mais citados	Os seis documentos que mais embasaram respostas
Lacunas do acervo	As 10 perguntas sem resposta mais recentes. **Buscar** leva a pergunta para a busca nos trechos; **Abrir** abre a conversa
Respostas avaliadas como “não ajudou”	As 10 respostas mais recentes marcadas como "não ajudou", com a pergunta

Rotina sugerida. Uma vez por semana, leia as lacunas. Se a pergunta é legítima e o assunto não está nos PDFs, envie o documento que falta. Se está, confira na busca nos trechos se os cortes estão descartando o trecho certo.

Copyright (©) 2026 Erik Pimenta

4.6 Integrações Novo

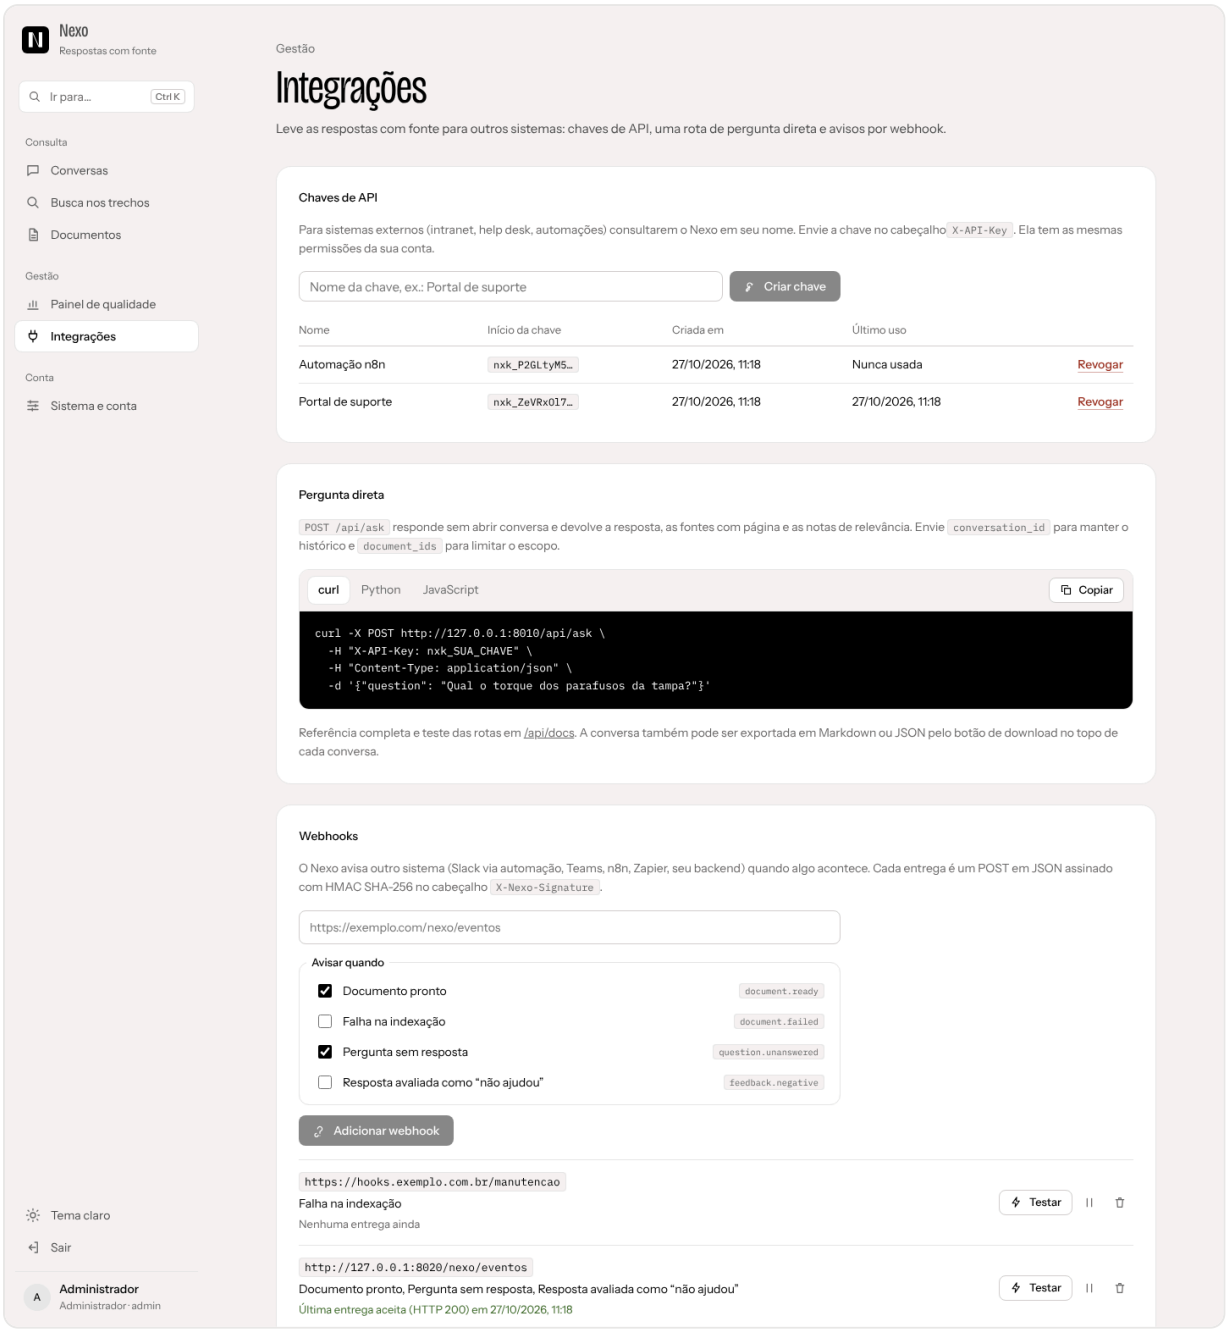


Figura 4.7 Integrações: chaves de API do usuário, a pergunta direta com exemplos em curl, Python e JavaScript e, para administradores, os webhooks.

Criar uma chave de API

1. Abra **Integrações** e, em **Chaves de API**, escreva um nome que diga onde a chave será usada, por exemplo "Portal interno".
2. Clique em **Criar chave**.
3. Copie a chave exibida. Ela começa com `nxk_` e aparece **uma única vez**; depois a tela mostra só o prefixo.
4. Guarde a chave no cofre de segredos do sistema que vai usá-la e teste com um dos exemplos de **Pergunta direta**: escolha a aba **curl**, **Python** ou **JavaScript** e clique em **Copiar**.

Copyright (©) 2026 Erik Pimenta

A lista mostra nome, prefixo, data de criação e último uso de cada chave. **Revogar** apaga a chave na hora; pedidos com ela passam a receber 401 `INVALID_API_KEY`.

Cadastrar um webhook (administrador)

1. Na seção **Webhooks**, informe no campo de endereço a URL `http` ou `https` que vai receber os avisos.
2. Em **Avisar quando**, marque ao menos um evento e clique em **Adicionar webhook**.
3. Copie o segredo de assinatura exibido (ele aparece uma única vez): o receptor precisa dele para conferir a assinatura. Pela API, é possível informar o próprio segredo no campo `secret`.
4. Clique em **Testar**. O Nexo entrega o evento `ping` na hora e mostra o status HTTP ou o erro.

Cada webhook mostra o resultado da última entrega e tem três ações: **Testar**, pausar / retomar (sem perder a configuração) e excluir. Os detalhes técnicos estão no capítulo 5.

4.7 Sistema e conta

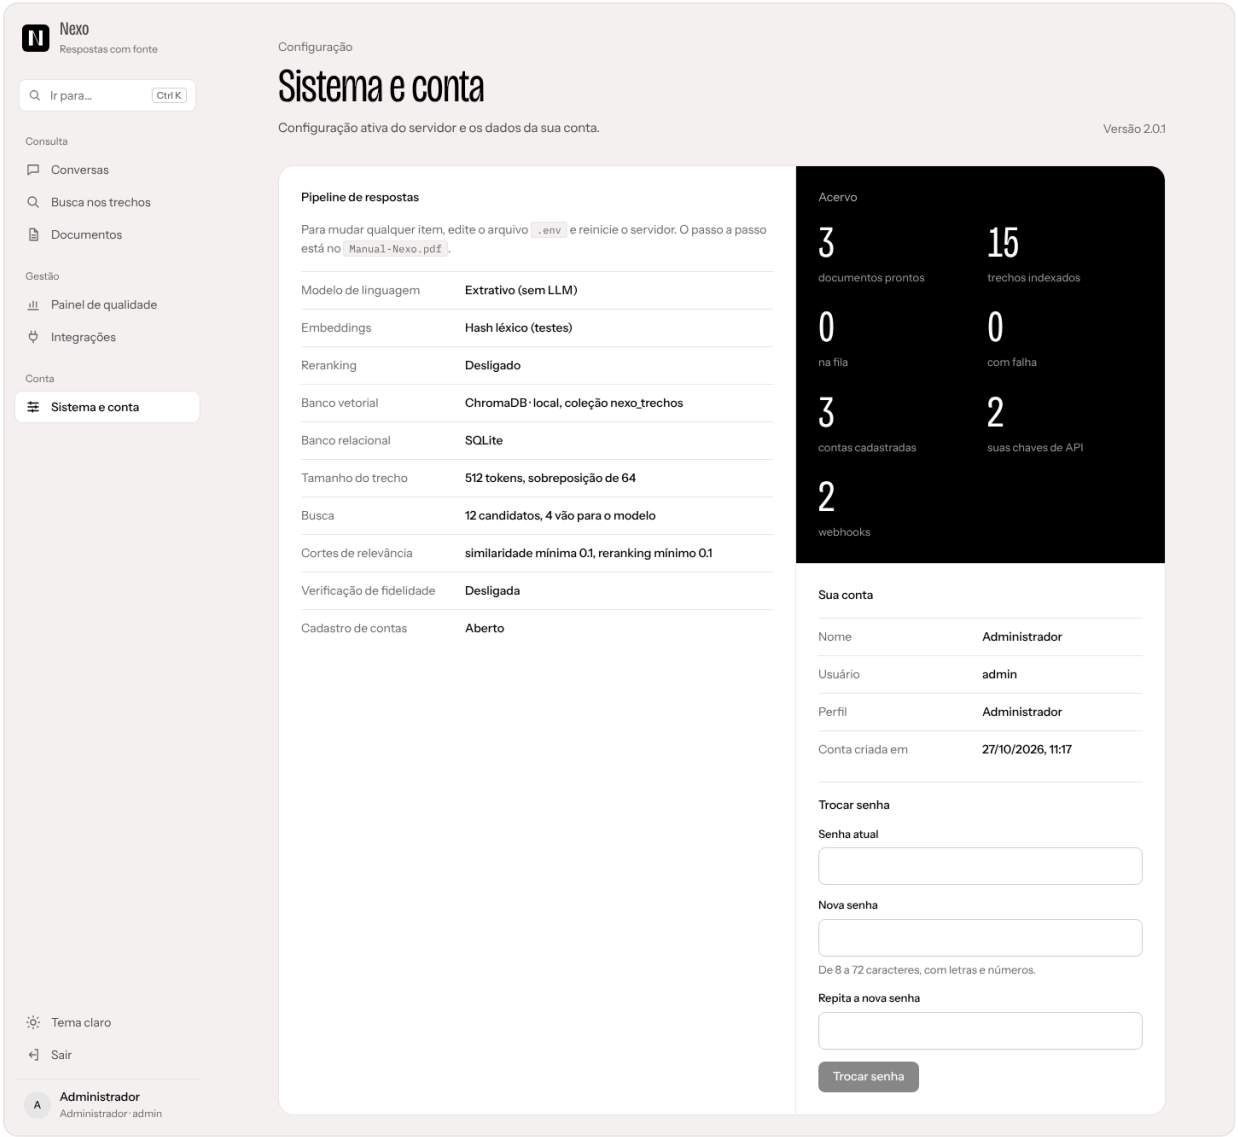


Figura 4.8 Sistema e conta: o pipeline de respostas com os provedores em uso, o acervo na tampa preta e os dados da conta.

Copyright (©) 2026 Erik Pimenta

O pipeline de respostas aparece na ordem em que a pergunta passa por ele (embeddings, banco vetorial, reranker, modelo de linguagem), com os parâmetros de busca. A tampa preta resume o acervo: documentos, trechos, chaves de API do usuário e, para administradores, webhooks. Em **Sua conta** ficam os dados da sessão e a opção de trocar senha (8 a 72 caracteres, com letras e números, sem conter o nome de usuário).

Gestão de contas (administrador)

Na seção **Contas**, o administrador vê cada conta com perfil, data de criação e último acesso, e pode:

- Mudar o **perfil**: promover um usuário a administrador ou rebaixar um administrador a usuário.
- **Excluir** uma conta. A exclusão apaga também as chaves de API e as conversas dela.

> **Proteções.** Ninguém rebaixa nem exclui a própria conta, e o último administrador não pode ser rebaixado. Assim o Nexo nunca fica sem alguém capaz de administrá-lo.

4.8 Paleta de comandos e atalhos Novo

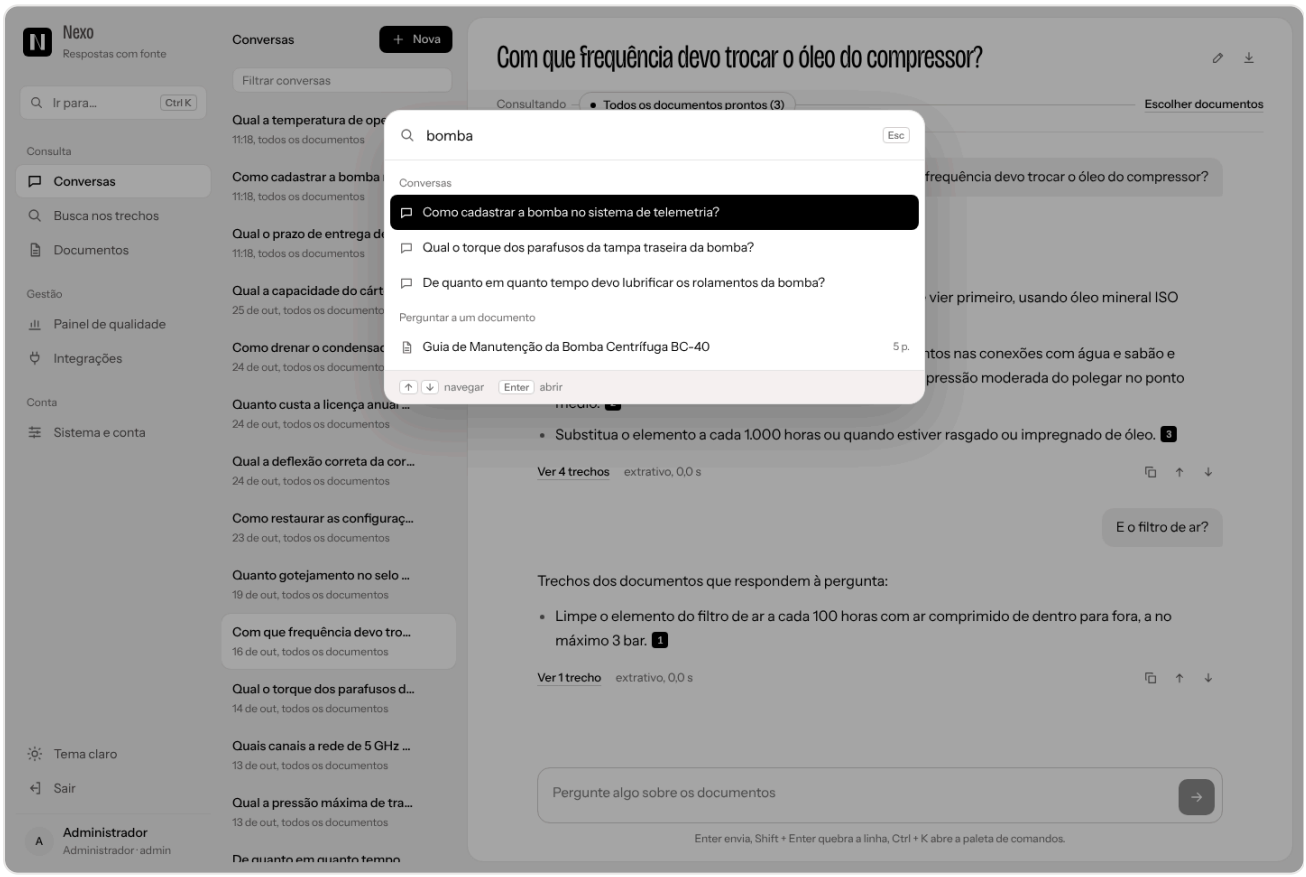


Figura 4.9 Paleta de comandos aberta com Ctrl + K sobre a tela de conversas.

Clique em **Ir para...** no topo do menu ou tecle Ctrl + K em qualquer tela, escreva parte do nome do que procura e tecle Enter. A paleta leva a qualquer tela e executa as ações principais, como abrir uma nova conversa ou trocar o tema, sem tirar as mãos do teclado.

Copyright (©) 2026 Erik Pimenta

Atalho	O que faz
Ctrl + K	Abre a paleta de comandos
Setas para cima e para baixo e Enter	Escolhem e executam um comando da paleta
Esc	Fecha a paleta
Enter	Envia a pergunta na conversa e a busca na tela de busca
Shift + Enter	Quebra a linha na pergunta

4.9 Tema e celular

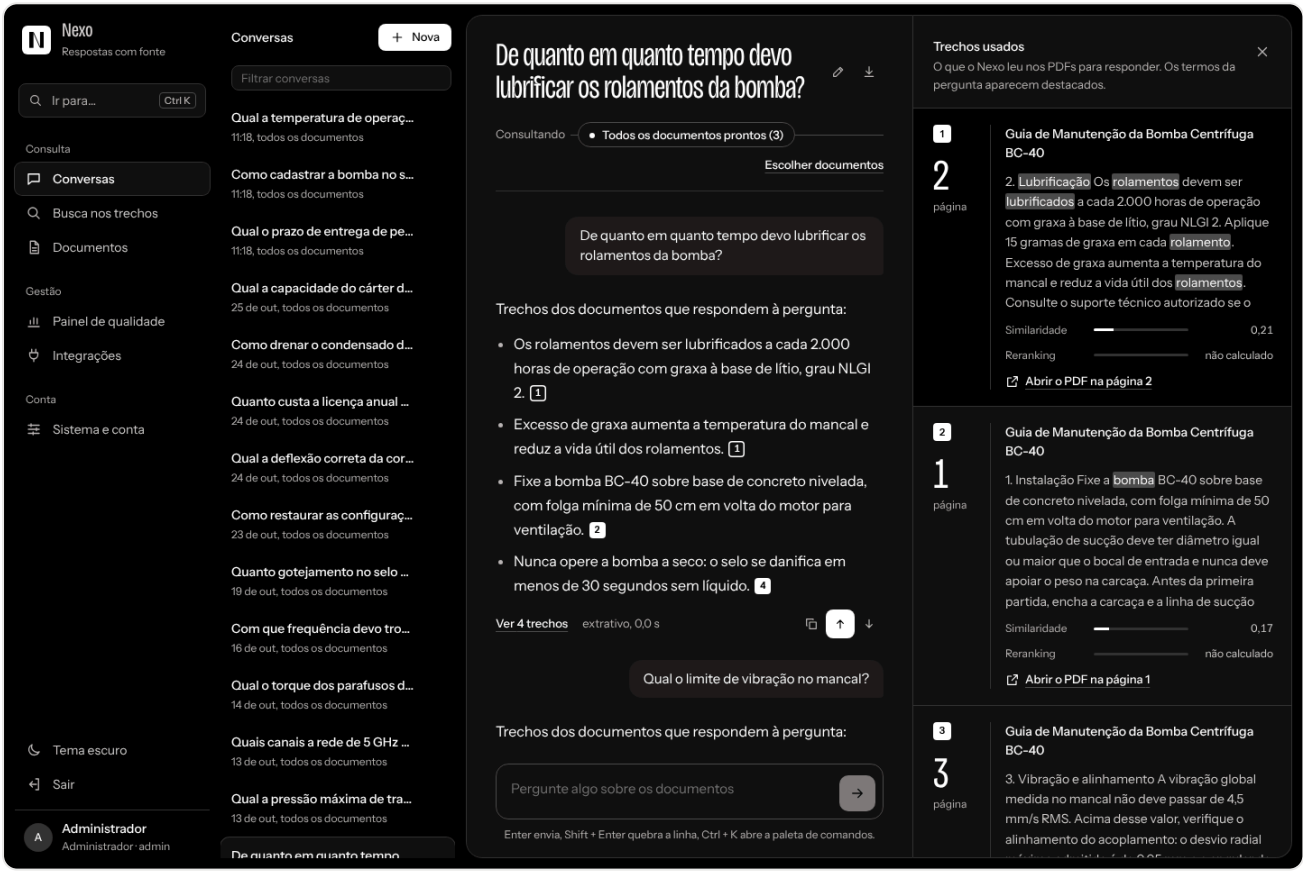


Figura 4.10 Tema escuro: os mesmos materiais da caixa única em tons escuros.

O botão de tema no rodapé do menu alterna **Tema claro**, **Tema escuro** e **Tema automático**, que segue a preferência do sistema operacional e muda sozinho quando ela muda. A escolha fica guardada no navegador.

Copyright (©) 2026 Erik Pimenta

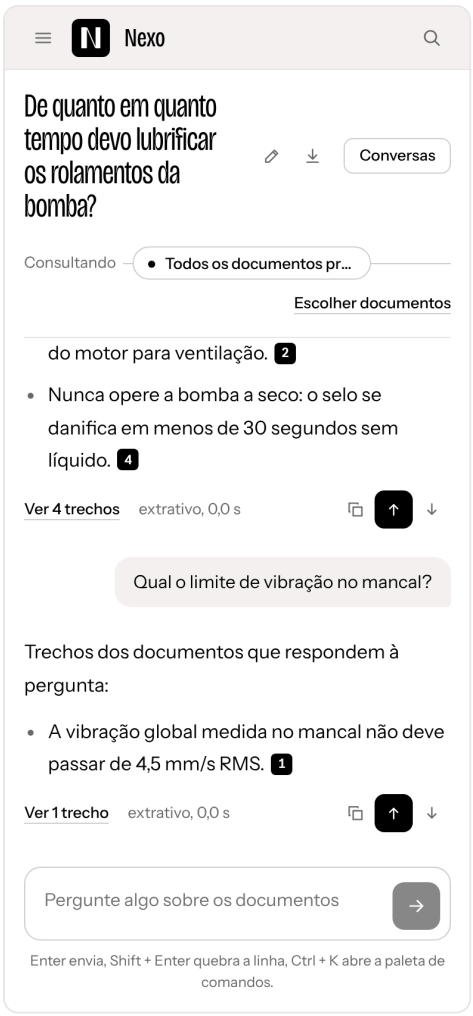


Figura 4.11 Conversa no celular, com o menu recolhido.

No celular

- O menu lateral recolhe para o botão no topo.
- A lista de conversas abre pelo botão **Conversas**.
- Conversa, trechos citados e escolha de documentos ficam numa coluna só.

A captura ao lado foi feita com 390 px de largura. Não há aplicativo separado: é a mesma interface, servida pelo mesmo endereço.

Copyright (©) 2026 Erik Pimenta

05

Integrações

Outros sistemas podem perguntar ao Nexo, buscar nos trechos e receber avisos. Este capítulo mostra como autenticar com uma chave de API, como usar a pergunta direta e como receber e conferir webhooks.

5.1 Autenticação por chave de API

Toda rota que aceita a sessão da interface também aceita uma chave de API. Envie a chave num destes cabeçalhos:

```
X-API-Key: nxk_Q2x5...                      # recomendado
Authorization: Bearer nxk_Q2x5...           # alternativa, para clientes que só enviam Bearer
```

- A chave age em nome de quem a criou, com as mesmas permissões. Uma chave de administrador pode tudo o que o administrador pode.
- Formato: `nxk_` seguido de 43 caracteres. O **prefixo** (os 12 primeiros caracteres) identifica a chave nas telas sem expô-la.
- O Nexo guarda só o hash SHA-256 da chave. Se ela se perder, revogue e crie outra: não há como recuperá-la.
- Cada uso atualiza a data de último uso. Chave inválida ou revogada recebe 401 `INVALID_API_KEY`. Excluir a conta apaga as chaves dela.

Método	Rota	O que faz
GET	`/api/keys`	Lista as chaves do usuário: `id`, `name`, `prefix`, `created_at`, `last_used_at`
POST	`/api/keys`	Cria uma chave. Corpo `{"name": "..."}` (1 a 80 caracteres). Devolve 201 com o campo `key`, exibido só aqui
DELETE	`/api/keys/{id}`	Revoga a chave. Só o dono. Devolve 204

5.2 Pergunta direta: /api/ask

Uma chamada, uma resposta com fontes. Sem `conversation_id`, a pergunta é respondida **sem estado**: nada é gravado no banco. Com `conversation_id`, o Nexo usa o histórico daquela conversa e grava pergunta e resposta, exatamente como no chat.

Copyright (©) 2026 Erik Pimenta

Campo do corpo	Tipo	Regra
`question`	texto	Obrigatório, 1 a 4000 caracteres
`document_ids`	lista de ids	Opcional. Vazio consulta todos os documentos prontos
`conversation_id`	id ou null	Opcional. Conversa do próprio usuário cujo histórico será usado e onde a troca será gravada

curl

```
curl -X POST http://127.0.0.1:8000/api/ask \
  -H "X-API-Key: $NEXO_CHAVE" \
  -H "Content-Type: application/json" \
  -d '{"question": "Qual a temperatura de operação do equipamento?"}'
```

Resposta

```
{
  "answer": "A faixa de operação vai de 5 °C a 40 °C [1].",
  "answered": true,
  "grounded": null,
  "model": "llama3.1",
  "latency_ms": 2140,
  "conversation_id": null,
  "sources": [
    { "rank": 1, "document_id": "3f2a…", "document_title": "Manual de exemplo",
      "page": 5, "similarity": 0.71, "rerank_score": 0.93,
      "excerpt": "Temperatura de operação: 5 °C a 40 °C…" }
  ]
}
```

Quando nada relevante é encontrado, `answered` vem `false`, `sources` vem vazia e `answer` traz a resposta padrão. `grounded` só é preenchido com `NEXO_VERIFY_ANSWERS=true`.

Python

```
import os
import requests   # pip install requests

resp = requests.post(
    "http://127.0.0.1:8000/api/ask",
    headers={"X-API-Key": os.environ["NEXO_CHAVE"]},
    json={"question": "Como restaurar as configurações de fábrica?"},
    timeout=180,
)
resp.raise_for_status()
dados = resp.json()
print(dados["answer"])
for f in dados["sources"]:
    print(f"[{f['rank']}] {f['document_title']}, página {f['page']}")
```

Copyright (©) 2026 Erik Pimenta

JavaScript (Node.js 18+ ou navegador)

```
const resp = await fetch("http://127.0.0.1:8000/api/ask", {
  method: "POST",
  headers: { "X-API-Key": process.env.NEXO_CHAVE, "Content-Type": "application/json" },
  body: JSON.stringify({ question: "Como restaurar as configurações de fábrica?" }),
});
if (!resp.ok) throw new Error((await resp.json()).message);
const dados = await resp.json();
console.log(dados.answer);
dados.sources.forEach(f => console.log(`[${f.rank}] ${f.document_title}, página ${f.page}`));
```

Tempo de resposta. A pergunta direta passa pelo mesmo pipeline do chat e pode levar o tempo do modelo de linguagem (até `NEXO_LLM_TIMEOUT`). Configure o tempo limite do cliente com folga.

5.3 Busca pela API

A busca nos trechos (seção 4.3) também está na API e não chama o modelo de linguagem.

```
curl -X POST http://127.0.0.1:8000/api/search \
  -H "X-API-Key: $NEXO_CHAVE" -H "Content-Type: application/json" \
  -d '{"query": "torque dos parafusos", "limit": 5, "rerank": true}'
```

A resposta traz `query`, `took_ms` e `results`, cada um com `rank`, `document_id`, `document_title`, `page`, `similarity`, `rerank_score` e `excerpt`. Sem documento pronto, devolve 409 `NO_DOCUMENTS`.

5.4 Webhooks

Webhooks avisam outro sistema quando algo acontece no Nexo. Só administradores cadastram webhooks; para os demais, as rotas devolvem 403 `FORBIDDEN`.

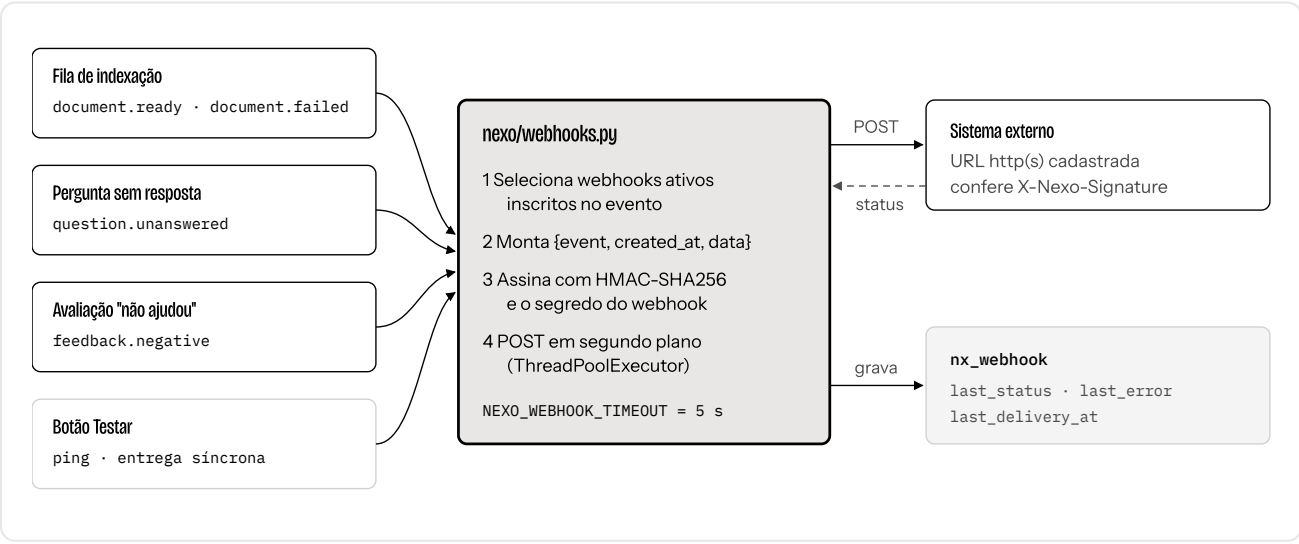


Figura 5.1 De onde vêm os eventos, o que o módulo de webhooks faz e onde o resultado de cada entrega é gravado.

Copyright (©) 2026 Erik Pimenta

Evento	Quando	Dados em `data`
`document.ready`	Um documento termina de indexar	`id`, `title`, `pages`, `chunks`
`document.failed`	A indexação de um documento falha	`id`, `title`, `error`
`question.unanswered`	Uma pergunta fica sem resposta (`answered = false`), no chat ou em `/api/ask`	`question`, `conversation_id` (nulo em `/api/ask` sem conversa), `username`
`feedback.negative`	Uma avaliação passa a ser "não ajudou" (rating −1); repetir −1 não dispara de novo	`message_id`, `question`, `answer`, `username`
`ping`	Botão **Testar** ou `POST /api/webhooks/{id}/test`	Entrega de teste, síncrona

Formato da entrega

Cada entrega é um `POST` com corpo JSON de três campos: `event`, `created_at` e `data`.

```
POST /recebe-nexo HTTP/1.1
Content-Type: application/json
User-Agent: Nexo/2.0.1
X-Nexo-Event: document.ready
X-Nexo-Signature: sha256=5d2b0c9e...

{"event": "document.ready",
 "created_at": "2026-10-27T14:32:08+00:00",
 "data": {"id": "3f2a…", "title": "Manual de exemplo", "pages": 12, "chunks": 41}}
```

Cabeçalho	Conteúdo
`Content-Type`	`application/json`
`User-Agent`	`Nexo/<versão>`, por exemplo `Nexo/2.0.1`
`X-Nexo-Event`	O nome do evento, igual ao campo `event` do corpo
`X-Nexo-Signature`	`sha256=` seguido do HMAC-SHA256 do corpo, em hexadecimal, calculado com o segredo do webhook

As entregas saem em segundo plano, sem atrasar a resposta ao usuário, e cada uma espera no máximo `NEXO_WEBHOOK_TIMEOUT` segundos (5 por padrão). Cada evento é entregue uma vez. O status HTTP, o erro e a data da última entrega ficam gravados no webhook e aparecem na tela Integrações.

Conferindo a assinatura

O receptor deve recalcular o HMAC sobre o **corpo bruto**, exatamente como chegou, antes de interpretar o JSON, e comparar em tempo constante. Pedidos com assinatura diferente devem ser recusados.

Copyright (©) 2026 Erik Pimenta

Python

```
import hashlib
import hmac

def assinatura_valida(corpo: bytes, cabecalho: str, segredo: str) -> bool:
    esperado = "sha256=" + hmac.new(segredo.encode(), corpo, hashlib.sha256).hexdigest()
    return hmac.compare_digest(esperado, cabecalho or "")

# Exemplo com FastAPI
@app.post("/recebe-nexo")
async def recebe(request: Request):
    corpo = await request.body()
    if not assinatura_valida(corpo, request.headers.get("X-Nexo-Signature", ""), SEGREDO):
        raise HTTPException(401, "assinatura inválida")
    evento = json.loads(corpo)
    ...
```

Node.js

```
const crypto = require("node:crypto");
const express = require("express");

function assinaturaValida(corpo, cabecalho, segredo) {
  const esperado = "sha256=" + crypto.createHmac("sha256", segredo).update(corpo).digest("hex");
  const a = Buffer.from(esperado);
  const b = Buffer.from(cabecalho || "");
  return a.length === b.length && crypto.timingSafeEqual(a, b);
}

const app = express();
app.post("/recebe-nexo", express.raw({ type: "application/json" }), (req, res) => {
  if (!assinaturaValida(req.body, req.get("X-Nexo-Signature"), process.env.NEXO_SEGREDO)) {
    return res.status(401).send("assinatura inválida");
  }
  const evento = JSON.parse(req.body.toString("utf8"));
  res.sendStatus(204);
});
```

Rotas de webhooks

Método	Rota	O que faz
GET	`/api/webhooks`	Lista os webhooks com eventos, situação e resultado da última entrega
POST	`/api/webhooks`	Cria. Corpo `{"url", "events", "secret"}`; sem `secret`, um é gerado. Devolve 201 com o segredo
PATCH	`/api/webhooks/{id}`	Pausa ou reativa: `{"active": false}`
DELETE	`/api/webhooks/{id}`	Exclui. Devolve 204
POST	`/api/webhooks/{id}/test`	Entrega `ping` na hora e devolve `{"status", "error"}`

Copyright (©) 2026 Erik Pimenta

5.5 Boas práticas

- Uma chave por sistema integrado, com nome claro. Revogar uma não derruba as outras.
- Responda ao webhook rápido (em menos de `NEXO_WEBHOOK_TIMEOUT`) e faça o trabalho pesado depois, numa fila do seu lado.
- Use HTTPS na URL do webhook e confira a assinatura sempre, mesmo em rede interna.
- Use `question.unanswered` para abrir tarefas de curadoria do acervo, e `feedback.negative` para revisar respostas.

5.6 Exportação de conversas

O ícone de exportar no topo da conversa (menu **Markdown** / **JSON**) e a rota `GET /api/conversations/{id}/export` baixam a conversa inteira. O formato padrão é Markdown.

Formato	Arquivo	Conteúdo
`markdown`	`nexo-<título-da-conversa>.md`	Título, data e escopo; cada pergunta como um título `##`, a resposta e a lista "Fontes" com documento e página
`json`	`nexo-<título-da-conversa>.json`	O mesmo conteúdo de `GET /api/conversations/{id}`, mais `exported_at`

```
curl -OJ "http://127.0.0.1:8000/api/conversations/ID/export?format=markdown" \
  -H "X-API-Key: $NEXO_CHAVE"
```

Trecho de uma exportação em Markdown

```
# Manutenção da bomba

Exportada em 27/10/2026 · Consultando: Manual de exemplo

## Como restaurar as configurações de fábrica?

Mantenha o botão RESET pressionado por 10 segundos com o equipamento ligado [1].

Fontes
- [1] Manual de exemplo, página 2
```

O nome do arquivo usa uma versão simplificada do título (minúsculas, sem acentos, palavras separadas por hífen) e vem no cabeçalho `Content-Disposition`.

Copyright (©) 2026 Erik Pimenta

06

Arquitetura

O Nexo é um único processo Python que serve a API e a interface compilada. Os componentes pesados (modelos e banco vetorial) são plugáveis por configuração.

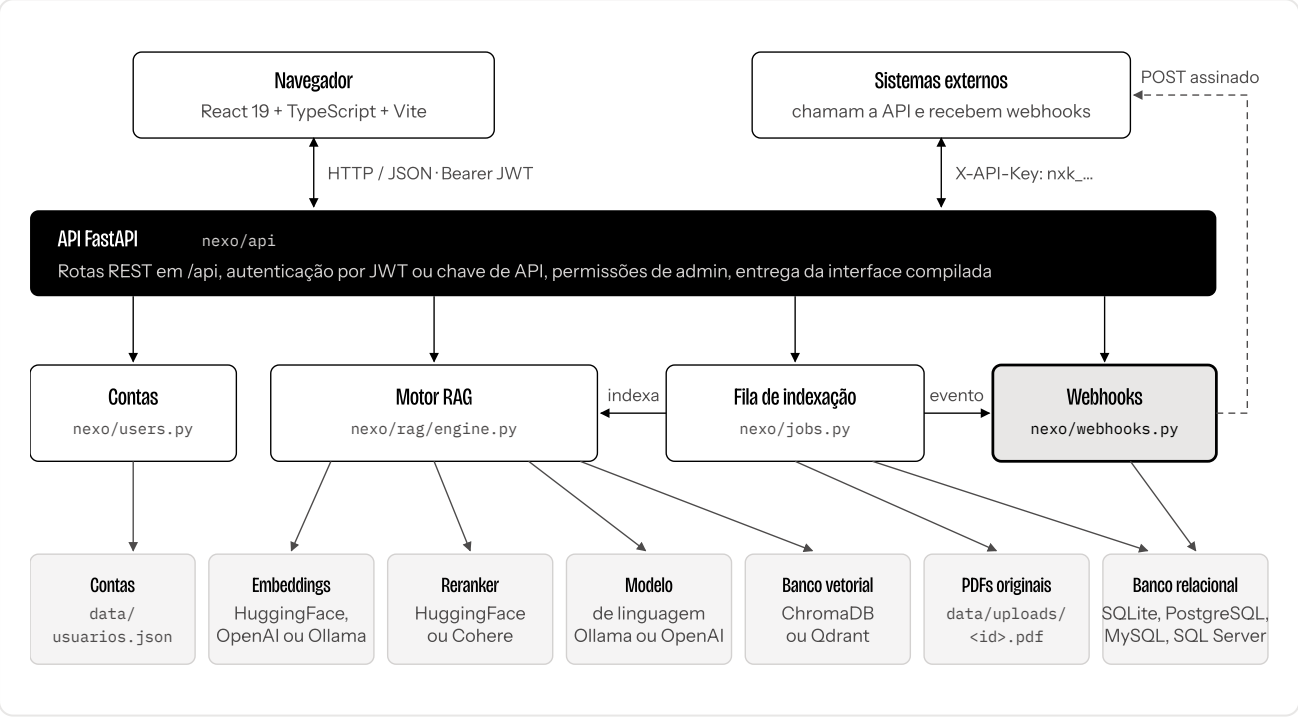


Figura 6.1 Componentes do Nexo 2.0. A API autentica por sessão ou chave de API; o módulo de webhooks avisa sistemas externos. O banco relacional é usado pela API, pela fila e pelos webhooks.

6.1 Módulos do código

Arquivo	Responsabilidade
`nexo/config.py`	Lê o `.env` com pydantic-settings e define os caminhos em `data/`
`nexo/db.py`	Modelos SQLAlchemy das oito tabelas, criação automática e sessões
`nexo/users.py`	Contas em JSON: cadastro, autenticação com bcrypt, bloqueio após 5 erros, troca de senha, mudança de perfil e exclusão
`nexo/security.py`	Emissão e leitura de tokens JWT (HS256)

Copyright (©) 2026 Erik Pimenta

Arquivo	Responsabilidade
`nexo/api/deps.py`	Identifica o usuário do pedido pelo token JWT ou pela chave de API e confere o perfil de administrador
`nexo/jobs.py`	Fila de indexação em uma thread, retomada de pendências ao iniciar, disparo de `document.ready` e `document.failed`
`nexo/webhooks.py` Novo	Seleciona os webhooks do evento, assina com HMAC, entrega em segundo plano e grava o resultado
`nexo/rag/engine.py`	Leitura dos PDFs, divisão em trechos, indexação, busca, reranking, prompt e resposta
`nexo/rag/providers.py`	Fábrica de LLM, embeddings, banco vetorial e reranker conforme o `.env`
`nexo/rag/hash_embedding.py`	Embedding léxico sem rede, usado nos testes e no modo de teste
`nexo/api/routes.py`	Rotas REST de autenticação, documentos, conversas, busca, métricas, chaves, webhooks, contas e sistema
`nexo/api/app.py`	Aplicação FastAPI, tratamento de erros, cabeçalhos de segurança e entrega da interface
`frontend/src`	Interface React: páginas, componentes, cliente da API, paleta de comandos, temas e a identidade visual

6.2 Indexação de um PDF

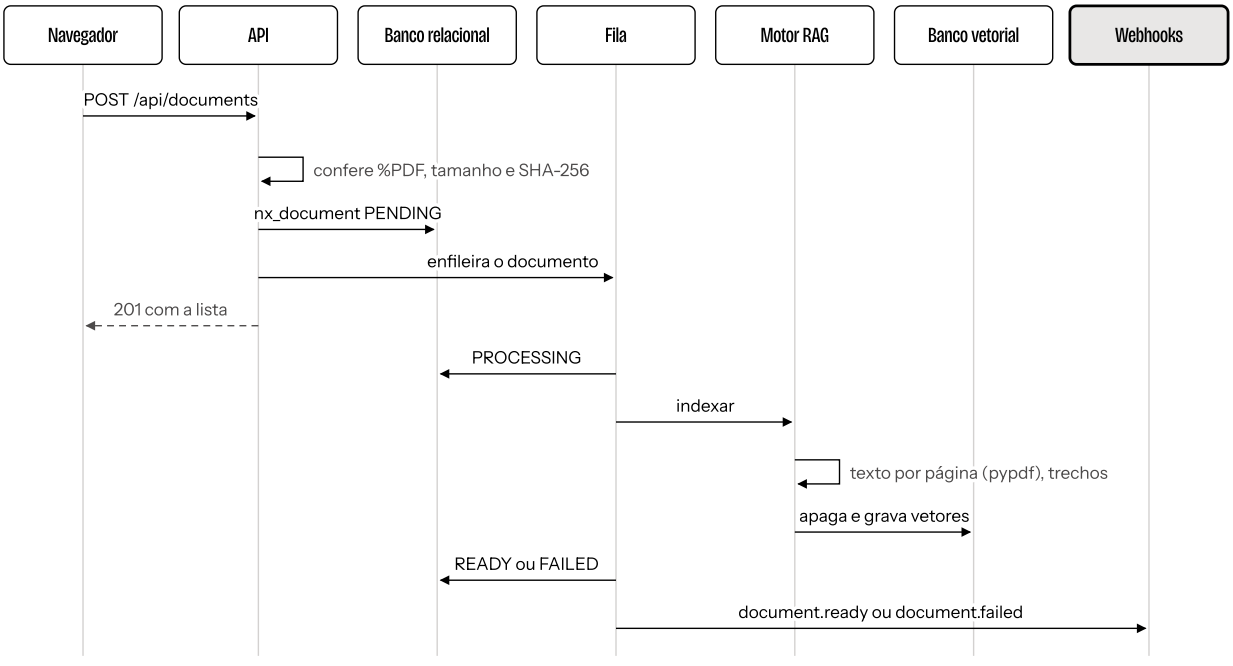


Figura 6.2 Sequência do envio à indexação. A resposta ao navegador sai logo depois do enfileiramento; o resto acontece em segundo plano.

- O texto de cada página é extraído com pypdf, com hifenizações desfeitas e quebras de linha do layout unidas.
- O SentenceSplitter do LlamaIndex divide o texto em trechos de `NEXO_CHUNK_SIZE` tokens respeitando frases, com sobreposição para não perder contexto na fronteira.

Copyright (©) 2026 Erik Pimenta

- Cada trecho guarda `source_id`, `title`, `filename`, `page` e `chunk_index`. Só o título entra no texto do embedding, junto com o conteúdo.
- Reindexar apaga os vetores antigos do documento antes de gravar os novos, então nunca há duplicação.
- Ao terminar, a fila dispara `document.ready` ou `document.failed` para os webhooks inscritos.

6.3 Respondendo uma pergunta

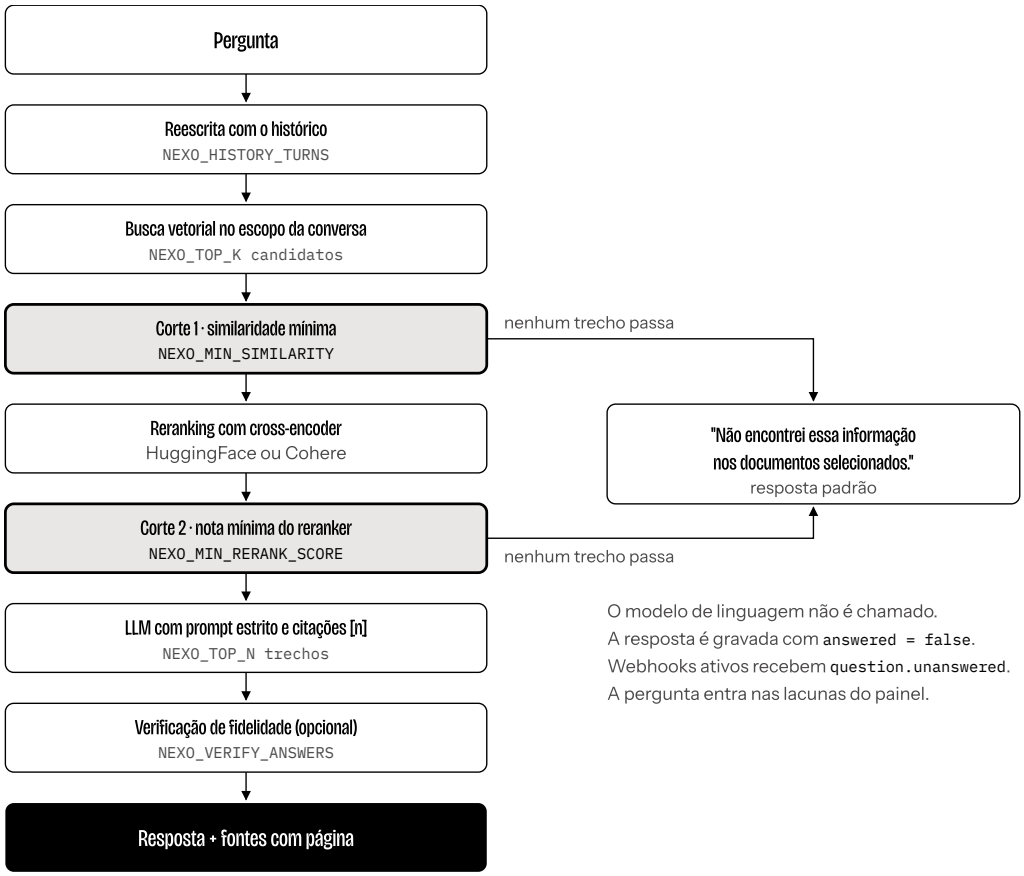


Figura 6.3 Os dois cortes de relevância, em destaque, decidem se o modelo de linguagem é chamado. A busca nos trechos para no reranking e devolve os candidatos sem passar pelo modelo.

6.4 Como as alucinações são reduzidas

Mecanismo	Efeito
Cortes de similaridade e de reranking	Trechos fracos são descartados. Sem trechos, o LLM não é chamado e a resposta padrão é devolvida
Reranking com cross-encoder	Lê pergunta e trecho juntos e reordena os candidatos por relevância real, não só proximidade vetorial
Prompt estrito	Proíbe conhecimento próprio, exige citação [n] em cada afirmação e define a frase exata para quando falta base
Temperatura 0,1	Respostas estáveis e próximas do texto

Copyright (©) 2026 Erik Pimenta

Mecanismo	Efeito
Escopo por conversa	Evita misturar manuais de equipamentos diferentes
Verificação de fidelidade	Opcional: uma segunda chamada confere se a resposta é sustentada pelos trechos e marca a mensagem quando não é
Fontes gravadas	Cada resposta guarda os trechos usados, o que permite auditar respostas antigas
Painel de qualidade	Mostra as perguntas sem resposta e as respostas mal avaliadas, para corrigir o acervo e os cortes

6.5 Segurança

- Senhas guardadas só como hash bcrypt. Cinco erros seguidos bloqueiam o usuário por 5 minutos.
- Sessões com JWT assinado por `NEXO_SECRET`, com validade de `NEXO_TOKEN_HOURS` horas. A interface guarda o token só na aba aberta (`sessionStorage`).
- Chaves de API guardadas só como hash SHA-256, exibidas uma única vez e revogáveis a qualquer momento. Excluir uma conta apaga as chaves e as conversas dela.
- Webhooks assinados com HMAC-SHA256 e um segredo por webhook; cadastro restrito a administradores.
- Conversas visíveis apenas para o dono. Documentos só podem ser alterados por quem enviou ou por um administrador. O painel mostra a cada usuário só os próprios números.
- Gestão de contas restrita a administradores, sem permitir excluir a si mesmo nem ficar sem administrador.
- Uploads validados pelo cabeçalho `%PDF`, pelo tamanho e pelo SHA-256. Nomes de arquivo são saneados e os PDFs são gravados com o id interno.
- Cabeçalhos `X-Content-Type-Options`, `X-Frame-Options` e `Referrer-Policy` em todas as respostas. A API não é guardada em cache.
- Chaves de provedores ficam só no `.env`, que está no `.gitignore`. A interface não carrega nada de fora: fontes, ícones e scripts vêm do próprio servidor.

Copyright (©) 2026 Erik Pimenta

07

Banco de dados

Resumo da estrutura dos dados. As tabelas são criadas automaticamente; a versão detalhada, com índices, restrições, decisões de arquitetura, consultas e escala, está em `Banco-de-Dados-Nexo.pdf`.

7.1 Onde cada dado fica

Camada	Local padrão	Conteúdo
Banco relacional	`data/nexo.db`	Documentos, conversas, mensagens, fontes citadas, avaliações, chaves de API e webhooks
Banco vetorial	`data/chroma/ ou data/qdrant/`	Trechos, embeddings e metadados de origem
Arquivos	`data/uploads/<id>.pdf`	PDFs originais
Contas	`data/usuarios.json`	Usuários, perfis e hashes de senha
Segredo	`data/.segredo`	Chave das sessões quando `NEXO_SECRET` está vazio

Copyright (©) 2026 Erik Pimenta

7.2 Diagrama de relacionamentos

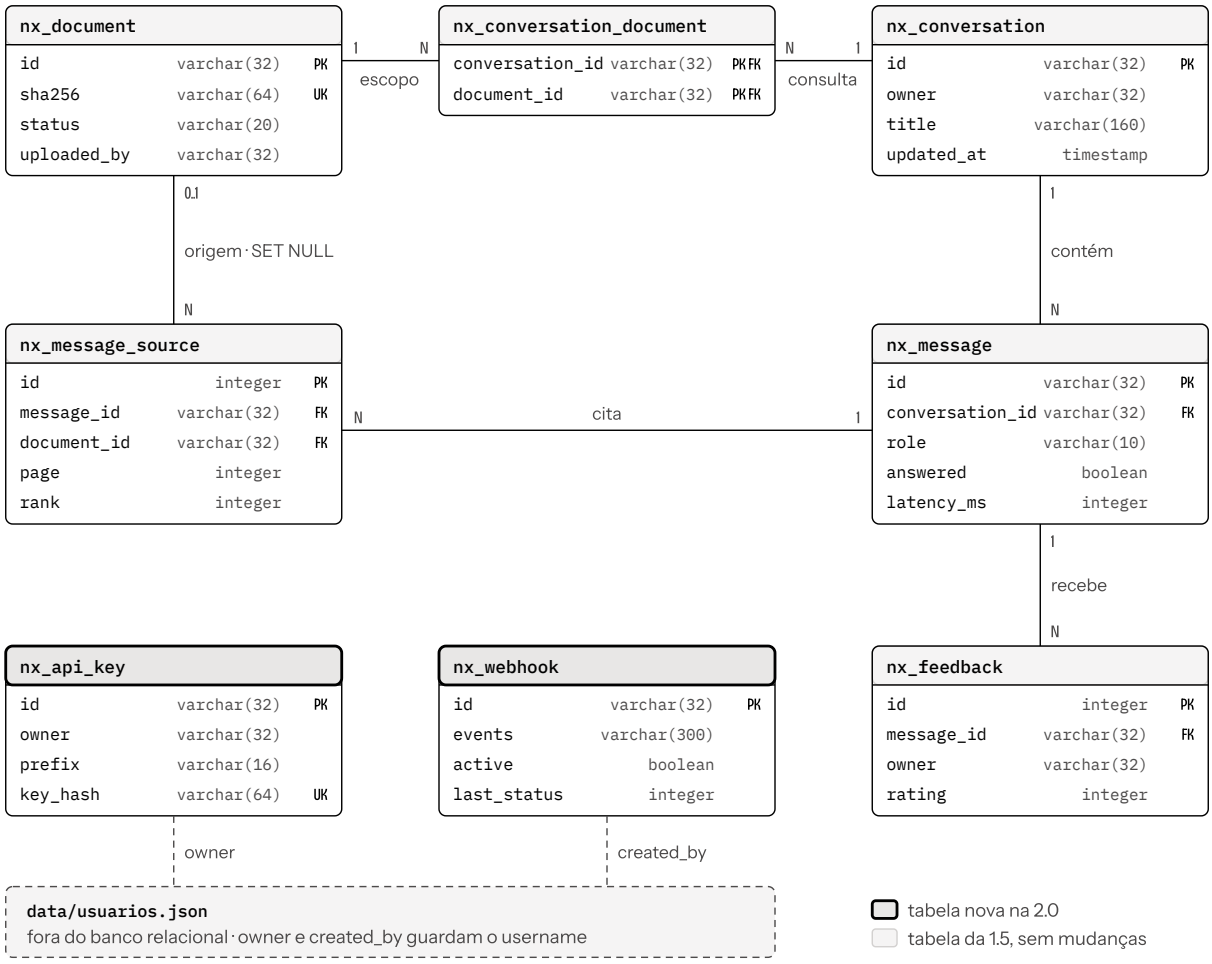


Figura 7.1 As oito tabelas. As duas novas, de integração, não têm chave estrangeira: ligam-se às contas pelo nome de usuário.

7.3 Tabelas

nx_document · um registro por PDF enviado

Coluna	Tipo	Regra
`id`	`varchar(32)`	PK. UUID em hexadecimal; nome do arquivo em `data/uploads`
`title / filename`	`varchar(200) / (255)`	Título dos metadados do PDF ou nome do arquivo; nome original saneado
`sha256`	`varchar(64)`	Único. Bloqueia envios repetidos
`size_bytes / pages / chunks`	`integer`	Tamanho, páginas do PDF e trechos indexados
`status / error`	`varchar(20) / text`	PENDING, PROCESSING, READY ou FAILED (indexado) e o motivo da falha
`uploaded_by`	`varchar(32)`	Usuário que enviou (indexado)
`created_at / indexed_at`	`timestamp`	Envio e fim da indexação, em UTC

Copyright (©) 2026 Erik Pimenta

nx_conversation e nx_conversation_document · conversas e escopo

Coluna	Tipo	Regra
`id / owner`	`varchar(32)`	PK; usuário dono (indexado)
`title`	`varchar(160)`	Padrão "Nova conversa"; recebe a primeira pergunta
`created_at / updated_at`	`timestamp`	`updated_at` indexado para ordenar a lista
`conversation_id + document_id`	`varchar(32)`	Escopo: PK composta, FKs com ON DELETE CASCADE. Sem linhas, consulta todos os prontos

nx_message · perguntas e respostas

Coluna	Tipo	Regra
`id / conversation_id`	`varchar(32)`	PK; FK para `nx_conversation`, ON DELETE CASCADE
`role / content`	`varchar(10) / text`	`user` ou `assistant`; texto com as citações [n]
`answered / grounded`	`boolean`	Falso quando não encontrou; resultado da verificação de fidelidade
`model / latency_ms`	`varchar(120) / integer`	Modelo que respondeu e tempo gasto
`created_at`	`timestamp`	Índice composto com `conversation_id`

nx_message_source e nx_feedback · fontes citadas e avaliações

Coluna	Tipo	Regra
`message_id`	`varchar(32)`	FK para `nx_message`, ON DELETE CASCADE (nas duas tabelas)
`document_id / document_title`	`varchar(32) / (200)`	FK com ON DELETE SET NULL; cópia do título para o histórico
`chunk_id / page / rank`	`varchar(80) / integer`	Id do trecho no banco vetorial, página e número da citação
`similarity / rerank_score / excerpt`	`float / text`	Notas da busca e texto do trecho (até 1.200 caracteres)
`owner / rating / comment`	`varchar(32) / int / text`	Avaliação: 1 útil, −1 não ajudou; única por usuário e resposta

nx_api_key Novo · chaves de API

Coluna	Tipo	Regra
`id`	`varchar(32)`	PK
`owner`	`varchar(32)`	Usuário dono (indexado)
`name / prefix`	`varchar(80) / (16)`	Nome dado pelo usuário; 12 primeiros caracteres da chave
`key_hash`	`varchar(64)`	Único. SHA-256 da chave em hexadecimal; a chave nunca é gravada
`created_at / last_used_at`	`timestamp`	Criação e último uso (nulo até o primeiro uso)

nx_webhook Novo · destinos dos avisos

Copyright (©) 2026 Erik Pimenta

Coluna	Tipo	Regra
`id / url`	`varchar(32) / (500)`	PK; URL http(s) de destino
`events`	`varchar(300)`	Eventos inscritos, separados por vírgula
`secret / active`	`varchar(80) / boolean`	Segredo do HMAC; webhook ligado (padrão verdadeiro)
`created_by / created_at`	`varchar(32) / timestamp`	Administrador que cadastrou e quando
`last_status / last_error / last_delivery_at`	`int / text / timestamp`	Resultado da última entrega; nulos até a primeira

7.4 Coleção vetorial

Campo	Conteúdo
`id`	UUID v5 calculado de documento + posição do trecho
`embedding`	Vetor do modelo de `NEXO_EMBED_MODEL`, distância de cosseno
`document`	Texto do trecho
`metadata.source_id`	`nx_document.id` de origem; usado nos filtros de escopo e na exclusão
`metadata.title / filename / page / chunk_index`	Título, nome do arquivo, página (a partir de 1) e posição do trecho

7.5 Arquivo de usuários

```
{
  "versao": 1,
  "usuarios": [
    { "username": "admin", "name": "Administrador", "role": "admin",
      "password_hash": "$2b$12$...", "created_at": "2026-01-01T12:00:00+00:00",
      "last_login_at": null }
  ]
}
```

O arquivo é regravado de forma atômica. Nomes de usuário têm de 3 a 32 caracteres minúsculos (letras, números, ponto, hífen e sublinhado). O administrador muda perfis e exclui contas pela tela Sistema e conta; o login pré-definido só é recriado se não houver nenhum administrador. Para redefinir uma senha esquecida, rode `python scripts/redefinir_senha.py nome-do-usuario` no servidor.

7.6 Outro banco relacional

Banco	Driver	NEXO_DATABASE_URL
PostgreSQL	`pip install "psycopg[binary]"`	`postgresql+psycopg://usuario:senha@host:5432/nexo`
MySQL / MariaDB	`pip install pymysql`	`mysql+pymysql://usuario:senha@host:3306/nexo`

Copyright (©) 2026 Erik Pimenta

Banco	Driver	NEXO_DATABASE_URL
SQL Server	`pip install pyodbc`	`mssql+pyodbc://usuario:senha@host/nexo?driver=ODBC+Driver+18+for+SQL+Server`

O DDL de referência está em `docs/schema-postgresql.sql` e `docs/schema-sqlite.sql`. O resumo deste capítulo também está em `docs/banco-de-dados.md`.

Copyright (©) 2026 Erik Pimenta

08

API

A interface usa a mesma API REST que fica disponível para integrações. A documentação interativa (OpenAPI) abre em `http://127.0.0.1:8000/api/docs`.

8.1 Autenticação

Fora `/api/health`, `/api/auth/options`, `/api/auth/login` e `/api/auth/register`, todas as rotas exigem um destes cabeçalhos: `Authorization: Bearer <token JWT>`, recebido no login, ou uma chave de API em `X-API-Key` ou `Authorization: Bearer nxk_...` (seção 5.1). As rotas marcadas como admin devolvem 403 `FORBIDDEN` para os demais usuários.

8.2 Rotas

Método	Rota	Descrição
Sessão e conta		
GET	`/api/health`	Situação do servidor e versão
GET	`/api/auth/options`	Cadastro aberto e se o login pré-definido ainda está ativo
POST	`/api/auth/login`	Entrar. Devolve token, validade e usuário
POST	`/api/auth/register`	Criar conta e entrar
GET	`/api/auth/me`	Usuário da sessão
PUT	`/api/auth/password`	Trocar a própria senha
GET	`/api/system/status`	Configuração ativa, números do acervo e `integrations` (chaves do usuário; webhooks para admin)
Documentos		
GET	`/api/documents`	Listar documentos
POST	`/api/documents`	Enviar um ou mais PDFs (multipart, campo `files`)
GET	`/api/documents/{id}`	Detalhes de um documento
PATCH	`/api/documents/{id}`	Renomear (reindexa)
GET	`/api/documents/{id}/file`	Baixar o PDF original
POST	`/api/documents/{id}/reindex`	Reindexar

Copyright (©) 2026 Erik Pimenta

Método	Rota	Descrição
DELETE	`/api/documents/{id}`	Excluir PDF, vetores e escopos
Conversas, perguntas e busca		
GET	`/api/conversations`	Listar as conversas do usuário
POST	`/api/conversations`	Criar conversa, com `document_ids` opcional
GET / PATCH / DELETE	`/api/conversations/{id}`	Abrir com mensagens, renomear ou mudar escopo, excluir
GET	`/api/conversations/{id}/export` Novo	Exportar em `markdown` (padrão) ou `json`
POST	`/api/conversations/{id}/messages`	Perguntar. Devolve pergunta, resposta com fontes e conversa
POST	`/api/messages/{id}/feedback`	Avaliar resposta: rating 1, –1 ou 0 para remover
POST	`/api/ask` Novo	Pergunta direta para integrações, com ou sem conversa
POST	`/api/search` Novo	Busca nos trechos, sem o modelo de linguagem
GET	`/api/metrics?days=30` Novo	Painel de qualidade (1 a 365 dias). Admin vê tudo; demais, só as próprias conversas
Integrações e contas		
GET / POST	`/api/keys` Novo	Listar ou criar chaves de API do usuário
DELETE	`/api/keys/{id}` Novo	Revogar chave (só o dono)
GET / POST	`/api/webhooks` Novo	Listar ou criar webhooks (admin)
PATCH / DELETE	`/api/webhooks/{id}` Novo	Pausar, reativar ou excluir (admin)
POST	`/api/webhooks/{id}/test` Novo	Entregar `ping` na hora (admin)
GET	`/api/users` Novo	Listar contas (admin)
PATCH	`/api/users/{username}` Novo	Mudar perfil: `{"role": "admin"}` ou `"user"` (admin)
DELETE	`/api/users/{username}` Novo	Excluir conta (admin)

Copyright (©) 2026 Erik Pimenta

8.3 Exemplo com curl

```
curl -X POST http://127.0.0.1:8000/api/auth/login \
  -H "Content-Type: application/json" \
  -d '{"username": "admin", "password": "Nexo@2026"}'

curl -X POST http://127.0.0.1:8000/api/documents \
  -H "Authorization: Bearer SEU_TOKEN" \
  -F "files=@manual.pdf"

curl -X POST http://127.0.0.1:8000/api/conversations \
  -H "Authorization: Bearer SEU_TOKEN" \
  -H "Content-Type: application/json" -d '{}'

curl -X POST http://127.0.0.1:8000/api/conversations/ID/messages \
  -H "Authorization: Bearer SEU_TOKEN" \
  -H "Content-Type: application/json" \
  -d '{"content": "Como restaurar as configurações de fábrica?"}'

curl "http://127.0.0.1:8000/api/metrics?days=7" -H "X-API-Key: $NEXO_CHAVE"
```

8.4 Erros

Todo erro volta como JSON com `code`, `message` e, quando for de campo, `fields`:

```
{"code": "NO_DOCUMENTS", "message": "Envie e aguarde a indexação de ao menos um PDF antes de perguntar.",
"fields": null}
```

HTTP	code	Quando
400	`EMPTY / NO_FILES / UNKNOWN_DOCUMENT`	Pergunta vazia, envio sem arquivos ou escopo com documento que não existe mais
400	`SELF / LAST_ADMIN`	Rebaixar ou excluir a própria conta, ou rebaixar o último administrador
400	`INVALID_URL / INVALID_EVENTS`	Webhook com URL que não é http(s) ou com lista de eventos vazia ou desconhecida
401	`UNAUTHENTICATED / SESSION_EXPIRED`	Sem credencial, usuário inexistente ou token vencido
401	`INVALID_API_KEY`	Chave de API inválida, revogada ou de conta excluída
401	`INVALID_CREDENTIALS`	Usuário ou senha errados no login
403	`FORBIDDEN / REGISTRATION_DISABLED`	Rota de administrador, ação sobre documento de outra pessoa ou cadastro fechado
404	`NOT_FOUND / FILE_MISSING`	Registro inexistente ou de outro usuário; PDF original ausente
409	`DUPLICATE / NO_DOCUMENTS / USERNAME_TAKEN`	PDF repetido, pergunta ou busca sem documentos prontos, usuário existente
413 / 415	`FILE_TOO_LARGE / NOT_A_PDF`	Arquivo grande demais ou que não é PDF

Copyright (©) 2026 Erik Pimenta

HTTP	code	Quando
422	–	Corpo fora do formato (por exemplo `limit` fora de 1 a 20), com os campos em `fields`
429	`LOCKED`	Cinco senhas erradas seguidas
502 / 503	`LLM_FAILURE / PROVIDER`	Modelo fora do ar, ou pacote ou chave de provedor ausente

Copyright (©) 2026 Erik Pimenta

09

Qualidade e manutenção

Testes automatizados, medição da busca, acompanhamento pelo painel, integração contínua, backup e solução de problemas.

9.1 Testes automatizados

```
pip install -r requirements-ci.txt
python -m pytest
```

Os testes rodam sem internet nem modelos (embedding hash, modo extrativo, reranker desligado) e cobrem: login pré-definido, bloqueio após cinco erros, cadastro gravado no arquivo com bcrypt, validações de senha e usuário, troca e redefinição de senha, envio e indexação do PDF de exemplo, resposta com fonte e página corretas, pergunta fora do conteúdo, isolamento de conversas entre usuários, avaliação, rejeição de arquivos inválidos e duplicados, permissões de exclusão, remoção dos vetores, filtro de escopo, reordenação e corte do reranker e os scripts auxiliares. Na 2.0 entram também a busca nos trechos, a exportação, as métricas, as chaves de API, a pergunta direta, os webhooks e a gestão de contas.

9.2 Medindo a recuperação

Crie um arquivo JSONL com uma pergunta por linha e a página onde a resposta está:

```
{"pergunta": "Como restaurar as configurações de fábrica?", "documento": "manual-exemplo.pdf", "pagina":
2}
{"pergunta": "Qual a temperatura de operação?", "documento": "manual-exemplo.pdf", "pagina": 5}
```

```
python scripts/avaliar.py exemplos/perguntas-exemplo.jsonl --detalhes
```

O script usa o banco e a configuração do `.env` e mostra, para a busca vetorial pura e com reranking, o **acerto** (a página certa apareceu entre os trechos enviados ao modelo) e o **MRR** (quanto mais perto do primeiro lugar, mais perto de 1). Repita depois de cada ajuste de parâmetros.

Do painel para o teste. As lacunas do painel de qualidade são boas candidatas a novas linhas do arquivo de avaliação: quando o documento certo é enviado, a pergunta passa a medir se o Nexo a encontra.

Copyright (©) 2026 Erik Pimenta

9.3 Integração contínua

O workflow `.github/workflows/ci.yml` roda os testes do Python e o build da interface a cada push e pull request.

9.4 Commit automático diário

O workflow `.github/workflows/diario.yml` acrescenta a data e a hora em `.github/atividade.txt` e faz um commit todos os dias às 11h37 de Brasília (14h37 UTC). Para ativar:

1. No repositório, abra **Settings › Secrets and variables › Actions › New repository secret**.
2. Crie `GIT_NAME` com o seu nome de usuário do GitHub e `GIT_EMAIL` com o e-mail da conta (ou o endereço `...@users.noreply.github.com`).
3. Em **Settings › Actions › General › Workflow permissions**, marque **Read and write permissions** e salve.
4. Em **Actions › Atividade diaria**, clique em **Run workflow** para testar.

9.5 Backup

Pare o servidor e copie a pasta `data` inteira. Ela contém tudo: banco SQLite (com chaves de API e webhooks), vetores locais, PDFs, usuários e segredo. Com bancos externos, faça também o backup deles pelas ferramentas próprias, no mesmo momento.

> **O backup contém segredos.** Os segredos dos webhooks ficam no banco, e `data/.segredo` assina as sessões. Guarde as cópias com o mesmo cuidado de uma senha.

9.6 Atualizando dependências

```
pip install --upgrade -r requirements.txt
cd frontend && npm update && npm run build
```

9.7 Solução de problemas

Sintoma	Causa provável	O que fazer
"O modelo não respondeu"	Ollama desligado ou modelo não baixado	Abra o Ollama e rode `ollama pull llama3.1`
"Instale o pacote ..."	Provedor configurado sem a biblioteca	`pip install` do pacote indicado na mensagem
"Defina OPENAI_API_KEY"	Provedor OpenAI sem chave	Preencha a chave no `.env` e reinicie
Documento em Falhou: sem texto	PDF digitalizado (imagem)	Aplique OCR (por exemplo OCRmyPDF) e envie de novo
Primeira pergunta demora	Download dos modelos do HuggingFace	Aguarde; as próximas são rápidas

Copyright (©) 2026 Erik Pimenta

Sintoma	Causa provável	O que fazer
Respostas sempre "Não encontrei"	Cortes de relevância altos para o modelo	Veja as notas na busca nos trechos e baixe `NEXO_MIN_SIMILARITY` e `NEXO_MIN_RERANK_SCORE`
Taxa de resposta caindo no painel	Perguntas sobre assuntos fora do acervo	Leia as lacunas e envie os documentos que faltam
Integração recebe 401 `INVALID_API_KEY`	Chave revogada, digitada errada ou de conta excluída	Crie uma chave nova em Integrações; confira o cabeçalho `X-API-Key`
Integração recebe 403	Rota de administrador com chave de usuário comum	Use uma chave criada por um administrador
Webhook com status vazio e erro de tempo	Receptor lento ou fora do ar	Responda em menos de `NEXO_WEBHOOK_TIMEOUT` segundos ou aumente o valor
Receptor recusa a assinatura	HMAC calculado sobre o JSON reformatado ou segredo errado	Calcule sobre o corpo bruto (seção 5.4) e confira o segredo
Não consigo rebaixar um admin	Ele é o último administrador	Promova outra conta antes
Tela em branco em /	Interface não compilada	`cd frontend`, `npm install` e `npm run build`
Sessão cai ao reiniciar	`NEXO_SECRET` vazio e pasta `data` apagada	Defina `NEXO_SECRET` fixo no `.env`
Esqueci a senha do admin	Senha trocada e perdida	`python scripts/redefinir_senha.py admin`

Copyright (©) 2026 Erik Pimenta